北京交通大学

硕士学位论文

稀疏低秩张量优化方法及其应用

Sparse and Low Rank Tensor Optimization Methods and Applications

作者: 宇晓彤

导师: 罗自炎

北京交通大学

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

中图分类号：O224　　学校代码：10004
UDC：519.8　　密级：公开

北京交通大学

硕士学位论文

稀疏低秩张量优化方法及其应用

Sparse and Low Rank Tensor Optimization Methods and Applications

作者姓名：宇晓彤　　学　　号：18121627

导师姓名：罗自炎　　职　　称：教授

学位类别：理学　　学位级别：硕士

学科专业：系统理论　　研究方向：复杂系统的建模、优化与分析

北京交通大学

中国知网　https://www.cnki.net

致谢

自2014年考入北京交通大学成为大一新生起，时光荏苒，我的硕士生涯即将接近尾声. 思东前玉兰花、益民前吃西瓜、秋日的银杏大道、冬泳的明湖鸭，这些时光碎片勾勒出我在红果园度过的七年春夏. 在北交大，我有幸得到很多学识渊博的老师、同学及朋友的帮助，在此由衷地感谢长期以来给予我关心的老师、同学、亲人们！

衷心感谢我的导师罗自炎教授！罗老师严谨的学习态度、一丝不苟的学术精神，以及对科研的追求和热爱，将永远是我学习的榜样. 在我本科阶段，罗老师是我大创项目的指导老师，她跟我讲“不会就去学，我很多东西也都是自己学的”，就是这样简单的一句话让当时的我知道搞科研是要主动学习、迎难而上，而不是完全被动的学习. 在我研究生阶段，我的每篇论文罗老师都投入了大量的精力，因为我自己专业知识不够扎实，做事马虎，罗老师每周都主动联系我与我讨论，督促我不断思考，论文的每一段每一句罗老师都帮我订正修改. 罗老师不仅是学术上的良师，更是生活中的益友。每当我想打退堂鼓或者遇事犹豫不决时，老师都会耐心的用自己的经历开导我，我也为自己很多不成熟的表现感到抱歉. 作为罗老师的第一个学生，我感到十分荣幸，感谢您对我的严厉、督促及包容. 我自知天资平庸，有幸能够取得一点小小的成绩都离不开罗老师对我的极大帮助，在她身上我能看到新时代女科技工作者的奉献精神和科学家精神，令我由衷地敬佩.

衷心感谢修乃华教授！正是修老师的最优化课程让我对优化领域产生科研兴趣，从而选择继续深造. 修老师待人亲和，对学术充满热情，对学生认真负责，是我们大组的大家长，他的一言一行都值得我们学习. 还要衷心感谢孔令臣教授及张超教授对我的科研的指导和帮助，他们在每次的讨论班汇报中都给予宝贵建议，为同学们答疑解惑，为大组营造了一种良好的学术氛围.

衷心感谢优化组师姐：赵晨、李鑫荣、王锐、王双月、陈阳、李小玉；感谢优化组师兄：张辉、王华军、陈黄岳，感谢他们在我学术研究方面给我的指导和帮助；感谢优化组师弟师妹：张鹏鹤、魏阳鑫、王灏、王洁丽、张鑫荣以及武柏芸等同学们，感谢他们在我学习生活中为我带来的帮助. 感谢实验室的师姐师兄们：张春田、张慧敏、孟凡婷、王蕊、闫冬阳、黄康、刘人铭，感谢他们在生活中像朋友一样的照顾我. 感谢我的好朋友杨瑜、张丽红、张伊冉、张心在交大七年对我的鼓励与帮助；感谢我的好朋友贺天艺、顾新多年来对我的陪伴与支持；感谢姚可为及其家人三年来对我的关爱与包容.

中国知网 https://www.cnki.net

感谢我的爸爸妈妈，让我在充满爱和安全感的家庭无忧无虑长大，是你们的言传身教和对我无条件的包容和支持，让我在遇到困难时咬牙坚持，我永远爱你们. 感谢我的爷爷奶奶、姑姑一家、姥姥姥爷以及众多的家人们，感谢你们对我经济上以及精神上的支持，一直保护我，我永远爱我们的大家庭.

感谢我的母校北京交通大学，感谢理学院和数学系给我提供了舒适的生活条件和良好的学习环境，感谢理学院的各位老师给予我学习上的指导、生活上的帮助.

最后衷心感谢各位评审专家在百忙之中审阅我的论文，并提出宝贵的意见与建议.

中国知网 https://www.cnki.net

中文摘要

张量是一种高阶高维的数据结构，在视频监控、数据挖掘、计算机视觉、信号处理、工程与统计中都有着广泛的应用. 近年来，由于实际问题产生的数据规模不断扩大，而稀疏性和低秩性是大规模优化问题中的重要特征，因此基于张量分解的稀疏低秩张量优化理论、算法与应用研究是优化领域极富挑战的前沿课题. 本文将稀疏低秩张量优化方法应用到了视频背景消除以及网络流量异常检测问题中.

针对压缩测量背景消除(BSCM)问题，首先本文充分利用视频中嵌入的时空特征，构建一个新的基于Tucker 分解的稀疏张量优化方法. 该方法利用目标函数中的ℓ_0-范数约束视频前景中的稀疏性，增强前景的时空连续性，从而提高前景检测的准确性；利用低秩Tucker 分解中因子矩阵的正交性约束保证低秩特征，增强背景的时空相关性，从而提高背景估计的准确性(见2.1节). 其次，本文在理论方面对模型进行分析，进而建立了最优性条件(见2.2节)，设计出一种基于硬阈值算子的交替方向乘子法(HT-ADMM)来求解模型(见2.3节). 最后，本文(见2.4节)通过真实数据集验证所构造模型的优越性和算法的有效性.

针对网络流量异常检测(ITAD)问题，首先本文充分利用异常流量数据的稀疏性、正常流量数据的低秩性、时间稳定性和周期性等内在的潜在特性，构建一个新的稀疏低秩张量优化模型来求解该问题(见3.1节). 其次，本文在理论方面对模型进行分析，尽管由于ℓ_0-范数和张量秩函数的存在，该优化模型是非凸非连续的，但本文借助稳定点建立了最优性条件(见3.2节)，并在此基础上设计出一种近端梯度算法，使其在理论上能够收敛于稳定点(见3.3节). 最后，本文(见3.4节)通过在网络流量跟踪数据集Abilene 和GÈANT上的数值实验验证所构造的稀疏低秩张量模型(SLRTA)的优越性和算法的有效性.

关键词： 背景消除; 张量Tucker分解; 交替方向乘子法; 网络流量异常检测; 近端梯度法

分类号： O224

中国知网 https://www.cnki.net

ABSTRACT

As a high-order and high-dimensional data structure, tensor has been widely used in video surveillance, data mining, computer vision, signal processing, engineering and statistics. In recent years, due to the continuous expansion of the data scale generated by practical problems, in which sparsity and low-rank are important characteristics, the theoretical algorithm and application research of sparse low-rank tensor optimization based on tensor decomposition have become very challenging frontier topics in the optimization field. In this paper, the sparse and low-rank tensor optimization method is applied to video background subtraction and internet traffic anomaly detection.

To address background subtraction from compressive measurements (BSCM), we firstly propose a new Tucker decomposition-based sparse tensor optimization method, which makes full use of the spatio-temporal features embedded in the video. The ℓ_0-norm in the objective function is used to constrain the sparseness of the spatio-temporal structure of video foreground, which enhances the spatio-temporal continuity and improves the accuracy of foreground detection. The orthogonality constraints on factor matrices in low-rank Tucker decomposition are used to characterize the spatio-temporal correlation of video background, which enhances low-rank characterization and makes better background estimation (see Section 2.1). Secondly, this paper analyzes the model in the theory, then establishes the optimality conditions for the proposed sparse tensor optimization problem (see Section 2.2) and a hard-thresholding based alternating direction method of multipliers (HT-ADMM) is designed for the proposed model (see Section 2.3). Finally, comprehensive experiments are conducted on real-world video datasets to demonstrate the superiority of our model and the effectiveness of the algorithm (see Section 2.4).

For the internet traffic anomaly detection (ITAD) problem, we firstly formulate it by a sparse and low-rank tensor optimization model, taking into full consideration the intrinsic and potential properties including the sparsity of anomalies, the low-rankness and temporal stability and periodicity of the normal traffic data (see Section 3.1). Secondly, this paper analyzes the model. Although the resulting optimization model is non-convex and discontinuous due to the involved ℓ_0-norm and the tensor rank function, optimality analysis via stationarity is established (see Section 3.2), based on which an efficient proximal gradient method with theoretical convergence to stationary points

中国知网 https://www.cnki.net

is designed (see Section 3.3). Finally, numerical experiments on internet traffic trace data Abilene and GÈANT demonstrate the high efficiency of our proposed sparse and low-rank tensor-based approach (SLRTA) for ITAD (see Section 3.4).

KEYWORDS: Background subtraction; Tensor Tucker decomposition; Alternative direction method of multipliers; Internet traffic anomaly detection; Proximal gradient descent

CLASSNO: O224

中国知网 https://www.cnki.net

第 0 章 符号说明

符号	含义
$\mathbb{R}^p$	p维实向量空间
$\delta_\Omega(\cdot)$	相对于集合Ω的示性函数
Prox_f	函数f的邻近点算子
$\Pi_\Omega(\cdot)$	集合Ω的投影算子
$\bigcap_{n=1}^N S_{(n)}$	集合$S_{(n)}, n = 1, ..., N$的交集
A^*	算子A的伴随
$\lvert\cdot\rvert$	绝对值
$\sharp C$	集合C中的元素个数
$\mathrm{dom}(f)$	函数f的定义域
$\liminf$	下限
$\lceil\cdot\rceil$	不小于参数的最小整数
$[n]$	指标集$\{1, 2, ..., n\}$
Γ_x	向量$\mathbf{x}$的支撑集
$\mathbf{x}_i$	向量$\mathbf{x}$的第i个分量
$\langle\mathbf{x}, \mathbf{y}\rangle$	向量$\mathbf{x}$与向量$\mathbf{y}$的内积
$\lVert\mathbf{x}\rVert_0$	向量$\mathbf{x} \in \mathbb{R}^p$的$\ell_0$-范数，即$\mathbf{x}$的非零元素的个数
$\lVert\mathbf{x}\rVert_1$	向量$\mathbf{x} \in \mathbb{R}^p$的$\ell_1$-范数，即$\lVert\mathbf{x}\rVert_1 = \sum_{i=1}^p \lvert\mathbf{x}_i\rvert$
$\lVert\mathbf{x}\rVert_q (q > 0)$	向量$\mathbf{x} \in \mathbb{R}^p$的$\ell_q$范数，即$\lVert\mathbf{x}\rVert_q = (\sum_{i=1}^p \lvert\mathbf{x}_i\rvert^q)^{\frac{1}{q}}$
I	单位矩阵
$\mathbf{X}^{-1}$	矩阵$\mathbf{X}$的逆
$\mathbf{X}^\top$	矩阵$\mathbf{X}$的转置
$\sigma(\mathbf{X})$	矩阵$\mathbf{X}$的特征值向量，且$\sigma_1(\mathbf{X}) \geq ... \geq \sigma_n(\mathbf{X})$
$\lVert\mathbf{X}\rVert_F$	矩阵$\mathbf{X} \in \mathbb{R}^{n\times p}$的Frobenius范数，即$\lVert\mathbf{X}\rVert_F = (\sum_{i=1}^n \sum_{j=1}^p \mathbf{X}_{ij}^2)^{\frac{1}{2}}$
$\mathrm{rank}(\mathcal{X})$	张量$\mathcal{X}$的Tucker秩
$\mathbf{X}_{(n)}$	张量$\mathcal{X}$的模-n展开
$\langle\cdot,\cdot\rangle_{(i)}$	张量的模-i收缩积
$\partial^F h(x)$	h在x处的Fréchet次微分
$\partial h(x)$	h在x处的次微分
$N_\Omega(x)$	集合Ω在点$x \in \Omega$处的Fréchet法锥，也称为正则法锥
$\nabla f(x)$	函数$f : \mathbb{R}^p \to \mathbb{R}$在$x$处的梯度
$\square$	证明结束

中国知网 https://www.cnki.net

目 录

中文摘要 iv

ABSTRACT v

符号说明 vii

第 1 章 绪论 1

1.1 研究背景 1

1.2 预备知识 2

1.2.1 张量代数 2

1.2.2 张量分解 3

1.2.3 张量函数 5

1.3 研究现状 7

1.3.1 视频监控背景消除的张量优化方法 7

1.3.2 网络流量异常检测的张量优化方法 9

1.4 本文的主要工作 10

第 2 章 视频监控背景消除的张量优化方法 11

2.1 模型建立 11

2.1.1 视频张量模型 11

2.1.2 稀疏张量优化 12

2.2 最优性条件 14

2.3 算法设计 18

2.4 数值试验 20

2.4.1 实验设置 21

2.4.2 性能评价 22

2.5 本章小结 30

第 3 章 网络流量异常检测的张量优化方法 31

3.1 模型建立 31

3.1.1 流量张量模型 31

3.1.2 稀疏低秩张量优化 33

3.2 最优性条件 34

中国知网 https://www.cnki.net

3.3 算法设计 ……36
3.3.1 算法框架……36
3.3.2 收敛性和复杂度分析……37
3.4 数值试验 ……38
3.4.1 实验设置……38
3.4.2 性能评价……40
3.5 本章小结 ……50
第 4 章 结论与展望 ……51
4.1 本文结论 ……51
4.2 未来展望 ……51
参考文献 …… I
作者简历及攻读硕士学位期间取得的研究成果 ……XII
独创性声明 ……XIII
学位论文数据集 …… XIV

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景

张量是一种高阶高维的数据结构，广泛存在于视频监控、数据挖掘、信号处理、计算机视觉、工程与统计中[113–117]. 随着现代科技的发展，大规模稀疏优化方法成为大数据时代的重要研究课题，广泛应用于信息重构、医学影像、交通运输、数据挖掘等领域[118–120]. 稀疏性和低秩性是大规模优化问题中的重要特征，蕴含着丰富的数学理论. 因此，基于张量分解的稀疏低秩优化理论、算法与应用研究是优化领域极富挑战的前沿课题.

随着互联网技术的快速发展，人们在日常生活中以更加多元化的方式获取到更多的信息量，其中通过视频的方式记录视觉信息，极大地提高了人们获取信息的能力. 随着图像及视频处理技术的蓬勃发展，视频监控系统智能化成为人们追求的目标，计算机凭借高效的海量数据处理功能，快速提取出对监控者有用的关键信息，例如视频背景消除，不仅对社会的安全稳定提供有力保障，并且对社会的和谐发展具有重要意义. 由于需要对视频数据进行存储，因此视频监控中的数据规模急剧增加. 如果直接用向量进行处理，不仅会破坏数据本身的结构，并且会造成维数灾难等问题. 因此，将张量的稀疏优化模型应用到视频监控的背景消除中是一个非常有意义的研究课题.

随着计算机网络规模的不断扩大以及网络应用的持续深化，互联网广泛应用到日常生活的各个领域，极大地提高了生产效率. 与此同时，各种网络攻击威胁着互联网的安全，增加了网络管理的难度. 网络中的异常行为会引起网络流量的某些特征发生显著变化，例如DOS攻击、扫描攻击等会引起IP地址数、端口数、数据包数及网络流量数据的显著变化，因此网络异常检测的重要数据源之一就是网络流量[123]. 网络流量异常检测是一种有效的网络防护手段，能够通过流量监测及时发现计算机网络所受到的恶意攻击，及时采取相应措施来有效应对，从而实现对计算机网络的实时安全监控[122]. 随着流量特征维数以及噪声数据的增加，传统的网络流量异常检测方法面临着检测准确率低、鲁棒性差等问题[124]. 因此，将张量的稀疏低秩优化模型应用到网络流量异常检测中是一个非常有意义的研究课题.

本文将针对视频监控背景消除问题和网络流量异常检测问题，开展进一步研究.

中国知网 https://www.cnki.net

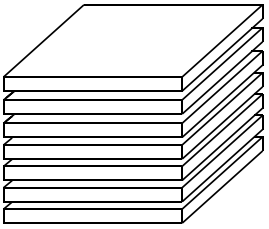
1.2 预备知识

本节主要介绍张量相关的基本概念，更多关于张量计算的内容可参考综述文章[72] 与著作[94].

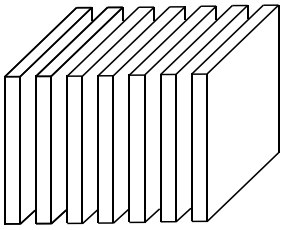
1.2.1 张量代数

N阶张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \ldots \times I_N}$是一个$N$维数组，其$(i_1, ..., i_N)$-分量记为$x_{i_1,...,i_N}$，$i_j = 1, ..., I_j$，$j = 1, ..., N$，$N$为张量$\mathcal{X}$的阶数，$I_1, ..., I_N$为相应的维数. 向量和矩阵是对应于$N = 1$和$N = 2$时的低维张量. 为方便起见，本文用黑体小写字母(例如,$\mathbf{x}$)表示向量、用黑体大写字母(例如,$\mathbf{X}$)表示矩阵、用花体字母(例如,$\mathcal{X}$)表示张量.

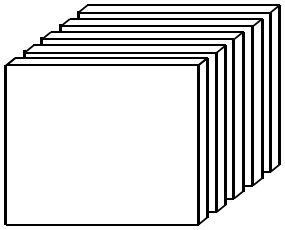
任意给定张量$\mathcal{X} \in \mathbb{R}^{I_1 \times \ldots \times I_N}$，固定张量$\mathcal{X}$元素中除第$n$个以及$n + 1$个下标以外的所有下标，可以得到一个$I_n \times I_{n+1}$维矩阵，称其为张量$\mathcal{X}$的一个切片. 图1.2-1.4给出了模-$n$三阶张量的切片. 任意给定张量$\mathcal{X} \in \mathbb{R}^{I_1 \times \ldots \times I_N}$，固定张量$\mathcal{X}$元素中除第$n$个下标以外的所有下标，可以得到一个$I_n$维列向量，称其为张量$\mathcal{X}$的一个模$n$-纤维. 图1.5-1.7给出了模-$n$三阶张量的纤维.



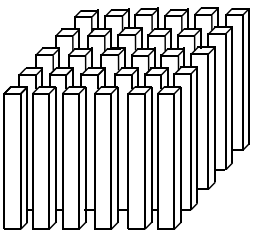
(a) 水平切片: $\mathbf{X}_{i::}$



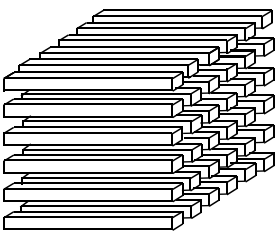
(b) 侧面切片: $\mathbf{X}_{:j:}$



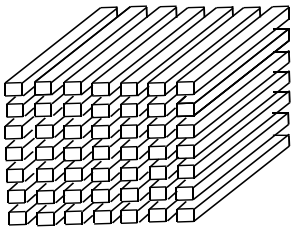
(c) 正面切片: $\mathbf{X}_{::k}$ (or $\mathbf{X}_k$)



(a) 模-1(列)纤维: $\mathbf{x}_{:jk}$



(b) 模-2(行)纤维: $\mathbf{x}_{i:k}$



(c) 模-3(管)纤维: $\mathbf{x}_{ij:}$

任意给定张量$\mathcal{X}$，$\mathcal{Y} \in \mathbb{R}^{I_1 \times I_2 \ldots \times I_N}$，张量Hadamard积定义为

$$\mathcal{X} * \mathcal{Y} := (x_{i_1 \cdots i_n} y_{i_1 \cdots i_n})_{i_1 \cdots i_n} \in \mathbb{R}^{I_1 \times I_2 \ldots \times I_N}. \tag{1.1}$$

张量内积定义为

$$\langle \mathcal{X}, \mathcal{Y} \rangle := \sum_{i_1=1}^{I_1} \cdots \sum_{i_N=1}^{I_N} x_{i_1 \ldots i_N} y_{i_1 \ldots i_N} \in \mathbb{R}. \tag{1.2}$$

中国知网 https://www.cnki.net

张量Frobenius范数定义为

$$\|\mathcal{X}\|_F := \sqrt{\langle \mathcal{X}, \mathcal{X} \rangle}. \tag{1.3}$$

张量ℓ_0-范数定义为

$$\|\mathcal{X}\|_0 := \sharp\{(i_1 \cdots i_N) : x_{i_1 \cdots i_N} \neq 0\}. \tag{1.4}$$

张量ℓ_1-范数定义为

$$\|\mathcal{X}\|_1 := \sum_{i_1=1}^{I_1} \sum_{i_2=1}^{I_2} \cdots \sum_{i_N=1}^{I_N} \left| x_{i_1 i_2 \ldots i_N} \right|. \tag{1.5}$$

将张量$\mathcal{X}$的所有模-n纤维按列组成一个$n \times \prod_{i \neq n} I_i$维的矩阵，其称为张量$\mathcal{X}$的模-$n$展开，记为$\mathbf{X}_{(n)}$. 任意给定一个矩阵$\mathbf{U} \in \mathbb{R}^{R_n \times I_n}$，张量$\mathcal{X}$与$\mathbf{U}$的模-$n$积，记为$\mathcal{X} \times_n \mathbf{U}$，是$\mathbb{R}^{I_1 \times \ldots \times I_{n-1} \times R_n \times I_{n-1} \times \ldots \times I_N}$空间中的一个张量，其$(i_1, \ldots, i_{n-1}, j, i_{n+1}, ..., i_N)$-分量定义为

$$(\mathcal{X} \times_n \mathbf{U})_{i_1 i_2 \cdots R_n \cdots i_N} = \sum_{i_n=1}^{I_n} \mathcal{X}_{i_1 i_2 \cdots i_n \cdots i_N} \mathbf{U}_{R_n i_n} \tag{1.6}$$

$$(\mathcal{X} \times_n \mathbf{U})_{(n)} = \mathbf{U}\mathbf{X}_{(n)} \tag{1.7}$$

任意给定张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$，$\mathcal{Y} \in \mathbb{R}^{r_1 \times I_2 \times I_3}$，张量的模-1收缩积定义为

$$\langle \mathcal{X}, \mathcal{Y} \rangle_{(1)} = \left(\sum_{i_2=1}^{I_2} \sum_{i_3=1}^{I_3} \mathcal{X}_{k,i_2,i_3} \mathcal{Y}_{l,i_2,i_3} \right) \in \mathbb{R}^{I_1 \times r_1} \tag{1.8}$$

$\langle \cdot, \cdot \rangle_{(2)}$及$\langle \cdot, \cdot \rangle_{(3)}$可以类似定义.

1.2.2 张量分解

低秩性是数据的内在属性，可以帮助挖掘高维数据中隐藏但重要的结构或特征. 学者们对矩阵中的低秩已经进行了广泛的研究(详见[63,92] 与其中的参考文献)，进而对高阶张量也进行了相应研究[96,101]. 低秩性在大规模数据计算中十分重要，因为可实现数据降维进而显著地降低存储和计算成本. 张量Tucker分解是高阶张量最重要的分解之一[72]. Tucker低秩性在图像处理、视频监控、机器学习等领域中得到了广泛的应用[12,116,121].

定义 1.1 (张量的Tucker分解)给定N阶张量$\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$，若存在正整数$r_1, ..., r_N$，张量$\mathcal{G} \in \mathbb{R}^{r_1 \times \cdots \times r_N}$，以及矩阵$\mathbf{U}_i \in \mathbb{R}^{I_i \times r_i}$ $(i \in [N])$ (通常是列正交的)，使得

$$\begin{aligned} \mathcal{X} &= \mathcal{G} \times_1 \mathbf{U}_1 \times_2 \mathbf{U}_2 \cdots \times_N \mathbf{U}_N \\ &=: [[\mathcal{G}; \mathbf{U}_1, \mathbf{U}_2, ..., \mathbf{U}_N]], \end{aligned} \tag{1.9}$$

中国知网 https://www.cnki.net

称(1.9)为张量$\mathcal{X}$的Tucker分解，其中$\mathcal{G}$为核张量，与$\mathcal{G}$每个模式相乘的矩阵$\mathbf{U}_1$,...,$\mathbf{U}_N$称为因子矩阵.

张量$\mathcal{X}$的Tucker秩定义为向量$(\text{rank}(\mathcal{X}_{(1)}), ..., \text{rank}(\mathcal{X}_{(N)}))$，简记为$\text{rank}(\mathcal{X})$，其中第$n$个分量为张量模-$n$展开的矩阵的秩，称为张量的$n$-秩. 在Tucker分解中，每个$n$-秩为$r_n$提供一个下界，尽管这样的分解不是唯一的，但只要满足$r_i \ll I_i$ $(i \in [N])$，那么$\mathcal{G}$就可以看作是$\mathcal{X}$的压缩，从而减少计算中的存储量(详见[25]). 由(1.6)可以验证，张量$\mathcal{X}$的Tucker秩是由满足(1.7)的最小的$r_1, ..., r_n$组成的. 有学者提出用截断的Tucker 分解来近似表示实际应用中的张量，以便在干扰环境下进行数据的存储从而降低计算成本. 张量$\mathcal{X}$的低秩$(r_1, \ldots, r_N)$Tucker分解可以通过文献[27]中的HOOI迭代算法得到，也可以通过截断型算法得到，例如文献[100]中的ST-HOSVD及文献[87]中改进的随机算法，以及高阶正交迭代算法和随机投影类型的方法(详见[60])得到. 图1.1给出了一个三阶张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 其Tucker秩为(r_1, r_2, r_3)的Tucker分解示意图，其中核张量$\mathcal{G} \in \mathbb{R}^{r_1 \times r_2 \times r_3}$，因子矩阵$\mathbf{U}_i \in \mathbb{R}^{I_i \times r_i}$.

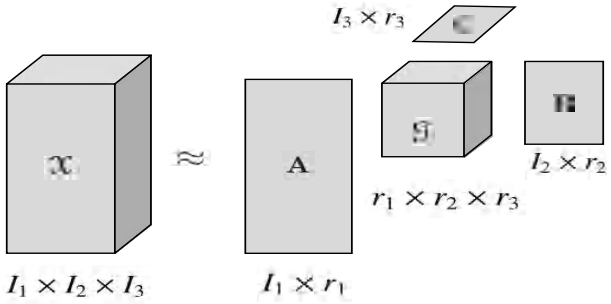


图 1.1: 三阶张量的Tucker分解

定义 1.2 (张量的CP分解)给定N阶张量$\mathcal{X} \in \mathbb{R}^{I_1 \times \ldots \times I_N}$，若$\mathcal{X}$可被表示为

$$\mathcal{X} = \sum_{r=1}^{R} \mathbf{a}_r^{(1)} \circ \mathbf{a}_r^{(2)} \circ \ldots \circ \mathbf{a}_r^{(N)} \tag{1.10}$$

称(1.10)为张量$\mathcal{X}$的CANDECOMP/PARAFAC(CP)分解，其中$\circ$为向量外积，向量$\mathbf{a}_r^{(j)} \in \mathbb{R}^{I_j}, r = 1, ..., R, j = 1, ..., N$.

张量$\mathcal{X}$的CP秩是指$\mathcal{X}$用秩一张量之和表示时所需要的秩一张量的最小个数. 图1.2给出了CP秩为R的三阶张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$的CP 分解示意图. 根据(1.9)和(1.10)可知，当核张量$\mathcal{G}$的各个维数相同且为对角张量时，Tucker分解就退化为CP分解，因而CP分解可以看作是Tucker分解的一种特殊形式，因此认为Tucker分解比CP分解更具一般性.

除此之后，文献[111]中给出了一种简单的非递归的张量分解形式－TT分解(tensor-train decomposition)，将原来的高维张量分解为多个三维张量的乘积(首

中国知网 https://www.cnki.net

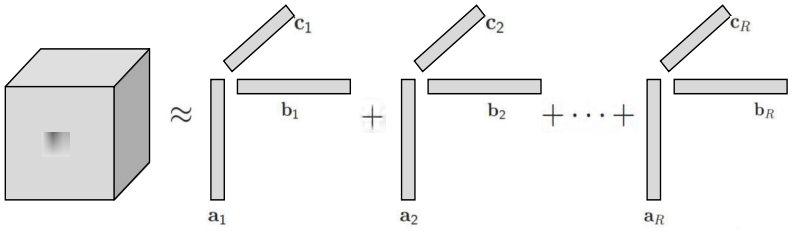


图 1.2: 三阶张量的CP分解

尾张量为二维)，避免了“维度诅咒”的影响，该分解形式得到的参数数量与正则分解(canonical decomposition)的参数数量相同，但更稳定，因为该种分解是基于辅助展开矩阵的低秩近似.

1.2.3 张量函数

次微分和邻近点算子的概念在优化理论与算法设计中十分重要. 本小节回顾一些定义和基本性质，更多相关内容可参考文献[62,88,93].

考虑正常函数h，即对所有x满足$h(x) > -\infty$，且函数的定义域为$\mathrm{dom}(h) := \{x : h(x) < +\infty\} \neq \emptyset$，对任意给定的$x \in \mathrm{dom}(h)$，$h$ 在x 处的Fréchet 次微分$\partial^F h(x)$定义为

$$\partial^F h(x) := \left\{ v : \liminf_{y \neq x, y \to x} \frac{h(y) - h(x) - \langle v, y - x \rangle}{\|y - x\|} \geq 0 \right\}, \tag{1.11}$$

h在x处的极限次微分(或简称次微分)$\partial h(x)$，定义为

$$\partial h(x) := \left\{ v : \exists x^k \to x, h(x^k) \to h(x), v^k \in \partial^F h(x^k) \to v \right\}. \tag{1.12}$$

h中变量所在的空间可以是欧几里德向量空间、矩阵空间、高阶张量空间甚至是更一般的内积空间，h 的值域空间是扩展的实空间，即$\mathbb{R} \cup \{+\infty\}$. 特别地，如果一个函数$h : \mathbb{R}^{I_1 \times \cdots \times I_N} \to \mathbb{R}$是连续可微的，那么对于任意$\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$，可得

$$\partial^F h(\mathcal{X}) = \partial h(\mathcal{X}) = \{\nabla h(\mathcal{X})\},$$

其中$\nabla h(\mathcal{X}) \in \mathbb{R}^{I_1 \times \cdots \times I_N}$ 是h在$\mathcal{X}$ 的梯度, 其$(i_1, \ldots, i_N)$-分量为

$$(\nabla h(\mathcal{X}))_{i_1 \cdots i_N} = \frac{\partial h(\mathcal{X})}{\partial x_{i_1 \cdots i_N}}.$$

值得注意的是，借助向量ℓ_0-范数的性质(定理1[74])以及向量空间$\mathbb{R}^{I_1 \cdots I_N}$ 和张量空间$\mathbb{R}^{I_1 \times \cdots \times I_N}$的同构，$h(\mathcal{X}) = \|\mathcal{X}\|_0$在任意张量$\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$的次微分和Fréchet次微分是一致的[1]，即如下结论.

[1]实际上，ℓ_0-范数的Fréchet次微分，次微分，Clarke次微分和水平次微分[62,93]是一致的.

中国知网 https://www.cnki.net

引理 1.1 对于任意给定的$\mathcal{E} \in \mathbb{R}^{I_1\times\cdots\times I_N}$，张量$\ell_0$-范数在$\mathcal{E}$上的Fréchet次微分和次微分一致，即:

$$\partial^F \|\mathcal{E}\|_0 = \partial \|\mathcal{E}\|_0 = \mathbb{R}^{I_1\times\cdots\times I_N}_{\Gamma_{\mathcal{E}}^c}, \tag{1.13}$$

其中$\mathbb{R}^{I_1\times\cdots\times I_N}_{\Gamma_{\mathcal{E}}^c} := \left\{\mathcal{Y} \in \mathbb{R}^{I_1\times\cdots\times I_N} : \mathcal{Y}_{\Gamma_{\mathcal{E}}} = \mathcal{O}\right\}$，$\Gamma_{\mathcal{E}} := \{(i_1,\ldots,i_N) \in I_1\times\cdots\times I_N : \mathcal{E}_{i_1\ldots i_N} \neq 0\}$是$\mathcal{E}$的支撑集，$\Gamma_{\mathcal{E}}^c$是$\Gamma_{\mathcal{E}}$的补集.

文献[93]中定义的正常函数f的临近点算子记作Prox_f，定义为

$$\mathrm{Prox}_f(\mathbf{y}) := \arg\min_{\mathbf{x}} \left\{ f(\mathbf{x}) + \frac{1}{2}\|\mathbf{x}-\mathbf{y}\|^2 \right\}. \tag{1.14}$$

张量ℓ_0-范数的临近点算子定义为

$$\mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}) = \left(\mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}_{i_1i_2i_3})\right)_{i_1,i_2,i_3}, \tag{1.15}$$

其中

$$\mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(t) = \begin{cases} t, & 若|t| > \sqrt{2\beta\lambda}; \\ \{t,0\}, & 若|t| = \sqrt{2\beta\lambda}; \\ 0, & 否则. \end{cases} \quad \forall t \in \mathbb{R}. \tag{1.16}$$

对于一个非空闭集Ω，关于Ω的示性函数记作δ_Ω，定义为

$$\delta_\Omega(x) := \begin{cases} 0, & 若x \in \Omega; \\ +\infty, & 否则. \end{cases} \tag{1.17}$$

显然，临近点算子$\mathrm{Prox}_{\delta_\Omega}$是$\Omega$集合上的投影算子$\Pi_\Omega$，即:

$$\mathrm{Prox}_{\delta_\Omega}(x) = \Pi_\Omega(x) := \arg\min_{y\in\Omega}\|x-y\|. \tag{1.18}$$

给定正整数$r_1,...,r_N$，引入Tucker低秩张量集合，其定义式为

$$S := \left\{\mathcal{X} \in \mathbb{R}^{I_1\times\cdots\times I_N} : \mathrm{rank}\,(\mathcal{X}) \le (r_1,\ldots,r_N)\right\}. \tag{1.19}$$

下面我们将简单探讨张量ℓ_0-范数$\|\cdot\|_0$与Tucker低秩张量集合S的微分性质.

引理 1.2 在(1.19)中定义的集合S是一个闭的半代数集.

证明. 将S等价刻画为

$$S = \bigcap_{n=1}^{N} S_{(n)} := \bigcap_{n=1}^{N} \left\{\mathcal{X} \in \mathbb{R}^{I_1\times\cdots\times I_N} : \mathrm{rank}(\mathbf{X}_{(n)}) \le r_n\right\}. \tag{1.20}$$

中国知网 https://www.cnki.net

由矩阵秩函数的下半连续性[69]可得$S_{(n)}$在$R^{I_1\times\cdots\times I_N}$上是闭集，从而这$N$个闭集的交集$S$也是闭的. 为了检验S的半代数性质，由文献[68]可知，低秩矩阵集是半代数的，这说明张量$S_{(n)}$是半代数的. 由于有限个半代数集的交集仍然是半代数集，因此得到了S是半代数集的结论. □

引理 1.3 *函数$p:\mathbb{R}^{I_1\times\cdots\times I_N}\times\mathbb{R}^{I_1\times\cdots\times I_N}\to\mathbb{R}\cup\{+\infty\}$其定义式$p(\mathcal{X},\mathcal{E}):=\lambda\|\mathcal{E}\|_0+\delta_S(\mathcal{X})$，则*

(1) *p是正常的、下半连续的半代数函数；*

(2) *p的次微分为*

$$\partial p\left(\bar{\mathcal{X}},\bar{\mathcal{E}}\right)=N_S(\mathcal{X})\times\mathbb{R}^{I_1\times\cdots\times I_N}_{\Gamma^c_{\mathcal{E}}},\tag{1.21}$$

其中$N_S(\mathcal{X})$是在$\mathcal{X}$处相对于集合S的法锥.

证明. (1) 由于p是非负的且对任意的$(\mathcal{X},\mathcal{E})\in S\times\mathbb{R}^{I_1\times\cdots\times I_N}$有有限值，所以$p$是非负正常的. 由引理1.2中$S$的闭性和文献[74]中$\ell_0$-范数的下半连续性可得$p$的下半连续性. 由引理1.2可知，$S$是半代数集，从而$\delta_S$是半代数函数. 另一方面，由文献[52]可知，$\ell_0$-范数是半代数函数，则和函数$\delta_S(\mathcal{X})+\lambda\|\mathcal{E}\|_0$是半代数的.

(2) p对于$\mathcal{X}$和$\mathcal{E}$的可分离性，连同(命题10.5[93])，可得

$$\partial p\left(\bar{\mathcal{X}},\bar{\mathcal{E}}\right)=\partial_{\mathcal{X}}\delta_S(\bar{\mathcal{X}})\times\partial_{\mathcal{E}}\lambda\|\bar{\mathcal{E}}\|_0.\tag{1.22}$$

利用引理1.1，以及$\partial_{\mathcal{X}}\delta_S(\mathcal{X})=N_S(\mathcal{X})$(练习8.14[93])，结论得证. □

1.3 研究现状

1.3.1 视频监控背景消除的张量优化方法

背景消除(background subtraction，BS)起源于计算机视觉的众多应用中，包括视频监控(检测人、车辆)、视觉对象跟踪、运动检测及多媒体应用等. 背景消除基本的操作包括视频采集、编码及解码，其中分离出的运动物体称为“前景”，静态场景称为“背景”[33]. 由于自然场景具有复杂性，例如突然的光照变化、阴影、树木中的风、水流等，因此背景消除任务具有非静态性. 在文献[7]中提出了几种复杂的背景模型用于解决动态场景中的背景消除问题.

随着科技的发展，实际问题产生的数据规模不断扩大，计算复杂度也随之增加. 由于传统的视频背景消除技术测试图像和背景通常都是完全采样的[10]，因此需要大量的存储空间. 受压缩感知(compressive sensing，CS)的数学理论[10]

中国知网 https://www.cnki.net

启发，在文献[18]中提出一个压缩成像方法，命名为基于压缩测量的背景消除方法(background subtraction from compressive measurements，BSCM)，从而基于压缩测量，同时实现重建原始视频和从视频背景中准确分离出移动对象.

在过去的十几年里，学者们提出了许多BSCM方法. BSCM的第一项开创性工作是由文献[13]提出的，通过压缩测量以较少的数据样本来刻画前景轮廓(二值背景消除图像). 受低秩矩阵分析[9]的启发，有部分学者在矩阵框架中建模不同的视频先验来处理BSCM问题[23,24,43,47]. 例如，在文献[43] 中，将矩阵鲁棒主成分分析(principal component analysis，RPCA)方法应用到BSCM 框架中，并设计了命名为SpaRCS的贪婪算法来进行求解.

也有一些学者未利用压缩测量来完成背景消除任务. 例如，在文献[46]中，在高斯混合模型(GMM) 中引入混合高斯概率密度函数，对背景的颜色强度变化进行建模. 聚类(详见[3,4]) 也用于解决背景消除问题，如文献[22]中的稀疏子空间聚类方法.

然而，基于矩阵的方法本质上是二维的，没有充分利用视频帧之间的先验信息. 基于张量的方法在提高多维信息提取的有效性方面具有优势，因此具有较好的性能. 考虑到视频前景的时空连续性和视频背景的时空相关性，一些学者提出了基于稀疏和低秩张量分解的张量模型，以传递视频更多的内在信息. 在文献[37]中，前景的稀疏性用ℓ_1-范数来刻画. ℓ_1-范数是ℓ_0-范数的凸松弛，因此在凸优化框架下提出了一种在线背景消除的方法(详见[34]). 在文献[21]中，采用三维局部自适应回归核结合ℓ_0范数来提高前景提取的鲁棒性. 在文献[36]中，提出了$\ell_{1,1,2}$-范数张量低秩稀疏分解来表征前景的群稀疏特性，并在不连续的光照变化下检测运动目标. 在压缩测量方面，曹等人将3D总差分融合到BSCM 的张量RPCA模型中，并在文献[12] 中将前景的时空连续性与ℓ_1-范数相结合. 对于背景模型建模，低秩张量分解可以通过多种分解方法实现，例如，在文献[72]中使用了Tucker分解，其是PCA 的一种高阶形式. 为了充分利用背景的低秩性质，可以对Tucker秩的凸松弛即张量核范数进行正则化. 在文献[14]中，提出了基于kronecker 基和$\ell_{1,1,2}$范数的背景消除分解模型. 在文献[29]中，提出了一种新的张量RPCA 模型(TRPCA)，该模型利用张量核范数对背景进行更精确的建模和恢复. 在文献[12]中，通过调整核张量的维数，将Tucker分解技术引入到稀疏张量框架中，完成了空间信息选择，从而实现了稳健的背景消除. 在文献[6]中，提出了多特征张量构建背景的鲁棒低秩模型，并设计了一种多特征增量张量子空间学习算法.

与上述的方法相比，针对视频监控的背景消除问题，本文通过结合时空连续性和ℓ_0范数直接对视频前景建模，而不是用松弛的方式间接的对视频前景建模；并且通过控制核心张量的维数提高背景消除的精度而不是用迂回的方式对视频背景建模. 对建立的稀疏张量优化模型进行最优性条件分析，并设计分

中国知网 https://www.cnki.net

块ADMM算法进行求解. 数值实验比较了本文方法与其他四种流行的方法来求解BSCM问题，结果显示本文方法在三个评价指标上效果较好，表明该方法在计算方面的优势.

1.3.2 网络流量异常检测的张量优化方法

异常点也称为异常值，是由Barnett和Lewis在文献[53]中从统计的角度定义的，指的是数据中不符合预期行为的模式. 异常值是样本中的个别值，其数值明显偏离其所属样本的其余观测值. 识别异常值的过程就是异常检测，它是许多安全、监测和监控系统的重要组成部分. 网络流量异常点检测(internet traffic anomaly detection，ITAD)主要用于检测由于突发访问、拒绝服务攻击、端口扫描、蠕虫传播等原因导致的网络流量异常. 开发出高效、可靠的网络流量异常检测方法已成为计算机科学及相关学科的研究热点，也是高级网络管理和服务的关键任务. 传统的网络流量检测方法是基于流量矩阵(traffic matrix，TM)构建的，在给定的时间内，指定网络中的起点和终点，其间测量出的流量数据会形成一个流量矩阵. 假设正常和异常流量数据在低维子空间中的分布明显不同，在文献[57,70,73,77–79,82,102,103,105,109] 中广泛研究了基于矩阵的光谱方法(即PCA/SVD方法)用于流量异常检测.

由于矩阵只能携带二维数据信息，因此一些有意义的异常点在传统的异常检测方法中并不可见. 自Nomikos 和MacGregor的开创性工作[91]以来，基于张量的异常检测方法随之出现，并获得了大量关注(详见[65]及其中的参考文献). 注意到张量可以较好地模拟出按照时间和/或周期维度的流量矩阵的动态变化，并且其涉及到的多线性结构有助于表征流量数据的时空特性和周期性. 周等人在文献[112]中按起点、终点和时间维度构建了流量数据的三阶张量，提出了一种鲁棒的时空张量恢复方法来处理缺失数据和异常值. 谢等人在文献[106]中以天为周期模式，以OD对、时间时隙、天数为坐标轴构建了一个三阶张量，用于网络流量数据的精确恢复. 在文献[104]中构建了一个ITAD三阶张量，特别地，根据文献[58,110]异常点通常远离正常数据，分布在低密度区域内，因此可以把异常值看作一个稀疏张量；正常的流量数据，由于时间相似性、空间相关性和周期性，因此可以根据文献[106]把正常流量数据看作一个低秩张量，在文献[104]中相应的稀疏低秩张量优化模型为：

$$\min_{\mathcal{X},\mathcal{E}} \{\|\mathcal{X}_0 - \mathcal{X} - \mathcal{E}\|_F : \operatorname{rank}(\mathcal{X}) \le (r_1, r_2, r_3), \|\mathcal{E}\|_0 \le \epsilon\}, \tag{1.23}$$

其中$\mathcal{X}_0$为OD对间的观测流量张量，$\mathcal{X}$和$\mathcal{E}$为待求的正常流量张量和异常流量张量，rank(·)为Tucker秩，$\|\cdot\|_0$是ℓ_0-范数即非零元素的个数，$\|\cdot\|_F$是张量Frobenius范数，r_i $(i = 1, 2, 3)$和ϵ 分别是控制秩和稀疏度的给定参数. 在网络流量追踪数据

中国知网 https://www.cnki.net

集Abilene[49]和GÈANT[99]上进行数值实验，采用块坐标下降法求解非凸非连续优化问题(1.23)时具有较快的计算速度.

在流量工程任务中，数据缺失是难以避免的，已有许多工作对有部分观测流量的网络流量数据进行恢复[81]，他们以对缺失数据进行高重建精度为目标，采用工业界中广泛使用的预测方法[67,75,83–86,97]. 任何大规模流量数据都必然有大量的缺失值，因为网络中的许多OD对流量是不能直接收集到的，只能通过链路测量来收集，因此(1.23)中提出的张量方法将不再适用. 针对基于矩阵的方法，Roughan 等人在文献[95] 中提出了一种稀疏正则化的矩阵分解(SRMF) 方法，用于处理一系列广泛的网络任务，包括层析成像、预测和异常检测，其相应的模型为：

$$\min_{L,R} \|A(\mathbf{L}\mathbf{R}^\top) - \mathbf{B}\|_F^2 + \lambda(\|\mathbf{L}\|_F^2 + \|\mathbf{R}\|_F^2) + \|\mathbf{S}(\mathbf{L}\mathbf{R}^\top)\|_F^2 + \|(\mathbf{L}\mathbf{R}^\top)\mathbf{E}^\top\|_F^2, \tag{1.24}$$

其中$\mathbf{S}$和$\mathbf{E}$是空间和时间约束矩阵，A是针对特定任务时具有不同结构的线性算子，包括不完全测量和链接测量两种情况，此处的流量矩阵由$\mathbf{L}\mathbf{R}^\top$生成.

一个很自然的问题为：能否利用流量张量数据中的低秩和稀疏性特征，在张量不完全测量和链接测量情况下设计有效的ITAD方法？在第三章中，我们将通过提出一个稀疏正则化的低秩约束张量优化模型来回答这个问题，并且设计了一种有效的近端梯度算法来求解所提出的张量优化问题.

1.4 本文的主要工作

本文的章节结构如下: 第2章针对视频监控的背景消除问题，构造稀疏张量优化模型，建立模型的最优性条件，设计基于硬阈值的交替方向乘子法来求解所提出的模型，在不同的真实数据集上进行实验验证模型的优越性和算法的高效性. 第3章针对网络流量异常检测问题，构造稀疏低秩张量优化模型，建立基于稳定点的最优性条件，为算法设计提供理论基础，设计近端梯度算法来求解所提出的模型，并在理论上验证其收敛性，在流量追踪数据集上进行数值实验证明该方法在异常检测的准确率和计算时间方面都具有优势. 第4章为结论与未来研究方向.

中国知网 https://www.cnki.net

第 2 章 视频监控背景消除的张量优化方法

运动目标检测是计算机视觉领域重要而基础的问题，其精确性、完整性和快速性将影响其后续的运动目标分析，因此视频序列中的运动目标检测具有十分重要的意义. 针对更加复杂的场景，本章建立了基于压缩测量的背景消除方法来实现视频前景、背景分离与视频重建.

2.1 模型建立

2.1.1 视频张量模型

张量结构: 类似于文献[12]，在一个时间段内的视频帧被收集为视频量，可以表示为3-阶张量. 具体来说，假设视频中的每一帧的像素大小为$I_1 \times I_2$ (高度× 宽度)，并且在短时间内收集到I_3 帧，因而很自然地引入一个张量$\mathcal{X}_0 \in \mathbb{R}^{I_1 \times I_2 \times I_3}$，其中$I_3$ 矩阵(帧)作为正面切片来表示帧量. 此外，我们还引入另外两个张量$\mathcal{X}_1$和$\mathcal{X}_2 \in \mathbb{R}^{I_1 \times I_2 \times I_3}$来表示视频的背景(静态分量)和前景(动态分量)，即

$$\mathcal{X}_0 = \mathcal{X}_1 + \mathcal{X}_2. \tag{2.1}$$

压缩测量: 视频压缩对于多媒体信息的存储和传输是至关重要和普遍的. 在压缩监控系统中，视频成像系统首先从场景中获取压缩测量值，然后将这些测量值传输到处理中心进行前景/背景重建. 压缩测量是通过压缩算子收集的，例如在文献[23]中的随机排列Walsh-Hadamard算子，随机排列的噪声算子[16]等. 设$A : \mathbb{R}^{I_1 \times I_2 \times I_3} \to \mathbb{R}^{I_5}$是视频数据$\mathcal{X}_0$的给定压缩算子，其中$I_5 \ll \Pi_{i=1}^{3} I_i$. 相应的压缩度量值，记为$\mathbf{y}$，可由下式得到

$$\mathbf{y} = A(\mathcal{X}_0). \tag{2.2}$$

具体来说，压缩算子可以表示为$A = D \cdot H \cdot P$，其中P是一个随机排列矩阵，H是Walsh-Hadamard 变换或噪声子变换，D是一个随机下采样算子. 压缩算子对视频量$\mathcal{X}_0$有两种编码方式. (1)整体方式: $\mathbf{y} = D \cdot H \cdot P(\mathbf{x}_0)$，即直接采集视频序列的完整3D测量结果. (2)逐帧方式: $\mathbf{y}_d = D_d \cdot H_d \cdot P_d(\mathbf{x}_0^d)$ $(d = 1, 2, ..., I_3)$, $P_d(\mathbf{x}_0^d) \in \mathbb{R}^{2^{\lceil log_2(I_1 \times I_2) \rceil}}$. 所有2D逐帧测量值$\mathbf{y}_{d=1}^{I_3}$将被收集并连接成一个列向量$\mathbf{y}$. 在本文中，压缩算子$A$是按照逐帧方式设置的.

中国知网 https://www.cnki.net

稀疏和低秩表示: 如文献[12]中阐述的，在同一视频量中背景图像有很高的时空相关性，因此利用截断低秩Tucker 分解刻画背景张量$\mathcal{X}_1$(由更小尺寸的核张量表示稀疏性). 考虑在实际监测情况中的噪声干扰，可得

$$\mathcal{X}_1 = \mathcal{G}\prod_{i=1}^{3}\times_i \mathbf{U}_i + \mathcal{E}, \tag{2.3}$$

其中$\mathcal{G}\in\mathbb{R}^{r_1\times r_2\times r_3}$, $\mathbf{U}_i\in \mathrm{St}(r_i, I_i)$, $r_i < I_i$, $i\in[3]$. 此处，$\mathrm{St}(r_i, I_i)$是Stiefel流形，其定义式为$\mathrm{St}(r_i, I_i) := \{\mathbf{U}\in\mathbb{R}^{I_i\times r_i} : \mathbf{U}^\top\mathbf{U} = \mathbf{I}_{r_i}\}$ (详见[2]). 因此，实现理想低秩背景张量的一种常用方法是：在最小二乘意义上极小化噪声张量$\mathcal{E}$ 的干扰(噪声$\mathcal{E}$服从高斯分布时即为最大似然估计[8])，相应的优化模型为:

$$\min \frac{1}{2}\left\|\mathcal{X}_1 - \mathcal{G}\prod_{i=1}^{3}\times_i \mathbf{U}_i\right\|_F^2. \tag{2.4}$$

根据实际应用问题中噪声的先验信息，还可以使用其他损失函数[38]，如$\mathcal{E}$ 服从拉普拉斯分布[8]的张量ℓ_1-范数(即张量中所有元素绝对值的总和).

2.1.2　稀疏张量优化

为了刻画视频前景中所蕴含的时空连续性，我们引入差分算子$D : \mathbb{R}^{I_1\times I_2\times I_3}\to\mathbb{R}^{I_4}$的稀疏表示[12]:

$$D(\mathcal{X}) := \left[(D_c(\mathcal{X}))^T, (D_r(\mathcal{X}))^T, (D_t(\mathcal{X}))^T\right]^T,\ \ \forall\mathcal{X}\in\mathbb{R}^{I_1\times I_2\times I_3} \tag{2.5}$$

其中$I_4 := (I_1-1)I_2I_3 + I_1(I_2-1)I_3 + I_1I_2(I_3-1)$, $\mathcal{X}$中对所有的行、列和管纤维差分算子$D_c(\mathcal{X})$, $D_r(\mathcal{X})$和$D_t(\mathcal{X})$分别定义为

$$\begin{cases} D_c(\mathcal{X}) := Vec\left(x_{i+1jk} - x_{ijk}\right)\in\mathbb{R}^{(I_1-1)I_2I_3}, \\ D_r(\mathcal{X}) := Vec\left(x_{ij+1k} - x_{ijk}\right)\in\mathbb{R}^{I_1(I_2-1)I_3}, \\ D_t(\mathcal{X}) := Vec\left(x_{ijk+1} - x_{ijk}\right)\in\mathbb{R}^{I_1I_2(I_3-1)}. \end{cases} \tag{2.6}$$

其中x_{ijk}表示张量$\mathcal{X}$在i, j, k位置的像素点，$Vec(\cdot)$表示向量化.

视频前景$\mathcal{X}_2$所涉及的时空连续性可以用向量$D(\mathcal{X}_2)$的稀疏性来表征. 受压缩感知中广泛使用的ℓ_0-范数的启发(详见[11])，可以通过最小化$\|D(\mathcal{X}_2)\|_0$来实现稀疏表示，其中$\|\cdot\|_0$是ℓ_0-范数.

中国知网　https://www.cnki.net

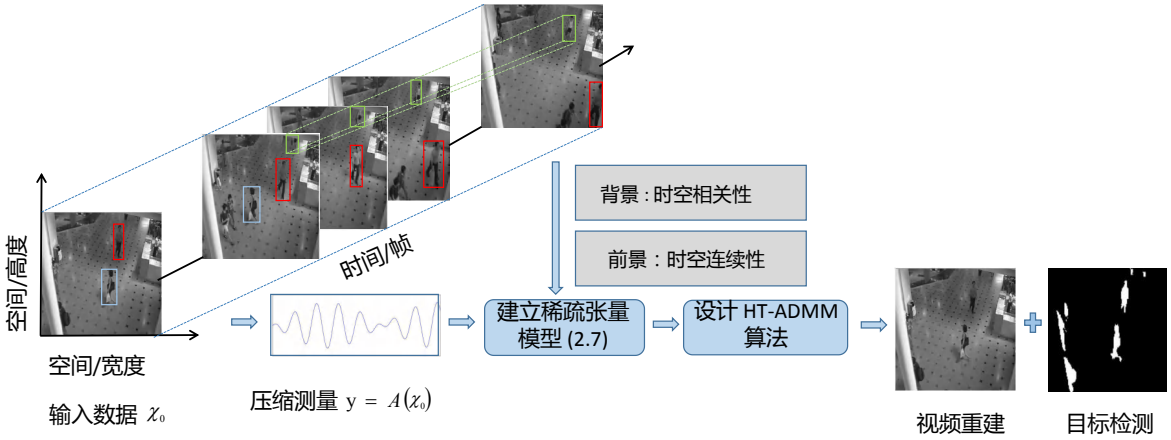


图 2.1: 方法的流程图.

综上所述，我们可以把BSCM问题用如下的稀疏张量优化问题表示：

$$\begin{aligned} \min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}} \ & f(\mathcal{H}) := \lambda\|\mathbf{z}\|_0 + \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^{3}\times_i\mathbf{U}_i\|_F^2 \\ \text{s.t. } & \mathbf{z} - D(\mathcal{X}_2) = 0 \\ & A(\mathcal{X}_0) = \mathbf{y} \\ & \mathbf{U}_i^\top\mathbf{U}_i = \mathbf{I}_{r_i}, i = 1,2,3 \end{aligned} \tag{2.7}$$

其中$\mathcal{H} := (\mathcal{X}_0, \mathcal{X}_2, \mathbf{z}, \mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3)$，$\mathcal{H}$所在的空间是

$$\mathbb{R}_{\mathcal{H}} := \mathbb{R}^{I_1\times I_2\times I_3}\times\mathbb{R}^{I_1\times I_2\times I_3}\times\mathbb{R}^{I_4}\times\mathbb{R}^{r_1\times r_2\times r_3}\times\prod_{i=1}^{3}\mathbb{R}^{I_i\times r_i}.$$

Tucker秩的上界$(r_1, r_2, r_3) < (I_1, I_2, I_3)$. 在本章中，我们将采用文献[12]中的策略，选择$r_1 = \lceil 0.65\times I_1\rceil$，$r_2 = \lceil 0.65\times I_2\rceil$及$r_3 = 1$. 对于任意$i = 1,2,3$，引入Stiefel流形$\mathrm{St}(r_i, I_i)$的示性函数，记为$\delta_{\mathrm{St}(r_i,I_i)}$. 记集合

$$\Omega := \left\{(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \in \mathbb{R}^{I_4}\times\mathbb{R}^{I_1\times I_2\times I_3}\times\mathbb{R}^{I_1\times I_2\times I_3} : \begin{array}{c}\mathbf{z} - D(\mathcal{X}_2) = 0 \\ A(\mathcal{X}_0) = \mathbf{y}\end{array}\right\} \tag{2.8}$$

并引入示性函数δ_Ω，借助上述示性函数，可将问题(2.7)等价转化为：

$$\min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}} \tilde{f}(\mathcal{H}) := \lambda\|\mathbf{z}\|_0 + \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^{3}\times_i\mathbf{U}_i\|_F^2 + \sum_{i=1}^{3}\delta_{\mathrm{St}(r_i,I_i)}(\mathbf{U}_i) + \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2). \tag{2.9}$$

由于ℓ_0-范数项是非凸非连续的，Stiefel流形的指示函数是非连续的，故而(2.9)是非凸非连续的. 因而，问题在复杂性上是NP-难的.

中国知网　https://www.cnki.net

2.2 最优性条件

本节将讨论帮助表征最优解性质的最优性条件(Karush-Kuhn-Tucker，KKT)，为后续的算法设计提供理论准备. 这里使用$\partial f(\cdot)$和$\hat{\partial} f(\cdot)$分别表示f的次微分和正则次微分，详细定义见(定义8.3[35]).

引理 2.1 ([2]) 给定正整数I和r，其中$I \geq r$, $\mathbf{U} \in \mathrm{St}(r, I)$,

$$\partial \delta_{\mathrm{St}(r,I)}(\mathbf{U}) = \{\mathbf{UW} : \mathbf{W} \in \mathbb{S}^r\}.$$

引理 2.2 Ω由(2.8)定义. 对任意给定的$(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \in \mathbb{R}^{I_4} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3}$, 有

$$\hat{\partial} \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) = \partial \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) = \left\{ \begin{pmatrix} \mathbf{w_z} \\ A^*(\mathbf{w}_{\mathcal{X}_0}) \\ -D^*(\mathbf{w_z}) \end{pmatrix} : \mathbf{w_z} \in \mathbb{R}^{I_4}, \mathbf{w}_{\mathcal{X}_0} \in \mathbb{R}^{I_5} \right\},$$

其中A^*是A的伴随算子.

证明. 引入线性算子$M : \mathbb{R}^{I_4} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \to \mathbb{R}^{I_4 \times I_5}$其定义为

$$M(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) := \begin{pmatrix} \mathbf{z} - D(\mathcal{X}_2) \\ A(\mathcal{X}_0) \end{pmatrix}.$$

由(2.8)可知，仿射子空间Ω可等价写成

$$\Omega = \left\{ (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) : M(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) = \begin{pmatrix} \mathbf{0} \\ \mathbf{y} \end{pmatrix} \right\}$$

因此, $\hat{\partial} \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$和$\partial \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$与$\Omega$在$(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$的正规子空间重合，恰好是伴随算子$M$的值域空间,

$$\left\{ M^* \begin{pmatrix} \mathbf{w_z} \\ \mathbf{w}_{\mathcal{X}_0} \end{pmatrix} : \mathbf{w_z} \in \mathbb{R}^{I_4}, \mathbf{w}_{\mathcal{X}_0} \in \mathbb{R}^{I_5} \right\} = \left\{ \begin{pmatrix} \mathbf{w_z} \\ A^*(\mathbf{w}_{\mathcal{X}_0}) \\ -D^*(\mathbf{w_z}) \end{pmatrix} : \mathbf{w_z} \in \mathbb{R}^{I_4}, \mathbf{w}_{\mathcal{X}_0} \in \mathbb{R}^{I_5} \right\}.$$

□

引理 2.3 设函数$g_0 : \mathbb{R}^{I_4} \times \mathbb{R}^{I_4} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \to \mathbb{R}$，定义式为$\Omega$，$g_0(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) := \lambda \|\mathbf{z}\|_0 + \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$，其中$\lambda > 0$为给定参数，$\Omega$为(2.8)中定义的集合. 则对任意给定

中国知网 https://www.cnki.net

的$(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \in \Omega$，有

$$\begin{aligned}\hat{\partial} g_0(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) &= \begin{pmatrix} \lambda\partial\|\mathbf{z}\|_0 \\ \mathcal{O} \\ \mathcal{O} \end{pmatrix} + \partial\delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \\ &= \left\{ \begin{pmatrix} \mathbf{v} + \mathbf{w}_\mathbf{z} \\ A^*(\mathbf{w}_{\mathcal{X}_0}) \\ -D^*(\mathbf{w}_\mathbf{z}) \end{pmatrix} : (\mathbf{v}, \mathbf{w}_\mathbf{z}, \mathbf{w}_{\mathcal{X}_0}) \in \mathbb{L} \right\}, \end{aligned} \tag{2.10}$$

其中$\mathbb{L} := \mathbb{R}^{I_4}_{[I_4]\setminus\Gamma_\mathbf{z}} \times \mathbb{R}^{I_4} \times \mathbb{R}^{I_5}$，$\Gamma_\mathbf{z} := \{i \in [I_4] : \mathbf{z}_i \neq 0\}$为$\mathbf{z}$ 的支撑集.

证明. 利用$\partial\|\mathbf{z}\|_0 = \{\mathbf{v} \in \mathbb{R}^{I_4} : \mathbf{v}_i = 0, \text{ 若 } \mathbf{z}_i \neq 0\}$，与引理2.2，我们可以得到(2.10)中的第二个等式. 现在只需要证明(2.10)中第一个等式中次微分的分解. 根据(推论10.9[35])，$\hat{\partial}\|\mathbf{z}\|_0 = \partial\|\mathbf{z}\|_0$与$\hat{\partial}\delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) = \partial\delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$，可得

$$\hat{\partial} g_0(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \supseteq \begin{pmatrix} \lambda\partial\|\mathbf{z}\|_0 \\ \mathcal{O} \\ \mathcal{O} \end{pmatrix} + \partial\delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2). \tag{2.11}$$

任意给定$(\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3) \in \hat{\partial} g_0\ (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$，根据(定义8.3[35])中次微分的定义，对任意的$(\mathbf{z}', \mathcal{X}_0', \mathcal{X}_2') \to (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$，可得

$$\begin{aligned} o(\|(\mathbf{z}', \mathcal{X}_0', \mathcal{X}_2') - (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)\|) \leq \|\mathbf{z}'\|_0 + \delta_\Omega(\mathbf{z}', \mathcal{X}_0', \mathcal{X}_2') - \|\mathbf{z}\|_0 - \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) - \mathbf{v}_1^T(\mathbf{z}' - \mathbf{z}) \\ - \mathbf{v}_2^T(\mathcal{X}_0' - \mathcal{X}_0) - \mathbf{v}_3^T(\mathcal{X}_2' - \mathcal{X}_2) \end{aligned} \tag{2.12}$$

特别地，若选取$(\tilde{\mathbf{z}}, \tilde{\mathcal{X}}_0, \tilde{\mathcal{X}}_2) \to (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$，满足$(\tilde{\mathbf{z}}, \tilde{\mathcal{X}}_0, \tilde{\mathcal{X}}_2) \in \Omega$，$\tilde{\mathbf{z}} \in \mathbb{R}^{I_4}_{I_z}$. 其中$I_z := \{i \mid \mathbf{z}_i \neq 0\}$，$\mathbb{R}^{I_4}_{I_z} := \{\mathbf{z} \in \mathbb{R}^{I_4} \mid \mathbf{z}_i = 0, i \notin I_z\}$. 对$(\tilde{\mathbf{z}}, \tilde{\mathcal{X}}_0, \tilde{\mathcal{X}}_2) \in \Omega \cap (\mathbb{R}^{I_4}_{I_z} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3})$，等式(2.12) 成立. 若满足$\tilde{\mathbf{z}} \to \mathbf{z}$与$\tilde{\mathbf{z}} \in \mathbb{R}^{I_4}_{I_y}$，则有$\|\tilde{\mathbf{z}}\|_0 = \|\mathbf{z}\|_0$，因此(2.12)可以得到

$$o(\|(\mathbf{z}', \mathcal{X}_0', \mathcal{X}_2') - (\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)\|) \leq -\mathbf{v}_1^T(\mathbf{z}' - \mathbf{z}) - \mathbf{v}_2^T(\mathcal{X}_0' - \mathcal{X}_0) - \mathbf{v}_3^T(\mathcal{X}_2' - \mathcal{X}_2) \tag{2.13}$$

即$(\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3) \in N_{\Omega \cap (\mathbb{R}^{I_4}_{I_z} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3})}(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$.

由于Ω及$\mathbb{R}^{I_4}_{I_z} \times \mathbb{R}_{I_1 \times I_2 \times I_3} \times \mathbb{R}_{I_1 \times I_2 \times I_3}$是凸多面集，根据(推论23.8.1[35])可得

$$N_{\Omega \cap (\mathbb{R}^{I_4}_{I_z} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3})}(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) = N_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) + N_{\mathbb{R}^{I_4}_{I_z} \times \mathbb{R}^{I_1 \times I_2 \times I_3} \times \mathbb{R}^{I_1 \times I_2 \times I_3}}(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2)$$

由于$\lambda\hat{\partial}\|\mathbf{z}\|_0 = \lambda\partial\|\mathbf{z}\|_0$，并结合$\partial\|\mathbf{z}\|_0 = \{h \in \mathbb{R}^{I_4} \mid h_i = 0, \text{ 若 } \mathbf{z}_i = 0\} = \mathbb{R}^{I_4}_{[I_4]\setminus I_y}$可得

中国知网　https://www.cnki.net

$$\hat{\partial} g_0(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2) \subseteq \begin{pmatrix} \lambda \partial \|\mathbf{z}\|_0 \\ \mathcal{O} \\ \mathcal{O} \end{pmatrix} + \partial \delta_\Omega(\mathbf{z}, \mathcal{X}_0, \mathcal{X}_2). \tag{2.14}$$

□

引理 2.4 给定$\mathcal{T} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$，定义函数$g : \mathbb{R}^{r_1 \times r_2 \times r_3} \times \prod_{i=1}^3 \mathbb{R}^{I_i, r_i} \to \mathbb{R}$，其表达式为$g(\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3) := \frac{1}{2}\|\mathcal{T} - \mathcal{G} \prod_{i=1}^3 \times_i \mathbf{U}_i\|_F^2$，则

$$\begin{cases} \nabla_{\mathcal{G}} g(\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3) = \left(\mathcal{G} \prod_{i=1}^3 \times_i \mathbf{U}_i - \mathcal{T}\right) \prod_{i=1}^3 \times_i \mathbf{U}_i^\top, \\ \nabla_{\mathbf{U}_i} g(\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3) = \left\langle \mathcal{G} \prod_{l=1}^3 \times_l \mathbf{U}_l - \mathcal{T}, \mathcal{G} \prod_{k \in [3], k \neq i} \times_k \mathbf{U}_k \right\rangle_{(i)}, \quad i = 1, 2, 3 \end{cases} \tag{2.15}$$

其中$\langle \cdot, \cdot \rangle_{(i)}$是张量的模-$i$收缩积.

证明. 根据光滑函数的微分定义，可以直接计算得到(2.15). □

现在考虑问题(2.7)，对任意的$\mathcal{H} \in \mathbb{R}_{\mathcal{H}}$，以及任意的

$$\mathcal{W} := \left(\mathbf{w}_{\mathbf{z}}, \mathbf{w}_{\mathcal{X}_0}, \{\mathbf{W}_{\mathbf{U}_i}\}_{i=1}^3\right) \in \mathbb{R}^{I_4} \times \mathbb{R}^{I_5} \times \prod_{i=1}^3 \mathbb{S}^{r_i} =: \mathbb{R}_{\mathcal{W}},$$

定义拉格朗日函数如下：

$$L(\mathcal{H}; \mathcal{W}) := f(\mathcal{H}) - \langle \mathbf{z} - D(\mathcal{X}_2), \mathbf{w}_{\mathbf{z}} \rangle - \langle A(\mathcal{X}_0) - \mathbf{y}, \mathbf{w}_{\mathcal{X}_0} \rangle - \sum_{i=1}^3 \langle \mathbf{U}_i^\top \mathbf{U}_i - \mathbf{I}_{r_i}, \mathbf{W}_{\mathbf{U}_i} \rangle. \tag{2.16}$$

借助引理2.4，问题(2.7)的KKT条件可表示为:

$$\begin{cases} \mathbf{0} \in \partial_{\mathbf{z}} L(\mathcal{H}; \mathcal{W}) = \lambda \partial \|\mathbf{z}\|_0 - \mathbf{w}_{\mathbf{z}} \\ \mathcal{O} = \nabla_{\mathcal{X}_0} L(\mathcal{H}; \mathcal{W}) = \mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G} \prod_{i=1}^3 \times_i \mathbf{U}_i - A^*(\mathbf{w}_{\mathcal{X}_0}) \\ \mathcal{O} = \nabla_{\mathcal{X}_2} L(\mathcal{H}; \mathcal{W}) = \mathcal{X}_2 - \mathcal{X}_0 + \mathcal{G} \prod_{i=1}^3 \times_i \mathbf{U}_i + D^*(\mathbf{w}_{\mathbf{z}}) \\ \mathcal{O} = \nabla_{\mathcal{G}} L(\mathcal{H}; \mathcal{W}) = \left(\mathcal{X}_2 - \mathcal{X}_0 + \mathcal{G} \prod_{i=1}^3 \times_i \mathbf{U}_i\right) \prod_{i=1}^3 \times_i \mathbf{U}_i^\top \\ \mathbf{O} = \nabla_{\mathbf{U}_i} L(\mathcal{H}; \mathcal{W}) \\ \quad = \left\langle \mathcal{X}_2 - \mathcal{X}_0 + \mathcal{G} \prod_{l=1}^3 \times_l \mathbf{U}_l, \mathcal{G} \prod_{k \in [3], k \neq i} \times_k \mathbf{U}_k \right\rangle_{(i)} - 2\mathbf{U}_i \mathbf{W}_{\mathbf{U}_i}, \quad i = 1, 2, 3. \\ \mathbf{z} - D(\mathcal{X}_2) = 0, \ A(\mathcal{X}_0) = \mathbf{y}, \ \mathbf{U}_i^\top \mathbf{U}_i = \mathbf{I}_{r_i}, \ i = 1, 2, 3. \end{cases} \tag{2.17}$$

定理 2.1 (一阶最优性条件) 如果$\bar{\mathcal{H}}$是问题(2.7)的局部最优解, 则存在$\bar{\mathcal{W}} \in \mathbb{R}_{\mathcal{W}}$使得$\left(\bar{\mathcal{H}}, \bar{\mathcal{W}}\right)$满足KKT条件(2.17).

中国知网 https://www.cnki.net

证明. 利用(2.7)和(2.9)之间的等价性，我们转而考虑(2.9)的最优性条件. 若$\bar{\mathcal{H}}$是问题(2.7)和问题(2.9)的局部最小值，由(定理10.1[35])可得

$$\mathcal{O} \in \hat{\partial} \tilde{f}(\bar{\mathcal{H}}). \tag{2.18}$$

为简单起见, 记$g_1(\mathcal{H}) := \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\|_F^2$. 利用(练习8.8(c)[35])和引理2.1-2.4，可得

$$\begin{aligned}
& \hat{\partial} \tilde{f}(\bar{\mathcal{H}}) \\
= \; & \hat{\partial}\left(g_0(\bar{\mathbf{z}}, \bar{\mathcal{X}}_0, \bar{\mathcal{X}}_2) + \sum_{i=1}^3 \delta_{\mathrm{St}(r_i, I_i)}(\bar{\mathbf{U}}_i) \right) + \nabla_{\mathcal{H}} g_1(\bar{\mathcal{H}}) \\
= \; & \hat{\partial} g_0(\bar{\mathbf{z}}, \bar{\mathcal{X}}_0, \bar{\mathcal{X}}_2) \times \{\mathcal{O}\}_{\mathbb{R}^{r_1 \times r_2 \times r_3}} \times \prod_{i=1}^3 \partial_{\mathbf{U}_i} \delta_{\mathrm{St}(r_i, I_i)}(\bar{\mathbf{U}}_i) + \nabla_{\mathcal{H}} g_1(\bar{\mathcal{H}}) \\
= \; & \left\{ \begin{pmatrix} \mathbf{v} + \mathbf{w}_{\mathbf{z}} \\ A^*(\mathbf{w}_{\mathcal{X}_0}) \\ -D^*(\mathbf{w}_{\mathbf{z}}) \\ \mathcal{O} \\ \left\{ \bar{\mathbf{U}}_i \mathbf{W}_{\mathbf{U}_i} \right\}_{i=1}^3 \end{pmatrix} : \begin{pmatrix} \mathbf{v} \\ \mathbf{w}_{\mathbf{z}} \\ \mathbf{w}_{\mathcal{X}_0} \\ \{\mathbf{W}_{\mathbf{U}_i}\}_{i=1}^3 \end{pmatrix} \in \lambda \partial \|\bar{\mathbf{z}}\|_0 \times \mathbb{R}^{I_4} \times \mathbb{R}^{I_5} \times \prod_{i=1}^3 \mathbb{S}^{r_i} \right\} \\
& + \begin{pmatrix} \mathbf{0} \\ \bar{\mathcal{X}}_0 - \bar{\mathcal{X}}_2 - \bar{\mathcal{G}} \prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i \\ \bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}} \prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i \\ \left(\bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}} \prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i \right) \prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i^\top \\ \left\{ \left\langle \bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}} \prod_{l=1}^3 \times_l \bar{\mathbf{U}}_l, \bar{\mathcal{G}} \prod_{k \in [3], k \neq i} \times_k \bar{\mathbf{U}}_k \right\rangle_{(i)} \right\}_{i=1}^3 \end{pmatrix}
\end{aligned}$$

设$\bar{\mathbf{w}}_{\mathbf{z}} := -\mathbf{w}_{\mathbf{z}}$, $\bar{\mathbf{w}}_{\mathcal{X}_0} := -\mathbf{w}_{\mathcal{X}_0}$, $\bar{\mathbf{W}}_{\mathbf{U}_i} = -\mathbf{W}_{\mathbf{U}_i}/2$ 在上述的表达式中. 根据KKT条件，如(2.17)，通过对$\hat{\partial} \tilde{f}(\bar{\mathcal{H}})$和(2.18)的刻画，以及局部最小值的可行性，可得推论. □

由(例子10.2[35])可知：

$$\bar{\mathbf{z}} = \mathrm{Prox}_{\lambda \|\cdot\|_0}(\bar{\mathbf{z}} + \bar{\mathbf{w}}_{\mathbf{z}}) \Longrightarrow \mathbf{0} \in \lambda \partial \|\bar{\mathbf{z}}\|_0 - \bar{\mathbf{w}}_{\mathbf{z}}.$$

中国知网　https://www.cnki.net

从而得到如下更强的KKT条件，也被称为“强稳定点”(详见[30,48])，其形式为

$$F(\bar{\mathcal{H}},\bar{\mathcal{W}}) := \begin{pmatrix} \bar{\mathbf{z}} - \mathrm{Prox}_{\lambda\|\cdot\|_0}(\bar{\mathbf{z}} + \bar{\mathbf{w}}_{\mathbf{z}}) \\ -A^*(\bar{\mathbf{w}}_{\mathcal{X}_0}) + \bar{\mathcal{X}}_0 - \bar{\mathcal{X}}_2 - \bar{\mathcal{G}}\prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i \\ D^*(\bar{\mathbf{w}}_{\mathbf{z}}) + \bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}}\prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i \\ \mathbf{z} - D(\mathcal{X}_2) \\ A(\mathcal{X}_0) - \mathbf{y} \\ \left(\bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}}\prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i\right)\prod_{i=1}^3 \times_i \bar{\mathbf{U}}_i^\top \\ \left\{-2\bar{\mathbf{U}}_i\bar{\mathbf{W}}_{\mathbf{U}_i} + \left\langle \bar{\mathcal{X}}_2 - \bar{\mathcal{X}}_0 + \bar{\mathcal{G}}\prod_{l=1}^3 \times_l \bar{\mathbf{U}}_l, \bar{\mathcal{G}}\prod_{k\in[3],k\neq i} \times_k \bar{\mathbf{U}}_k \right\rangle_{(i)}\right\}_{i=1}^3 \\ \mathbf{U}_1^\top\mathbf{U}_1 - \mathbf{I}_{r_i} \\ \mathbf{U}_2^\top\mathbf{U}_2 - \mathbf{I}_{r_2} \\ \mathbf{U}_3^\top\mathbf{U}_3 - \mathbf{I}_{r_3} \end{pmatrix} = O. \tag{2.19}$$

在优化算法迭代过程中，根据映射$\|F(\mathcal{H},\mathcal{W})\|_F$的范数来求解$\mathcal{H}$.

2.3　算法设计

本节针对问题(2.7)提出了一种基于硬阈值的分块交替方向乘子方法(hard thresholding-alternating direction method of multipliers，HT-ADMM). 本文对问题(2.7)进行了简化，为算法设计进行了如下等价的表述:

$$\begin{aligned} \min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}}\ & \lambda\|\mathbf{z}\|_0 + \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\|_F^2 + \sum_{i=1}^3 \delta_{\mathrm{St}(r_i,I_i)}(\mathbf{U}_i) \\ \text{s.t. } & \mathbf{z} - D(\mathcal{X}_2) = 0 \\ & A(\mathcal{X}_0) = \mathbf{y}. \end{aligned} \tag{2.20}$$

注意，与问题(2.20)相关的增广拉格朗日函数有如下表示：

$$\begin{aligned} L_\sigma(\mathcal{H};\mathbf{w}_{\mathbf{z}},\mathbf{w}_{\mathcal{X}_0}) \ :=\ & \lambda\|\mathbf{z}\|_0 + \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\|_F^2 + \sum_{i=1}^3 \delta_{\mathrm{St}(r_i,I_i)}(\mathbf{U}_i) \\ & -\langle \mathbf{z} - D(\mathcal{X}_2), \mathbf{w}_{\mathbf{z}}\rangle - \langle A(\mathcal{X}_0) - \mathbf{y}, \mathbf{w}_{\mathcal{X}_0}\rangle \\ & +\frac{\sigma_1}{2}\|\mathbf{z} - D(\mathcal{X}_2)\|^2 + \frac{\sigma_2}{2}\|A(\mathcal{X}_0) - \mathbf{y}\|^2 \end{aligned} \tag{2.21}$$

对任意$\mathcal{H}\in\mathbb{R}_{\mathcal{H}}$和$(\mathbf{w}_{\mathbf{z}},\mathbf{w}_{\mathcal{X}_0})\in\mathbb{R}^{I_4}\times\mathbb{R}^{I_5}$，其中$\sigma := (\sigma_1;\sigma_2)\in\mathbb{R}_{++}^2$，$\mathbb{R}_{++}^2$是二维正实数空间，是问题(2.20)中等式约束的惩罚参数向量.

经典的分块ADMM方法(详见[17])，分别求解问题(2.20)中关于$\{\mathbf{z}\}$, $\{\mathcal{X}_0\}$, $\{\mathcal{X}_2\}$,

中国知网　https://www.cnki.net

及$\left\{\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3\right\}$的子问题，其迭代算法为

$$\begin{cases} \mathbf{z}^{k+1} \in \arg\min_{\mathbf{z}} L_\sigma(\mathbf{z}, \mathcal{X}_0^k, \mathcal{X}_2^k, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k), \\ \mathcal{X}_0^{k+1} = \arg\min_{\mathcal{X}_0} L_\sigma(\mathbf{z}^{k+1}, \mathcal{X}_0, \mathcal{X}_2^k, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k), \\ \mathcal{X}_2^{k+1} = \arg\min_{\mathcal{X}_2} L_\sigma(\mathbf{z}^{k+1}, \mathcal{X}_0^{k+1}, \mathcal{X}_2, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k), \\ \left(\mathcal{G}^{k+1}, \{\mathbf{U}_i^{k+1}\}_{i=1}^3\right) \in \arg\min_{\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3} L_\sigma(\mathbf{z}^{k+1}, \mathcal{X}_0^{k+1}, \mathcal{X}_2^{k+1}, \mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k), \\ \left(\mathbf{w}_{\mathbf{z}}^{k+1}, \mathbf{w}_{\mathcal{X}_0}^{k+1}\right) = \left(\mathbf{w}_{\mathbf{z}}^k - \tau\sigma_1\left(\mathbf{z}^{k+1} - D(\mathcal{X}_2^{k+1})\right), \mathbf{w}_{\mathcal{X}_0}^k - \tau\sigma_2\left(A(\mathcal{X}_0^{k+1}) - \mathbf{y}^{k+1}\right)\right), \end{cases} \tag{2.22}$$

其中$\tau \in \left(0, \frac{\sqrt{5}+1}{2}\right)$是对偶步长.

更具体地说，对于迭代公式(2.22)中的$\mathbf{z}$-子问题，利用(1.15)中硬阈值算子的定义

$$\begin{aligned} \mathbf{z}^{k+1} &\in \arg\min_{\mathbf{z}} L_\sigma(\mathbf{z}, \mathcal{X}_0^k, \mathcal{X}_2^k, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k) \\ &= \arg\min_{\mathbf{z}} \lambda\|\mathbf{z}\|_0 - \langle \mathbf{z}, \mathbf{w}_{\mathbf{z}}^k\rangle + \frac{\sigma_1}{2}\|\mathbf{z} - D(\mathcal{X}_2^k)\|^2 \\ &= \mathrm{Prox}_{\frac{\lambda}{\sigma_1}\|\cdot\|_0}\left(\frac{\mathbf{w}_{\mathbf{z}}^k}{\sigma_1} + D(\mathcal{X}_2^k)\right). \end{aligned} \tag{2.23}$$

利用$\mathcal{X}_0$和$\mathcal{X}_2$子问题的一阶最优性(即对光滑无约束凸极小化问题，其目标函数的梯度在任何最优解处消失)，可得

$$\begin{aligned} \mathcal{X}_0^{k+1} &= \arg\min_{\mathcal{X}_0} L_\sigma(\mathbf{z}^{k+1}, \mathcal{X}_0, \mathcal{X}_2^k, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k) \\ &= \arg\min_{\mathcal{X}_0} \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2^k - \mathcal{G}^k\prod_{i=1}^3 \times_i \mathbf{U}_i^k\|_F^2 - \langle A(\mathcal{X}_0), \mathbf{w}_{\mathcal{X}_0}^k\rangle + \frac{\sigma_2}{2}\|A(\mathcal{X}_0) - \mathbf{y}\|^2 \\ &= (\mathbf{I} + \sigma_2 A^*A)^{-1}\left(\mathcal{X}_2^k + \mathcal{G}^k\prod_{i=1}^3 \times_i \mathbf{U}_i^k + A^*(\mathbf{w}_{\mathcal{X}_0}^k + \sigma_2\mathbf{y})\right), \end{aligned} \tag{2.24}$$

以及

$$\begin{aligned} \mathcal{X}_2^{k+1} &= \arg\min_{\mathcal{X}_2} L_\sigma(\mathbf{z}^{k+1}, \mathcal{X}_0^{k+1}, \mathcal{X}_2, \mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3; \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k) \\ &= \arg\min_{\mathcal{X}_2} \frac{1}{2}\|\mathcal{X}_0^{k+1} - \mathcal{X}_2 - \mathcal{G}^k\prod_{i=1}^3 \times_i \mathbf{U}_i^k\|_F^2 + \langle D(\mathcal{X}_2), \mathbf{w}_{\mathbf{z}}^k\rangle + \frac{\sigma_1}{2}\|D(\mathcal{X}_2) - \mathbf{z}^{k+1}\|^2 \\ &= (\mathbf{I} + \sigma_1 D^*D)^{-1}\left(\mathcal{X}_0^{k+1} - \mathcal{G}^k\prod_{i=1}^3 \times_i \mathbf{U}_i^k - D^*(\mathbf{w}_{\mathbf{z}}^k - \sigma_1\mathbf{z}^{k+1})\right). \end{aligned} \tag{2.25}$$

一般来说，当逆很难处理时，可使用共轭梯度法近似求解线性方程组(2.24)和(2.25). 如果压缩算子A满足$AA^* = \mathbf{I}$，则借助Sherman-Morison-Woodbery公式，可得(2.24)中

中国知网　https://www.cnki.net

$(\mathbf{I}+\sigma_2 A^*A)^{-1}$的显示解.

$$\mathcal{X}_0^{k+1}=\left(\mathbf{I}-\frac{\sigma_2}{1+\sigma_2}A^*A\right)\left(\mathcal{X}_2^k+\mathcal{G}^k\prod_{i=1}^{3}\times_i\mathbf{U}_i^k+A^*(\mathbf{w}_{\mathcal{X}_0}^k+\sigma_2\mathbf{y})\right). \tag{2.26}$$

由于D^*D的块循环结构来自差分算子D(详见[12])，更新$\mathcal{X}_2^{k+1}$时可以使用3D傅里叶变换进行快速计算.

更新$\left\{\mathcal{G},\{\mathbf{U}_i\}_{i=1}^3\right\}$的子问题可以等价为下面的流形约束优化问题：

$$\begin{aligned}\min_{\mathcal{G},\{\mathbf{U}_i\}_{i=1}^3}\ &\frac{1}{2}\|\mathcal{X}_0^{k+1}-\mathcal{X}_2^{k+1}-\mathcal{G}\prod_{i=1}^{3}\times_i\mathbf{U}_i\|_F^2\\ \text{s.t. }&\mathbf{U}_i^\top\mathbf{U}_i=\mathbf{I}_{r_i},\ i=1,2,3.\end{aligned} \tag{2.27}$$

尽管Stiefel流形约束允许无限多个最优解，但相应Tucker分解生成的张量将是唯一的. 因此，我们简单地调用经典的HOOI算法[27]来近似求解子问题(2.27)，以生成$\left(\mathcal{G}^{k_1},\{\mathbf{U}_i^{k+1}\}_{i=1}^3\right)$的近似形式.

此外，为了更好地实现性能，我们还可以根据等式约束下不可行性的变化自适应地更新惩罚参数. 例如,

$$\begin{cases}\sigma_1^{k+1}=c_1\sigma_1^k, & \text{若}\|\mathbf{z}^{k+1}-D(\mathcal{X}_2^{k+1})\|>c_1'\|\mathbf{z}^k-D(\mathcal{X}_2^k)\|;\\ \sigma_2^{k+1}=c_2\sigma_1^k, & \text{若}\|\mathbf{y}-A(\mathcal{X}_0^{k+1})\|>c_2'\|\mathbf{y}-A(\mathcal{X}_0^k)\|,\end{cases} \tag{2.28}$$

c_1和c_2略大于1，c_1'和c_2'略小于1，如$c_1=c_2=1.15$，$c_1'=c_2'=0.95$.

算法框架在算法1中给出.

2.4　数值试验

在本节中将比较本文提出的方法与其他四种方法(包括基于矩阵的SpaRCS方法[43]和其它三种松弛张量方法)来评估性能. 此处，标号为A5的SpaRCS方法是典型的基于矩阵的方法，所涉及的ℓ_0-范数有三种常用的松弛方法标号为A1-A3，模型如下:

A1: ℓ_1-范数松弛方法用$\|\mathbf{z}\|_1:=\sum_{i=1}^{I_4}|z_i|$ 代替$\|\mathbf{z}\|_0$;

A2: ℓ_2-范数松弛方法用$\|\mathbf{z}\|$代替$\|\mathbf{z}\|_0$;

A3: $\ell_{1/2}$-范数松弛方法用$\|\mathbf{z}\|_{1/2}^{1/2}:=\sum_{i=1}^{I_4}|z_i|^{1/2}$ 代替$\|\mathbf{z}\|_0$.

A1在文献[12]中提出，在表2.1中比较优化模型A1-A3, A5以及本文提出的方法(标为A4).

中国知网　https://www.cnki.net

算法 1: HT-ADMM 求解问题(2.20)

输入: 测量向量$\mathbf{y}$, 尺寸参数r_1, r_2 和r_3, 模型参数λ, 算法参数σ_1^0, σ_2^0, $\tau > 0$, c_1, c_2, c_1', c_2'.

输出: $\mathcal{X}_0^k$,$\mathcal{X}_2^k$,和$\left(\mathcal{G}^k, \{\mathbf{U}_i^k\}_{i=1}^3\right)$.

步 0: (初始化) 计算截断$A^*(\mathbf{y})$的(r_1, r_2, r_3)-Tucker分解，通过HOOI算法得到$(\mathcal{G}', \{\mathbf{U}_i^0\}_{i=1}^3)$，设 $\mathcal{X}_2^0 = A^*(\mathbf{y}) - \mathcal{G}^0 \prod_{i=1}^3 \times_i \mathbf{U}_i^0$，其他变量初始化为0；设$k = 0$.

步 1: 通过(2.23) 和(1.15)计算$\mathbf{z}^{k+1}$.

步 2: 通过(2.24)计算$\mathcal{X}_0^{k+1}$.

步 3: 通过(2.25)计算$\mathcal{X}_2^{k+1}$.

步 4: 通过HOOI (2.27)计算$\left(\mathcal{G}^{k+1}, \{\mathbf{U}_i^{k+1}\}_{i=1}^3\right)$.

步 5: 通过(2.22)的最后一行更新乘子$\mathbf{w}_{\mathbf{z}}^{k+1}$, $\mathbf{w}_{\mathcal{X}_0}^{k+1}$.

步 6: 通过(2.28)更新参数；设$k = k + 1$，若满足某种停机准则，则算法停止，否则，返回步1.

表 2.1: 五种不同的比较方法

方法	优化模型
A1	$\min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}, \mathcal{E}\in\mathbb{R}^{I_1\times I_2\times I_3}, \mathbf{U}_i\in \mathrm{St}(r_i, I_i)} \left\{\lambda\|\mathbf{z}\|_1 + \frac{1}{2}\|\mathcal{E}\|_F^2 : \mathbf{z} = D(\mathcal{X}_2), A(\mathcal{X}_0) = \mathbf{y}, \mathcal{X}_0 - \mathcal{X}_2 - \mathcal{E} = \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\right\}$
A2	$\min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}, \mathcal{E}\in\mathbb{R}^{I_1\times I_2\times I_3}, \mathbf{U}_i\in \mathrm{St}(r_i, I_i)} \left\{\lambda\|\mathbf{z}\|_2 + \frac{1}{2}\|\mathcal{E}\|_F^2 : \mathbf{z} = D(\mathcal{X}_2), A(\mathcal{X}_0) = \mathbf{y}, \mathcal{X}_0 - \mathcal{X}_2 - \mathcal{E} = \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\right\}$
A3	$\min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}, \mathcal{E}\in\mathbb{R}^{I_1\times I_2\times I_3}, \mathbf{U}_i\in \mathrm{St}(r_i, I_i)} \left\{\lambda\|\mathbf{z}\|_{1/2}^{1/2} + \frac{1}{2}\|\mathcal{E}\|_F^2 : \mathbf{z} = D(\mathcal{X}_2), A(\mathcal{X}_0) = \mathbf{y}, \mathcal{X}_0 - \mathcal{X}_2 - \mathcal{E} = \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\right\}$
A4	$\min_{\mathcal{H}\in\mathbb{R}_{\mathcal{H}}, \mathbf{U}_i\in \mathrm{St}(r_i, I_i)} \left\{\lambda\|\mathbf{z}\|_0 + \frac{1}{2}\|\mathcal{X}_0 - \mathcal{X}_2 - \mathcal{G}\prod_{i=1}^3 \times_i \mathbf{U}_i\|_F^2 : \mathbf{z} = D(\mathcal{X}_2), A(\mathcal{X}_0) = \mathbf{y}\right\}$
A5	$\min\{\|y - A(L + S)\|_2 : \mathrm{rank}(L) \le r, \ \|vec(S)\|_0 \le K\}$

本文将在真实视频数据集上进行实验，包括CD.net数据集[32]，I2R 数据集[28]和CAVIAR数据集[1][1]. 所有计算结果均在一台64 位Windows操作系统、Intel(R) Core(TM) i5-5250U CPU@ 1.60GHZ RAM 4.0G、Matlab R2016b 的笔记本电脑上得到.

2.4.1　实验设置

记$\mathcal{X}_0$，$\mathcal{X}_1$和$\mathcal{X}_2$分别为视频张量、背景张量和前景张量的真实值，而$\hat{\mathcal{X}}_0$, $\hat{\mathcal{X}}_1$和$\hat{\mathcal{X}}_2$是通过给定方法生成的相应张量. 为了评估某一方法的性能，我们采

[1]与文献[12]相同，对于每个视频，选择128灰度视频帧作为实验的视频量.

中国知网　https://www.cnki.net

用F-measure来评估视频前景$\mathcal{X}_2$的检测性能，峰值信噪比(PSNR)和结构相似度指数(SSIM)来衡量$\mathcal{X}_0$的重构精度. F-measure的定义如下

$$\text{F-measure} := 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}, \tag{2.29}$$

其中

$$\text{precision} := \frac{\text{TP}}{\text{TP} + \text{FP}}, \ \text{recall} := \frac{\text{TP}}{\text{TP} + \text{FN}},$$

TP(真阳性)是在$\hat{\mathcal{X}}_2$正确分类为前景像素的总数，FP(假阳性)是$\hat{\mathcal{X}}_2$被错误地归类为背景的像素总数，FN(假阴性)是$\hat{\mathcal{X}}_2$被错误地归类为前景的像素总数. 适用于3D视频的PSNR 定义如下

$$\text{PSNR} := \frac{10}{I_3} \sum_{k=1}^{I_3} \log_{10} \frac{255^2}{\sum\limits_{i,j} \left((\mathcal{X}_0)_{ijk} - (\hat{\mathcal{X}}_0)_{ijk} \right)^2} \tag{2.30}$$

类似地，用SSIM[42]刻画视频帧的结构相似度：

$$\text{SSIM} := \frac{1}{I_3} \sum_{k=1}^{I_3} \frac{\left(2u_k(\mathcal{X}_0)u_k(\hat{\mathcal{X}}_0) + c_1\right)\left(2\sigma_k(\mathcal{X}_0, \hat{\mathcal{X}}_0) + c_2\right)}{\left(u_k^2(\mathcal{X}_0) + u_k^2(\hat{\mathcal{X}}_0) + c_1\right)\left(\sigma_k^2(\mathcal{X}_0) + \sigma_k^2(\hat{\mathcal{X}}_0) + c_2\right)}, \tag{2.31}$$

其中$u_k(\mathcal{X}) := \frac{1}{I_1 I_2} \sum\limits_{i,j} \mathbf{x}_{ijk}$ 和$\sigma_k(\mathcal{X}) := \sqrt{\frac{1}{I_1 I_2 - 1} \sum\limits_{i,j} \left(\mathbf{x}_{ijk} - u_k(\mathcal{X}) \right)^2}$ 是$\mathbf{X}_{::k}$的平均值和标准差，而

$$\sigma_k(\mathcal{X}, \mathcal{Y}) := \frac{1}{I_1 I_2 - 1} \sum_{i,j} \left(\mathbf{x}_{ijk} - u_k(\mathcal{X}) \right)\left(\mathbf{y}_{ijk} - u_k(\mathcal{Y}) \right)$$

是$\mathbf{X}_{::k}$和$\mathbf{Y}_{::k}$的协方差, c_1, c_2是给定的参数，如$c_1 = (0.01 * 255)^2$，$c_2 = (0.03 * 255)^2$. 显然，这些评价指标的值越大，表明该方法对BSCM的性能越好.

张量优化问题A1[12]、A2和A3使用分块ADMM算法求解，但A1, A2 和A3中$\mathbf{z}$-子问题的求解方法不同. A1, A2 和A3子问题分别通过投影算子$\text{Prox}_{\|\cdot\|_1}$ (软阈值算子)，$\text{Prox}_{\|\cdot\|_2}$和$\text{Prox}_{\|\cdot\|_{1/2}^{1/2}}$ (硬阈值算子)求解，其有显示解，A5由文献[43]中提出的贪婪算法实现.

通过网格搜索对本文提出的方法和其它方法进行参数调整，使平均PSNR指标达到满意的性能. 如果符合以下两项条件之一，算法将被终止:

(1) 相对误差$\zeta := \frac{\|A(\mathcal{X}_0^k) - \mathbf{y}\|}{\max\{1, \|\mathbf{y}\|\}} < 1\text{e}{-6}$； (2) 迭代次数达到1000.

2.4.2　性能评价

我们将在选取的几个真实视频上进行数值实验，并对数值结果进行分析，

中国知网　https://www.cnki.net

以证明我们的方法相对于其它方法的效率和优越性.

2.4.2.1　在“ShoppingMall”视频的数值实验

为了测试前景检测和背景消除的性能，通常选择真实拍摄的视频“ShoppingMall”进行试验，其中有多个行人标记为前景(如[12]). 表格2.2 列出了“ShoppingMall” 视频在设置不同采样比(SR) 下五种方法的实验比较，其中最好的结果用粗体标记.

表 2.2: 在“ShoppingMall” 视频上不同方法的比较

采样率	方法	PSNR	SSIM	F-measure
1/30	A1	28.3846	0.7573	0.5828
	A2	26.5074	0.7098	0.4507
	A3	24.0747	0.6151	0.0626
	A4	**29.1522**	**0.7912**	**0.6032**
	A5	23.8682	0.5948	0.1451
1/25	A1	29.8280	0.8245	0.6050
	A2	27.0848	0.7510	0.5091
	A3	24.4355	0.6624	0.0875
	A4	**30.4297**	**0.8450**	**0.6102**
	A5	24.9909	0.6429	0.1620
1/20	A1	31.2438	0.8742	0.6239
	A2	27.7155	0.7887	0.5448
	A3	24.7134	0.6966	0.0972
	A4	**31.9404**	**0.8979**	**0.6312**
	A5	27.2580	0.7151	0.1763
1/10	A1	36.2236	0.9456	0.6692
	A2	26.6945	0.8041	0.6032
	A3	25.3349	0.7437	0.1202
	A4	**38.4756**	**0.9619**	**0.6737**
	A5	26.8707	0.8023	0.2058
1/5	A1	**40.9762**	**0.9768**	**06794**
	A2	31.4624	0.8821	0.6135
	A3	27.7065	0.8267	0.1256
	A4	40.6144	0.9747	0.6771
	A5	33.4809	0.8496	0.2265

从表2.2中可以看出，我们的方法A4在低采样率1/30，1/25，1/20，和1/10时，在PSNR，SSIM和F-measure上比其他的方法更优越. 在采样率相对较高的情况，如SR= 1/5时，A4与A1 具有竞争性. 由于A4中使用的ℓ_0-范数项$\|\mathbf{z}\|_0$比其松弛项更好地表征了前景中由于时空连续性而产生的内在稀疏性，因此A4 具有这样的优越性是合理的. 表2.3收集了A1、A4和真实值在不同采样率下生成的$\mathbf{z}$所对应的稀疏性，其中“nnz”列刻画$\mathbf{z}$中的非零元个数，使得nnz := $\min\left\{t : \sum_{i=1}^{t} |\mathbf{z}|_{(i)} \geq 0.9999\|\mathbf{z}\|_1\right\}$其中$|\mathbf{z}|_{(i)}$是$\mathbf{z}$中绝对值第$i$大值，“比例”表示nnz占视频

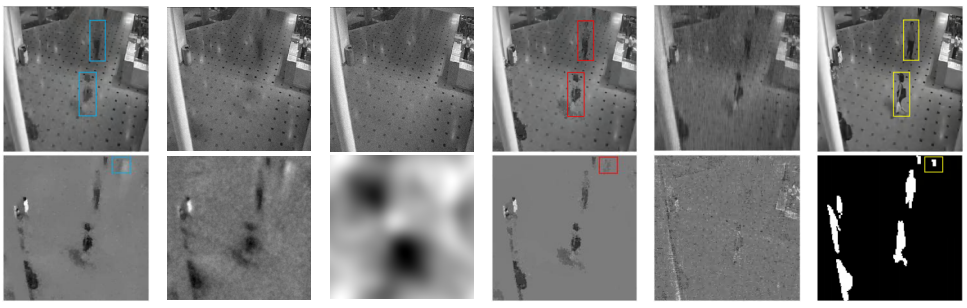
中国知网　https://www.cnki.net

像素总数的百分比. 如表2.3所示，真实值“nnz”的百分比为2.16%，表示真实值中的稀疏性特征. 可以观察到在表2.3中，A4比A1有更好的稀疏性，而在表2.2中对于采样率SR= 1/5，A4的性能接近A1的部分原因是A4的稀疏性并不那么明显(比例超过15%).

表 2.3: 由A1和A4生成的**z**的稀疏性

方法	评价指标	1/30	1/25	1/20	1/10	1/5
真实值	nnz	542976	542976	542976	542976	542976
	比例	2.16%	2.16%	2.16%	2.16%	2.16%
*A*1	nnz	11171495	11747914	12704395	13043982	15674382
	比例	44.39%	46.68%	50.48%	51.83%	62.28%
*A*4	nnz	1819252	1908935	2057997	2965730	4187801
	比例	7.23%	7.59%	8.18%	11.78%	16.64%

为了更直观地了解这几种方法在性能上的差异，我们在视频中随机选取一些SR= 1/25的典型帧，并通过图2.2中的可视化结果来说明A4的优越性. 第一行图像显示重建效果，第二行图像显示检测出的前景，比较真实值可以看出，A3的重构视频模糊，被检测到的行人并不完整，无法重建出原始视频. A1优于A2 和A3，但生成的重建视频和分离的前景视频不如A4清晰，可以通过图2.2中标记的区域直观地观察到. 与A4相比，A5重建视频中的地板模糊，被检测人受到噪声点的干扰. 表2.2中的数值结果与图2.2中的可视化结果是一致的，因此我们的方法在视觉效果上和数值效果上都更好.



(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.2: “ShoppingMall”视频某一帧重建和检测的视觉结果(SR= 1/25)

众所周知，非凸ADMM方法的理论收敛性并不总是得到保证，除非在目标函数和模型的可行域上添加一些较强的条件[41]. 遗憾的是，这些现有的条件不能满足我们提出的模型(2.20). 为了部分地证明数值收敛行为，我们记录以下两项:

中国知网 https://www.cnki.net

- 每个$\mathcal{X}_0^k$相对于真实值$\mathcal{X}_0$的相对误差的变化：

$$\text{relErrorX0}_k := \frac{\|\mathcal{X}_0^k - \mathcal{X}_0\|_F}{\max\{1, \|\mathcal{X}_0\|_F\}},$$

  对于第k次迭代, $k \geq 0$.

- 最优性分析中相对KKT残差的变化：

$$\xi_k := \frac{\|\tilde{F}(\mathcal{H}^k, \mathbf{w}_{\mathbf{z}}^k, \mathbf{w}_{\mathcal{X}_0}^k)\|_F}{\max\{1, \|\mathcal{X}_0\|_F\}},$$

  其中$\tilde{F}(\mathcal{H}, \mathbf{w}_{\mathbf{z}}, \mathbf{w}_{\mathcal{X}_0})$由移除(2.19)中定义的$F(\mathcal{H}, \mathcal{W})$中的后五行得到. 因为在我们的算法中，HOOI被调用来处理$\{\mathcal{G}, \{\mathbf{U}_i\}_{i=1}^3\}$.

对于五种不同采样率，以上两项的变化结果分别显示在图2.3和图2.4中. 如图2.3所示，对于所有5个实例，A4在小于400次时终止，并且对应的相对误差逐渐减小到每个实例的稳定值. 这个稳定值随着采样率的增大而减小，这也是合理的，因为采样率越高，我们可以捕捉到的信息就越多，从而得到更好的重构图像. 如图2.4 所示，迭代过程中相对KKT残差逐渐趋于0(数值结果为2.9e-3 水平).

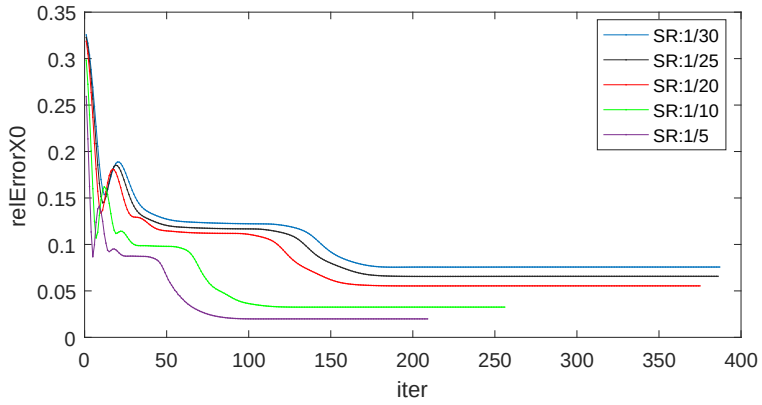


图 2.3: “ShoppingMall”在A4中使用不同采样率迭代时相对误差的变化

2.4.2.2　在更多真实视频的数值实验

选择CD.net数据集、I2R数据集和CAVIAR数据集中的真实视频进行测试. 这些视频可以分为三类: (1) 8 个有静止背景的视频包括“Pedestrains”, “PET-2006”,

中国知网　https://www.cnki.net

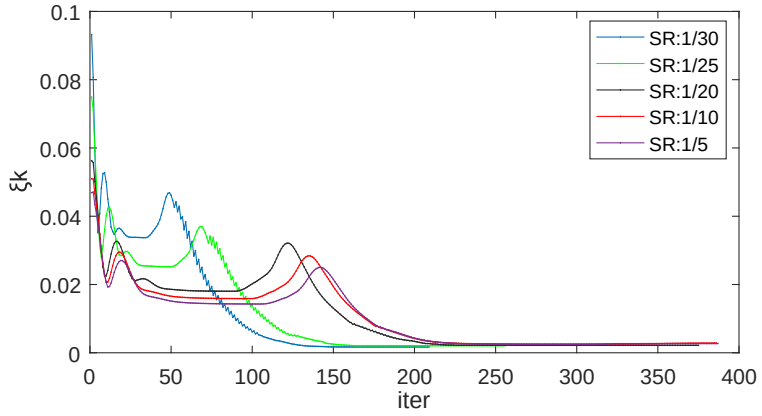


图 2.4: “ShoppingMall”在A4中使用不同采样率迭代时ξ 的变化

“Office”, “WalkbyShop1front”, “ShopAssistant1front”, “Lobby”, “Bootstrap”及“Hall” (标为v1-v8); (2) 4个有阴影的视频包括“CopyMachine”, “Bungalows”, “Cubicle”及“PeopleInShade” (标为v9-v12); (3) 2 个有动态背景的视频包括“Fountain02”及“Watersurface” (标记为v13-v14). 这些结果表示在表2.4 中. 本文在表2.4中仅仅列出了SR= 1/25的情况，因为在其他低采样率情况下本文提出的方法也得到了类似的结果.

从表2.4中的“A4” 列可以看到，本文提出的方法在所有三个度量中都优于其他四种方法，特别是对于视频v3、v4、v8、v10、v12和v14. 这六个场景的可视化结果见图2.5-2.10，在图中可以观察到我们提出的方法A4有明显改进，特别是用方框标记的区域. 例如，在图2.7中，其为静态背景视频中有带有阴影的多运动对象，我们观察到，与A4相比，A1和A2的重建视频和检测前景都比较模糊.

在五种方法中，可以看出A3完全没有提取出前景. 与A1-A3相比，A5获得了更好的重建结果，但检测结果中仍然保留了一部分背景，前景目标模糊. 通过对比，本文提出的方法A4的整体视觉效果最好，因此本文的方法的整体重建和分离结果优于其他方法. 动态背景视频具有非静态特性，例如图2.10中存在水面区域. A3主要受动态背景的影响，重构视频中出现重影图像，并且前景站立的人完全消失.

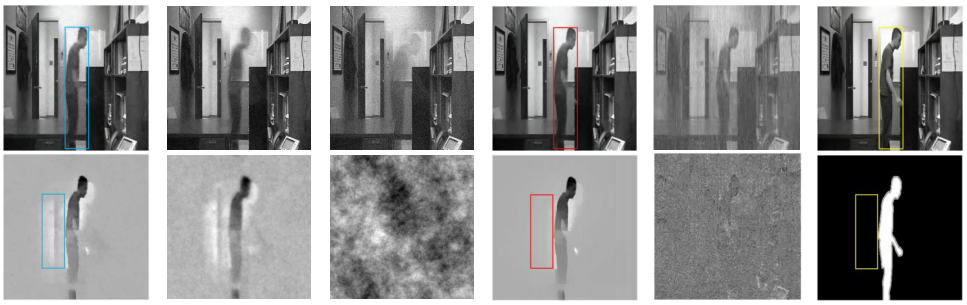
A1、A2提取的前景部分相对于A3来说较为完整，但是A1、A2的背景去除效果弱于A4. 可以看出，A5在提取前景方面与A4相比效果更差，在图2.10中，A4可以抑制水面波动的影响，A4背景被清除的比较干净，前景目标清晰. 从数值结果可以看出，我们提出的方法在PSNR、SSIM 和F-measure上都优于其他方法.

中国知网 https://www.cnki.net

表 2.4: 比较更多真实视频的结果. “-”表示由于缺少标签而产生的空值.

标号	视频名称	评价指标	A1	A2	A3	A4	A5
v1	Pedestrians	PSNR	35.7238	28.6967	24.8632	**37.0800**	27.7507
		SSIM	0.9430	0.8368	0.7237	**0.9623**	0.6958
		F-measure	0.7640	0.7043	0.0660	**0.7658**	0.2523
v2	PET-2006	PSNR	41.4694	36.6641	34.2893	**42.7995**	38.6763
		SSIM	0.9741	0.9583	0.9390	**0.9848**	0.9585
		F-measure	0.7081	0.5809	0.0549	**0.7640**	0.1116
v3	Office	PSNR	30.1761	26.7237	20.0219	**32.8389**	23.1593
		SSIM	0.8296	0.7769	0.5410	**0.9105**	0.5780
		F-measure	0.5868	0.5658	0.1561	**0.6674**	0.1315
v4	WalkbyShop1front	PSNR	33.8996	32.8808	29.6642	**39.5099**	27.4759
		SSIM	0.9387	0.9257	0.8771	**0.9718**	0.7653
		F-measure	-	-	-	-	-
v5	ShopAssistant1front	PSNR	34.4330	33.0646	29.6014	**39.9558**	28.3934
		SSIM	0.9577	0.9465	0.9096	**0.9815**	0.8503
		F-measure	-	-	-	-	-
v6	Lobby	PSNR	38.7894	32.7315	29.7329	**40.3737**	30.5825
		SSIM	0.9568	0.8986	0.8350	**0.9745**	0.8523
		F-measure	0.6015	0.4131	0.0671	**0.6473**	0.1370
v7	Bootstrap	PSNR	25.6619	22.5628	18.5955	**25.6705**	27.5701
		SSIM	0.6871	0.5433	0.3560	**0.7008**	0.6698
		F-measure	0.5554	0.4957	0.1070	**0.5891**	0.1393
v8	Hall	PSNR	28.6103	28.6846	25.5396	**34.2927**	27.7305
		SSIM	0.8357	0.8349	0.7486	**0.9357**	0.7165
		F-measure	0.7418	0.7268	0.0635	**0.7465**	0.1421
v9	CopyMachine	PSNR	30.7860	26.8660	19.5812	**31.4714**	25.5642
		SSIM	0.8486	0.7419	0.4871	**0.8656**	0.6083
		F-measure	0.6859	0.5482	0.2018	**0.7038**	0.1935
v10	Bungalows	PSNR	31.3207	25.9580	20.8963	**32.8547**	25.8854
		SSIM	0.8325	0.6413	0.4410	**0.8716**	0.6219
		F-measure	0.5225	0.5304	0.0372	**0.5324**	0.3334
v11	Cubicle	PSNR	32.7630	26.2798	19.7082	**33.0721**	23.5093
		SSIM	0.8605	0.6897	0.4483	**0.8844**	0.5987
		F-measure	0.6490	0.5150	0.0622	**0.6773**	0.1280
v12	PeopleInShade	PSNR	28.9840	23.1803	18.5494	**30.9391**	27.8298
		SSIM	0.7900	0.5765	0.3961	**0.8504**	0.6980
		F-measure	0.7117	0.4899	0.0615	**0.7142**	0.1739
v13	Fountain02	PSNR	31.3160	29.6624	26.8331	**31.8179**	26.9269
		SSIM	0.8853	0.8670	0.7920	**0.8925**	0.8404
		F-measure	0.6460	0.2925	0.0490	**0.6535**	0.0597
v14	Watersurface	PSNR	30.4506	28.6865	20.9707	**32.1767**	30.4230
		SSIM	0.7536	0.7156	0.4232	**0.8065**	0.7299
		F-measure	0.6372	0.5834	0.1103	**0.6838**	0.1260

中国知网 https://www.cnki.net



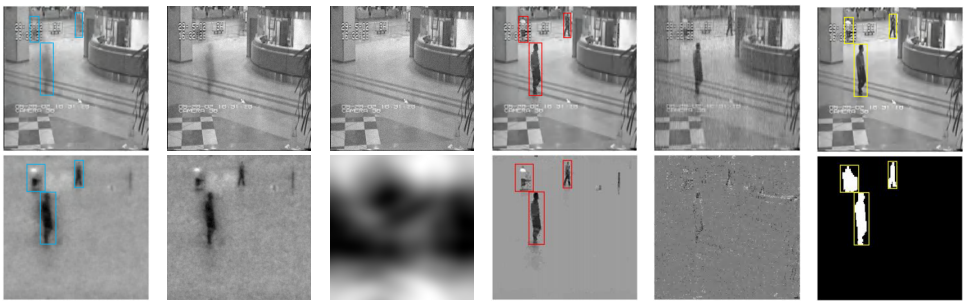
(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.5: 在v3视频某一帧上重建和检测的视觉结果(SR= 1/25)



(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

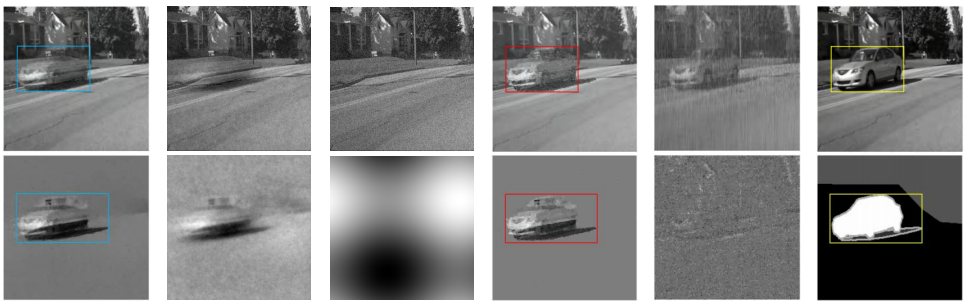
图 2.6: 在v4视频某一帧上重建和检测的视觉结果(SR= 1/25)



(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.7: 在v8视频某一帧上重建和检测的视觉结果(SR= 1/25)

中国知网 https://www.cnki.net



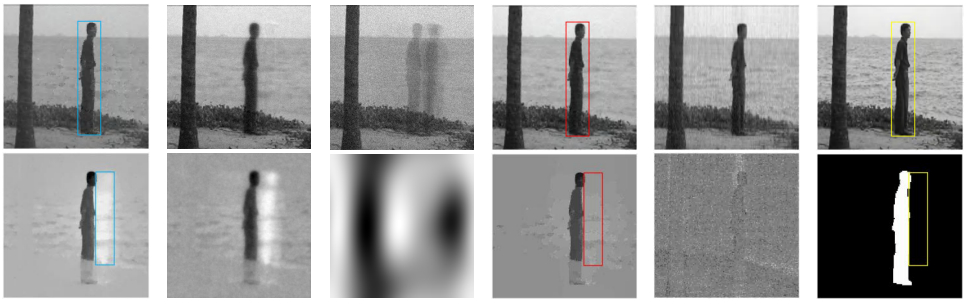
(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.8: 在v10视频某一帧上重建和检测的视觉结果(SR= 1/25)



(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.9: 在v12视频某一帧上重建和检测的视觉结果(SR= 1/25)



(a) A1 (b) A2 (c) A3 (d) A4 (e) A5 (f) 真实值

图 2.10: 在v14视频某一帧上重建和检测的视觉结果(SR= 1/25)

中国知网 https://www.cnki.net

可以从表2.5中得出，其符号与表2.3中的符号相同，我们模型中采用的ℓ_0-范数的优势，使得这些视频(不包括v4)中带有标签的视频具有优越的性能. 在这些场景中，我们很容易发现真实值中的稀疏性特征，我们的方法比A1更好地获取了该特征.

表 2.5: A1和A4对$\mathbf{z}$稀疏性的比较(SR= 1/25)

方法	评价指标	v3	v8	v10	v12	v14
真实值	nnz	7518	5898	7879	11005	5926
	比例	3.82%	2.99%	4.01%	5.60 %	3.01 %
*A*1	nnz	40587	49454	19844	32437	32628
	比例	20.64%	25.15%	10.09%	16.50%	16.60%
*A*4	nnz	12528	13676	11819	21320	21828
	比例	6.37%	6.96%	6.01%	10.84%	11.10%

2.5 本章小结

本章针对视频监控的背景消除问题，通过结合时空连续性和ℓ_0范数直接对视频前景建模，并且通过控制核心张量的维数提高背景消除的精度对视频背景建模，建立了稀疏张量优化模型(2.7). 利用变分分析，以及ℓ_0-范数的性质，建立了最优性条件(KKT)条件来研究解的性质. 这不仅丰富了非连续非凸优化理论，而且也为算法设计提供了理论支持，因此具有重要的理论意义. 利用硬阈值算子的优点，我们设计了一种基于分块硬阈值的交替方向乘子法(HT-ADMM)来解决所提出的张量优化问题. 在CD.net 数据集、I2R数据集和CAVIAR 数据集上的实验结果表明了本文方法的有效性和优越性.

中国知网 https://www.cnki.net

第 3 章 网络流量异常检测的张量优化方法

网络流量管理是互联网管理的重要内容，梳理及分析网络流量异常检测对了解流量异常检测技术、及时发现网络异常、保证网络正常运行具有重要意义. 针对不完全测量和链路测量的网络流量数据，本文建立了稀疏低秩张量优化模型，并对其进行最优性条件分析，设计近端梯度算法(proximal gradient descent，PGD)进行求解.

3.1 模型建立

3.1.1 流量张量模型

构建高阶张量来收集网络流量数据，能够灵活地揭示时间稳定性、空间相关性和周期性的内在特征(详见[104]). 更具体地说，在一个具有m个点(points of presence，PoPs)的典型网络中，存在m^2个PoP-对，因此存在m^2个OD 对. 随着时间的推移，对OD对流量进行连续测量，例如有d个时间结点，将产生一个大小为$m^2 \times d$的矩阵，称为流量矩阵(traffic matrix, TM)，其在文献[73,95]中得到了广泛研究. 实际上，本文不需要将所有的OD对流量收集成一个沿着时间序列的矩阵，而仅需要收集每天的数据转换为流量矩阵，这样的维度结构允许利用数据潜在的时间稳定性和周期性. 本文将OD对划分为两个不同的维度，每个维度的大小为m，进一步揭示了空间相关性. 由于预期的空间相关性不如时间属性可靠，我们将遵循文献[104,106]中的张量建模过程，构建三阶流量张量模型进行异常检测，其中流量张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$，$I_1$为天数，$I_2$为每天的时间间隔数，$I_3$为OD对数. 图3.1为广泛使用的公共流量追踪数据集Abilene[49]的张量模型.

由于网络可能受到意外攻击，真实的流量张量数据，如$\tilde{\mathcal{X}}$，可以分解为预期的正常数据$\mathcal{X}$和异常数据$\mathcal{E}$，

$$\tilde{\mathcal{X}} = \mathcal{X} + \mathcal{E}. \tag{3.1}$$

Tucker 低秩性: 低秩性作为底层数据的全局结构属性，是网络流量跟踪数据压缩或降维的常用特性，例如，在文献[95]中，Roughan等人讨论了流量矩阵的低秩近似，谢等人在文献[104]中研究了流量张量的Tucker低秩约束. 具体来说，在Tucker 低秩的意义上，前面提到的以天(或周)、时间间隔和OD对为坐标轴建

中国知网 https://www.cnki.net

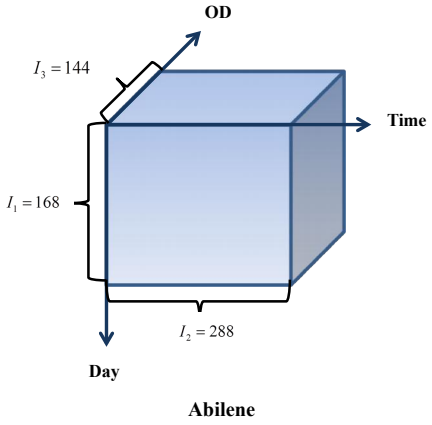


图 3.1: Abilene张量模型

模的三阶正常流量张量$\mathcal{X}$(见图3.1) 将受到如下约束

$$\text{rank}(\mathcal{X}) \leq (r_1, r_2, r_3), \text{ 等价于 } \text{rank}(\mathbf{X}_{(n)}) \leq r_n, \ n = 1, 2, 3, \tag{3.2}$$

其中r_n为$\mathcal{X}$的展开矩阵$\mathbf{X}_{(n)}$的秩的设定上界. 由于$\mathbf{X}_{(1)}$由每日(或每周)数据作为列组成，约束$\text{rank}(\mathbf{X}_{(1)}) \leq r_1$代表了天(或周)之间的内在相关性，从而反映了流量数据中一些潜在的周期性特征. 同样地，$\text{rank}(\mathbf{X}_{(2)}) \leq r_2$和$\text{rank}(\mathbf{X}_{(3)}) \leq r_3$代表时间间隔之间和OD对之间的相关性，这在一定程度上反映了时间稳定性和空间相关性，从而显示出Tucker低秩约束(3.2)的优势.

时间稳定性和周期性: 为了进一步表征时间稳定性和周期性，基于两个连续时间段和天数之间可能有相似的OD对流量的先验知识，在文献[95]中考虑了捕捉流量矩阵中时间稳定性和相似性的正则项. 具体来说，采用大小适当的简单Toeplitz矩阵来表征每两个连续数据在天和时间段内的差异，即对于流量张量$\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$相邻的差异可以用$\sum_{n=1}^{2} \|\mathcal{X} \times_n F_n\|_F^2$ 表示，其中$F_n = \text{Toeplitz}(0, 1-1) \in \mathbb{R}^{(I_n - 1) \times I_n}$ $(n = 1, 2)$，Toeplitz矩阵的中心对角线全为1，上对角线全为-1。

稀疏性: 突发访问，拒绝服务攻击，端口扫描或蠕虫传播，都导致了异常张量数据$\mathcal{E}$ 的稀疏性. $\mathcal{E}$中所有非零项的个数，用$\|\mathcal{E}\|_0$表示，我们希望它是比较小的. 通常将稀疏性约束强加到异常检测模型上，(对ε设置上限，即$\|\mathcal{E}\|_0 \leq \varepsilon$)，(详见[104])或加稀疏正则化到目标函数上(即$\lambda\|\mathcal{E}\|_0$，包含调优参数$\lambda > 0$). 对于稀疏性上界未知的情况，本文采用后一种方法.

中国知网 https://www.cnki.net

3.1.2　稀疏低秩张量优化

根据3.1.1小节的分析，本文建立如下网络流量异常检测的优化模型:

$$\begin{aligned}&\min_{\mathcal{X},\mathcal{E}} \frac{1}{2}\|A(\mathcal{X}+\mathcal{E})-\mathcal{B}\|_F^2+\lambda\|\mathcal{E}\|_0+\tilde{\lambda}\left(\sum_{n=1}^{2}\|\mathcal{X}\times_n F_n\|_F^2\right)\\&\text{s.t. rank}\,(\mathcal{X})\le(r_1,r_2,r_3)\end{aligned}\tag{3.3}$$

其中$\mathcal{B}\in\mathbb{R}^{I_1\times I_2\times I_3}$为网络流量的观测张量，$\lambda>0$为异常流量张量稀疏性的参数，$F_n=\text{Toeplitz}(0,1-1)\in\mathbb{R}^{(I_n-1)\times I_n}$ $(n=1,2)$是表征流量数据中时间属性的Toeplitz矩阵，A是一个给定的线性算子，有以下两种情况:

(1) 不完全测量: $A(\mathcal{X})=\Pi_{\text{Ind}}(\mathcal{X})$，其中$\text{Ind}\subseteq[I_1]\times[I_2]\times[I_3]$是指标的子集,

$$(\Pi_{\text{Ind}}(\mathcal{X}))_{i_1i_2i_3}=\begin{cases}x_{i_1i_2i_3}, & \text{若}(i_1,i_2,i_3)\in\text{Ind};\\ 0, & \text{否则}.\end{cases}\tag{3.4}$$

也就是说，存在一个张量$\mathcal{A}\in\{0,1\}^{I_1\times I_2\times I_3}$ 其中$\mathcal{A}_{i_1i_2i_3}=1$ 若$(i_1,i_2,i_3)\in\text{Ind}$，否则为0，使得$A(\mathcal{X})=\mathcal{A}*\mathcal{X}$. 显然算子$A$是自伴随算子(即$A^*=A$)，且$A^*A=A$.

(2) 链路测量: 对于某些给定的路由矩阵$\mathbf{A}_L\in\{0,1\}^{I\times I_3}$，$A(\mathcal{X})=\mathcal{X}\times_3\mathbf{A}_L$. 对任意的$\mathcal{Y}\in\mathbb{R}^{I_1\times I_2\times l}$，伴随算子$A^*$为$A^*(\mathcal{Y})=\mathcal{Y}\times_3\mathbf{A}_L^\top$.

记

$$f(\mathcal{X},\mathcal{E}):=\frac{1}{2}\|A(\mathcal{X}+\mathcal{E})-\mathcal{B}\|_F^2+\tilde{\lambda}\left(\sum_{n=1}^{2}\|\mathcal{X}\times_n F_n\|_F^2\right).\tag{3.5}$$

直接计算可以得到梯度的表达式$\nabla f=(\nabla_{\mathcal{X}}f,\nabla_{\mathcal{E}}f)$为

$$(\nabla_{\mathcal{X}}f(\mathcal{X},\mathcal{E}),\nabla_{\mathcal{E}}f(\mathcal{X},\mathcal{E}))=\left(\mathcal{T}+2\tilde{\lambda}\left(\sum_{n=1}^{2}\mathcal{X}\times_n(F_n^\top F_n)\right),\mathcal{T}\right)\tag{3.6}$$

其中$\mathcal{T}:=A^*(A(\mathcal{X}+\mathcal{E})-\mathcal{B})$.

命题 3.1　函数f定义在(3.5)中，其Lipschitz梯度是常数$L_f\le\sqrt{2\|A^*A\|+128\tilde{\lambda}^2}$，其中$\|A^*A\|$是线性算子$A^*A$的谱范数. 也就是说, 对任意$\mathcal{X},\mathcal{X}',\mathcal{E},\mathcal{E}'\in\mathbb{R}^{I_1\times I_2\times I_3}$, 有

$$\|\nabla f(\mathcal{X},\mathcal{E})-\nabla f(\mathcal{X}',\mathcal{E}')\|_F\le\sqrt{2\|A^*A\|+128\tilde{\lambda}^2}\,\|(\mathcal{X}-\mathcal{X}',\mathcal{E}-\mathcal{E}')\|_F\,.\tag{3.7}$$

证明.由(命题4.1[81])可知，对于$n=1,2$，有$\|F_n^\top F_n\|=\bar{\sigma}(F_n)\le4$，其中$\bar{\sigma}$是矩阵$F_n^TF_n$的最大特征值. 由函数$f$的梯度表达式(3.6)，直接计算可得(3.7). □

中国知网　https://www.cnki.net

特别地，对于前面提到的两种算子A，可得

(1) 对于某些张量$\mathcal{A} \in \{0,1\}^{I_1 \times I_2 \times I_3}$，若满足$A(\mathcal{X}) = \mathcal{A} * \mathcal{X}$，则

$$\|A^* A\| = \|A\| \leq 1, \text{ 可得 } L_f \leq \sqrt{2 + 128\tilde{\lambda}^2}; \tag{3.8}$$

(2) 对于某些矩阵$\mathbf{A}_L \in \{0,1\}^{I \times I_3}$，若满足$A(\mathcal{X}) = \mathcal{X} \times_3 \mathbf{A}_L$，则

$$\|A^* A\| = \lambda_{\max}(\mathbf{A}_L^\top \mathbf{A}_L) = \bar{\sigma}^2(\mathbf{A}_L), \text{ 可得 } L_f \leq \sqrt{2\bar{\sigma}^2(\mathbf{A}_L) + 128\tilde{\lambda}^2}. \tag{3.9}$$

值得一提的是，Lipschitz常数在算法设计中起着重要作用，因为它限制了数值迭代的步长，从算法收敛性的后续分析中可以看出.

3.2　最优性条件

受稀疏优化[54]和低秩矩阵优化[80] 中的稳定点概念的启发，对于提出的稀疏低秩张量优化问题(3.3)，接下来引入驻点的概念.

定义 3.1　考虑张量$\bar{\mathcal{X}}, \bar{\mathcal{E}} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$.

(1) 给定一个标量$\beta > 0$，$\left(\bar{\mathcal{X}}, \bar{\mathcal{E}}\right)$称为问题(3.3)的$\beta$-稳定点，若满足

$$\left(\bar{\mathcal{X}}, \bar{\mathcal{E}}\right) \in \Pi_S(\bar{\mathcal{X}} - \beta \nabla_{\mathcal{X}} f(\bar{\mathcal{X}}, \bar{\mathcal{E}})) \times \mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\bar{\mathcal{E}} - \beta \nabla_{\mathcal{E}} f(\bar{\mathcal{X}}, \bar{\mathcal{E}})). \tag{3.10}$$

(2) $\left(\bar{\mathcal{X}}, \bar{\mathcal{E}}\right)$称为问题(3.3)的稳定点，若满足

$$\left(\nabla_{\mathcal{X}} f(\bar{\mathcal{X}}, \bar{\mathcal{E}}), \nabla_{\mathcal{E}} f(\bar{\mathcal{X}}, \bar{\mathcal{E}})\right) \in N_S^F(\bar{\mathcal{X}}) \times \mathbb{R}^{I_1 \times I_2 \times I_3}_{\Gamma^c_{\bar{\mathcal{E}}}}. \tag{3.11}$$

定理 3.1　考虑问题(3.3). (1) 任何局部极小值也是一个稳定点; (2) 任何β-稳定点($\beta > 0$)也是一个驻点; (3) 任何全局最小化点$(\mathcal{X}^*, \mathcal{E}^*)$对所有的$\beta \in (0, 1/L_f)$是$\beta$-稳定点. 此外，$\Pi_S(\mathcal{X}^* - \beta \nabla_{\mathcal{X}} f(\mathcal{X}^*, \mathcal{E}^*)) \times \mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}^* - \beta \nabla_{\mathcal{E}} f(\mathcal{X}^*, \mathcal{E}^*))$是一个单元素集合.

证明. (1) 设$\left(\bar{\mathcal{X}}, \bar{\mathcal{E}}\right)$为(3.3)的任意局部最小值. 问题(3.3) 可被重写为

$$\min_{\mathcal{X}, \mathcal{E}} f(\mathcal{X}, \mathcal{E}) + p(\mathcal{X}, \mathcal{E}), \tag{3.12}$$

其中f定义为(3.5)和$p(\mathcal{X}, \mathcal{E}) = \lambda\|\mathcal{E}\|_0 + \delta_S(\mathcal{X})$. 结合(1.21)，我们可以应用广义费马规则(定理10.1[93])得到所需的推论.

中国知网　https://www.cnki.net

(2) $\left(\bar{\mathcal{X}},\bar{\mathcal{E}}\right)$为问题(3.3)的一个$\beta$-稳定点，

$$\bar{\mathcal{X}} \in \Pi_S(\bar{\mathcal{X}} - \beta\nabla_{\mathcal{X}} f(\bar{\mathcal{X}},\bar{\mathcal{E}})) = \arg\min_{\mathcal{X}} \left\{ \frac{1}{2} \left\| \mathcal{X} - \left(\bar{\mathcal{X}} - \beta\nabla_{\mathcal{X}} f(\bar{\mathcal{X}},\bar{\mathcal{E}})\right) \right\|_F^2 + \delta_S(\mathcal{X}) \right\},$$

结合(定理10.1[93])中的广义费马规则和(练习8.14[93])中的$\hat{\partial}_{\mathcal{X}}\delta_S(\bar{\mathcal{X}}) = N_S(\bar{\mathcal{X}})$，得到$\mathcal{O} \in \bar{\mathcal{X}} - \left(\bar{\mathcal{X}} - \beta\nabla_{\mathcal{X}} f(\bar{\mathcal{X}},\bar{\mathcal{E}})\right) + N_S(\bar{\mathcal{X}})$，因为$N_S(\bar{\mathcal{X}})$的二次曲线性质，恰好得到$\nabla_{\mathcal{X}} f(\bar{\mathcal{X}},\bar{\mathcal{E}}) \in N_S(\bar{\mathcal{X}})$. 此外，结合$\bar{\mathcal{E}} \in \mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\bar{\mathcal{E}} - \beta\nabla_{\mathcal{E}} f(\bar{\mathcal{X}},\bar{\mathcal{E}}))$和(1.15)中的表达式, 可推出对任意$(i,j,k) \in \Gamma_{\bar{\mathcal{E}}}$，$\left(\nabla_{\mathcal{E}} f(\bar{\mathcal{X}},\bar{\mathcal{E}})\right)_{ijk} = 0$，因此, $\nabla_{\mathcal{E}} f(\bar{\mathcal{X}},\bar{\mathcal{E}}) \in \mathbb{R}^{I_1\times I_2\times I_3}_{\Gamma^c_{\bar{\mathcal{E}}}}$.

(3) 为简单起见，$\mathcal{T}_1^* := \nabla_{\mathcal{X}} f(\mathcal{X}^*,\mathcal{E}^*)$，$\mathcal{T}_2^* := \nabla_{\mathcal{E}} f(\mathcal{X}^*,\mathcal{E}^*)$. 调用$\nabla f$ 的Lipschitz连续性, 下降引理[56]可得

$$f(\mathcal{X},\mathcal{E}) \le f(\mathcal{X}',\mathcal{E}') + \langle \nabla f(\mathcal{X}',\mathcal{E}'), (\mathcal{X}-\mathcal{X}',\mathcal{E}-\mathcal{E}')\rangle + \frac{L_f}{2}\|(\mathcal{X}-\mathcal{X}',\mathcal{E}-\mathcal{E}')\|_F^2, \quad (3.13)$$

对任意的$\mathcal{X}$, $\mathcal{X}'$, $\mathcal{E}$, $\mathcal{E}' \in \mathbb{R}^{I_1\times I_2\times I_3}$. 接下来我们将证明正推反推两部分. 假设对某些$\beta < 1/L_f$，$(\mathcal{X}^*,\mathcal{E}^*)$ 不是问题的β-稳定点. 那么便可以找到与$(\mathcal{X}^*,\mathcal{E}^*)$不等的值$(\mathcal{X}_0,\mathcal{E}_0)$，使得

$$(\mathcal{X}_0,\mathcal{E}_0) \in \Pi_S(\mathcal{X}^* - \beta\mathcal{T}_1^*) \times \mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}^* - \beta\mathcal{T}_2^*).$$

结论$\mathcal{X}_0 \in \Pi_S(\mathcal{X}^* - \beta\mathcal{T}_1^*)$ 表明

$$\left\|\mathcal{X}_0 - (\mathcal{X}^* - \beta\mathcal{T}_1^*)\right\|_F^2 \le \left\|\mathcal{X}^* - (\mathcal{X}^* - \beta\mathcal{T}_1^*)\right\|_F^2,$$

等价于，

$$\langle \mathcal{T}_1^*, \mathcal{X}_0 - \mathcal{X}^*\rangle \le -\frac{1}{2\beta}\|\mathcal{X}_0 - \mathcal{X}^*\|_F^2. \quad (3.14)$$

此外，关系式$\mathcal{E}_0 \in \mathrm{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}^* - \beta\mathcal{T}_2^*)$意味着

$$\frac{1}{2}\left\|\mathcal{E}_0 - (\mathcal{E}^* - \beta\mathcal{T}_2^*)\right\|_F^2 + \lambda\beta\|\mathcal{E}\|_0 \le \frac{1}{2}\left\|\mathcal{E}^* - (\mathcal{E}^* - \beta\mathcal{T}_2^*)\right\|_F^2 + \lambda\beta\|\mathcal{E}^*\|_0,$$

化简后可得

$$\lambda\|\mathcal{E}_0\|_0 + \frac{1}{2\beta}\|\mathcal{E}_0 - \mathcal{E}^*\|_F^2 + \langle \mathcal{T}_2^*, \mathcal{E}_0 - \mathcal{E}^*\rangle \le \lambda\|\mathcal{E}^*\|_0. \quad (3.15)$$

根据(3.13)，(3.14)及(3.15)，可得

$$f(\mathcal{X}_0,\mathcal{E}_0) + \lambda\|\mathcal{E}_0\|_0 \le f(\mathcal{X}^*,\mathcal{E}^*) + \lambda\|\mathcal{E}^*\|_0 + \left(\frac{L_f}{2} - \frac{1}{2\beta}\right)\|(\mathcal{X}_0 - \mathcal{X}^*, \mathcal{E}_0 - \mathcal{E}^*)\|_F^2. \quad (3.16)$$

注意到$\beta < 1/L_f$，$\delta_S(\mathcal{X}_0) = \delta_S(\mathcal{X}^*)$. (3.16) 中的不等式与$(\mathcal{X}^*,\mathcal{E}^*)$最优性矛盾. 因此,

中国知网　https://www.cnki.net

$(\mathcal{X}^*, \mathcal{E}^*)$ 是$\Pi_S(\mathcal{X}^* - \beta\mathcal{T}_1^*) \times \text{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}^* - \beta\mathcal{T}_2^*)$中唯一的元素. □

3.3　算法设计

当求解稀疏低秩张量优化问题(3.3)时，如3.1节所述，如何有效地解决这种非凸非连续问题是一个核心和关键的任务. 由于近端梯度下降(PGD) 方法已经成功地应用到了一般张量空间中，例如，在文献[61]中应用张量回归的非凸近端梯度下降法，在文献[66]中应用张量分解的随机PGD方法. 在本节中，我们将提出一个非凸非光滑PGD 方法来求解问题(3.3)，并进行收敛性和复杂性分析. 将我们提出的以稀疏和低秩张量为基础解决ITAD的方法记为SLRTA.

3.3.1　算法框架

借助3.2节的β-稳定点的最优性分析，我们设计求解问题(3.3)的近端梯度下降算法，相应的迭代公式为:

$$\left(\mathcal{X}^{k+1}, \mathcal{E}^{k+1}\right) \in \left(\Pi_S(\mathcal{X}^k - \beta\mathcal{T}_1^k), \text{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E}^k - \beta\mathcal{T}_2^k)\right), \tag{3.17}$$

其中$\mathcal{T}_1^k := \nabla_{\mathcal{X}} f(\mathcal{X}^k, \mathcal{E}^k)$，$\mathcal{T}_2^k := \nabla_{\mathcal{E}} f(\mathcal{X}^k, \mathcal{E}^k)$. 算法2给出了求解问题(3.3)的PGD算法框架.

算法 2: SLRTA: 求解问题(3.3)的PGD算法

输入: $\mathcal{B}$ 流量矩阵, Tucker秩的上界(r_1, r_2, r_3), β, λ
输出: $\mathcal{E}^k, \mathcal{X}^k$.

步 0: 初始化$\mathcal{X}^0$和$\mathcal{E}^0$, 设置准确率参数$\epsilon > 0$, 设$k = 0$.

步 1: 通过(3.17)计算$\left(\mathcal{X}^{k+1}, \mathcal{E}^{k+1}\right)$.

步 2: 若满足停止准则则停止, 否则设$k = k + 1$, 返回步1.

在数值实验中，对于$\mathcal{X}$的更新，我们可以采用序列截断高阶奇异值分解(sequentially truncated higher order singular value decomposition，ST-HOSVD)[1] 得到对低秩张量集合S的近似投影，即

$$\mathcal{X}^{k+1} = \text{ST-HOSVD}\left(\mathcal{X}^k - \beta\mathcal{T}_1^k, (r_1, r_2, r_3)\right). \tag{3.18}$$

[1]http://www.tensortoolbox.org/

中国知网　https://www.cnki.net

这一近似投影可保证$\mathcal{X}^{k+1} \in S$(详见[87])，且误差满足:

$$\left\|\left(\mathcal{X}^k - \beta\mathcal{T}_1^k\right) - \mathcal{X}^{k+1}\right\|_F \leq \sqrt{3}\left\|\left(\mathcal{X}^k - \beta\mathcal{T}_1^k\right) - \tilde{\mathcal{X}}^{k+1}\right\|_F,$$

其中$\tilde{\mathcal{X}}^{k+1}$是$\mathcal{X}^k - \beta\mathcal{T}_1^k$在$S$上的精确投影，也就是说，$\tilde{\mathcal{X}}^{k+1} \in \Pi_S(\mathcal{X}^k - \beta\mathcal{T}_1^k)$.

对于$\mathcal{E}$的更新，根据式(1.15)的$\text{Prox}_{\beta\lambda\|\cdot\|_0}$临近点算子，则可以通过下式更新$\mathcal{E}$，

$$\mathcal{E}_{i_1i_2i_3}^{k+1} = \begin{cases} (\mathcal{E}^k - \beta\mathcal{T}_2^k)_{i_1i_2i_3}, & \text{若}|(\mathcal{E}^k - \beta\mathcal{T}_2^k)_{i_1i_2i_3}| > \sqrt{2\beta\lambda}; \\ 0, & \text{否则}. \end{cases} \tag{3.19}$$

3.3.2　收敛性和复杂度分析

问题(3.3)可以等价刻画为无约束问题(3.12). 因为非光滑函数$p(\mathcal{X},\mathcal{E})$中$\mathcal{X}$和$\mathcal{E}$是可分的，因此产生了其近端映射的可分离性，即

$$\text{Prox}_p(\mathcal{X},\mathcal{E}) = (\Pi_S(\mathcal{X}), \text{Prox}_{\lambda\|\cdot\|_0}(\mathcal{E})), \quad \forall \mathcal{X},\mathcal{E} \in \mathbb{R}^{I_1\times I_2\times I_3}. \tag{3.20}$$

对任意的$\beta > 0$，可得$\text{Prox}_{\beta p}(\mathcal{X},\mathcal{E}) = \left(\Pi_S(\mathcal{X}), \text{Prox}_{\beta\lambda\|\cdot\|_0}(\mathcal{E})\right)$. 因此，PDG中的迭代步骤(3.17)为

$$\left(\mathcal{X}^{k+1},\mathcal{E}^{k+1}\right) \in \text{Prox}_{\beta p}\left((\mathcal{X}^k,\mathcal{E}^k) - \beta\nabla f(\mathcal{X}^k,\mathcal{E}^k)\right). \tag{3.21}$$

此外，如3.1.2所述，f梯度为常数L_f，其为梯度Lipschitz 连续的. 因此，结合$f+p$的半代数性质即$f+p$是Kurdyka-Łojasiewicz (KL)函数(详见[51]). 我们可以应用文献[52]中关于非光滑非凸优化问题的前后向分割算法的收敛结果，得到算法的如下收敛性.

定理 3.2　设$\beta \in (0, 1/L_f)$和$\left\{\left(\mathcal{X}^k,\mathcal{E}^k\right)\right\}$为算法2 生成的迭代序列. 若$\left\{\left(\mathcal{X}^k,\mathcal{E}^k\right)\right\}$ 有界，则它收敛到问题(3.3)的一个稳定点.

证明. 由p是正常的、下半连续的半代数函数，如引理1.3(1) 所述，注意到$f+p$是非负的，因此是有界的. 根据∇f的L_f-Lipschitz 连续性，以及定义3.1中的稳定点定义，利用(定理5.1 & 标注5.2(a)[52])，可得收敛性. □

根据(定理5.1 & 标注5.2(a)[52])，对任意给定的$\underline{\beta}$和$\bar{\beta}$，有$0 < \underline{\beta} < \beta_k < \bar{\beta} < 1/L_f$，算法中的变量$\beta_k$可达到定理3.2中的收敛性. 加速策略(详见[55,89,90])也可使得算法有更好的效果, 这些都可以为后续的数值实现提供更多可能性.

此外，在数值实验的每步迭代中，计算开销主要来自于$\mathcal{X}$的更新，其复杂度为$\mathcal{O}\left(I_1^2I_2I_3 + r_1I_2^2I_3 + r_1r_2I_3^2\right)$，而$\mathcal{E}$更新的计算成本相对较低，其复杂度为$\mathcal{O}(I_1I_2I_3\log(I_1I_2I_3))$.

中国知网　https://www.cnki.net

表 3.1: 数据集

数据集	日期	时间长度	时间间隔	数据维度
Abilene1	Mar. 2004	2 weeks	5min	$14 \times 288 \times 144$
GÈANT1	Jan. 2005	2 weeks	15min	$14 \times 96 \times 529$
Abilene2	Mar.1st - Sep.10th, 2004	168 days	5min	$168 \times 288 \times 144$
GÈANT2	Jan.1st - Apr.29th, 2005	116 days	15min	$116 \times 96 \times 529$
D1	–	365 days	5min	$365 \times 288 \times 6400$

3.4 数值试验

本节在公共流量追踪数据集Abilene[49]和GÈANT[99]上分别进行了不完全测量和链路测量两种情况下的数值实验，以评估本文提出的SLRTA方法的性能.

所有计算结果均在一台64位Windows操作系统、(Intel(R) Core(TM) i5-5250U CPU@ 1.60GHZ RAM 4.0G)、Matlab R2016b 的笔记本电脑上[2]，利用Matlab Tensor Toolbox[3]和Tensorlab计算[4]得到.

3.4.1 实验设置

按照3.1.1小节中描述的方式用Abilene和GÈANT中的流量数据分别构造出两个三阶流量张量模型. 特别地，从这两个数据集中选择2周数据用于测试. 并且模拟Abilene数据集合成一天中288个时段的低秩张量数据集D1. 实验中使用的五个数据集汇总在表3.1中.

另外，Abilene和GÈANT网络的拓扑图分别绘于图3.2和图3.4中，Abilene网络有30条链路，GÈANT网络有74条链路. 为了得到链路负载对应的路由矩阵，本文使用最短路径算法生成拓扑图中任意两个节点的最短路径，得到两个大小分别为30×144和74×529的矩阵. 这些路由矩阵的可视化结果如图3.3和图3.5所示，其中黑色方块表示0，白色方块表示1. 在D1数据集中，本文假设存在968个链路，使用最短路径算法生成对应的路由矩阵.

对表3.1中的流量张量进行归一化处理，以更有效地处理数据[50]. 在我们的实验中，标准化张量$\mathcal{X}$被视为真实值，由下式得到

$$\mathcal{X}_{ijk} = \frac{\mathcal{M}_{ijk} - \min\limits_{i',j',k'}\{\mathcal{M}_{i'j'k'}\}}{\max\limits_{i',j',k'}\{\mathcal{M}_{i'j'k'}\} - \min\limits_{i',j',k'}\{\mathcal{M}_{i'j'k'}\}}, \quad \forall i,j,k \tag{3.22}$$

[2]添加的大规模数据集D1 将在配备Matlab R2020a 的桌面(Intel(R) Xeon(R) Gold 5222 CPU@ 3.80GHZ RAM 128G) 上进行数值实验.

[3]http://www.sandia.gov/tgkolda/ TensorToolbox

[4]http://www.esat.kuleuven.be/sista/tensorlab

中国知网 https://www.cnki.net

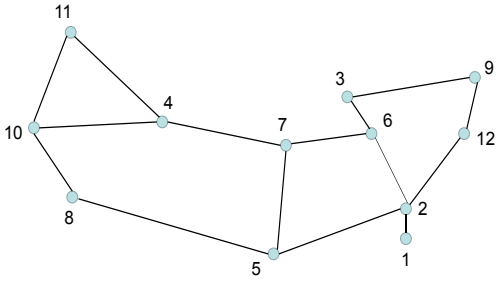


图 3.2: Abilene 网络

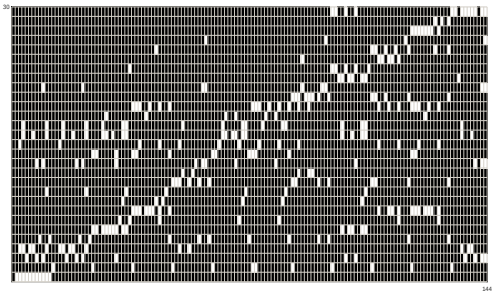


图 3.3: Abilene 路由矩阵

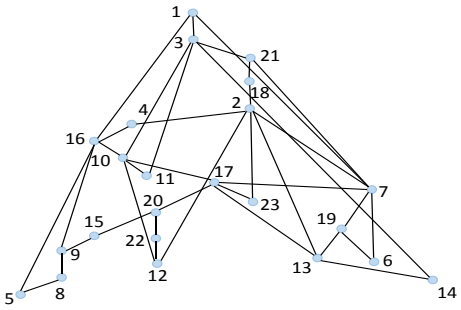


图 3.4: GÈANT 网络

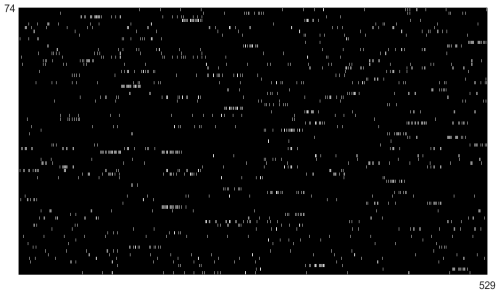


图 3.5: GÈANT 路由矩阵

其中$\mathcal{M}$中流量张量的最大值为$\max_{i',j',k'}\{m_{i'j'k'}\}$最小值为$\min_{i',j',k'}\{m_{i'j'k'}\}$.

根据文献[104,108]，本文将异常数据添加到归一化流量张量$\mathcal{X}$中，以不同比例$\gamma = 10\%, 1\%, 0.1\%$，在一些指定的位置上合成异常点. 对于不完全测量，索引集Ind从$[I_1]\times[I_2]\times[I_3]$中随机选择，缺失比例为$\nu = 70\%$，即$|\text{Ind}| = (1-\nu)I_1I_2I_3$；而对于链路测量，异常点可以分布在整个索引集中，即$\text{Ind} = [I_1]\times[I_2]\times[I_3]$. 为了测试，假设添加的异常值分布，遵循高斯分布$N(\mu,\sigma^2)$，变化均值$\mu$和方差$\sigma^2$，以说明异常强度对检测性能的影响. 对不同的异常值分布，如指数型分布，也可以用本文的方法处理，得到相似的数值性能，但在本文中省略此种分布.

为了得到模型(3.3)中Tucker秩(r_1, r_2, r_3)的上界，本文采用文献[64,104,107]中的策略，用下式来保留数据的主要特征：

$$r_n = \min_{1\le l\le I_n}\left\{l : \frac{\sum_{i=1}^{l}\tilde{\sigma}_i^2(\mathbf{X}_{(n)})}{\sum_{i=1}^{I_n}\tilde{\sigma}_i^2(\mathbf{X}_{(n)})} \ge \theta\right\},\quad n = 1,2,3, \tag{3.23}$$

其中模-n展开矩阵$\mathbf{X}_{(n)}$的第i大奇异值是$\tilde{\sigma}_i(\mathbf{X}_{(n)})$. 本文设置数据可变性保存的比例为$\theta = 99\%$.

该算法将$\mathcal{E}^0, \mathcal{X}^0$初始化为零张量，如果符合以下两项条件之一，算法将被终止：

中国知网 https://www.cnki.net

(1) 迭代次数达到Itermax； (2) 连续两次迭代的相对误差小于固定值，即

$$\text{relError} := \frac{\left\| A\left(\mathcal{X}^{k+1} + \mathcal{E}^{k+1}\right) - A\left(\mathcal{X}^{k} + \mathcal{E}^{k}\right) \right\|_F}{\|\mathcal{B}\|_F} \leq \text{tol}. \tag{3.24}$$

此处设置Itermax =5000，tol =10^{-3}.

将数据的正则模型与每个位置的真实数据进行比较，然后寻找差值超过某个阈值η的点进行异常检测. 本文中设置$\eta = 10^{-6}$. 对于检测精度，本文将采用常用的指标*False Positive Rate (FPR)*, *True Positive Rate (TPR)*和*True skill score (TSS)* 来评估异常检测性能. FPR 记录了被错误识别为异常值的非异常值的比例，TPR测量了被正确识别的异常值的比例，TSS在真阳性率和假阳性率之间提供了一个平衡，即，

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}, \quad \text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{TSS} = \text{TPR} - \text{FPR}. \tag{3.25}$$

FP代表非异常点被错误判定为异常点的数量，TN代表非异常点被正确判定为非异常点的数量，TP代表异常点被正确判定为异常点的数量，FN代表异常点被错误判定成非异常点的数量. 显然，FPR越小，TPR越高，检测性能越好. 同时，为了评估算法的时间效率，我们将报告每个测试实例的CPU时间. 对于每个实验设置，我们随机进行10 次实验，并报告结果的平均值.

3.4.2　性能评价

为了说明本文提出的方法SLRTA对ITAD的有效性，在检测精度和计算时间方面，我们将与文献[95] 中基于矩阵的方法SRMF进行比较，与基于时间序列技术的差分法记性比较，与文献[71]中提出的基于低秩稀疏矩阵的松弛方法进行比较，与基于低秩稀疏张量的松弛Candecomp/PARAFAC(CP)方法进行比较. 在文献[71]中提出了基于链路测量的矩阵方法，设计了交替方向乘子法(ADMM)来求解以下模型，简称LRXV：

$$\text{(LRXV)} \quad \min_{\mathbf{X},\mathbf{V},\mathbf{M},\mathbf{Q}} \frac{1}{2}\|\mathbf{Y} - \mathbf{A}_L(\mathbf{X} + \mathbf{V})\|_F^2 + \mu_r(\|\mathbf{M}\|_F^2 + \|\mathbf{Q}\|_F^2) + \mu_s\|\mathbf{V}\|_1$$

其中μ_r和μ_s分别控制秩约束和稀疏约束，$\mathbf{A}_L$为路由矩阵，$\mathbf{M}^\top\mathbf{Q}$为$\mathbf{A}_L\mathbf{X}$的分解. 受文献[71]的启发，针对不完全测量，提出CP低秩稀疏张量松弛方法，并设计ADMM算法来求解以下模型，HSCP模型如下：

$$\text{(HSCP)} \quad \min_{\mathbf{A},\mathbf{B},\mathbf{C},\mathcal{X},\mathcal{E}} \frac{1}{2}\|\Pi_{\text{Ind}}[\mathcal{B} - (\mathcal{X} + \mathcal{E})]\|_F^2 + \mu_r(\|\mathbf{A}\|_F^2 + \|\mathbf{B}\|_F^2 + \|\mathbf{C}\|_F^2) + \mu_s\|\mathcal{E}\|_1$$

中国知网　https://www.cnki.net

其中μ_r和μ_s分别控制秩约束和稀疏约束，**A**,**B**和**C**生成标准流量张量$\mathcal{X}$的CP 分解. 在文献[95]中基于矩阵的方法SRMF能够处理不完全测量和链路测量两种情况，并设计交替最小二乘法来求解优化问题(1.24). 在差分方法中，利用指数和OneClassSVM[5] 的一阶差分来检测异常点[109].

3.4.2.1 在$\gamma = 0.1\%$时Abilene1 和GÈANT1 的性能比较

对表3.1中描述的2周的流量数据，即Abilene1和GÈANT1数据集，分别进行了不完全测量和链路测量情况下的数值实验. 为了方便起见，本文用A1和A2分别表示这两个测量的线性算子.

在低离群值比$\gamma = 0.1\%$的情况下，本文评估了SLRTA、SRMF、Differecncing、LRXV和HSCP的性能，线性算子为A1和A2的Abilene1和GÈANT1数据集的比较结果见表3.2 和3.3.

表 3.2: A1在$\gamma = 0.1\%$时的精度比较

(a) Abilene1

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	11	2.20
		SRMF	0	1	1	10	**1.75**
		Differencing	0	1	1	–	7200
		HSCP	0	1	1	8	1.98
1	1	SLRTA	**0**	**1**	**1**	13	2.52
		SRMF	0	0.9937	0.9937	12	**2.04**
		Differencing	2.10e-4	1	0.9998	–	7500
		HSCP	0	0.9713	0.9713	8	2.28
0.1	1	SLRTA	1.90e-5	**0.9949**	**0.9949**	12	2.40
		SRMF	**0**	0.9865	0.9865	9	**1.56**
		Differencing	9.80e-4	0.2509	0.2499	–	9000
		HSCP	0	0.9598	0.9598	8	1.80
0.01	1	SLRTA	2.76e-5	**0.9944**	**0.9944**	12	2.37
		SRMF	1.48e-6	0.9817	0.9817	8	**1.36**
		Differencing	8.60e-4	0.2443	0.2434	–	11520
		HSCP	**0**	0.9310	0.9310	8	2.28
1	10	SLRTA	**0**	**1**	**1**	11	2.19
		SRMF	0	1	1	11	**1.85**
		Differencing	3.00e-2	1	0.9700	–	9480
		HSCP	0	0.9713	0.9713	8	2.17
1	0.1	SLRTA	1.55e-5	**1**	**1**	11	2.15
		SRMF	**0**	0.9893	0.9893	18	3.01
		Differencing	2.56e-2	1	0.9744	–	8580
		HSCP	0	0.9655	0.9655	8	**1.79**
1	0.01	SLRTA	5.17e-5	**1**	**0.9999**	11	2.17
		SRMF	**0**	0.9878	0.9878	10	**0.63**
		Differencing	2.57e-2	1	0.9743	–	7320
		HSCP	0	0.9425	0.9425	8	1.87

(b) GÈANT1

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	12	3.50
		SRMF	3.28e-6	1	1	14	9.34
		Differencing	0	1	1	–	6840
		HSCP	2.81e-6	1	1	8	**2.09**
1	1	SLRTA	5.63e-5	**1**	**0.9999**	13	3.85
		SRMF	4.22e-6	0.9747	0.9747	14	9.45
		Differencing	2.49e-4	1	0.9998	–	4500
		HSCP	**1.41e-6**	0.9765	0.9765	8	**2.13**
0.1	1	SLRTA	2.96e-5	**0.9910**	0.9910	13	3.81
		SRMF	9.38e-6	0.9552	0.9552	14	9.51
		Differencing	3.74e-2	0.3740	0.3366	–	6780
		HSCP	**2.81e-6**	0.9671	0.9671	8	**1.93**
0.01	1	SLRTA	7.46e-5	**0.9901**	**0.9900**	15	4.47
		SRMF	1.03e-5	0.9542	0.9542	14	9.47
		Differencing	1.90e-3	0.2882	0.2863	–	7380
		HSCP	**4.22e-6**	0.9484	0.9484	8	**2.16**
1	10	SLRTA	2.96e-5	**1**	**1**	14	4.15
		SRMF	7.50e-6	0.9837	0.9837	14	9.45
		Differencing	1.25e-2	1	0.9875	–	7260
		HSCP	**1.41e-6**	0.9812	0.9812	8	**2.06**
1	0.1	SLRTA	6.75e-5	**1**	**0.9999**	12	3.53
		SRMF	**1.88e-6**	0.9875	0.9875	24	15.70
		Differencing	9.50e-3	1	0.9905	–	3840
		HSCP	2.22e-6	0.9578	0.9578	8	**2.11**
1	0.01	SLRTA	6.33e-5	**1**	**0.9999**	13	3.85
		SRMF	**1.88e-6**	0.9733	0.9733	24	15.92
		Differencing	1.46e-2	1	0.9854	–	6540
		HSCP	2.41e-6	0.9484	0.9484	8	**2.12**

从表3.2和3.3可以看到，当均值较大为$\mu = 10$和$\mu = 1$时，使用A1 的三种方法的检测率达到相似的结果$FPR \approx 1$，而当均值较小为$\mu = 0.1$和$\mu = 0.01$时，SLRTA、SRMF、LRXV和HSCP在检测精度上显著优于Differencing的性

[5] *http : //scikit − learn.org/stable/modules/outlier_detection.html#outlier − detection*

中国知网 https://www.cnki.net

表 3.3: A2在$\gamma = 0.1\%$时的精度比较

(a) Abilene1

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	7.45e-4	**1**	**0.9993**	11	**2.48**
		SRMF	1.79e-4	1	0.9998	58	3.75
		Differencing	**1.10e-4**	0.3465	0.3464	–	8760
		LRXV	2.75e-3	0.9368	0.9340	51	6.44
1	1	SLRTA	1.59e-3	**1**	**0.9984**	18	3.91
		SRMF	2.99e-3	0.9761	0.9731	49	**3.04**
		Differencing	**1.10e-4**	0.3504	0.3503	–	8460
		LRXV	9.84e-3	0.8966	0.8868	54	6.83
0.1	1	SLRTA	1.93e-3	**1**	**0.9981**	16	3.50
		SRMF	**3.67e-4**	0.9691	0.9687	59	**3.45**
		Differencing	1.10e-3	0.3536	0.3525	–	8760
		LRXV	6.80e-2	0.8851	0.8171	54	6.46
0.01	1	SLRTA	2.75e-3	**0.9712**	**0.9684**	15	**3.14**
		SRMF	**2.02e-4**	0.9633	0.9631	51	3.21
		Differencing	3.40e-4	0.1448	0.1445	–	6540
		LRXV	8.98e-2	0.8563	0.7665	54	6.39
1	10	SLRTA	**6.24e-4**	**1**	**0.9994**	18	3.92
		SRMF	1.13e-3	0.9841	0.9830	54	**3.39**
		Differencing	2.50e-3	0.3293	0.3268	–	6000
		LRXV	8.50e-3	0.9195	0.9110	52	6.35
1	0.1	SLRTA	2.94e-3	**1**	**0.9971**	13	**2.92**
		SRMF	1.14e-2	1	0.9886	54	3.44
		Differencing	**1.10e-3**	0.3121	0.3110	–	6480
		LRXV	8.08e-2	0.8908	0.8100	54	6.50
1	0.01	SLRTA	**2.24e-3**	**1**	**0.9978**	11	**2.77**
		SRMF	5.71e-2	1	0.9429	54	3.41
		Differencing	3.40e-3	0.1610	0.1576	–	7020
		LRXV	9.56e-2	0.8851	0.7895	54	6.68

(b) GÈANT1

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**1.28e-3**	**1**	**0.9987**	10	**3.22**
		SRMF	5.79e-3	1	0.9942	17	7.47
		Differencing	3.06e-3	0.2520	0.2489	–	5520
		LRXV	7.74e-3	0.9531	0.9454	81	29.07
1	1	SLRTA	1.44e-3	**1**	**0.9986**	10	**3.28**
		SRMF	**1.27e-3**	0.9765	0.0546	13	5.49
		Differencing	2.19e-3	0.2394	0.2372	–	5820
		LRXV	8.32e-2	0.8568	0.7736	77	27.76
0.1	1	SLRTA	2.17e-3	**1**	**0.9978**	18	5.89
		SRMF	**5.12e-4**	0.9531	0.9526	12	**5.05**
		Differencing	1.39e-2	0.1268	0.1129	–	5880
		LRXV	9.51e-2	0.8169	0.7218	77	28.21
0.01	1	SLRTA	2.90e-3	**0.9737**	**0.9708**	14	**4.40**
		SRMF	**3.48e-4**	0.9484	0.9481	12	5.30
		Differencing	9.19e-2	0.1127	0.0208	–	5580
		LRXV	9.64e-2	0.8028	0.7064	77	27.86
1	10	SLRTA	**1.58e-3**	**1**	**0.9984**	18	**5.58**
		SRMF	2.71e-3	0.9853	0.9826	14	5.84
		Differencing	7.98e-3	0.2371	0.2291	–	5460
		LRXV	5.75e-2	0.8639	0.8064	78	27.75
1	0.1	SLRTA	2.05e-3	**1**	**0.9980**	9	**2.89**
		SRMF	**5.19e-4**	0.9505	0.9500	14	5.54
		Differencing	7.99e-3	0.1798	0.1718		5040
		LRXV	8.91e-2	0.8404	0.7513	77	29.11
1	0.01	SLRTA	2.70e-3	**1**	**0.9973**	10	**3.16**
		SRMF	**8.04e-4**	0.9544	0.9536	14	5.92
		Differencing	1.34e-2	0.1592	0.1458	–	5640
		LRXV	9.06e-2	0.8310	0.7404	77	28.41

能(见列“TPR”和“FPR”). 对于所有的实例，SLRTA就TSS而言性能优于其他四种方法(见列“TSS”). 此外，在所有测试实例中Differencing的时间效率(见“时间(s)”列)都非常差，因此在后面的实验中，只比较SLRTA、SRMF、HSCP和LRXV这几种方法. 对于SLRTA和SRMF之间的比较，从“FPR”列中可知，SLRTA在所有实例中都优于SRMF，特别是在异常值强度较低的情况下(例如，$(\mu, \sigma^2) = (0.1, 1), (0.01, 1), (1, 0.1), (1, 0.01)$). 同时，本文提出的SLRTA方法在计算时间上比SRMF 有竞争力，在一些情况下甚至更快. 例如，对于表3.2(b)中的$(\mu, \sigma^2) = (1, 0.1), (1, 0.01)$，SLRTA几乎比SRMF快4倍. 对于本文提出的SLRTA方法得到的TPR分别比HSCP和LRXP方法得到的TPR至少高2.34%和4.69%，因为两者都缺乏对流量数据中时间属性的考虑. SLRTA在链路测量下的计算时间方面具有相当的竞争力，在表3.3(b)中，对于$(\mu, \sigma^2) = (1, 0.1), (1, 0.01)$的情况，SLRTA几乎比LRXV快5倍.

对A1和A2的异常比例为$\gamma = 10\%, 1\%, 0.1\%$的情况，在全数据集Abilene2 和GÈANT2上对SLRTA 和SRMF，LRXV，HSCP进行了较为全面的数值比较.

高异常比$\gamma = 10\%$: 在这种情况下，流量数据被注入$\gamma = 10\%$的异常值. 这只是出于测试目的，与一般实际中的网络流量追踪结果不同. 比较结果显示在表3.4和3.5中. 对于不完全测量的情况，从表3.4看出，SLRTA对所有的例子

中国知网 https://www.cnki.net

在TPR和TSS上都优于HSCP. 对于更加复杂的情况，对Abilene2和GÈANT2数据集，当$(\mu,\sigma) = (0.01,1)$时，SLRTA 的TPR分别比SRMF和HSCP高出5%和3.5%. 如图3.6和3.7所示，对SLRTA 而言所有7个实例对应的相对误差都逐渐减小到一个稳定值从而终止. 对于链路测量A2的情况，SLRTA比LRXV检测精度更高，并且其时间效率优于SRMF和LRXV.

表 3.4: A1在$\gamma = 10\%$时的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	13	20.29
		SRMF	0	1	1	8	**5.25**
		HSCP	0	1	1	8	10.41
1	1	SLRTA	**0**	**0.9891**	**0.9891**	15	23.22
		SRMF	0	0.9794	0.9794	14	**8.78**
		HSCP	0	0.9663	0.9663	8	10.51
0.1	1	SLRTA	2.06e-5	**0.9806**	**0.9806**	6	**9.83**
		SRMF	**0**	0.9278	0.9278	20	12.54
		HSCP	0	0.9442	0.9442	8	10.66
0.01	1	SLRTA	2.99e-5	**0.9809**	**0.9809**	7	11.30
		SRMF	**0**	0.9223	0.9223	20	12.72
		HSCP	1.48e-7	0.9437	0.9437	8	**10.41**
1	10	SLRTA	**0**	**0.9933**	**0.9933**	10	15.81
		SRMF	0	0.9665	0.9665	12	**7.73**
		HSCP	0	0.9832	0.9832	8	10.31
1	0.1	SLRTA	**0**	**0.9832**	**0.9832**	15	24.46
		SRMF	0	0.9781	0.9781	14	**8.71**
		HSCP	0	0.9508	0.9508	8	10.64
1	0.01	SLRTA	**0**	**0.9875**	**0.9875**	14	22.89
		SRMF	0	0.9708	0.9708	14	**8.67**
		HSCP	0	0.9483	0.9483	8	10.03

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	13	20.29
		SRMF	5.25e-7	1	1	7	**9.85**
		HSCP	1.75e-6	1	1	8	8.79
1	1	SLRTA	**0**	**0.9891**	**0.9891**	15	23.22
		SRMF	3.50e-7	0.9860	0.9860	14	19.60
		HSCP	3.33e-2	0.9672	0.9339	8	**8.58**
0.1	1	SLRTA	2.06e-5	**0.9806**	**0.9806**	6	9.83
		SRMF	4.56e-4	0.9431	0.9426	17	8.90
		HSCP	**3.50e-6**	0.9457	0.9457	8	**8.56**
0.01	1	SLRTA	2.99e-5	**0.9809**	**0.9809**	7	11.63
		SRMF	4.13e-4	0.9379	0.9375	16	**8.08**
		HSCP	**2.96e-6**	0.9438	0.9438	8	9.83
1	10	SLRTA	**0**	**0.9933**	**0.9933**	10	15.81
		SRMF	8.75e-7	0.9832	0.9832	14	19.44
		HSCP	2.28e-2	0.9831	0.9603	8	**8.60**
1	0.1	SLRTA	**0**	**0.9879**	**0.9879**	15	24.46
		SRMF	7.00e-7	0.9654	0.9654	14	**22.91**
		HSCP	3.15e-6	0.9492	0.9492	8	**9.30**
1	0.01	SLRTA	**0**	**0.9875**	**0.9875**	13	20.20
		SRMF	5.25e-7	0.9675	0.9675	14	23.11
		HSCP	2.80e-6	0.9511	0.9511	8	**8.52**

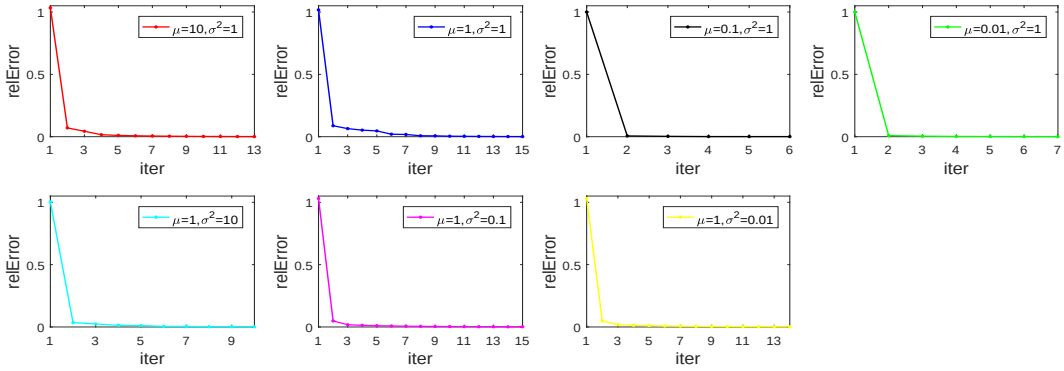


图 3.6: A1在Abilene2数据集$\gamma = 10\%$时的收敛性图像

异常比$\gamma = 1\%$: A1和A2在$\gamma = 1\%$时的比较结果分别显示在表3.6和3.7 中. 由于异常点比例降低，两种方法都比$\gamma = 10\%$时的检测精度高. 在不完全测量情况下，SLRTA对ITAD具有较高的TPR和TSS，并且在链路测量情况下具有更快的计算速度.

中国知网 https://www.cnki.net

表 3.5: A2在$\gamma = 10\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	5.92e-2	0.9195	0.8603	11	**22.52**
		SRMF	**2.06e-5**	**0.9481**	**0.9481**	62	33.41
		LRXV	1.42e-1	0.8757	0.7337	65	108.64
1	1	SLRTA	6.35e-2	0.9156	0.8521	5	**10.33**
		SRMF	**1.50e-4**	**0.9345**	**0.9344**	62	33.12
		LRXV	1.89e-2	0.7263	0.7074	55	91.46
0.1	1	SLRTA	9.18e-2	0.9011	0.8093	3	**6.35**
		SRMF	**4.80e-3**	**0.9333**	**0.9285**	60	31.92
		LRXV	1.93e-1	0.7073	0.5143	53	87.98
0.01	1	SLRTA	9.95e-2	0.9005	0.8010	3	**6.33**
		SRMF	**4.04e-3**	**0.9254**	**0.9214**	60	32.24
		LRXV	1.94e-1	0.7062	0.5122	53	87.67
1	10	SLRTA	6.01e-2	0.9066	0.8465	3	**6.38**
		SRMF	**9.96e-4**	**0.9366**	0.9356	60	32.79
		LRXV	1.80e-1	0.7339	0.5539	54	93.83
1	0.1	SLRTA	6.16e-2	0.9052	0.8436	5	**10.40**
		SRMF	**1.34e-3**	**0.9248**	**0.9235**	62	32.98
		LRXV	1.90e-1	0.7148	0.5248	44	72.12
1	0.01	SLRTA	6.35e-2	0.9018	0.8383	6	**12.41**
		SRMF	**1.06e-3**	**0.9246**	**0.9235**	62	32.68
		LRXV	1.93e-1	0.7071	0.5141	42	71.03

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	9.73e-2	0.9426	0.8453	5	**9.60**
		SRMF	**0**	**0.9663**	**0.9663**	19	23.00
		LRXV	1.27e-2	0.9229	0.9102	91	191.67
1	1	SLRTA	9.28e-2	0.9185	0.8257	3	**6.23**
		SRMF	**1.40e-4**	**0.9361**	**0.9360**	19	23.90
		LRXV	7.42e-2	0.8287	0.7545	89	190.64
0.1	1	SLRTA	9.17e-2	0.9072	0.8155	3	**5.82**
		SRMF	**2.10e-4**	**0.9328**	**0.9326**	19	22.71
		LRXV	7.91e-2	0.8192	0.7401	86	183.29
0.01	1	SLRTA	9.87e-2	0.9116	0.8129	3	**5.93**
		SRMF	**2.28e-4**	**0.9283**	**0.9281**	19	25.04
		LRXV	8.03e-2	0.8088	0.7285	87	185.68
1	10	SLRTA	9.22e-2	0.9212	0.8290	3	**6.01**
		SRMF	**2.64e-4**	**0.9587**	**0.9584**	19	23.37
		LRXV	6.99e-2	0.8306	0.7607	88	190.64
1	0.1	SLRTA	9.77e-2	0.9145	0.8168	4	**7.76**
		SRMF	**2.28e-4**	**0.9314**	**0.9312**	19	25.24
		LRXV	7.97e-2	0.8158	0.7361	90	191.85
1	0.01	SLRTA	9.84e-2	0.9109	0.8125	5	**9.69**
		SRMF	**2.50e-4**	**0.9387**	**0.9385**	19	24.30
		LRXV	8.47e-2	0.8099	0.7252	91	191.48

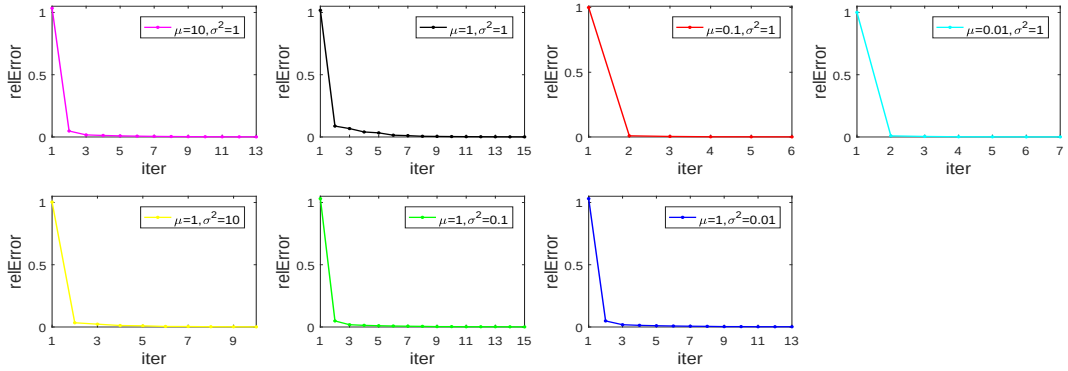


图 3.7: A1在GÈANT2数据集$\gamma = 10\%$时的收敛性图像

表 3.6: A1在$\gamma = 1\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	9	15.24
		SRMF	0	1	1	7	**4.49**
		HSCP	0	1	1	8	10.53
1	1	SLRTA	**0**	**0.9906**	**0.9906**	7	11.72
		SRMF	1.44e-7	0.9804	0.9804	29	18.21
		HSCP	1.44e-7	0.9661	0.9661	8	**10.52**
0.1	1	SLRTA	3.17e-6	**0.9898**	**0.9898**	7	12.12
		SRMF	**0**	0.9250	0.9250	33	21.30
		HSCP	0	0.9465	0.9465	8	**10.79**
0.01	1	SLRTA	6.91e-6	**0.9893**	**0.9893**	10	17.99
		SRMF	**0**	0.9206	0.9206	34	21.23
		HSCP	0	0.9425	0.9425	8	**10.26**
1	10	SLRTA	**0**	**0.9956**	**0.9956**	10	15.94
		SRMF	0	0.9670	0.9670	24	15.33
		HSCP	0	0.9832	0.9832	8	**10.53**
1	0.1	SLRTA	**0**	**0.9901**	**0.9901**	11	17.43
		SRMF	0	0.9599	0.9599	30	18.74
		HSCP	0	0.9496	0.9496	8	**10.68**
1	0.01	SLRTA	**0**	**0.9877**	**0.9877**	12	20.68
		SRMF	0	0.9704	0.9704	30	18.69
		HSCP	0	0.9478	0.9478	8	**10.27**

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	9	15.24
		SRMF	1.32e-6	1	1	7	9.66
		HSCP	3.41e-6	1	1	8	**8.39**
1	1	SLRTA	**0**	**0.9906**	**0.9906**	7	11.72
		SRMF	3.41e-7	0.9865	0.9865	14	19.20
	HSCP	2.72e-6	0.9648	0.9648	8	**8.40**	
0.1	1	SLRTA	3.17e-6	**0.9892**	**0.9892**	17	27.12
		SRMF	**0**	0.9477	0.9477	14	19.41
		HSCP	3.24e-6	0.9464	0.9464	8	**9.05**
0.01	1	SLRTA	6.91e-6	**0.9893**	**0.9893**	18	27.99
		SRMF	**8.51e-7**	0.9413	0.9413	14	19.82
		HSCP	3.41e-6	0.9431	0.9431	8	**9.25**
1	10	SLRTA	**0**	**0.9956**	**0.9956**	10	15.94
		SRMF	1.70e-7	0.9933	0.9933	14	20.48
		HSCP	3.40e-6	1	1	8	**8.35**
1	0.1	SLRTA	**0**	**0.9901**	**0.9901**	11	17.43
		SRMF	3.41e-7	0.9760	0.9760	17	24.31
		HSCP	2.38e-6	0.9494	0.9494	8	**8.64**
1	0.01	SLRTA	**0**	**0.9872**	**0.9872**	12	20.68
		SRMF	1.70e-7	0.9707	0.9707	14	19.27
		HSCP	3.92e-6	0.9477	0.9477	8	**8.49**

中国知网　https://www.cnki.net

表 3.7: A2在$\gamma = 1\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	6.23e-3	0.9371	0.9309	5	**10.28**
		SRMF	**3.37e-5**	**0.9557**	**0.9557**	61	32.20
		LRXV	3.43e-2	0.9187	0.8844	73	123.85
1	1	SLRTA	1.89e-2	0.9268	0.9079	4	**8.32**
		SRMF	**1.44e-4**	**0.9390**	**0.9389**	60	32.09
		LRXV	7.58e-2	0.8576	0.7818	54	89.59
0.1	1	SLRTA	2.57e-2	0.9168	0.8911	7	**14.85**
		SRMF	**1.37e-3**	**0.9349**	**0.9335**	60	32.71
		LRXV	8.38e-2	0.8529	0.7691	54	88.56
0.01	1	SLRTA	3.13e-2	0.9124	0.8811	6	**12.17**
		SRMF	**1.09e-3**	**0.9254**	**0.9243**	60	32.38
		LRXV	8.50e-2	0.8345	0.7495	54	88.68
1	10	SLRTA	3.59e-2	0.9321	0.8962	4	**8.30**
		SRMF	**2.40e-4**	**0.9374**	**0.9372**	61	33.49
		LRXV	5.23e-2	0.8624	0.8101	53	90.01
1	0.1	SLRTA	6.16e-2	0.9018	0.8402	5	**10.40**
		SRMF	**2.06e-4**	**0.9308**	**0.9306**	60	33.15
		LRXV	7.52e-2	0.8575	0.7823	54	87.97
1	0.01	SLRTA	6.35e-2	0.9056	0.8421	6	**12.41**
		SRMF	**1.80e-4**	**0.9302**	**0.9300**	60	32.39
		LRXV	8.52e-2	0.8438	0.7586	54	91.79

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	3.14e-2	**0.9796**	0.9482	3	**5.99**
		SRMF	**0**	0.9756	**0.9756**	19	23.21
		LRXV	1.52e-2	0.9343	0.9191	91	194.36
1	1	SLRTA	7.72e-3	0.9348	0.9271	3	**5.89**
		SRMF	**1.36e-4**	**0.9384**	**0.9383**	18	21.76
		LRXV	8.09e-2	0.8436	0.7627	90	188.92
0.1	1	SLRTA	6.56e-3	0.9111	0.9045	3	**5.91**
		SRMF	**2.21e-4**	**0.9296**	**0.9294**	18	22.25
		LRXV	8.55e-2	0.8343	0.7488	86	177.57
0.01	1	SLRTA	6.64e-3	0.9049	0.8983	3	**5.85**
		SRMF	**2.34e-4**	**0.9307**	**0.9305**	18	21.25
		LRXV	8.67e-2	0.8305	0.7438	85	177.91
1	10	SLRTA	1.21e-2	0.9487	0.9366	3	**5.78**
		SRMF	**2.13e-4**	**0.9588**	**0.9586**	19	22.68
		LRXV	8.05e-2	0.8494	0.7689	88	184.02
1	0.1	SLRTA	9.71e-3	0.9302	0.9205	3	**5.80**
		SRMF	**1.36e-4**	**0.9303**	**0.9302**	18	21.62
		LRXV	8.49e-2	0.8398	0.7549	87	177.57
1	0.01	SLRTA	9.21e-3	0.9211	0.9119	3	**5.74**
		SRMF	**2.21e-4**	**0.9277**	**0.9275**	18	22.13
		LRXV	9.23e-2	0.8187	0.7264	90	187.56

低异常比$\gamma = 0.1\%$: A1和A2在$\gamma = 0.1\%$时的结果显示在表3.8和表3.9中. 在本文的模型(3.3)中，ℓ_0-范数正则项能够很好的表征低异常率，因此SLRTA的性能更好. 从表3.8(a)中可以看出，在不完全测量的情况下，SLRTA在Abilene2 数据集所有实例中，相较于SRMF和HSCP表现出更高的TPR和TSS，并且时间效率更高. 从表3.8(b)中可以看到，对于GÈANT2 数据集的7个实例，SLRTA实现了6个实例的TPR达到= 1和TSS达到= 1. 对于链路测量，表3.9表明SLRTA在检测精度上具有优势，在时间效率上优于SRMF 和LRXV.

同时，在异常比$\gamma = 0.1\%$时，本文研究了ITAD在不完全测量和链路测量两种情况下，改变μ(默认$\sigma^2 = 1$)和σ^2(默认$\mu = 0$)时TPR和FPR的变化. 结果如图3.8和3.9所示，其中SLRTA用红色表示，SRMF用蓝色表示，HSCP和LRXV用黑色表示. 可以看到，SLRTA在整个方差和均值范围内性能都很好. 除了比较两种方法的检测精度外，从图中还可以看出，随着异常的方差σ^2 和均值μ的增加，TPR增加，FPR降低. 这一现象可以解释为，当异常值的均值μ和方差σ^2较大时，生成的异常值之间的距离也较大，因此更容易从正态数据中被检测出来. 在不完全测量的情况下，使用单位算子A进行检测，(μ, σ^2)对ITAD的影响也可以在文献[104]中观察到.

中国知网 https://www.cnki.net

表 3.8: A1在$\gamma = 0.1\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	3	**5.43**
		SRMF	0	1	1	5	7.49
		HSCP	0	1	1	8	10.61
1	1	SLRTA	**0**	**0.9950**	**0.9950**	5	**8.58**
		SRMF	1.43e-7	0.9842	0.9842	26	16.25
		HSCP	0	0.9675	0.9675	8	9.92
0.1	1	SLRTA	**0**	**0.9941**	**0.9941**	5	**8.46**
		SRMF	0	0.9579	0.9579	29	17.93
		HSCP	1.44e-7	0.9402	0.9402	8	10.82
0.01	1	SLRTA	**0**	**0.9904**	**0.9904**	6	**10.00**
		SRMF	0	0.9589	0.9589	28	18.39
		HSCP	0	0.9483	0.9483	8	10.46
1	10	SLRTA	**0**	**1**	**1**	8	**13.04**
		SRMF	0	0.9785	0.9785	24	15.08
		HSCP	1.44e-7	0.9842	0.9842	8	11.30
1	0.1	SLRTA	**0**	**0.9945**	**0.9945**	5	**8.53**
		SRMF	0	0.9794	0.9794	27	16.84
		HSCP	0	0.9445	0.9445	8	10.06
1	0.01	SLRTA	1.48e-7	**1**	**1**	3	**5.55**
		SRMF	**0**	0.9766	0.9766	27	17.16
		HSCP	0	0.9498	0.9498	8	10.71

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	3	**4.69**
		SRMF	3.05e-7	1	1	6	8.40
		HSCP	3.40e-6	1	1	8	8.55
1	1	SLRTA	1.28e-6	**1**	**1**	8	11.43
		SRMF	**1.70e-7**	0.9717	0.9717	14	19.09
		HSCP	3.57e-6	0.9677	0.9677	8	**8.81**
0.1	1	SLRTA	2.42e-6	**1**	**1**	8	11.37
		SRMF	**3.40e-7**	0.9428	0.9428	14	18.91
		HSCP	4.08e-6	0.9496	0.9496	8	**9.40**
0.01	1	SLRTA	**0**	**0.9815**	**0.9815**	14	19.42
		SRMF	6.79e-7	0.9320	0.9320	14	19.31
		HSCP	3.06e-6	0.9434	0.9434	8	**9.20**
1	10	SLRTA	**0**	**1**	**1**	9	13.48
		SRMF	1.70e-7	0.9874	0.9874	9	12.52
		HSCP	3.22e-6	0.9859	0.9859	8	**9.33**
1	0.1	SLRTA	1.28e-6	**1**	**1**	7	10.06
		SRMF	**3.39e-7**	0.9887	0.9887	14	19.68
		HSCP	3.63e-6	0.9502	0.9502	8	**8.33**
1	0.01	SLRTA	6.42e-6	**1**	**1**	10	14.30
		SRMF	**3.40e-7**	0.9774	0.9774	14	19.05
		HSCP	2.55e-6	0.9542	0.9542	8	**9.09**

表 3.9: A2在$\gamma = 0.1\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	6.61e-4	**0.9617**	**0.9610**	5	**10.31**
		SRMF	**2.06e-5**	0.9585	0.9585	61	28.37
		LRXV	1.53e-3	0.9220	0.9205	53	88.79
1	1	SLRTA	3.44e-3	**0.9507**	**0.9473**	7	**14.39**
		SRMF	**1.44e-4**	0.9421	0.9420	59	27.17
		LRXV	2.58e-2	0.8871	0.8613	54	90.85
0.1	1	SLRTA	**3.31e-3**	**0.9470**	**0.9437**	7	**14.35**
		SRMF	4.31e-3	0.9418	0.9375	58	27.03
		LRXV	2.41e-2	0.8627	0.8386	53	88.99
0.01	1	SLRTA	**3.03e-3**	**0.9422**	**0.9392**	6	**12.44**
		SRMF	5.29e-3	0.9411	0.9358	58	28.32
		LRXV	2.01e-2	0.8609	0.8408	53	89.25
1	10	SLRTA	3.61e-3	0.9522	0.9486	6	**12.31**
		SRMF	**5.22e-4**	**0.9537**	**0.9532**	60	28.28
		LRXV	4.53e-2	0.9163	0.8710	54	90.87
1	0.1	SLRTA	3.33e-3	**0.9452**	**0.9419**	6	**12.35**
		SRMF	**1.43e-4**	0.9407	0.9406	59	28.94
		LRXV	2.96e-2	0.8612	0.8316	54	90.74
1	0.01	SLRTA	3.24e-3	**0.9426**	0.9394	4	**8.40**
		SRMF	**1.04e-4**	0.9415	**0.9414**	59	27.45
		LRXV	6.17e-2	0.8598	0.7981	54	90.17

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	6.11e-3	**0.9831**	**0.9770**	4	**8.20**
		SRMF	**0**	0.9763	0.9763	18	21.85
		LRXV	5.65e-3	0.9576	0.9519	86	183.81
1	1	SLRTA	6.18e-3	**0.9661**	**0.9599**	5	**10.36**
		SRMF	**1.26e-4**	0.9496	0.9495	16	19.99
		LRXV	3.94e-2	0.9372	0.8978	87	186.88
0.1	1	SLRTA	8.06e-3	**0.9605**	**0.9524**	4	**8.32**
		SRMF	**2.21e-4**	0.9434	0.9432	16	20.39
		LRXV	4.78e-2	0.9310	0.8832	83	173.96
0.01	1	SLRTA	8.29e-3	**0.9576**	**0.9493**	4	**8.31**
		SRMF	**2.20e-3**	0.9276	0.9254	15	17.96
		LRXV	4.98e-2	0.9196	0.8698	86	181.31
1	10	SLRTA	3.20e-3	**0.9671**	**0.9639**	5	**10.47**
		SRMF	**2.74e-3**	0.9525	0.9498	17	20.66
		LRXV	5.61e-2	0.9417	0.8856	83	174.26
1	0.1	SLRTA	6.24e-3	**0.9578**	**0.9516**	7	**14.50**
		SRMF	**1.35e-4**	0.9502	0.9501	16	20.33
		LRXV	4.29e-2	0.9134	0.8705	87	181.76
1	0.01	SLRTA	6.79e-3	**0.9585**	**0.9517**	7	**13.32**
		SRMF	**1.84e-4**	0.9327	0.9325	16	19.48
		LRXV	5.28e-2	0.9038	0.8510	87	179.48

3.4.2.2 在周期性缺失$\gamma = 0.1\%$时Abilene2和GÈANT2的性能比较

尽管在表3.2, 3.4, 3.6, 3.8, 3.11(a)中已经讨论过随机缺失的情况，本文还通过在一个固定的时间段内固定OD对的数目来设计周期性缺失的情况. 表3.10表明，SLRTA的检测能力比基于矩阵的检测算法和HSCP算法稳定得多.

中国知网 https://www.cnki.net

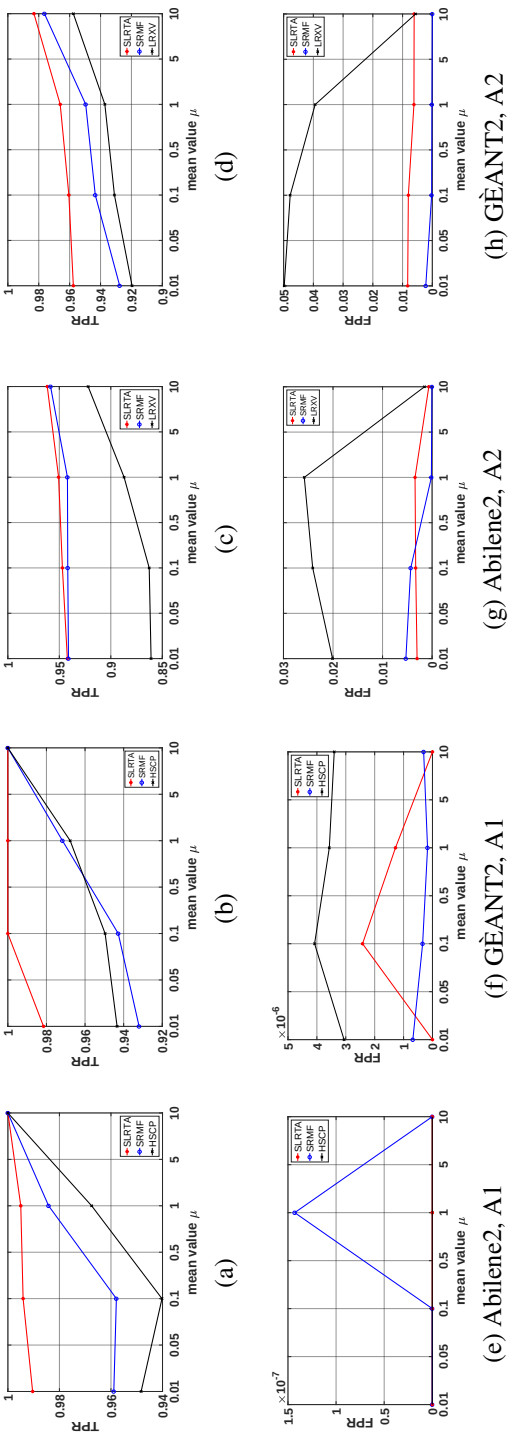


图 3.8: 在$\gamma = 0.1\%, \sigma^2 = 1$时在不同$\mu$下的精度比较

中国知网 https://www.cnki.net

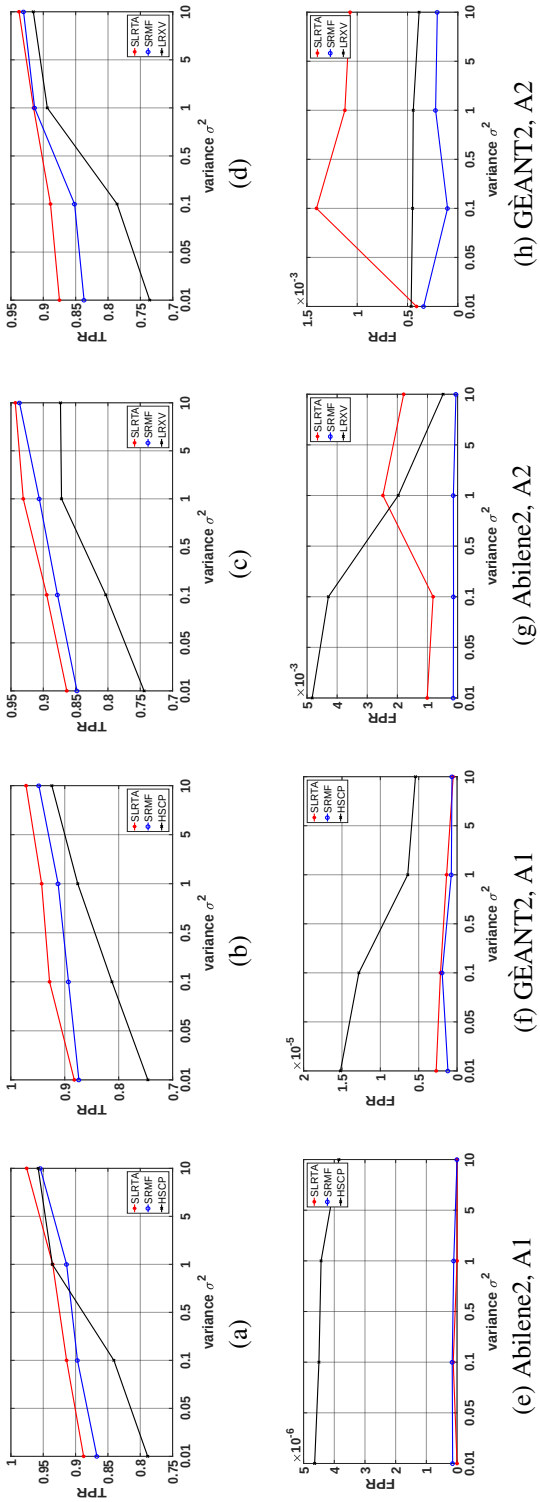


图 3.9: 在$\gamma = 0.1\%, \mu = 0$时在不同σ^2下的精度比较

中国知网 https://www.cnki.net

与SRMF和HSCP相比，通过改变平均值μ和方差σ^2，本文提出的SLRTA方法得到较高的TPR、TSS和较低的FPR，因此具有更好的性能.

表 3.10: 周期性缺失在$\gamma = 0.1\%$的精度比较

(a) Abilene2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	4	**7.78**
		SRMF	1.44e-7	1	1	11	7.91
		HSCP	0	1	1	8	9.86
1	1	SLRTA	**0**	**0.9933**	**0.9933**	6	12.11
		SRMF	1.44e-7	0.9788	0.9788	15	9.99
		HSCP	0	0.9644	0.9644	8	**9.53**
0.1	1	SLRTA	**0**	**0.9918**	**0.9918**	8	16.07
		SRMF	1.44e-7	0.9541	0.9541	17	11.42
		HSCP	0	0.9428	0.9428	8	**10.17**
0.01	1	SLRTA	**1.44e-7**	**0.9846**	**0.9846**	8	16.42
		SRMF	1.44e-7	0.9498	0.9498	17	11.31
		HSCP	0	0.9337	0.9337	8	**10.50**
1	10	SLRTA	**0**	**0.9952**	**0.9952**	9	17.99
		SRMF	1.44e-7	0.9837	0.9837	14	**9.64**
		HSCP	0	0.9841	0.9841	8	11.06
1	0.1	SLRTA	**0**	**0.9914**	**0.9914**	6	12.08
		SRMF	1.44e-7	0.9702	0.9702	16	10.66
		HSCP	0	0.9520	0.9520	8	**10.38**
1	0.01	SLRTA	**1.44e-7**	**0.9865**	**0.9865**	7	13.69
		SRMF	1.44e-7	0.9649	0.9649	16	10.70
		HSCP	1.44e-7	0.9505	0.9505	8	**9.55**

(b) GÈANT2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	4	**7.25**
		SRMF	8.32e-6	1	1	24	34.97
		HSCP	2.38e-6	1	1	8	8.29
1	1	SLRTA	**2.89e-6**	**0.9955**	**0.9955**	6	11.28
		SRMF	2.53e-5	0.9910	0.9910	24	35.53
		HSCP	3.57e-6	0.9642	0.9642	8	**8.15**
0.1	1	SLRTA	**2.55e-6**	**0.9852**	**0.9852**	6	10.65
		SRMF	1.84e-4	0.9681	0.9679	24	35.30
		HSCP	3.06e-6	0.9409	0.9409	8	**8.81**
0.01	1	SLRTA	**1.87e-6**	**0.9841**	**0.9841**	11	20.96
		SRMF	1.68e-4	0.9626	0.9624	24	34.29
		HSCP	4.08e-6	0.9471	0.9471	8	**9.33**
1	10	SLRTA	**3.06e-6**	**0.9960**	**0.9960**	10	17.43
		SRMF	3.31e-5	0.9844	0.9844	24	34.10
		HSCP	4.25e-6	0.9835	0.9835	8	**8.90**
1	0.1	SLRTA	**1.53e-6**	**0.9932**	**0.9932**	9	16.97
		SRMF	1.19e-5	0.9703	0.9703	24	33.89
		HSCP	2.38e-6	0.9499	0.9499	8	**9.48**
1	0.01	SLRTA	**2.89e-6**	**0.9892**	**0.9892**	9	16.19
		SRMF	1.02e-5	0.9699	0.9699	24	34.48
		HSCP	3.06e-6	0.9483	0.9483	8	**8.75**

3.4.2.3　在$\gamma = 0.1\%$时D1的性能比较

除了Abilene和GÈANT网络流量数据集之外，本文还生成了D1数据集用来评价所提出的方法. 数值结果收集在表3.11中，从表中可以看出，本文所提出的方法在所有测试实例中，在不完全测量和链路测量的情况下，在不同的平均值μ和方差σ^2情况下，都获得了最高的TPR和TSS. 特别地，在链路测量情况下，SLRTA 比SRMF和LRXV显示出了显著的时间效率，如表3.11(b)所示.

数值结果表明，本文提出的SLRTA方法是一种鲁棒的异常检测技术，它可以充分利用张量中的多维信息而不是矩阵信息来实现更精确的异常检测. 更重要的是，通过利用(3.3)中的l_0范数和低秩约束，本文的方法具有更快的计算速度(从每个实例的迭代次数可以看出)，特别是在链路测量情况下，在计算时间上具有明显的优势.

中国知网　https://www.cnki.net

表 3.11: D1在$\gamma = 0.1\%$的精度比较

(a) A1

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	**0**	**1**	**1**	11	770.53
		SRMF	2.01e-2	1	0.9799	3	1222.66
		HSCP	2.66e-1	1	0.7340	10	**499.46**
1	1	SLRTA	8.96e-2	**0.9405**	**0.8509**	4	**301.79**
		SRMF	**2.56e-2**	0.8614	0.8358	5	2011.33
		HSCP	2.65e-1	0.9320	0.6670	9	474.77
0.1	1	SLRTA	8.21e-2	**0.8869**	**0.8048**	7	510.62
		SRMF	**2.62e-2**	0.7956	0.7694	6	2481.67
		HSCP	2.65e-1	0.8756	0.6106	9	**468.83**
0.01	1	SLRTA	8.39e-2	**0.8839**	**0.8000**	11	776.93
		SRMF	**3.24e-2**	0.7440	0.7116	7	3003.21
		HSCP	2.57e-1	0.8734	0.6164	9	**437.41**
1	10	SLRTA	8.82e-2	**0.9665**	**0.8783**	10	707.96
		SRMF	**2.25e-2**	0.8814	0.8589	6	2501.31
		HSCP	2.68e-1	0.9618	0.6938	9	472.86
1	0.1	SLRTA	9.03e-2	**0.9395**	**0.8492**	9	624.99
		SRMF	**6.63e-2**	0.8441	0.7778	5	2088.67
		HSCP	2.65e-1	0.9234	0.6584	9	**452.96**
1	0.01	SLRTA	9.05e-2	**0.9172**	**0.8267**	9	637.16
		SRMF	**7.20e-2**	0.8167	0.7447	5	2136.86
		HSCP	2.60e-1	0.8952	0.6352	9	**478.30**

(b) A2

μ	σ^2	Approach	FPR	TPR	TSS	iter	time(s)
10	1	SLRTA	1.19e-2	**0.9754**	**0.9546**	9	**976.22**
		SRMF	**8.66e-3**	0.9087	0.9000	13	4165.91
		LRXV	1.29e-1	0.7528	0.6238	72	26420.00
1	1	SLRTA	2.34e-2	**0.8189**	**0.7955**	9	**969.09**
		SRMF	**9.92e-3**	0.7105	0.7006	13	4296.60
		LRXV	1.53e-1	0.6739	0.5209	72	24036.29
0.1	1	SLRTA	2.73e-2	**0.7684**	**0.7411**	9	**965.48**
		SRMF	**1.73e-2**	0.6100	0.5927	12	3918.90
		LRXV	1.64e-1	0.5788	0.4148	72	23977.27
0.01	1	SLRTA	2.14e-2	**0.6998**	**0.6784**	9	**974.81**
		SRMF	**2.03e-2**	0.5753	0.5550	12	3969.30
		LRXV	1.80e-1	0.5410	0.3610	72	25182.60
1	10	SLRTA	2.74e-2	**0.8405**	**0.8103**	9	**960.54**
		SRMF	**9.87e-3**	0.7625	0.7526	13	4068.73
		LRXV	1.48e-1	0.6863	0.5383	72	25545.70
1	0.1	SLRTA	2.79e-2	**0.7964**	**0.7685**	9	**956.96**
		SRMF	**1.21e-2**	0.6794	0.6673	13	4049.71
		LRXV	1.62e-1	0.6106	0.4506	72	27409.00
1	0.01	SLRTA	2.93e-2	**0.7649**	**0.7356**	9	**977.89**
		SRMF	**1.23e-2**	0.6287	0.6164	12	3866.67
		LRXV	1.64e-1	0.6090	0.4450	72	24870.82

3.5 本章小结

本章对网络流量异常检测问题，提出了一种更通用的张量优化模型，该模型既能处理不完全测量，也能处理链路测量的情况，并且对异常点进行稀疏正则化处理，对正常网络流量运用Tucker低秩约束进行时间稳定性和周期性正则化处理. 并且对非凸非连续优化模型进行基于稳定点的最优性条件分析，不仅为算法设计提供了理论基础，而且丰富了张量优化理论的内涵; 并且设计了一种有效的近端梯度算法来求解所提出的张量优化问题，该方法使用了截断高阶奇异值分解(ST-HOSVD)，并且在理论上证明了该算法的收敛性. 在网络流量追踪数据集Abilene 和GÈANT上及一个大型的合成数据集上进行了大量的数值实验，并与基于矩阵的异常检测方法进行比较，证明本文提出的稀疏张量优化方法在异常检测的准确率和计算时间方面都具有优势.

中国知网 https://www.cnki.net

第 4 章 结论与展望

4.1 本文结论

稀疏低秩张量优化是在大数据背景下，结合实际需求所产生的，在视频监控、数据挖掘、计算机视觉、信号处理等领域有着广泛的应用. 本文针对基于视频监控的背景消除以及网络流量异常检测这两个实际问题，建立了求解这些问题的优化模型，并设计求解相应模型的算法，在数值实验上表现优异. 本文的创新之处归纳总结如下:

(1) i) 在模型的理论研究方面：针对视频监控背景消除问题，本文建立了稀疏张量优化模型，在该模型中利用三阶视频张量不同模间的差分算子的ℓ_0-范数来表征视频前景的时空连续性，并利用张量Tucker分解来表征视频背景的时空相关性. 针对该模型，分析目标函数和约束函数的数学性质，利用变分分析方法对最优性条件进行分析，在理论上丰富了非凸非连续优化理论的内容，并方便算法的设计. ii) 在算法设计方面：利用硬阈值算子，本文设计了基于硬阈值算子的ADMM(HT-ADMM)方法进行求解，尽管理论上的收敛性并未证明，但是本文的数值结果表明该方法在PSNR、SSIM、F-measure等方面具有优势，即对稀疏前景和低秩背景进行了高精度的恢复和分离. 从视觉效果来看，本文提出的方法较好地恢复出清晰的视频并能分离出相对完整清晰的前景.

(2) i) 在模型的理论研究方面: 针对网络流量异常检测问题，本文基于异常点的稀疏性、Tucker低秩约束、正则化张量流量数据的时间稳定性和周期性，建立了稀疏低秩张量优化方法，用于解决在不完全测量和链路测量情况下的网络流量异常检测问题. 本文分析该模型的数学性质，挖掘出模型的一些好的理论结果，方便算法的设计，接着本文针对该优化问题进行β-稳定点和稳定点的最优性条件分析. ii) 在算法设计方面: 针对提出的模型，设计了非光滑非凸近端梯度算法，并证明其能够收敛到稳定点. 本文在Abilene和GÈANT网络追踪数据集以及大规模模拟数据集上进行了大量的数值实验，表明本文方法的有效性.

4.2 未来展望

本文在以下几个方面有待进一步研究：

(1) 视频监控背景消除的张量优化方法：由于本文中的HT-ADMM是一阶算法，因此在计算过程中只使用了函数的一阶导数信息. 未来的研究将考虑基于最

中国知网 https://www.cnki.net

优性分析的一些二阶方法，进一步加速迭代过程. 此外，由于张量建模在很大程度上依赖于所研究的特定视频的特征，未来的研究还将重点放在地铁监控等特殊视频场景的张量建模以及相应稀疏张量优化模型的算法设计上.

(2) 网络流量异常检测的张量优化方法：在未来的研究中将考虑具有非负性或流量数据带宽限制等更复杂的情况. 近来，针对直接OD流量测量下的在线网络流量异常检测问题，李等人在文献[76]中提出一种基于张量CP分解的快速在线更新方法，因此处理更多实际中的链路负载测量下的在线网络流量异常检测，也是我们未来的研究课题之一.

中国知网 https://www.cnki.net

参考文献

[1] The EC Funded CAVIAR project/IST 2001 37540, found at URL: http://homepages.inf.ed.ac.uk/rbf/CAVIAR/

[2] Mahony P Absil and Rodolphe Sepulchre. Optimization algorithms on matrix manifolds. *Princeton University Press*, 2008.

[3] Qasim Abualigah and Laith Mohammad. Feature selection and enhanced krill herd algorithm for text document clustering. *Springer Nature Switzerland AG*, 2019.

[4] Laith Mohammad Abualigah, Ahamad Tajudin Khader, and Essam Said Hanandeh. Hybrid clustering analysis using improved krill herd algorithm. *Applied Intelligence*, 48:4047–4071, 2018.

[5] Andrews Sobral and Antoine Vacavant. A comprehensive review of background subtraction algorithms evaluated with synthetic and real videos. *Computer Vision and Image Understanding*, 122:4–21, 2014.

[6] Andrews Sobral, Christopher Grover Baker, Thierry Bouwmans, and El-hadi ZAHZAH. Incremental and multi-feature tensor subspace learning applied for background modeling and subtraction. *In: International Conference Image Analysis and Recognition*, 94–103, 2014.

[7] Thierry Bouwmans. Traditional and recent approaches in background modeling for foreground detection: An overview. *Computer Science Review*, 11-12:31–66, 2014.

[8] Stephen Boyd and Lieven Vandenberghe. Convex Optimization. *Cambridge University Press*, 2004.

[9] Candès Emmanuel and Benjamin Recht. Exact matrix completion via convex optimization. *Foundations of Computational Mathematics*, 9(6): 717–772, 2009.

[10] Candès Emmanuel, Justin Romberg, and Terence Tao. Robust uncertainty principles: exact signal reconstruction from highly incomplete frequency information. *IEEE Transactions on Information Theory*, 52(2): 489–509, 2006.

[11] Candès Emmanuel and Terence Tao. Decoding by linear programming. *IEEE Transactions on Information Theory*, 51(12): 4203–4215, 2005.

中国知网 https://www.cnki.net

[12] Wenfei Cao, Yao Wang, Jian Sun, Deyu Meng, Can Yang, Cichocki Andrzej, and Zongben Xu. Total variation regularized tensor rpca for background subtraction from compressive measurements. *IEEE Transactions on Image Processing*, 25(9): 4075–4090, 2016.

[13] Volkan Cevher, Aswin C. Sankaranarayanan, Marco Duarte, Dikpal Reddy, Richard Baraniuk, and Rama Chellappa. Compressive sensing for background subtraction. *In: 10th European Conference on Computer Vision: Part II*, 155–168, 2008.

[14] Lixia Chen, Junli Liu, and Xuewen Wang. Background subtraction with kronecker-basis-representation based tensor sparsity and $l_{1,1,2}$ norm. *Multidimensional Systems and Signal Processing*, 5-6: 1–14, 2020.

[15] Andrzej Cichocki, Rafal Zdunek, Anh-Huy Phan, and Shun-ichi Amari. Nonnegative Matrix and Tensor Factorizations: Applications to Exploratory Multi-way Data Analysis and Blind source separation. *Wiley Publishing*, 2009.

[16] Ronald R Coifman, Frank B Geshwind, and Yves F Meyer. Noiselets. *Applied and Computational Harmonic Analysis*, 10(1): 27–44, 2001.

[17] Wei Deng, Mingjun Lai, Zhimin Peng, and Wotao Yin. Parallel multi-block admm with $o(1/k)$ convergence. *Journal of Scientific Computing*, 71(2):712–736, 2013.

[18] Marco Duarte, Dror Baron, Kevin Kelly, and Richard Baraniuk. A new compressive imaging camera architecture using optical-domain compression. *Computational Imaging IV at SPIE Electronic Imaging*, 6065: 43–52, 2006.

[19] Foucart Simon. Hard thresholding pursuit: An algorithm for compressive sensing. *SIAM Journal on Numerical Analysis*, 49(6): 2543–2563, 2011.

[20] Zhi Gao, Loong-Fah Cheong, and Yuxiang Wang. Block-sparse RPCA for salient motion detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 36(10): 1975–1987, 2014.

[21] Wenrui Hu, Yehui Yang, Wensheng Zhang, and Yuan Xie. Moving object detection using tensor-based low-rank and saliently fused-sparse decomposition. *IEEE Transactions On Image Processing*, 26(2): 724–737, 2017.

[22] Sajid Javed, Arif Mahmood, Thierry Bouwmans, and Soon Ki Jung. Background-foreground modeling based on spatiotemporal sparse subspace clustering. *IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society*, 26(12): 5840–5854, 2017.

[23] Hong Jiang, Wei Deng, and Zuowei Shen. Surveillance video processing using compressive sensing. *Inverse Problems and Imaging*, 6(2): 201–204, 2012.

中国知网 https://www.cnki.net

[24] Hong Jiang, Songqing Zhao, Zuowei Shen, Wei Deng, Paul A Wilford, and Raziel Haimi-Cohen. Surveillance video analysis using compressive sensing with low latency. *Bell Labs Technical Journal*, 18(4): 63–74, 2014.

[25] Brett W Bader and Tamara G Kolda. Efficient MATLAB computations with sparse and factored tensors. *SIAM Journal on Scientific Computing*, 30: 205–231, 2007.

[26] Brett W Bader and Tamara G Kolda. Tensor decompositions and applications. *SIAM Review*, 51(3): 455–500, 2009.

[27] Lieven De Lathauwer, Bart L.R. De Moor, and Joos Vandewalle. On the best rank-1 and rank-$(r_1, r_2, ..., r_n)$ approximation of higher-order tensors. *SIAM Journal On Matrix Analysis and Applications*, 21: 1324–1342, 2000.

[28] Liyuan Li, Weimin Huang, Irene Gu, and Qi Tian. Statistical modeling of complex backgrounds for foreground object detection. *IEEE Transactions on Image Processing*, 13(11): 1459–1472, 2004.

[29] Canyi Lu, Jiashi Feng, Yudong Chen, Wei Liu, Zhouchen Lin, and Shuicheng Yan. Tensor robust principal component analysis with a new tensor nuclear norm. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4): 925–938, 2020.

[30] Zhaosong Lu. Optimization over sparse symmetric sets via a nonmonotone projected gradient method. *arXiv:1509.08581*, 2015.

[31] Ziyan Luo, Xiaotong Yu, and Xiaoyu Li. An ℓ_0-norm minimization for energy-efficient timetabling in subway systems. *IEEE Access*, 7: 59422–59436, 2019.

[32] Nil Goyette, Pierre-Marc Jodoin, Fatih Porikli, Janusz Konrad, and Prakash Ishwar. Changedetection.net: A new change detection benchmark dataset. *In: 2012 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops*, 1–8, 2012.

[33] Massimo Piccardi. Background subtraction techniques: a review. *In: IEEE International Conference on Systems IEEE*, 3099–3104, 2005.

[34] Donald Goldfarb and Zhiwei (Tony) Qin. Robust low-rank tensor recovery: models and algorithms. *SIAM Journal on Matrix Analysis and Applications*, 35(1): 225–253, 2014.

[35] Tyrrell R Rockafellar and Roger Wets. Variational analysis. *Sobolev and BV Spaces, MPS-SIAM Series on Optimization*, 30: 324–326, 1998.

[36] Moein Shakeri and Hong Zhang. Moving object detection under discontinuous change in illumination using tensor low-rank and invariant sparse decomposition. *arXiv:1904.03175*, 2019.

中国知网 https://www.cnki.net

[37] Andrews Sobral, Sajid Javed, Soon Ki Jung, Thierry Bouwmans, and El-hadi ZAHZAH. Online stochastic tensor decomposition for background subtraction in multispectral video sequences. *In: IEEE International Conference on Computer Vision (ICCV), Workshop on Robust Subspace Learning and Computer Vision (RSL-CV)*, 946–953, 2015.

[38] Qiong Luo, Zhi Han, Xiai Chen, Yao Wang, Deyu Meng, Dong Liang, and Yandong Tang. Tensor rpca by bayesian cp factorization with complex noise. *In: IEEE International Conference on Computer Vision*, 5029–5038, 2017.

[39] Thierry Bouwmans and El-hadi ZAHZAH. Robust pca via principal component pursuit: A review for a comparative evaluation in video surveillance. *Computer Vision and Image Understanding*, 122:22–34, 2014.

[40] Michael B. Wakin, Jason N Laska, Marco F Duarte, Dror Baron, Shriram Sarvotham, Dharmpal Takhar, Kevin F Kelly, and Richard G Baraniuk. An architecture for compressive imaging. *In: Image Processing, 2006 IEEE International Conference*, 1273–1276, 2006.

[41] Yu Wang, Wotao Yin, and Jinshan Zeng. Global convergence of ADMM in nonconvex nonsmooth optimization. *Journal of Scientific Computing*, 78(1): 29–63, 2019.

[42] Zhou wang, Alan Bovik, and Eero P Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4): 600–612, 2014.

[43] Andrew E Waters, Aswin C Sankaranarayanan, and Richard G Baraniuk. SpaRCS: Recovering low-rank and sparse matrices from compressive measurements. *In: Neural Information Processing Systems (NIPS)*, 1089–1097, 2011.

[44] Stephen Wright, Robert D Nowak, and Mário Figueiredo. Sparse reconstruction by separable approximation. *In: IEEE International Conference on Acoustics, Speech and Signal Processing*, 57:2479–2493, 2008.

[45] Tianzhu Zhang, Si Liu, Narendra Ahuja, Ming-Hsuan Yang, and Bernard Ghanem. Robust visual tracking via consistent low-rank sparse learning. *International Journal of Computer Vision*, 111(2): 171–190, 2015.

[46] Tianzhu Zhang, Si Liu, Changsheng Xu, and Hanqing Lu. Mining semantic context information for intelligent video surveillance of traffic scenes. *IEEE Transactions on Industrial Informatics*, 9(1): 149–160, 2013.

[47] Qian Zhao, Deyu Meng, Zongben Xu, Wangmeng Zuo, and Lei Zhang. Robust principal component analysis with complex noise. *In: International Conference on Machine Learning*, 55–63, 2014.

中国知网 https://www.cnki.net

[48] Shenglong Zhou, Naihua Xiu, and Houduo Qi. Global and quadratic convergence of newton hard-thresholding pursuit. *Journal of Machine Learning Research*, 22(12):1-45, 2019.

[49] *The Abilene Observatory Data Collections*. Accessed:2013, Available: http://abilene.internet2.edu/observatory/data-collections.html.

[50] Selim Aksoy and Robert M Haralick. Feature normalization and likelihood-based similarity measures for image retrieval. *Pattern Recognition Letters*, 22:563–582, 2001.

[51] Hedy Attouch, JérôMe Bolte, Patrick Redont, and Antoine Soubeyran. Proximal alternating minimization and projection methods for nonconvex problems. an approach based on the Kurdyka-Łojasiewicz inequality. *Mathematics of Operations Research*, 35(2):438–457, 2010.

[52] Hedy Attouch, JérôMe Bolte, and Benar Fux Svaiter. Convergence of descent methods for semi-algebraic and tame problems: proximal algorithms, forward-backward splitting, and regularized Gauss-Seidel methods. *Mathematical Programming*, 137(1-2):91–129, 2013.

[53] Vic Barnett and Toby Lewis. Outliers in Statistical Data (3rd ed). *Chichester: John Wiley & Sons, Inc*, 1994.

[54] Amir Beck and Yonina C Eldar. Sparsity constrained nonlinear optimization: Optimality conditions and algorithms. *SIAM Journal on Optimization*, 23(3):1480–1509, 2013.

[55] Amir Beck and Marc Teboulle. A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, 2(1):183–202, 2009.

[56] Dimitri P Bertsekas. Nonlinear Programming, 2nd edition. *Athena Scientific, Belmont, MA*, 1999.

[57] Daniela Brauckhoff, Kave Salamatian, and Matin May. Applying PCA for traffic anomaly detection: Problems and solutions. *In Proceedings IEEE INFOCOM 2009, the 28th IEEE International Conference on Computer Communications*, 2866–2870, 2009.

[58] Markus M Breunig, Hans Peter Kriegel, Raymond T Ng, and Jörg Sander. LOF: Identifying density-based local outliers. *In Proceedings of the 2000 ACM SIGMOD international conference on Management of data*, 29:93–104, 2000.

[59] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys*, 41(3):1–58, 2009.

中国知网 https://www.cnki.net

[60] Maolin Che, Yimin Wei, and Hong Yan. The computation of low multilinear rank approximation of tensors via power scheme and random projection. *SIAM Journal on Matrix Analysis and Applications*, 41:605–636, 2020.

[61] Han Chen, Garvesh Raskutti, and Ming Yuan. Non-convex projected gradient descent for generalized low-rank tensor regression. *Journal of Machine Learning Research*, 20:1–37, 2019.

[62] Frank H Clarke. Optimization and Nonsmooth Analysis. *Wiley*, 1983.

[63] Mark A Davenport and Justin Romberg. An overview of low-rank matrix recovery from incomplete observations. *IEEE Journal of Selected Topics in Signal Processing*, 10(4):608–622, 2016.

[64] Carl Eckart and Gale Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1:211–218, 1936.

[65] Hadi Fanaee-T and Joao Gama. Tensor-based anomaly detection: An interdisciplinary survey. *Knowledge Based Systems*, 98:130–147, 2016.

[66] Xiao Fu, Shahana Ibrahim, Hoi-To Wai, Cheng Gao, and Kejun Huang. Block-randomized stochastic proximal gradient for low-rank tensor factorization. *IEEE Transactions on Signal Processing*, 68:2170–2185, 2020.

[67] Shangce Gao, Mengchu Zhou, Yirui Wang, Jiujun Cheng, Hanaki Yachi, and Jiahai Wang. Dendritic neuron model with effective learning algorithms for classification, approximation and prediction. *IEEE Transactions on Neural Networks and Learning Systems*, 30(2):601–604, 2019.

[68] Jean-Baptiste Hiriart-Urruty and Hai-Yen Le. From Eckart and Young approximation to Moreau envelopes and vice versa. *RAIRO Operations Research*, 47(3):299–310, 2013.

[69] Jean-Baptiste Hiriart-Urruty and Hai-Yen Le. A variational approach of the rank function. *TOP*, 21:207–240, 2013.

[70] Ling Huang, XuanLong Nguyen, Minos Garofalakis, Joseph M Hellerstein, Michael I Jordan, Anthony D Joseph, and Nina Taft. Communication-efficient online detection of network-wide anomalies. *In Proceedings IEEE INFOCOM 2007, the 26th IEEE International Conference on Computer Communications*, 134–142, 2007.

[71] Hiroyuki Kasai, Wolfgang Kellerer, and Martin Kleinsteuber. Network volume anomaly detection and identification in large-scale networks based on online time-structured traffic tensor tracking. *IEEE Transactions on Network and Service Management*, 13(3):636–650, 2016.

中国知网 https://www.cnki.net

[72] Tamara G Kolda and Brett W Bader. Tensor decompositions and applications. *SIAM Review*, 51(3):455–500, 2009.

[73] Anukool Lakhina, Konstantina Papagiannaki, Mark Crovella, Christophe Diot, Eric D Kolaczyk, and Nina Taft. Structural analysis of network traffic flows. *In ACM SIGMETRICS Performance Evaluation Review*, 61–72, 2004.

[74] Haiyen Le. Generalized subdifferentials of the rank function. *Optimization Letters*, 7:731–743, 2013.

[75] Runmei Li, Yinfeng Huang, and Jian Wang. Long-term traffic volume prediction based on k-means gaussian interval type-2 fuzzy sets. *IEEE/CAA Journal of Automatica Sinica*, 6(6):1344–1351, 2019.

[76] Xiaocan Li, Kun Xie, Xin Wang, Gaogang Xie, and Zheng Qin. Online internet anomaly detection with high accuracy: A fast tensor factorization solution. *In IEEE INFOCOM 2019-IEEE Conference on Computer Communications*, 1900–1908, 2019.

[77] Xin Li, Fang Bian, Mark Crovella, Christophe Diot, Ramesh Govindan, Gianluca Iannaccone, and Anukool Lakhina. Detection and identification of network anomalies using sketch subspaces. *In Proceedings of the 6th ACM SIGCOMM conference on Internet Measurement*, 147–152, 2006.

[78] Xin Li, Fang Bian, Hui Zhang, Christophe Diot, Ramesh Govindan, Wei Hong, and Gianluca Iannaccone. MIND: A distributed multi-dimensional indexing system for network diagnosis. *In Proceedings IEEE INFOCOM 2006, the 25th IEEE International Conference on Computer Communications*,1–12, 2006.

[79] Xin Li, Fang Bian, Hui Zhang, Christophe Diot, Ramesh Govindan, Wei Hong, and Gianluca Iannaccone. Sensitivity of PCA for traffic anomaly detection. *In Proceedings of the 2007 ACM SIGMETRICS International Conference on Measurement and Modeling of Computer Systems*, 109–120, 2007.

[80] Xinrong Li, Naihua Xiu, and Wen Song. Optimality conditions for rank-constrained matrix optimization. *Journal of the Operations Research Society of China*, 7(2):285–301, 2019.

[81] Chen Ling, Gaohang Yu, Liqun Qi, and Yanwei Xu. A parallelizable optimization method for missing internet traffic tensor data. *arXiv 2005.09838*, 2020.

[82] Yang Liu, Linfeng Zhang, and Yong Guan. Sketch-based streaming PCA algorithm for network-wide traffic anomaly detection. *In Proceedings 2010 International Conference on Distributed Computing Systems, ICDCS 2010, Genova, Italy, June 21-25, 2010*, 807–816, 2010.

中国知网 https://www.cnki.net

[83] Xin Luo, Hao Wu, Huaqiang Yuan, and MengChu Zhou. Temporal pattern-aware qos prediction via biased non-negative latent factorization of tensors. *IEEE Transactions on Cybernetics*, 50(5):1798–1809, 2020.

[84] Xin Luo, Mengchu Zhou, Yunni Xia, Qingsheng Zhu, Ahmed Chiheb Ammari, and Ahmed Alabdulwahab. Generating highly accurate predictions for missing qos data via aggregating nonnegative latent factor models. *IEEE Transactions on Neural Networks & Learning Systems*, 27(3):579–592, 2016.

[85] Xin Luo, Mengchu Zhou, Shuai Li, and Mingsheng Shang. An inherently non-negative latent factor model for high-dimensional and sparse matrices from industrial applications. *IEEE Transactions on Industrial Informatics*, 14:2011–2022, 2018.

[86] Xin Luo, MengChu Zhou, Shuai Li, YunNi Xia, Zhuhong You, QingSheng Zhu, and Hareton Leung. Incorporation of efficient second-order solvers into latent factor models for accurate prediction of missing qos data. *IEEE transactions on cybernetics*, 48(4):1216–1228, 2018.

[87] Rachel Minster, Arvind K Saibaba, and Misha E Kilmer. Randomized algorithms for low-rank tensor decompositions in the Tucker format. *SIAM Journal on Mathematics of Data Science*, 2(1):189–215, 2020.

[88] Boris S Mordukhovich. Variational Analysis and Generalized Differentiation. I. Basic Theory. *Grundlehren der Mathematischen Wissenschaften*, 48(3):619–620, 2006.

[89] Yurii Nesterov. A method of solving a convex programming problem with convergence rate O($1/k^2$). *Soviet Mathematics Doklady*, 27(2):372–376, 1983.

[90] Yurii Nesterov. Gradient methods for minimizing composite functions. *Mathematical Programming*, 140(1):125–161, 2013.

[91] Paul Nomikos and John F. MacGregor. Monitoring batch processes using multiway principal component analysis. *AIChE Journal*, 40(8):1361–1375, 1994.

[92] Benjamin Recht, Maryam Fazel, and Pablo A Parrilo. Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization. *SIAM Review*, 52(3):471–501, 2018.

[93] Tyrrell R Rockafellar and Roger J B Wets. Variational Analysis. *Springer Dordrecht Heidelberg London New York*, 2009.

[94] Liqun Qi and Ziyan Luo. Tensor analysis: spectral theory and special tensors. *SIAM*, 2017.

中国知网 https://www.cnki.net

[95] Matthew Roughan, Yin Zhang, Walter Willinger, and Lili Qiu. Spatio-temporal compressive sensing and internet traffic matrices (extended version). *IEEE/ACM Transations on Networking*, 20(3):662–676, 2012.

[96] Nicholas Sidiropoulos, Lieven De Lathauwer, Xiao Fu, Kejun Huang, Evangelos Papalexakis, and Christos Faloutsos. Tensor decomposition for signal processing and machine learning. *IEEE Transactions on Signal Processing*, 65(13):3551–3582, 2017.

[97] J.S. Solis-Chaves, Lucas L Rodrigues, C M Rocha-Osorio, and Alfeu Sguarezi J Filho. A long-range generalized predictive control algorithm for a dfig based wind energy system. *IEEE/CAA Journal of Automatica Sinica*, 6(5):1209–1219, 2019.

[98] Hui Tian, M Roughan, Yingpeng Sang, and Shen Hong. Diffusion wavelets-based analysis on traffic matrices. *In Parallel and Distributed Computing, Applications and Technologies (PDCAT), 2011 12th Internetional Conference on IEEE*, 116–121, 2011.

[99] Steve Uhlig, Bruno Quoitin, Jean Lepropre, and Simon Balon. Providing public intradomain traffic matrices to the research community. *ACM SIGCOMM Computer Communication Review*, 36(1):83–86, 2006.

[100] Nick Vannieuwenhoven, Raf Vandebril, and Karl Meerbergen. A new truncation strategy for the higher-order singular value decomposition. *SIAM Journal on Scientific Computing*, 34(2):A1027–A1052, 2012.

[101] Yao Wang, Deyu Meng, and Ming Yuan. Sparse recovery: from vectors to tensors. *National Science Review*, 5:756–767, 2018.

[102] Gaogang Xie, Kun Xie, Jun Huang, Xin Wang, and Jigang Wen. Fast low-rank matrix approximation with locality sensitive hashing for quick anomaly detection. *In Proceedings IEEE INFOCOM 2017, the 36th IEEE International Conference on Computer Communications*, 1–9, 2017.

[103] Kun Xie, Xiaocan Li, Xin Wang, Jiannong Cao, Gaogang Xie, Jigang Wen, Dafang Zhang, and Zheng Qin. On-line anomaly detection with high accuracy. *IEEE/ACM Transactions on Networking*, 26:1–14, 2018.

[104] Kun Xie, Xiaocan Li, Xin Wang, Gaoyang Xie, Jigang Wen, Jiannong Cao, and Dafang Zhang. Fast tensor factorization for accurate internet anomaly detection. *IEEE/ACM Transactions on Networking*, 25:3794–3807, 2017.

[105] Kun Xie, Lele Wang, Xin Wang, Gaogang Xie, and Jigang Wen. Sequential and adaptive sampling for matrix completion in network monitoring systems. *In Proceedings IEEE INFOCOM 2015, the 34th IEEE International Conference on Computer Communications*,2443–2451, 2015.

中国知网 https://www.cnki.net

[106] Kun Xie, Lele Wang, Xin Wang, Gaoyang Xie, Jigang Wen, and Guangxing Zhang. Accurate recovery of internet traffic data: A tensor completion approach. *In Proceeding of IEEE INFOCOM 2016*, 1–9, 2016.

[107] Jieping Ye. Generalized low rank approximations of matrices. *Machine Learning*, 61:167–191, 2005.

[108] Bin Zhang, Jiahai Yang, Jianping Wu, Donghong Qin, and Lei Gao. PCA-subspace method - is it good enough for network-wide anomaly detection. *In Network Operations and Management Symposium (NOMS), IEEE*, 359–367, 2012.

[109] Yin Zhang, Zihui Ge, Albert Greenberg, and Matthew Roughan. Network anomography. *In Proceedings of the 5th ACM SIGCOMM conference on Internet Measurement*, 317–330, 2005.

[110] Manqi Zhao and Venkatesh Saligrama. Anomaly detection with score functions based on nearest neighbor graphs. *In Proceedings of the 22nd International Conference on Neural Information Processing Systems*, 2250–2258, 2009.

[111] Oseledets I V. Tensor-train decomposition. *In SIAM Journal on Scientific Computing*, 2295-2317, 2011.

[112] Huibin Zhou, Dafang Zhang, Kun Xie, and Yuxiang Chen. Robust spatio-temporal tensor recovery for internet traffic data. *In 2016 IEEE Trustcom/BigDataSE/I SPA*, 1404–1411, 2016.

[113] Sheheryar Khan, Guoxia Xu, and Hong Yan. Tensor learningusing N-mode SVD for dynamic background modelling and subtraction. *In 2017 Second Russian-Pacific Conference on Computer Technology and Applications (RPC)*, 6-10, 2017.

[114] Eleftherios Kofidis and Phillip A Regalia. Tensor Approximation and Signal Processing Applications. *Contempory Mathematics*, 2001.

[115] Aaron Schein, John Paisley, David M Blei, and Hanna Wallach. Bayesian Poisson Tensor Factorization for Inferring Multilateral Relations from Sparse Dyadic Event Counts. *In proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1045-1054, 2015.

[116] Jianguang Zhang, Yahong Han, and Jianmin Jiang. Tucker decomposition-based tensor learning for human action recognition. *Multimedia Systems*, 22(3):343-353, 2016.

[117] Andrzej Cichocki, Rafal Zdunek, Anh-Huy Phan, and Shun-ichi Amari. Nonnegative matrix and tensor factorizations: applications to exploratory multi-way data analysis and blind source separation. *Hobolcen Wiley*, 10-20, 2009.

中国知网 https://www.cnki.net

[118] Feiping Nie, Heng Huang, Xiao Cai, and Chris Ding. Efficient and robust feature selection via joint $l_{1,1,2}$-norms minimization. *In Advances in Neural Information Processing Systems 23: 24th Annual Conference on Neural Information Processing Systems*, 1-9, 2010.

[119] Liping Wang, Songcan Chen, and Yuanping Wang. A unified algorithm for mixed-minimizations and its $l_{2,p}$ application in feature selection. *Computational Optimization and Applications*, 58(2):409-421, 2014.

[120] Liping Wang and Songcan Chen. Joint representation classification for collective face recognition. *Pattern Recognition*, 63:182-192, 2017.

[121] Avinash Ratre and Vinod Pankajakshan. Tucker tensor decomposition-based tracking and Gaussian mixture model for anomaly localisation and detection in surveillance videos. *IET Computer Vision*, 12(6):933-940, 2018.

[122] 曹蓉. 计算机网络流量异常检测技术研究. 计算机产品与流通, 7:31, 2020.

[123] 孟永伟, 秦涛, 赵亮, 马文强, 王换招. 利用残差分析的网络异常流量检测方法. 西安交通大学学报, 54(1):42-48+84, 2020.

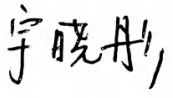
[124] 董书琴, 张斌. 基于深度特征学习的网络流量异常检测方法. 电子与信息学报, 42(3):695-703, 2020.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：  　　签字日期：　2021年6月1日

中国知网　https://www.cnki.net

学位论文数据集

表1.1：数据集页

关键词*	密级*	中图分类号*	UDC	论文资助
背景消除; 张量Tucker分解; 交替方向乘子法; 网络流量异常检测; 近端梯度法	公开	O224	519.8	国家自然基金
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	理学	硕士
论文题名*		并列题名		论文语种*
稀疏低秩张量优化方法及其应用				中文
作者姓名*	宇晓彤		学号*	18121627
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村3号	100044
学科专业*		研究方向*	学制*	学位授予年*
系统理论		复杂系统的建模、优化与分析	3 年	2021
论文提交日期*	2021年5月31日			
导师姓名*	罗自炎		职称*	教授
评阅人	答辩委员会主席*		答辩委员会成员	
	王立春		孔令臣、王周宏、桂文豪、倪旭敏	
电子版论文提交格式文本（）图像（）视频（）音频（）多媒体（）其他（） 推荐格式：application/msword；application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
		北京交通大学		完全
论文总页数*	77			
共33项，其中带*为必填数据，为22项。				

中国知网 https://www.cnki.net