北京交通大學

博士学位论文

稀疏低秩支持张量机的优化理论与算法研究

Optimization Theory and Algorithms for Sparse and Low Rank Support Tensor Machine

作者：王双月

导师：罗自炎

北京交通大学

2024年 6月

中国知网 https://www.cnki.net

学校代码：10004 密级：公开

北京交通大学

博士学位论文

稀疏低秩支持张量机的优化理论与算法研究

Optimization Theory and Algorithms for Sparse and Low Rank Support Tensor Machine

作者姓名：王双月 学　　号：19118016

导师姓名：罗自炎 职　　称：教授

学位类别：理学 学位级别：博士

学科专业：系统理论 研究方向：运筹学中的统计分析

北京交通大学

2024年 6月

中国知网 https://www.cnki.net

答辩委员会名单

答辩委员会	姓名	工作单位	职称
主席	文再文	北京大学	教授
委员	韩丛英	中国科学院大学	教授
委员	张立平	清华大学	副教授
委员	张超	北京交通大学	教授
委员	周声龙	北京交通大学	教授
秘书	罗俊杰	北京交通大学	讲师

中国知网 https://www.cnki.net

摘要

在大数据时代背景下, 以张量形式存在的数据分布于医学成像、计算机视觉、工程与统计等众多领域. 由于张量的多重线性结构, 与张量相关的很多问题都是NP-难的. 张量分解通过挖掘高维张量数据的内部结构信息获得数据的低维表示, 成为分析处理张量数据的一种有效工具. 张量理论的发展使得基于张量的建模与计算应运而生并备受关注. 支持张量机 (STM) 作为监督张量学习方法的一种, 在机器学习及相关应用中受到众多关注, 包括遥感成像、视频处理、故障诊断等. 本文侧重于从稀疏低秩的角度对 STM 进行探讨, 充分挖掘数据的结构信息, 构建合理的分类模型, 设计高效的求解算法, 具有重要的实际意义. 主要研究工作包括:

(1) 针对近似线性可分的二分类张量数据, 已有的 STM 模型中采用的损失函数多为 0/1 损失函数的代理函数, 本章直接使用 0/1 损失这一本原函数作为损失函数, 并利用张量数据的低秩性, 提出了基于 $\ell_{0/1}$ 软间隔损失的低秩 STM 模型. 对于这一非凸非连续的张量优化问题, 设计交替方向乘子法进行求解, 并通过对模拟数据和真实数据进行数值实验, 验证模型与算法的有效性.

(2) 针对近似线性可分的二分类张量数据, 已有的 STM 工作缺乏对张量权重参数稀疏性的考虑, 本章利用 ℓ_1 正则化进行特征选择, 并结合 0/1 损失提出了双稀疏秩一 STM 模型. 对于带有非线性等式约束的非凸非连续优化问题, 设计基于 Bregman 距离的交替方向乘子法来求解, 并证明了在温和条件下, 借助 KL 性质, 算法具有全局收敛性. 基于模拟数据的数值实验结果验证了所提算法的有效性.

(3) 针对非线性可分的二分类张量数据, 本章在特征空间的背景下对对偶变量施加稀疏性建立了稀疏 STM, 并利用核技巧进行非线性分类, 如广泛使用的高斯 RBF 核. 为了减轻张量高斯 RBF 核函数中恒定核宽度带来的局部风险, 以数据依赖的方式对核函数进行尺度化. 利用子空间牛顿法求解非凸不连续的优化模型, 以实现有效的局部收敛计算. 在实际数据集上进行了数值实验, 数值结果表明, 所提出的两阶段稀疏 STM 方法在分类精度方面是有效的.

(4) 针对近似线性可分的多分类张量数据, 本章设计了一种基于张量格式的分段二次损失函数来刻画训练过程中样本造成的损失. 在此基础上, 提出了多模态稀疏 STM 模型用来直接处理多分类问题. 采用牛顿类型算法从对偶角度求解所提模型. 基于真实数据集的数值实验结果表明了所提方法在分类精度和训练时间方面的有效性.

关键词： 支持张量机; 稀疏低秩; 算法; 尺度化核函数; 分类

中国知网 https://www.cnki.net

分类号： 65K10; 90C46; 68T05

中国知网 https://www.cnki.net

ABSTRACT

In the context of the practical application needs of the big data era, data in the form of tensors exist in medical imaging, computer vision, engineering and statistics, and so on. Due to the multilinear structure of tensors, many problems related to tensors are NP-hard. Tensor decomposition has become an effective tool to analyze and process tensorial data by exploiting the structural information of high dimensional tensor to obtain a low dimensional representation. With the development of tensor theory, the modeling and computing based on tensors have attracted much attention. As one of the supervised tensor learning methods, the support tensor machine (STM) for tensorial data classification is receiving increasing attention in machine learning and related applications, including remote sensing imaging, video processing, fault diagnosis, etc. In this thesis, we focus on combining tensor decomposition and optimization algorithms to discuss the STM model from the perspective of sparsity and low-rank to exploit the structural information of data, construct reasonable classifiers and design efficient algorithms, which have important practical significance. The contributions are summarized as follows:

Consider the linearly separable tensorial data for binary classification, the involved loss functions in most of the existing STM models are surrogates of the $0/1$ loss function. Considering the original $0/1$ loss for the binary classification, a low rank STM is proposed with consideration of the intrinsic low-rankness of tensorial data. The resulting nonconvex and discontinuous tensor optimization problem is solved by an alternating direction method of multipliers. Numerical experiments are conducted on synthetic data and real dataset to demonstrate the effectiveness of the proposed approach.

Consider the linearly separable tensorial data for binary classification, the sparsity for tensorial weight parameter is lack of consideration in most of the previous research work. A doubly sparse rank-one support tensor machine model is developed in which the ideal 0/1 loss is adopted and ℓ_1 regularization is applied for feature selection. The alternating direction method of multipliers with Bregman distance is designed for the resulting nonconvex and noncontinuous optimization problem with nonlinear equality constraints. Under the mild conditions, the proposed approach owns global convergence in virtue of the KL property. The numerical experiments based on synthetic data show the effectiveness of the proposed method.

中国知网 https://www.cnki.net

Consider the nonlinearly separable tensorial data for binary classification, a novel sparse STM model is built by imposing the sparsity on the dual variables in the context of the feature space, which facilitates the nonlinear classification with kernel tricks, such as the widely used Gaussian RBF kernel. To alleviate the local risk associated with the constant width in the tensor Gaussian RBF kernel, a scaling strategy on the kernel function in a data-dependent way is advocated. To resolve the nonconvex and discontinuous optimization problem, a subspace Newton method is tailored for the sparsity-constrained optimization for effective computation with local convergence. Numerical experiments are conducted on real datasets, and the numerical results demonstrate the effectiveness of our proposed two-stage sparse STM approach in terms of classification accuracy.

Consider the linearly separable tensorial data for multiple classification, a piecewise quadratic loss function in tensorial format is designed to describe the loss in the training process. In this premise, a multimodal sparse STM model is developed and Newton type algorithm is tailored for solving the proposed model. Numerical experiments conducted on the real datasets show the effectiveness of the proposed methods in terms of classification accuracy and training time.

KEYWORDS: Support tensor machine; Sparsity and low rank; Scaling kernel function; Algorithm; Classification

CLASSNO: 65K10; 90C46; 68T05

中国知网 https://www.cnki.net

主要符号对照表

$\mathbb{R}$	实数域
$\mathbb{R}^m$	m 维欧式空间
$\mathbb{R}^{I_1 \times I_2 \times \cdots \times I_N}$	N 阶张量空间
x	标量
$\mathbf{x}$	向量
X	矩阵
$\mathcal{X}$	张量
$\mathbf{x}^\top$	向量 $\mathbf{x}$ 的转置
x_i	向量 $\mathbf{x}$ 的第 i 个分量
$\mathbf{1}$	分量全为1的向量
$[M]$	指标集 $\{1, 2, \cdots, M\}$
$\|T\|$	集合 $T \subseteq [M]$ 所含元素的个数
$\bar{T}$	指标集 T 的补集
$\boldsymbol{\alpha}$	对偶变量
$\boldsymbol{\Lambda}$	拉格朗日乘子
$\kappa(\cdot, \cdot)$	核函数
K	核矩阵
$\mathbb{I}$	单位矩阵
$\mathrm{Diag}(\mathbf{x})$	以向量 $\mathbf{x}$ 的分量为对角元素的对角矩阵
$\langle \cdot, \cdot \rangle$	内积
$\circ$	外积
$\otimes$	Hadamard积
$\times_n$	张量的 $n-$ 模乘积
$\times_{J_p, \cdots, J_q}^{I_s, \cdots, I_t}$	张量多模态乘积
$\mathcal{A} \circledcirc \mathcal{B}$	张量 $\mathcal{A}$ 的每一个元素都大于等于张量 $\mathcal{B}$ 的每个元素
$\|\mathbf{x}\|_0$	向量 $\mathbf{x} \in \mathbb{R}^m$ 的 ℓ_0-范数, 即向量 $\mathbf{x}$ 中非零元素的个数
$\|\mathbf{x}\|_1$	向量 $\mathbf{x} \in \mathbb{R}^m$ 的 ℓ_1-范数
$\|\mathbf{x}\|$	向量 $\mathbf{x} \in \mathbb{R}^m$ 的 ℓ_2-范数
$\|\mathcal{X}\|_F$	张量 $\mathcal{X}$ 的 Frobenius 范数
$\square$	证明结束

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景.....1
1.2 研究现状.....2
1.3 预备知识.....5
1.3.1 张量基本概念.....5
1.3.2 变分分析基础.....9
1.4 本文主要工作.....12
1.5 本文创新点总结.....13
2 0/1 损失低秩支持张量机.....15
2.1 优化模型.....15
2.2 算法设计.....16
2.3 数值实验.....18
2.3.1 模拟数据.....19
2.3.2 真实数据.....20
2.4 本章小结.....22
3 双稀疏秩一支持张量机.....23
3.1 优化模型.....24
3.2 算法设计.....27
3.3 收敛性分析.....29
3.4 数值实验.....41
3.5 本章小结.....43
4 尺度化核技术稀疏支持张量机.....45
4.1 优化模型.....45
4.2 尺度化核函数.....47
4.3 算法设计.....52
4.4 数值实验.....54
4.4.1 数据集.....56
4.4.2 数值结果.....56
4.5 本章小结.....59
5 多模态稀疏支持张量机.....61
5.1 优化模型.....61
5.2 算法设计.....63
5.3 数值实验.....65
5.3.1 数据集.....66

中国知网　https://www.cnki.net

5.3.2 数值结果.....67
5.4 本章小结.....69
6 总结与展望.....71
参考文献.....73

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景

机器学习是人工智能的一种分支领域, 致力于让计算机系统通过分析和处理大量的数据, 发现数据中的模式和规律, 然后利用这些模式和规律对新的数据进行预测、分类或优化. 随着国家大数据战略的实施和现代科学技术的发展, 数据已经成为推动社会进步和科学发展的重要驱动力. 传统的数据处理方法已经无法有效应对多元化、复杂化的数据形式, 这就需要引入更加高效灵活的数据表示方式. 张量, 作为一种多维数组, 能够很好地表达多元化的数据特征, 同时也为机器学习算法提供了更加丰富的数据表达形式. 以张量形式收集的数据广泛存在于视频监控、数据挖掘、社交网络测量、神经科学等众多领域[1–5]. 例如, 以二阶张量 (矩阵) 表示的灰度人脸图像[6], 以三阶张量表示的彩色图像[7]、灰度视频序列[8]、步态剪影序列[9]、高光谱数据[10], 以四阶张量表示的彩色视频[11] 等. 在这样的背景下, 研究如何利用张量来处理多元化的数据, 以支持机器学习算法的发展变得尤为重要. 通过对张量数据的分析、建模和处理, 可以更好地挖掘数据之间的关联性和规律性, 从而提升机器学习算法的性能和效果. 这种研究不仅有助于推动数据科学领域的发展, 也有利于加速人工智能技术在各个领域的应用和推广, 促进现代科学技术的持续进步与创新.

虽然使用张量数据表示复杂数据具有很好的多维特征表达能力, 但在分析处理数据时, 许多经典的机器学习方法是基于向量空间的, 不能直接处理非向量形式的数据. 如果直接进行向量化处理, 不仅会带来数据空间结构信息的损失, 忽略数据不同模态之间的互补性与相关性, 无法满足当前信息时代日益复杂化与多元化的数据的刻画需求, 也会造成维数灾难以及小样本问题[12,13]. 因而, 基于张量的统计学习方法因时而生并引起关注, 如多线性主成分分析 (multilinear principal component analysis, MPCA)[13]、有监督的张量学习框架 (supervised tensor learning, STL)[14,15]、多线性判别分析 (multilinear discriminant analysis, MDA)[16] 等. 支持向量机 (support vector machine, SVM)[17] 是统计学与最优化交叉融合产生的一类重要的机器学习分类方法, 其处理的数据是以向量形式存储的. 该方法于 1995 年首次提出, 并广泛应用于图像分类[18,19]、疾病诊断[20–24] 等领域, 其基本思想是寻找一个最优的划分超平面, 使得不同类别的样本尽可能地分开, 并且远离超平面. 作为 SVM 的一种高阶推广, 支持张量机 (support tensor machine, STM)[15,25–30]以

中国知网 https://www.cnki.net

张量形式作为输入, 借助张量这一数据结构, 不仅可以极大程度地能保留原始数据的结构信息, 同时可以借助张量的低秩性来减少数据冗余, 缓解小样本问题带来的过拟合现象. 已有的张量学习文献中, 张量低秩性的刻画方式可简单概括为如下三类 : (1) 张量分解转化. 其基本思想是借助张量分解, 将原来的待估张量权重参数转化为分解中的因子矩阵与/或核张量来进行计算. 常用张量分解包括 CANDECOMP/PARAFAC (CP) 分解[31]、Tucker 分解[32]、张量列车 (tensor train, TT) 分解[33] 等. (2) 低秩正则. 其基本思想是将张量秩函数或者近似函数以正则项的形式加到相应极小化问题的目标函数中. 例如, 文献 [34,35] 中使用的张量多线性核范数正则等. (3) 低秩约束. 其基本思想是将张量低秩作为约束条件引入到原来的极小化问题中. 在秩的上界为先验信息时, 这一方式可以直观准确地表示出低秩性.

已有的一些研究结果表明, 在机器学习方法中直接处理张量类型数据, 不但可以保留结构信息和不同模态之间的相关性, 同时可以结合张量分解借助张量计算方法简化数学运算, 使得对复杂数据的处理更加高效和可靠. 基于上述讨论, 借助张量优化的理论与算法来发展支持张量机技术, 是兼具基础性与创新性的前沿课题. 问题本身来源于实际生活, 使得研究具有十分重要的实际应用价值. 本文侧重于针对不同类型的数据, 思考如何通过张量数据蕴含的结构信息来构建合理的分类模型, 并设计高效的算法来进行求解.

1.2 研究现状

支持张量机作为一种机器学习分类方法, 以张量样本作为输入, 寻找一个超平面使正负类的样本尽可能的分开, 以实现间隔最大化和经验损失最小化. 对于二分类问题, 给定训练集 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 其中 $\mathcal{X}_i \in \mathbb{R}^{I_1\times\cdots\times I_N}$ 为张量样本, $y_i \in \{-1, 1\}$ 为其对应的标签, STM 通过给定的 M 个样本训练出最优超平面 $\langle \mathcal{W}, \mathcal{X}\rangle + b = 0$, 其中 $\mathcal{W} \in \mathbb{R}^{I_1\times\cdots\times I_N}$ 是张量权重参数, $b \in \mathbb{R}$ 是偏置. 若考虑直接将经典的 SVM 推广至张量形式可得优化模型为

$$\begin{aligned} \min_{\mathcal{W},b,\xi} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + C\sum_{i=1}^{M}\xi_i \\ \text{s.t.} \quad & y_i(\langle \mathcal{W}, \mathcal{X}_i\rangle + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i \in [M]. \end{aligned} \tag{1-1}$$

上述模型弥补了经典的 SVM 向量化处理张量数据的不足, 但本质上仍为 SVM 的一个线性映射, 未能体现出张量数据的内部结构信息. 基于这样的考虑, 2006 年 Cai 等[11] 首次提出 STM 的概念并应用于文本分类. 这一 STM 方法是通过计算一个秩

中国知网 https://www.cnki.net

一的二阶张量 (矩阵) 权重 $\mathcal{W} := uv^\top$ 来确定分类超平面, 与 SVM 相比, 极大减少了待估参数个数. 2007 年 Tao 等[15] 提出了基于高阶张量的 STM 模型, 其权重参数为 CP 分解意义下的秩一张量, 其优化模型为

$$\begin{aligned} \min_{\{\mathbf{w}_n\}_{n=1}^N, b, \xi} \quad & \tfrac{1}{2}\|\mathbf{w}_1 \circ \cdots \circ \mathbf{w}_N\|_F^2 + C\sum_{i=1}^M \xi_i \\ \text{s.t.} \quad & y_i(\mathcal{X}_i \prod_{n=1}^N \times_n \mathbf{w}_n + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0, i \in [M]. \end{aligned} \tag{1-2}$$

并设计了交替投影方法求解上述模型, 即因张量权重参数为秩一张量, 分类器利用一组向量将张量数据逐一沿每一个模式映射为一个数. 为了弥补秩一张量的弱表达性, Kotsia 等[36] 提出基于张量 CP 分解的高秩 STM 模型并应用于视觉识别, 其中的权重张量为多个秩一张量之和. 这里的高秩 STM 是相对秩一 STM 而言. 除了张量 CP 分解外, Kotsia 等[25] 提出了基于张量 Tucker 分解的 STM, 同样减少对张量权重参数的计算. 考虑到数据冗余与小样本问题, 所使用的秩与数据维数相比, 仍是一个比较小的数. 基于这一低秩的思想, 杨[37] 提出了低秩约束的 STM 的一般模型. 这里的低秩约束可以通过如上 CP 分解的形式进行转化, 亦可通过惩罚的方式作为低秩正则项加到目标函数中. 基于低秩正则化的思想, Lian[34] 借助张量多线性核范数来近似张量秩函数, 建立凸 STM 模型并分析其统计性质. 这里的多线性核范数可以看成是张量 Tucker 分解意义下的张量秩的一种凸松弛. 除了上述提到的张量 CP 分解与 Tucker 分解外, 张量列车 (tensor train, TT) 分解也是目前常用的一种张量分解方式. 这一分解也被用于 STM 的数据降维中. 例如, Chen 等[38] 提出了基于张量 TT 分解的 STM 模型. 上述所提工作均侧重于线性近似可分的张量数据. 众所周知, 线性可分即意味着所有训练样本可被完全正确分开. 当这些样本中存在一些离群点时, 除去这些离群点, 剩下大部分的样本数据是线性可分的, 即称数据线性近似可分. 这两类数据均可通过输入数据所在空间的超平面进行分类.

已有的 STM 在处理这类问题时, 大多借助合页损失函数 (hinge loss) 来表示离群样本造成的损失, 其数学表达式为

$$\ell_{hl}(t) = \begin{cases} t, & t > 0, \\ 0, & t \leq 0. \end{cases} \tag{1-3}$$

它是如下 0/1 损失函数

$$\ell_{0/1}(t) = \begin{cases} 1, & t > 0, \\ 0, & t \leq 0, \end{cases} \tag{1-4}$$

的一种最常见的凸的代理函数. 注意到 0/1 损失函数对 $t \leq 0$ 的样本, 取值为 0; 对 $t > 0$ 的样本, 取值为 1. 因此, 0/1 损失函数是二分类问题最理想的损失函数[17]. 值

中国知网 https://www.cnki.net

得注意的是, 这一损失函数在原点处是非凸非连续的, 因而涌现出各种不同的代理函数. 例如, 王等[39] 总结了 0/1 损失函数及其 18 种不同的SVM 代理损失函数的变分性质. 由于损失函数决定着模型的稀疏性和对训练数据噪音的敏感性, 各类代理函数与本原的 0/1 损失函数相比, 在一定程度上可以便利计算与理论分析, 但是在分类精度上可能有所影响. 鉴于此, Wang 等[40] 提出基于 0/1 软间隔损失函数的 SVM 模型, 并设计了交替方向乘子法 (alternating direction method of multipliers, ADMM) 来求解, 提高了分类精度.

而在许多实际应用中, 线性决策边界难以适应真实数据[41]. 因此, 如何保留张量数据的多维结构来构建非线性 STM 学习模型是值得研究的. 而对于非线性可分的数据, SVM 通过引入核函数将输入空间转至更高维的空间中进行分类, 其优化问题可以从对偶的角度进行有效求解. 受此启发, He 等[42] 考虑对模型 (1-1) 引入了非线性映射 $\Phi : \mathcal{X} \in \mathbb{R}^{I_1\times\cdots\times I_N} \to \Phi(\mathcal{X}) \in \mathbb{R}^{H_1\times\cdots\times H_N}$, 将张量样本映射到更高维的希尔伯特空间, 或称为张量特征空间, 其维度由所取的映射 $\Phi(\cdot)$ 决定. 借助与在原始张量空间中进行线性分类相似的思想对数据进行非线性分类, 可得

$$\begin{aligned} \min_{\mathcal{W},b,\xi} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + C\sum_{i=1}^{M}\xi_i \\ \text{s.t.} \quad & y_i(\langle\mathcal{W},\Phi(\mathcal{X}_i)\rangle + b) \geq 1-\xi_i, \\ & \xi_i \geq 0, i \in [M], \end{aligned}$$

其中, $\mathcal{W} \in \mathbb{R}^{H_1\times\cdots H_N}$. 对于上述模型, 从张量特征空间来看, 可视为一个线性模型. 然而, 若从原始张量空间来看, 又可视为一个非线性模型. 通过引入张量空间中的核函数, 文献 [42] 从对偶角度提出了 DuSK 模型, 并借助张量 CP 低秩分解来简化计算. 特别地, 当核函数为线性核时, DuSK 模型即退化为 Hao 等[43] 提出的线性支持高阶张量机模型 (SHTM). 关于 STM 基于其它张量分解与核函数结合的应用, 可参考文献 [44–47]. 作为最常用的核函数之一, 恒定核宽度的高斯 RBF 核在距离度量上存在一定的局部风险和缺乏灵活性, 特别是在处理模式空间的不均匀性时. 为了解决这个问题, 考虑到非线性映射可诱导黎曼几何结构[48], 文献 [49–53] 考虑对基于高斯核函数的 SVM 进行保形修改的尺度化技术来间接改变核宽度, 为了提高分类性能, 提出了一种两阶段的方法: 第一阶段使用原始核来寻找支持向量的位置, 第二阶段基于支持向量的先验信息对核进行保形尺度化,来构建最终的非线性分类器.

此外, 上述研究均关注于数据的二分类问题, 但在现实中多分类学习也较常见, 如垃圾分类[54–56], 天气分类[57] 等. 已有的关于 SVM 求解多分类问题的工作可分为三类: (1) 间接法. 即将多分类问题拆分为多个二分类进行求解. 常用的拆分策略有“一对一” (One vs. One, OVO) 或“一对多” (One vs. Rest, OVR). 若

中国知网 https://www.cnki.net

给定 N 个类别的样本, 利用 OVO 方法求解会产生 $N(N-1)/2$ 个二分类任务, 而 OVR 只需训练 N 个分类器, 如文献 [58]; (2) 直接法. 对 SVM 优化模型进行改写, 通过求解最优化问题直接实现多分类 [59,60]; (3) 将 SVM 与其他可实现多分类的学习算法相结合进行求解问题. 考虑到 SVM 不能以张量作为输入, Ma 等[61] 利用张量的多模态乘积构建了支持多模态张量机 (support multimode tensor machine, SMTM) 直接求解张量数据的多分类问题, 其思想类似于传统的 ECOC 策略, 具体地说, 给定训练集 $\{\mathcal{X}_i, \mathcal{Y}_i\}_{i=1}^M$, 其中 $\mathcal{X}_i \in \mathbb{R}^{I_1\times\cdots\times I_s\times\cdots\times I_t\times\cdots\times I_N}$ 为张量样本, $\mathcal{Y}_i \in \mathbb{R}^{I_1\times\cdots\times I_{s-1}\times I_{t+1}\times\cdots\times I_N\times J_1\times\cdots\times J_{p-1}\times J_{q+1}\times\cdots\times J_H}$ 为对应的张量标签, 其每个元素为 $\{1,-1\}$, $\mathcal{I}$ 是全 1 张量. 张量权重参数 $\mathcal{W} = \mathbf{w}_1 \circ \cdots \circ \mathbf{w}_N \in \mathbb{R}^{J_1\times\cdots\times J_p\times\cdots\times J_q\times\cdots\times J_H}$ 由向量 $\mathbf{w}_n$, $n = 1,\ldots,N$ 生成, 维度 $J_p = I_s,\ldots,J_q = I_t$, $\mathcal{B}$ 为偏置张量, 可得 SMTM 的优化模型为

$$\begin{aligned}\min_{\{\mathbf{w}_n\}_{n=1}^N,\mathcal{B},\xi}\ & \frac{1}{2}\left\|\prod_{n=1}^{N}\circ\mathbf{w}_n\right\|_F^2 + C\sum_{j=1}^{M}\sum_{i_1=1}^{I_1}\cdots\sum_{i_{s-1}=1}^{I_{s-1}}\sum_{i_{t+1}=1}^{I_{t+1}}\cdots\sum_{i_N=1}^{I_N}(\xi_j)_{i_1\cdots i_{s-1}i_{t+1}\cdots i_N}\\ \text{s.t.}\ & \mathcal{Y}_i \odot \left(\left(\prod_{n=1}^{N}\circ\mathbf{w}_n\right)\times_{J_p,\ldots,J_q}^{I_s,\ldots,I_t}\mathcal{X}_i + \mathcal{B}\right) \geqslant \mathcal{I} - \xi_j,\\ & (\xi_j)_{i_1\cdots i_{s-1}i_{t+1}\cdots i_N} \geq 0,\quad j\in[M], i_n\in[I_n], n\in[N].\end{aligned} \tag{1-5}$$

随着张量理论的发展与 STM 在张量数据分类中的优势, STM 已经应用于遥感成像[62–65]、图像处理[66,67]、金融[68,69]、机械故障诊断[70,71]、交通[72] 等多个领域. 为了处理不同的分类任务, 大量关于 STM 的变体分类模型也得到了发展, 如单分类 STM[27,73], 孪生 STM[28–30], 半监督 STM[74,75] 及处理不平衡数据的 STM[70,76] 等.

1.3 预备知识

1.3.1 张量基本概念

本小节主要介绍张量相关的基本概念, 更多有关张量多线性代数的内容可参考文献 [77,78]. 称 $\mathcal{X} \in \mathbb{R}^{I_1\times\cdots\times I_N}$ 为 N 阶张量, 其 $(i_1,\ldots,i_N)$- 分量记为 $x_{i_1,\ldots,i_N}$, $i_j = 1,\ldots,I_j$, $j = 1,\ldots,N$. 这里 N 为张量 $\mathcal{X}$ 的阶数, I_1, ..., I_N 为相应的维数. 特别地, 一阶张量为向量, 二阶张量为矩阵.

定义 1.1： 任意给定张量 $\mathcal{X},\mathcal{Y} \in \mathbb{R}^{I_1\times\cdots\times I_N}$, 其张量内积定义为

$$\langle\mathcal{X},\mathcal{Y}\rangle := \sum_{i_1,\ldots,i_N} x_{i_1,\ldots,i_N}y_{i_1,\ldots,i_N}.$$

中国知网 https://www.cnki.net

由这一内积诱导出的张量 Frobenius 范数为 $\|\mathcal{X}\|_F := \sqrt{\langle \mathcal{X}, \mathcal{X} \rangle}$. 对任意整数 $n \in [N]$, 固定张量 $\mathcal{X}$ 元素中除第 n 个下标以外的所有下标, 可以得到一个 I_n 维列向量, 称其为张量 $\mathcal{X}$ 的一个模 n- 纤维. 将所有这些模 n- 纤维按列组成一个 $I_n \times \Pi_{i \neq n} I_i$ 维矩阵, 称其为张量 $\mathcal{X}$ 的模 n- 展开, 记为 $X_{(n)}$.

定义 1.2： 任意给定一个矩阵 $U \in \mathbb{R}^{r_n \times I_n}$, 张量 $\mathcal{X}$ 与 U 的模 n- 积, 记为 $\mathcal{X} \times_n U$, 是 $\mathbb{R}^{I_1 \times \cdots \times I_{n-1} \times r_n \times I_{n+1} \times \cdots \times I_N}$ 空间中的一个张量, 其 $(i_1, \ldots, i_{n-1}, j, i_{n+1}, \ldots, i_N)$- 分量定义为

$$(\mathcal{X} \times_n U)_{i_1, \ldots, i_{n-1}, j, i_{n+1}, \ldots, i_N} := \sum_{i_n=1}^{I_n} x_{i_1, \ldots i_n, \ldots, i_N} u_{j, i_n}.$$

容易验证

$$(\mathcal{X} \times_n U)_{(n)} = U X_{(n)}. \tag{1-6}$$

定义 1.3： 给定张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, $\mathcal{Y} \in \mathbb{R}^{J_1 \times \cdots \times J_M}$, $\mathcal{X}$ 与 $\mathcal{Y}$ 的外积定义为

$$(\mathcal{X} \circ \mathcal{Y})_{i_1 \cdots i_N j_1 \cdots j_M} := x_{i_1 \cdots i_N} y_{j_1 \cdots j_M} \in \mathbb{R}^{I_1 \times \cdots \times I_N \times J_1 \times \cdots \times J_M}.$$

定义 1.4： 给定 N 阶张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, 若存在正整数 $r_1, \ldots, r_N$, 矩阵 $U_i \in \mathbb{R}^{I_i \times r_i}$ (通常是列正交的), $i = 1, \ldots, N$, 以及张量 $\mathcal{G} \in \mathbb{R}^{r_1 \times \cdots \times r_N}$, 使得

$$\begin{aligned} \mathcal{X} &= \mathcal{G} \times_1 U_1 \times_2 U_2 \times \cdots \times_N U_N \\ &=: [\![\mathcal{G}; U_1, U_2, \ldots, U_N]\!], \end{aligned} \tag{1-7}$$

则称 (1-7) 为张量 $\mathcal{X}$ 的 Tucker 分解, 其中 $\mathcal{G}$ 称为核张量, 与 $\mathcal{G}$ 每个模式相乘的矩阵 $U_1, \ldots, U_N$ 称为因子矩阵.

张量 $\mathcal{X}$ 的 Tucker 秩定义为向量 $(\mathrm{rank}(X_{(1)}), \cdots, \mathrm{rank}(X_{(N)}))$, 简记为 $\mathrm{rank}_T(\mathcal{X})$, 其中的第 n 个分量为张量模 n- 展开的矩阵秩, 称为张量 $\mathcal{X}$ 的 n- 秩. 由 (1-6) 不难验证, 张量 $\mathcal{X}$ 的 Tucker 秩是满足(1-7)的最小的 $r_1, \ldots, r_N$ 组成的. 图 1.1 给出一个 Tucker 秩为 (r_1, r_2, r_3) 的三阶张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 的 Tucker 分解示意图, 其中核张量为 $\mathcal{G} \in \mathbb{R}^{r_1 \times r_2 \times r_3}$, 因子矩阵为 $U_i \in \mathbb{R}^{I_i \times r_i}$, $i = 1, 2, 3$.

定义 1.5： 给定 N 阶张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, 若 $\mathcal{X}$ 可被表示为

$$\mathcal{X} = \sum_{r=1}^{R} \mathbf{u}_r^{(1)} \circ \mathbf{u}_r^{(2)} \circ \cdots \circ \mathbf{u}_r^{(N)} \tag{1-8}$$

其中, "$\circ$" 为向量外积, 向量 $\mathbf{u}_r^{(j)} \in \mathbb{R}^{I_j}$, $r = 1, \ldots, R$, $j = 1, \ldots, N$, 则称 (1-8) 为张量 $\mathcal{X}$ 的一个 CP 分解. 特别地, 若 $R = 1$, $\mathcal{X}$ 为秩一张量.

中国知网 https://www.cnki.net

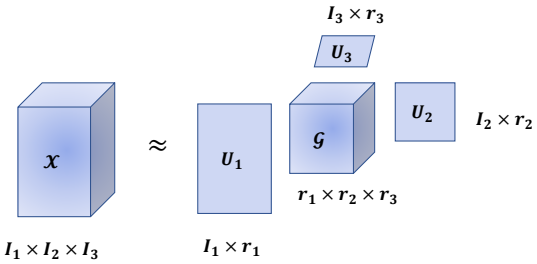


图 1.1 三阶张量的 Tucker 分解

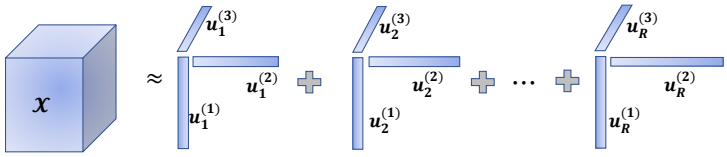


图 1.2 三阶张量的 CP 分解.

Fig 1.2 CP decomposition of a third-order tensor.

张量 $\mathcal{X}$ 的 CP 秩是指 $\mathcal{X}$ 用秩一张量之和表示时所需要的秩一张量的最小个数. 图 1.2 给出 CP 秩为 R 的三阶张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 的 CP 分解示意图. 由分解式 (1-7) 与 (1-8) 不难看出, 当核张量 $\mathcal{G}$ 的各个维数相同且为对角张量时, Tucker 分解就退化为 CP 分解, 因而 CP 分解可以看作是 Tucker 分解的一种特殊形式, 也意味着 Tucker 分解比 CP 分解更具一般性. 定义 Tucker 低秩张量集合为

$$\mathcal{S} := \{\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N} : \operatorname{rank}_T(\mathcal{X}) \leq (r_1, \ldots, r_N)\}.$$

由文献 [79] 的引理 2.2 可知, $\mathcal{S}$ 是非空闭集. 因而任意张量在该集合上的投影一定存在, 即

$$\Pi_{\mathcal{S}}(\mathcal{X}) := \arg\min_{\mathcal{Y} \in \mathcal{S}} \|\mathcal{X} - \mathcal{Y}\|_F = \arg\min_{\mathcal{Y}} \left\{ \|\mathcal{X} - \mathcal{Y}\|_F^2 + \delta_{\mathcal{S}}(\mathcal{X}) \right\} \neq \emptyset, \quad \forall \mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}, \tag{1-9}$$

其中 $\delta_{\mathcal{S}}$ 为示性函数, 其定义式为

$$\delta_{\mathcal{S}}(\mathcal{X}) := \begin{cases} 0, & \mathcal{X} \in \mathcal{S}, \\ +\infty, & \mathcal{X} \notin \mathcal{S}. \end{cases} \tag{1-10}$$

关于这一非凸集上的投影计算, 可以通过截断类型算法, 如 ST-HOSVD[80] 及其改进方法[81]; 或者采用迭代类型方法, 如高阶正交迭代 (HOOI) 以及随机投影类型方法等[82].

对于特征选择和/或降维的目的, 张量低秩近似可以通过给定一个小的 R 利用 CP 分解产生, 并使用线搜索策略增强的交替最小二乘 (ALS) 算法[83] 获得. 由此得到的低秩 CP 分解格式可证明有利于张量核函数的设计. 一个典型的例子是在文献 [42] 中提出的对偶结构保持内核 (DuSK).

中国知网 https://www.cnki.net

定义 1.6： (张量核函数) 令 ϕ 是向量空间中常规的特征映射. 给定张量 $\mathcal{X}, \mathcal{Y} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, 其 CP 分解为

$$\mathcal{X} = \sum_{r=1}^{R} \prod_{n=1}^{N} \circ \mathbf{x}_r^{(n)} \quad \mathcal{Y} = \sum_{r=1}^{R} \prod_{n=1}^{N} \circ \mathbf{y}_r^{(n)},$$

张量核函数定义为

$$\kappa(\mathcal{X}, \mathcal{Y}) = \left\langle \Phi\left(\sum_{r=1}^{R} \prod_{n=1}^{N} \circ \mathbf{x}_r^{(n)}\right), \Phi\left(\sum_{r=1}^{R} \prod_{n=1}^{N} \circ \mathbf{y}_r^{(n)}\right) \right\rangle = \sum_{p=1}^{R} \sum_{q=1}^{R} \prod_{n=1}^{N} \kappa\left(\mathbf{x}_p^{(n)}, \mathbf{y}_q^{(n)}\right), \quad (1\text{-}11)$$

其中, 诱导的非线性特征映射 $\Phi : \mathbb{R}^{I_1 \times \cdots \times I_N} \to \mathbb{R}^{H_1 \times \cdots \times H_N}$ 在 $\Phi : \sum_{r=1}^{R} \prod_{n=1}^{N} \circ \mathbf{x}_r^{(n)} \to \sum_{r=1}^{R} \prod_{n=1}^{N} \circ \phi\left(\mathbf{x}_r^{(n)}\right)$ 的意义下保留了分解结构.

此外, 张量列车 (TT) 分解也是一种常用的张量分解形式.

定义 1.7： 给定张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, 若张量 $\mathcal{X}$ 可被表示为

$$\mathcal{X}(i_1, \cdots, i_N) = \mathcal{X}^{(1)}(:, i_1, :) \cdots \mathcal{X}^{(N)}(:, i_N, :), \quad (1\text{-}12)$$

其中, $\mathcal{X}^{(k)}(:, i_k, :)$ 为固定第二个指标下的矩阵, 张量 $\mathcal{X}^{(k)} \in \mathbb{R}^{r_k \times I_k \times r_{k+1}}$ 称为 TT 核, $r_1 = r_{N+1} = 1$, 称 (1-12) 为张量 $\mathcal{X}$ 的 TT 分解. 称向量 $(r_2, \cdots, r_N)$ 为张量的 TT 秩.

图 1.3 给出了 TT 秩为 (r_2, r_3) 的三阶张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 的 TT 分解示意图.

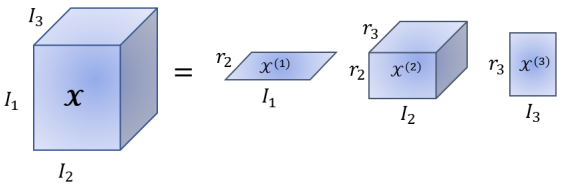


图 1.3　三阶张量的 TT 分解.

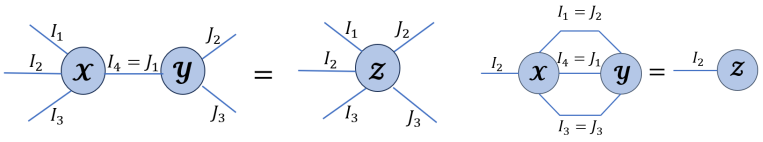
Fig 1.3　TT decomposition of a third-order tensor.

定义 1.8： 给定张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_s \times \cdots \times I_t \times \cdots \times I_N}$, $\mathcal{Y} \in \mathbb{R}^{J_1 \times \cdots \times J_p \times \cdots \times J_q \times \cdots \times J_M}$, 其中 $I_s = J_p, \cdots, I_t = J_q$, $\mathcal{X}$ 与 $\mathcal{Y}$ 的多模态乘积[84] 定义为 $\mathcal{Z} = \mathcal{X} \times_{J_p, \ldots, J_q}^{I_s, \ldots, I_t} \mathcal{Y}$, 其 $(i_1, \cdots, i_{s-1}, i_{t+1}, \cdots, i_N, j_1, \cdots, j_{p-1}, j_{q+1}, \cdots, j_M)$- 分量定义为

$$z_{i_1 \cdots i_{s-1} i_{t+1} \cdots i_N j_1 \cdots j_{p-1} j_{q+1} \cdots j_M} = \sum_{i_s=1}^{I_s} \cdots \sum_{i_t=1}^{I_t} x_{i_1 \cdots i_s \cdots i_t \cdots i_N} y_{j_1 \cdots j_p \cdots j_q \cdots j_M}.$$

中国知网　https://www.cnki.net

该运算可以看作是两个张量在相同维度下的缩并运算. 图 1.4 给出了两个张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3 \times I_4}$ 和 $\mathcal{Y} \in \mathbb{R}^{J_1 \times J_2 \times J_3}$ 的多模态乘积的示意图.



(a) (b)

图 1.4 两个张量的多模态乘积.

Fig 1.4 Multimodal products of two tensors.

1.3.2 变分分析基础

本小节主要介绍后续章节需要用到的优化理论结果, 涉及非凸非光滑最优性理论的内容.

定义 1.9： (下半连续函数[85]): 设函数 $f : \mathbb{R}^m \to (-\infty, +\infty]$ 满足

$$\liminf_{\mathbf{x} \to \bar{\mathbf{x}}} f(\mathbf{x}) \geq f(\bar{\mathbf{x}}),$$

则 f 在 $\bar{\mathbf{x}}$ 处是下半连续函数. 当 f 在 $\mathbb{R}^m$ 中的每一点都满足上述条件, 称 f 是下半连续函数.

定义 1.10： (Moreau 包络函数[85]): 设函数 $f : \mathbb{R}^m \to (-\infty, +\infty]$ 为正常的下半连续函数. 对于 $\mathbf{y} \in \mathbb{R}^m$ 和 $\lambda > 0$, Moreau包络函数为

$$M_{\lambda f}(\mathbf{y}) := \min_{\mathbf{x} \in \mathbb{R}^m} \left\{ f(x) + \frac{1}{2\lambda} \|\mathbf{x} - \mathbf{y}\|^2 \right\}.$$

定义 1.11： (邻近点算子[85]): 设函数 $f : \mathbb{R}^m \to (-\infty, \infty]$ 是正常的下半连续函数. 给定 $y \in \mathbb{R}^m$ 和 $\lambda > 0$, 邻近点算子定义为

$$\mathrm{Prox}_{\lambda f}(\mathbf{y}) := \arg\min_{x \in \mathbb{R}^m} \left\{ f(x) + \frac{1}{2\lambda} \|\mathbf{x} - \mathbf{y}\|^2 \right\}.$$

定义 1.12： (共轭函数[85]): 设函数 $f : \mathbb{R}^m \to (-\infty, \infty]$ 是正常的下半连续函数. 其共轭函数为

$$f^*(y) := \sup_{x \in \mathbb{R}^m} \{\langle x, y \rangle - f(x)\}.$$

定义 1.13： (距离函数[86]): 给定 $\mathbf{x} \in \mathbb{R}^m$ 和非空闭凸集 $\Omega \subseteq \mathbb{R}^m$, 距离函数的定义为

$$\mathrm{dist}(\mathbf{x}, \Omega) := \inf\{\|\mathbf{x} - \omega\| : \omega \in \Omega\}.$$

中国知网 https://www.cnki.net

定义 1.14： (次微分[85]) 给定函数 $f:\mathbb{R}^m\to(-\infty,\infty]$ 以及点 $\mathbf{u}\in\mathbb{R}^m$, 若 $f(\mathbf{u})$ 是有限的,

(i) 定义 f 在 $\mathbf{u}$ 点处的正则次微分为

$$\hat{\partial}f(\mathbf{u}):=\left\{\mathbf{v}\in\mathbb{R}^m:\liminf_{\mathbf{x}\to\mathbf{u}}\frac{f(\mathbf{x})-f(\mathbf{u})-\langle\mathbf{v},\mathbf{x}-\mathbf{u}\rangle}{\|\mathbf{x}-\mathbf{u}\|}\geq 0\right\}.$$

(ii) 定义 f 在 $\mathbf{u}$ 点处的极限次微分为

$$\partial f(\mathbf{u}):=\{\mathbf{v}\in\mathbb{R}^m:\text{存在序列 }\mathbf{x}^k\xrightarrow{f}\mathbf{u},\mathbf{v}^k\in\hat{\partial}f(\mathbf{x}^k)\text{ 使得 }\mathbf{v}^k\to\mathbf{v}\}.$$

(iii) 定义 f 在 $\mathbf{u}$ 点处的地平次微分为

$$\partial^\infty f(\mathbf{u}):=\{\mathbf{v}\in\mathbb{R}^m:\text{存在序列 }\mathbf{x}^k\xrightarrow{f}\mathbf{u},\mathbf{v}^k\in\hat{\partial}f(\mathbf{x}^k)\text{ 满足对某一序列}\sigma^k\searrow 0\text{ 有 }\sigma^k\mathbf{v}^k\to\mathbf{v}\}.$$

(iv) 定义 f 在 $\mathbf{u}$ 点处的 Clarke 次微分为

$$\partial^C f(\mathbf{u}):=\{\mathbf{v}\in\mathbb{R}^m:\langle\mathbf{v},\xi\rangle\leq f^o(\mathbf{u};\xi),\forall\,\xi\in\mathbb{R}^m\},$$

其中, $f^o(\mathbf{u};\xi)$ 为 f 在 $\mathbf{u}$ 处沿方向 $\xi\in\mathbb{R}^m$ 上的 Clarke 方向导数, 即

$$f^o(\mathbf{u};\xi):=\lim_{\epsilon\downarrow 0}\limsup_{\substack{\mathbf{x}\to\mathbf{u}\\ \rho\downarrow 0}}\inf_{\xi\in\mathbf{v}+\epsilon B}\frac{f(\mathbf{x}+\rho\xi)-f(\mathbf{x})}{\rho}.$$

若 f 是凸函数, 则极限次微分将变成凸函数的次微分, 即

$$\partial f(\mathbf{u})=\{\mathbf{v}\in\mathbb{R}^m:f(\mathbf{x})-f(\mathbf{u})\geq\langle\mathbf{v},\mathbf{x}-\mathbf{u}\rangle,\forall\mathbf{x}\in\mathbb{R}^m\}.$$

接下来给出一些特殊函数的临近点算子的具体形式.

引理 1.1： (软阈值算子[87]): 取 $f(\mathbf{x})=\lambda\|\mathbf{x}\|_1$, 其邻近点算子称为软阈值算子, 定义为

$$\mathrm{Prox}_{\lambda\|\cdot\|_1}(\mathbf{y})=\mathrm{sign}(\mathbf{y})\cdot\max\{|\mathbf{y}|-\lambda,\mathbf{0}\}.$$

引理 1.2： 给定 $\boldsymbol{\alpha}\in\mathbb{R}^m$, 定义硬阈值算子

$$\begin{aligned}\mathbb{P}_s(\boldsymbol{\alpha})&:=\arg\min_{\mathbf{u}}\{\|\mathbf{u}-\boldsymbol{\alpha}\|:\|\mathbf{u}\|_0\leq s\}\\&=\{(\boldsymbol{\alpha}_T;\mathbf{0}):T\in\mathbb{T}_s(\boldsymbol{\alpha})\},\end{aligned}$$

其中,

$$\mathbb{T}_s(\boldsymbol{\alpha}):=\left\{T\subseteq[m]:\begin{array}{l}|T|=s,\\ |\alpha_i|\geq|\alpha_j|,\forall\,i\in T,\forall\,j\notin T.\end{array}\right\}.$$

中国知网 https://www.cnki.net

引理 1.3： 给定 $\gamma, c > 0$, $\ell_{0/1}$ 的邻近点算子[40] 表达式为

$$\mathrm{Prox}_{\gamma c\mathcal{L}_{0/1}}(\mathbf{u}) := \begin{bmatrix} \mathrm{Prox}_{\gamma c\ell_{0/1}}(u_1) \\ \vdots \\ \mathrm{Prox}_{\gamma c\ell_{0/1}}(u_m) \end{bmatrix}, \forall\, \mathbf{u} \in \mathbb{R}^m,$$

其中,

$$\mathrm{Prox}_{\gamma c\ell_{0/1}}(s) := \begin{cases} s, & \text{若 } s > \sqrt{2\gamma c}, \\ \{0, s\}, & \text{若 } s = \sqrt{2\gamma c}, \\ 0, & \text{若 } 0 \le s < \sqrt{2\gamma c}, \\ s, & \text{若 } s < 0, \end{cases} \quad \forall\, s \in \mathbb{R}.$$

性质 1.3.1： 对于给定的 $\mathbf{u} \in \mathbb{R}^m$, $\ell_{0/1}$ 函数在 $\mathbf{u} \in \mathbb{R}^m$ 处的正则、极限和地平次微分[88] 均相等, 其显式表达式为

$$\begin{aligned} \Omega(\mathbf{u}) \quad &:= \hat{\partial}\ell_{0/1}(\mathbf{u}) = \partial\ell_{0/1}(\mathbf{u}) = \partial^{\infty}\ell_{0/1}(\mathbf{u}) \\ &= \left\{ \mathbf{v} \in \mathbb{R}^m : v_i \begin{cases} \ge 0, & u_i = 0, \\ = 0, & u_i \ne 0, \end{cases} i \in [m] \right\}. \end{aligned} \tag{1-14}$$

定义 1.15： (稳定点[89]): 满足 $0 \in \partial f(\mathbf{x})$ 的点 $\mathbf{x}$ 称为 f 的稳定点 .

定义 1.16： 可微凸函数 $\varphi : \mathbb{R}^n \to \mathbb{R}$ 的 Bregman 距离[90] 为

$$D_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla\varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle, \forall\, \mathbf{x}, \mathbf{y} \in \mathbb{R}^n.$$

性质 1.3.2： 令 φ 为一凸函数, $\Delta_{\varphi}(\cdot, \cdot)$ 为相应的 Bregman 距离, 则 $D_{\varphi}(\cdot, \cdot)$ 满足以下性质:

(i) 非负性: $D_{\varphi}(\mathbf{x}, \mathbf{y}) \ge 0$, $D_{\varphi}(\mathbf{x}, \mathbf{x}) = 0$, $\forall\, \mathbf{x}, \mathbf{y}$;

(ii) 凸性: $D_{\varphi}(\mathbf{x}, \mathbf{y})$ 在 $\mathbf{x}$ 处具有凸性, 在 $\mathbf{y}$ 不一定具有凸性;

(iii) 强凸性: 若 φ 是 $\delta-$ 强凸的, 则 $D_{\varphi}(\mathbf{x}, \mathbf{y}) \ge \frac{\delta}{2}\|\mathbf{x} - \mathbf{y}\|^2$, $\forall\, \mathbf{x}, \mathbf{y}$.

给定 $\eta \in (0, +\infty]$, 记 Ψ 为满足如下条件全体凹函数 $\psi : [0, \eta) \to [0, +\infty)$ 的集合: (i) ψ 在 0 处连续, 在区间 $(0, \eta)$ 上一阶连续可微; (ii) $\psi(0) = 0$; (iii) $\psi'(t) > 0$, $\forall\, t \in (0, \eta)$.

定义 1.17： (KL 性质[91]): 设 $f : \mathbb{R}^n \to (-\infty, +\infty]$ 是正常下半连续函数, $\bar{\mathbf{x}} \in \mathrm{dom}\, \partial f := \{\mathbf{x} \in \mathbb{R}^n : \partial f(\mathbf{x}) \ne \emptyset\}$. 若存在 $\eta \in (0, +\infty]$, $\bar{\mathbf{x}}$ 的邻域 $\mathcal{U}$ 以及某一凹函数 $\psi \in \Psi$, 使得如下 Kurdyka-Łojasiewicz 不等式成立

$$\psi'(f(\mathbf{x}) - f(\bar{\mathbf{x}}))\mathrm{dist}(0, \partial f(\mathbf{x})) \ge 1, \forall \mathbf{x} \in \mathcal{U} \cap \{\mathbf{x} | f(\bar{\mathbf{x}}) < f < f(\bar{\mathbf{x}}) + \eta\},$$

中国知网 https://www.cnki.net

则称函数 f 在点 $\bar{\mathbf{x}}$ 处满足 Kurdyka-Łojasiewicz (KL) 性质. 若函数 f 在 $\mathrm{dom}\partial f$ 中的每一点都具有 KL 性质, 则称 f 为一个 KL 函数.

定义 1.18： (一致 KL 性质[91]): 设$f:\mathbb{R}^n\to(-\infty,+\infty]$ 是正常下半连续函数, Ω 为紧集. 若 $\forall\,\mathbf{x}\in\Omega$, 有 $f(\mathbf{x})$ 为常值且在 Ω 上满足 KL 性质, 则存在 $\varepsilon>0,\eta>0,\psi\in\Psi$, 使得对每个 $\bar{\mathbf{x}}\in\Omega$ 及 $\mathbf{x}\in\{\mathbf{x}\in\mathbb{R}^n:\mathrm{dist}(\mathbf{x},\Omega)<\varepsilon\}\cap\{\mathbf{x}:f(\bar{\mathbf{x}})<f(\mathbf{x})<f(\bar{\mathbf{x}})+\eta\}$, 都有

$$\psi'(f(\mathbf{x})-f(\bar{\mathbf{x}}))\mathrm{dist}(0,\partial f(\mathbf{x}))\geq 1.$$

引理 1.4： [92] (引理 1.2) 令 $Q\in\mathbb{R}^{p\times n}$ 为一非零矩阵, μ_Q 为 $QQ^\top$ 的最小正特征值. 记 $\mathrm{Im}(Q):=\{Q\mathbf{x}:\mathbf{x}\in\mathbb{R}^n\}$ 为 Q 的像空间, P_Q 为在 $\mathrm{Im}(Q)$上的欧氏投影. 则

$$\|P_Q(\mathbf{u})\|\leq\frac{1}{\sqrt{\mu_Q}}\|Q^\top\mathbf{u}\|,\mathbf{u}\in\mathbb{R}^p.$$

1.4 本文主要工作

作为支持向量机的一种高阶推广, 用于处理张量数据分类的支持张量机在众多领域中获得了广泛的运用. 目前已有的 STM 研究成果都是在寻找高维数据的低秩结构信息. 除了挖掘数据蕴含的低秩信息外, 基于先验信息来合理的构造正则项或约束条件, 利用张量子空间提高数据的信息表达能力, 提高模型的学习能力, 也具有一定的研究意义. 本文将充分挖掘数据的低秩、稀疏等特性对支持张量机的优化模型进行深入的研究. 论文的具体内容研究如下:

在第二章中, 对于近似线性可分的二分类数据, 考虑二分类的本原损失函数——0/1 损失, 结合高阶张量数据的低秩约束, 提出了 0/1 损失低秩 STM 模型并将其用于图像分类问题,并设计了交替方向乘子法来求解该优化问题, 通过数值实验验证算法的有效性.

在第三章中, 对于近似线性可分的二分类数据, 提出了双稀疏秩一支持张量机, 该模型不但保留了 0/1 损失函数对张量样本选择, 还对张量权重参数考虑了 ℓ_1 正则化进行特征选择. 对于带有非线性等式约束的非连续优化模型, 定义了邻近算子稳定点, 分析了其与最优解的关系, 并设计了带有 Bregman 距离的交替方向乘子法进行求解, 在温和条件下, 借助 KL 性质证明了全局收敛性, 并且数值实验验证了算法的性能.

在第四章中, 对于非线性可分的二分类数据, 考虑到已有的 STM 方法在数据约简方面缺乏对支持张量的考虑, 建立了一种稀疏 STM 模型, 通过稀疏约束来控制支持张量的数量. 由于实际生活中的张量数据并不都是线性可分的, 借助张量高斯 RBF 核函数进行非线性分类. 为了缓解 RBF 核函数恒定核宽度带来的局部风

中国知网 https://www.cnki.net

险, 我们提出了一种两阶段的分类方法: 在第一阶段, 对所提的稀疏 STM 进行训练以获得支持张量的相关信息; 在第二阶段, 利用第一阶段所得到的相关信息, 以数据依赖的方式对核函数进行尺度化. 由于稀疏约束的存在, 两阶段中所求解的优化模型具有非凸不连续的特性. 为了解决这一计算难题, 提出了一种适合稀疏约束优化的子空间牛顿法以实现有效的局部收敛计算. 最后, 将算法用在实际数据集上, 通过数值实验说明所提的两阶段稀疏 STM 方法有效.

在第五章中, 对于近似线性可分的多分类数据, 提出了一种直接处理张量数据多分类的 STM 方法. 其中, 训练过程中的损失函数为一种新的基于张量格式的损失函数. 此外, 为了缓解小样本的过拟合现象, 对对偶变量加以稀疏性, 构造了多模态稀疏支持张量机模型. 对所提的模型采用牛顿法求解, 并基于真实数据集的数值实验结果说明所提算法有效.

在第六章中, 对全文研究内容进行总结, 并给出了关于 STM 的未来研究方向.

1.5 本文创新点总结

本文围绕稀疏低秩支持张量机的优化理论和算法展开, 建立有效的模型求解张量数据的分类问题, 其主要创新点如下:

(1) 针对近似线性可分的二分类数据, 考虑二分类的本原损失0-1损失, 分别建立了基于0/1损失函数的低秩支持张量机和双稀疏秩一支持张量机模型及其算法;

(2) 针对非线性可分的二分类数据, 利用核技巧和稀疏约束建立了稀疏支持张量机方法, 并提出了两阶段算法对核函数进行尺度化以减少恒定核宽度带来的局部风险;

(3) 针对近似线性可分的多分类数据, 构造了张量损失函数, 并利用多模态乘积提出了可直接处理多分类问题的稀疏多模态支持张量机方法.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

2　0/1 损失低秩支持张量机

本章主要关注近似线性可分的张量数据二分类问题. 已有的 STM 在刻画训练过程中样本造成的损失多采用合页损失, 它是 0/1 损失的一种常见的凸代理函数. 考虑二分类的本原损失函数为 0/1 损失, 本章研究 0/1 损失作为损失函数的支持张量机.

2.1　优化模型

对于张量数据的二分类问题, 给定训练集 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 其中张量 $\mathcal{X}_i \in \mathbb{R}^{I_1\times\cdots\times I_N}$ 为输入数据, $y_i \in \{-1, 1\}$ 是其对应的标记. STM 的基本思想是寻找一个最优的超平面 $\langle\mathcal{W}, \mathcal{X}\rangle + b = 0$ 将样本尽可能划分开来,其中待求参数 $\mathcal{W} \in \mathbb{R}^{I_1\times\cdots\times I_N}$ 为权重, $b \in \mathbb{R}$ 为偏置. 在允许异常点存在的情形下, 相应的软间隔低秩 STM 的优化问题[37] 为:

$$\begin{aligned} \min_{\mathcal{W},b,\xi} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + C\sum_{i=1}^M \xi_i \\ \text{s.t.} \quad & y_i(\langle\mathcal{W}, \mathcal{X}_i\rangle + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0, i \in [M], \\ & \text{Rank}(\mathcal{W}) \leq \mathbf{r}, \end{aligned} \tag{2-1}$$

其中 Rank(·) 为张量的任一给定类型的秩, $\mathbf{r}$ 为相应张量秩的上界, $C > 0$ 为损失项的惩罚参数. 借助合页损失函数 (1-3), 模型 (2-1) 可等价转化为:

$$\begin{aligned} \min_{\mathcal{W},b} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + C\sum_{i=1}^M \ell_{hl}(1 - y_i(\langle\mathcal{W}, \mathcal{X}_i\rangle + b)) \\ \text{s.t.} \quad & \text{Rank}(\mathcal{W}) \leq \mathbf{r}. \end{aligned}$$

考虑到张量秩在不同分解下有不同的定义, 在本文中, 选择基于 Tucker 分解的低秩约束来直观地表现张量的低秩性. 采用 Tucker 秩, 而非 CP 秩的原因主要是: (1) CP 秩难以准确计算, 而 Tucker 秩可以通过相应的矩阵秩唯一确定; (2) 与 CP 分解相比, Tucker 分解允许张量数据在每个模式上有不同数量的秩. 当张量数据的低秩性在不同维度上有倾斜时, 选用 Tucker 秩更为灵活 [36]. STM 作为 SVM 的推广模型, 损失函数的选取同样重要. 考虑到 0/1 函数 (1-4) 为二分类问题最理想的损失函数, 我们提出如下低秩支持张量机模型:

$$\begin{aligned} \min_{\mathcal{W},b} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + C\sum_{i=1}^M \ell_{0/1}(1 - y_i(\langle\mathcal{W}, \mathcal{X}_i\rangle + b)) \\ \text{s.t.} \quad & \text{rank}_T(\mathcal{W}) \leq (r_1, r_2, \cdots, r_N). \end{aligned} \tag{2-2}$$

中国知网　https://www.cnki.net

为简单起见, 对于给定的训练集 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 引入线性算子 $\mathfrak{A}: \mathbb{R}^{I_1\times\cdots\times I_N} \to \mathbb{R}^M$, 其定义式为:

$$\mathfrak{A}\mathcal{W} := (\langle\mathcal{W}, y_1\mathcal{X}_1\rangle, \cdots, \langle\mathcal{W}, y_M\mathcal{X}_M\rangle)^\top, \quad \forall\, \mathcal{W} \in \mathbb{R}^{I_1\times\cdots\times I_N}.$$

容易验证, 该线性算子的伴随算子 $\mathfrak{A}^*: \mathbb{R}^M \to \mathbb{R}^{I_1\times\cdots\times I_N}$ 为

$$\mathfrak{A}^*\mathbf{d} := \sum_{i=1}^M y_i d_i \mathcal{X}_i, \quad \forall\, \mathbf{d} \in \mathbb{R}^M.$$

通过引入辅助变量 $\mathbf{z} \in \mathbb{R}^M$, 模型 (2-2) 可转化为如下非凸非连续的张量优化问题:

$$\begin{aligned} \min_{\mathcal{W},b,\mathbf{z}} \quad & f(\mathcal{W}, b, \mathbf{z}) = \tfrac{1}{2}\|\mathcal{W}\|_F^2 + \delta_{\mathcal{S}}(\mathcal{W}) + C\mathcal{L}_{0/1}(\mathbf{z}) \\ \text{s.t.} \quad & \mathfrak{A}\mathcal{W} + b\mathbf{y} + \mathbf{z} - \mathbf{1} = \mathbf{0}, \end{aligned} \tag{2-3}$$

其中, $\delta_{\mathcal{S}}$ 的定义式为 (1-10), $\mathbf{y} := (y_1, \ldots, y_M)^\top$, $\mathbf{1} \in \mathbb{R}^M$ 为全 1 向量, $\mathcal{L}_{0/1}(\mathbf{z}) := \sum_{i=1}^M \ell_{0/1}(z_i)$. 称 (2-3) 为基于 $\ell_{0/1}$ 软间隔损失函数的低秩 STM 模型.

2.2 算法设计

对任意 $(\mathcal{W}, b, \mathbf{z}, \mathbf{\Lambda}) \in \mathbb{R}^{I_1\times\cdots\times I_N} \times \mathbb{R} \times \mathbb{R}^M \times \mathbb{R}^M$, 模型 (2-3) 的增广拉格朗日函数为

$$\begin{aligned} L_\sigma(\mathcal{W}, b, \mathbf{z}; \mathbf{\Lambda}) = \; & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + c\mathcal{L}_{0/1}(\mathbf{z}) + \delta_{\mathcal{S}}(\mathcal{W}) - \langle\mathbf{\Lambda}, \mathfrak{A}\mathcal{W} + b\mathbf{y} + \mathbf{z} - \mathbf{1}\rangle \\ & + \tfrac{\sigma}{2}\left\|\mathfrak{A}\mathcal{W} + b\mathbf{y} + \mathbf{z} - \mathbf{1}\right\|^2, \end{aligned}$$

其中 $\sigma > 0$ 为增广项罚参数, Λ 为拉格朗日乘子. 给定初始点 $(\mathcal{W}^0, b^0, \mathbf{z}^0, \mathbf{\Lambda}^0)$, 可以利用 ADMM 算法求解 (2-3), 其迭代框架为:

$$\begin{cases} \mathcal{W}^{k+1} \in \arg\min\limits_{\mathcal{W}} L_\sigma(\mathcal{W}, b^k, \mathbf{z}^k; \mathbf{\Lambda}^k) + \frac{1}{2}\|\mathcal{W} - \mathcal{W}^k\|_{\mathcal{Q}}^2, \\ b^{k+1} = \arg\min\limits_{b} L_\sigma(\mathcal{W}^{k+1}, b, \mathbf{z}^k; \mathbf{\Lambda}^k), \\ z^{k+1} = \arg\min\limits_{\mathbf{z}} L_\sigma(\mathcal{W}^{k+1}, b^{k+1}, \mathbf{z}; \mathbf{\Lambda}^k), \\ \mathbf{\Lambda}^{k+1} = \mathbf{\Lambda}^k - \tau\sigma(\mathfrak{A}\mathcal{W}^{k+1} + b^{k+1}\mathbf{y} + \mathbf{z}^{k+1} - \mathbf{1}), \end{cases} \tag{2-4}$$

其中 $\tau \in \left(0, \frac{1+\sqrt{5}}{2}\right)$ 为步长, $\mathcal{Q}$ 为某一半正定算子. 在线性化 ADMM 算法中, 可取 $\mathcal{Q} := \eta\mathcal{I} - \mathfrak{A}^*\mathfrak{A}$, 其中 $\eta := \|\mathfrak{A}^*\mathfrak{A}\| = \sum_{i=1}^M \|\mathcal{X}_i\|_F^2$, $\mathcal{I}$ 为恒等算子. 下面给出 (2-4) 中三个核心子问题的求解公式.

中国知网 https://www.cnki.net

(i) 关于 $\mathcal{W}-$ 子问题的求解.

$$\begin{aligned}\mathcal{W}^{k+1} &\in \arg\min_{\mathcal{W}} L_\sigma(\mathcal{W}, b^k, \mathbf{z}^k; \mathbf{\Lambda}^k) + \tfrac{1}{2}\|\mathcal{W}-\mathcal{W}^k\|_Q^2 \\ &= \arg\min_{\mathcal{W}} \tfrac{1}{2}\|\mathcal{W}\|_F^2 + \delta_{\mathcal{S}}(\mathcal{W}) - \langle \mathbf{\Lambda}^k, \mathfrak{A}\mathcal{W}\rangle + \sigma(\tfrac{1}{2}\|\mathfrak{A}\mathcal{W}^k + b^k\mathbf{y} + \mathbf{z}^k - \mathbf{1}\|^2 \\ &\qquad +\langle \mathfrak{A}^*(\mathfrak{A}\mathcal{W}^k + b^k\mathbf{y} + \mathbf{z}^k - \mathbf{1}), \mathcal{W}-\mathcal{W}^k\rangle + \tfrac{\eta}{2}\|\mathcal{W}-\mathcal{W}^k\|^2) \\ &= \Pi_{\mathcal{S}}(\tfrac{\sigma\eta\mathcal{W}^k + \mathfrak{A}^*\mathbf{\Lambda}^k - \sigma\mathfrak{A}^*(\mathfrak{A}\mathcal{W}^k + \mathbf{d}^k)}{\sigma\eta+1}),\end{aligned} \tag{2-5}$$

其中 $\mathbf{d}^k := b^k\mathbf{y} + \mathbf{z}^k - \mathbf{1}$, $\Pi_{\mathcal{S}}(\cdot)$ 为集合 $\mathcal{S}$ 上的投影算子.

(ii) 关于 $b-$ 子问题的求解.

$$\begin{aligned} b^{k+1} &= \arg\min_{b} L_\sigma(\mathcal{W}^{k+1}, b, \mathbf{z}^k; \mathbf{\Lambda}^k) \\ &= \tfrac{\langle \mathbf{y}, \mathbf{r}^k\rangle}{\|\mathbf{y}\|^2}, \end{aligned} \tag{2-6}$$

其中, $\mathbf{r}^k = \frac{\mathbf{\Lambda}^k}{\sigma} + \mathbf{1} - \mathfrak{A}\mathcal{W}^{k+1} - \mathbf{z}^k$.

(iii) 关于 $\mathbf{z}-$ 子问题的求解.

$$\begin{aligned}\mathbf{z}^{k+1} &= \arg\min_{\mathbf{z}} L_\sigma(\mathcal{W}^{k+1}, b^{k+1}, \mathbf{z}; \mathbf{\Lambda}^k) \\ &= \mathrm{Prox}_{\frac{C}{\sigma}\mathcal{L}_{0/1}}(\mathbf{1} - \mathfrak{A}\mathcal{W}^{k+1} - b^{k+1}\mathbf{y} + \tfrac{\mathbf{\Lambda}^k}{\sigma}),\end{aligned}$$

其中, $\mathrm{Prox}_{\frac{C}{\sigma}\mathcal{L}_{0/1}}(\cdot)$ 为 $\mathcal{L}_{0/1}$ 函数的邻近点算子. 由引理 1.3 可知, $\mathbf{z}^{k+1}$ 的显示表达式为:

$$\mathbf{z}_i^{k+1} = \begin{cases} 0, & 0 < (\mathbf{1} - \mathfrak{A}\mathcal{W}^{k+1} - b^{k+1}\mathbf{y} + \frac{\mathbf{\Lambda}^k}{\sigma})_i \le \sqrt{\frac{2C}{\sigma}}, \\ (\mathbf{1} - \mathfrak{A}\mathcal{W}^{k+1} - b^{k+1}\mathbf{y} + \frac{\mathbf{\Lambda}^k}{\sigma})_i, & \text{否则}. \end{cases} \tag{2-7}$$

综上可知, ADMM 求解模型 (2-3) 的算法框架可总结为算法 1:

算法 1 (ADMM-STM)　求解问题 (2-3) 的 ADMM 算法

输入: 训练样本 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, Tucker 秩上界 $(r_1, \ldots, r_N)$, 惩罚参数 C, 增广项罚参数 σ, 线性化 ADMM 参数 η, 精度参数 $\epsilon > 0$.

输出: 张量权重参数 $\mathcal{W}$, 偏置 b.

步 1. 选取初始点 $(\mathcal{W}^0, b^0, \mathbf{z}^0, \mathbf{\Lambda^0})$, 令 $k = 0$;

步 2. 由式子 (2-5), (2-6), (2-7) 和 (2-4) 分别计算 $(\mathcal{W}^{k+1}, b^{k+1}, \mathbf{z}^{k+1}, \mathbf{\Lambda}^{k+1})$;

步 3. 若满足给定的终止准则与精度要求, 则停止迭代. 否则, 令 $k = k + 1$, 转**步 2**.

在实际计算中, 采用 ST-HOSVD 近似计算非凸低秩集 $\mathcal{S}$ 上的投影, 求得 $\mathcal{W}-$ 子问题的近似解. 如下给出算法 1 的复杂度分析: 计算 $\mathcal{W}-$ 子问题时的计算复杂度约为 $O(MI_1\cdots I_N + I_1^2 I_2\cdots I_N + r_1 I_2^2 I_3\cdots I_N + \cdots + r_1\cdots r_{N-1}I_N^2)$, 在子空间上计

中国知网　https://www.cnki.net

算$\mathbf{z}-$子问题的复杂度为$O(MI_1\cdots I_N)$, 计算$b-$子问题与$\Lambda-$子问题的复杂度均为$O(MI_1\cdots I_N)$. 故在算法 1 中, 每次迭代的总复杂度为$O(MI_1\cdots I_N + I_1^2 I_2\cdots I_N + r_1 I_2^2 I_3\cdots I_N + \cdots + r_1\cdots r_{N-1} I_N^2)$.

当求解模型 (2-3) 得到$\mathcal{W}$和b后, 测试数据$\mathcal{X}\in\mathbb{R}^{I_1\times\cdots\times I_N}$可通过决策函数$f(\mathcal{X}) = \mathrm{sgn}(\langle\mathcal{W},\mathcal{X}\rangle + b)$确定类别, 其中符号函数

$$\mathrm{sgn}(t) = \begin{cases} 1, & \text{若 } t > 0; \\ -1, & \text{若 } t \le 0. \end{cases} \tag{2-8}$$

算法 ADMM-STM 求解张量数据二分类的流程图如图 2.1 所示.

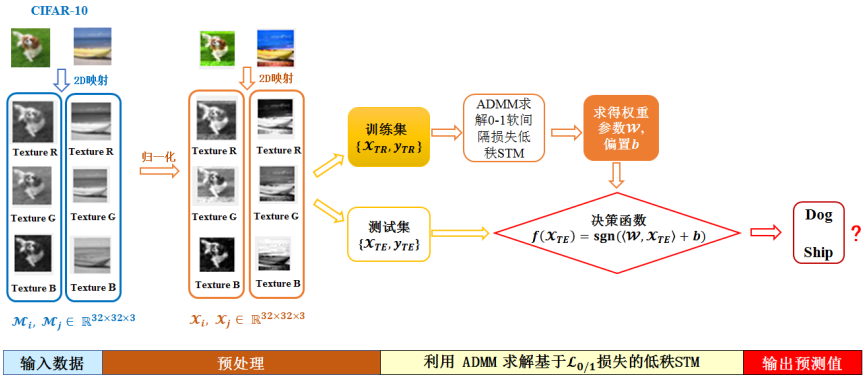


图 2.1　ADMM 求解$\ell_{0/1}$-STM 流程图.

Fig 2.1　A flowchart of ADMM for $\ell_{0/1}$- STM.

2.3　数值实验

为验证所提的模型及其算法在二分类问题中的有效性, 挑选出三类代表性的算法, 以分类精度为衡量标准, 分别在模拟数据和真实数据集上, 与 ADMM-STM 进行数值实验比较. 这些算法包括经典的支持向量机 LIBSVM[93], 基于张量 CP 分解的 SHTM[43], 以及基于张量 TT 分解的 K-STTM[45] 方法. 数值实验均在 Intel(R) Core(TM) i7-8565U CPU @1.8GHz 电脑上进行, 使用 Matlab 2018b, 并调用 Matlab Tensor Toolbox① 进行计算.

在算法 1 中, 采取简单的点距停机准则, 即对于当前迭代点$(\mathcal{W}^k, b^k)$, 若满足如下条件:

$$\max\left\{\frac{\|\mathcal{W}^k - \mathcal{W}^{k-1}\|_F}{\|\mathcal{W}^{k-1}\|_F}, \frac{|b^k - b^{k-1}|}{|b^{k-1}|}\right\} < \epsilon,$$

① https://www.sandia.gov/~tgkolda/TensorToolbox

中国知网 https://www.cnki.net

或迭代次数 k = itermax, 则算法停止, 这里取精度参数 $\epsilon = 10^{-2}$, 最大迭代次数 itermax = 5000. 为公平起见, 调用线性核的 LIBSVM[①]. 鉴于 SHTM 是线性核的 DuSK 的一个特例, 直接调用 DuSK 的已有程序包[②], 并取核函数为线性核函数. 在 K-STTM 算法中, 选取其 Matlab 程序包 [③] 中的 K-STTM-Prod 方法. 上述四类算法中涉及到的模型参数 C, 将采用网格搜索从集合$\{2^0, 2^1, \cdots, 2^9\}$ 中选取.

2.3.1　模拟数据

随机生成 n 个张量样本 $\mathcal{X}_i \in \mathbb{R}^{16\times16\times8}$, $i = 1, \ldots, n$, 所有分量均服从标准正态分布且相互独立. 随机生成一个张量 $\mathcal{W}' \in \mathbb{R}^{16\times16\times8}$, 其分量服从标准正态分布且为独立同分布的. 借助截断型方法 ST-HOSVD 作用到 $\mathcal{W}'$ 上, 产生一个 Tucker 秩为 (r_1, r_2, r_3) 的张量 $\mathcal{W}_{\text{true}}$. 取 $b_{\text{true}} = 1$. 将 $(\mathcal{W}_{\text{true}}, b_{\text{true}})$ 设定为上述 n 个张量样本二分类的最优超平面参数. 相应的样本标记 y_i 由分类问题的决策函数 f 产生, 即

$$y_i = f(\mathcal{X}_i) := \operatorname{sgn}\left(\langle \mathcal{W}_{\text{true}}, \mathcal{X}_i \rangle + b_{\text{true}}\right),\ i = 1, \ldots, n,$$

在算法 1 中, 取初始点 $\mathcal{W}^0 = \mathcal{W}_{\text{true}} - 0.1 \times \text{tenrand}(16, 16, 8)$, $b^0 = 0$, $z^0 = \mathbf{0}$, $\Lambda^0 = \mathbf{0}$, 增广拉格朗日罚参数 $\sigma = 0.055$, 步长 $\tau = 1.618$. 在模拟数据的数值实验中, 我们将选取不同的样本数 n 以及不同的 Tucker 秩 (r_1, r_2, r_3) 进行测试, 其中 $n = 50, 100, 200, 500, 1000$, $(r_1, r_2, r_3) = (2, 1, 1), (2, 2, 2), (2, 3, 2), (3, 3, 2), (4, 3, 3)$. 所有的数值结果均为 5 次 10 折交叉验证结果的均值, 并记录在图 2.2 与表 2.1 中.

图 2.2 记录了固定 Tucker 秩 $(r_1, r_2, r_3) = (2, 2, 2)$ 时, 四种方法在不同样本总量 n 下的预测精度. 由图 2.2 可知, 在分类精度方面, 所提的 ADMM-STM 方法明显高于其他三类方法. 而且, 随着总样本量的增加, ADMM-STM 的分类精度相对稳定, 可以正确预测 90% 以上的样本.

表 2.1 记录了固定样本量 $n = 100$ 时, 四种方法在不同 Tucker 秩 (r_1, r_2, r_3) 下的预测精度. 由表 2.1 可知, 所提方法 ADMM-STM 明显优于其他三类方法, 其分类精度高于其他所有算法 20% 以上.

由于生成的模拟数据中真实的张量权重参数具有 Tucker 低秩性, 符合所提的低秩 STM 模型的约束条件, 且算法采用的初始点离真实值不远, 因而 ADMM-STM 可以得到很好的近似最优解, 这也是图 2.2 与表 2.1 中 ADMM-STM 均优于其他三类方法的主要原因.

① https://www.csie.ntu.edu.tw/~cjlin/libsvm/
② https://github.com/LifangHe/SDM14_DuSK
③ https://github.com/git2cchen/KSTTM

中国知网　https://www.cnki.net

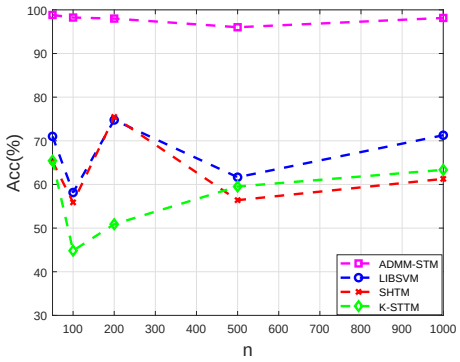


图 2.2　固定 Tucker 秩为 $[2,2,2]$，不同总样本量下的分类精度.

Fig 2.2　The classification accuracy under different sample sizes with $[r_1, r_2, r_3] = [2,2,2]$.

表 2.1　固定总样本量, 不同 Tucker 秩下的分类精度 (%).

Tab 2.1　The classification accuracy under different Tucker rank with $n = 100$.

Tucker 秩	ADMM-STM	LIBSVM	SHTM	K-STTM
(2, 1, 1)	**99.64**	68.05	70.57	33.74
(2, 2, 2)	**94.92**	63.93	61.44	61.84
(2, 3, 2)	**97.71**	72.56	67.16	44.05
(3, 3, 2)	**96.17**	62.82	57.16	41.30
(4, 3, 3)	**98.96**	62.69	63.17	56.88

2.3.2　真实数据

为了进一步验证算法 ADMM-STM 的实际性能, 在真实数据集 CIFAR-10 数据集[94] 上进行数值实验. 该数据集包含 5000 个训练样本和 1000 个测试样本. 每个样本是一张 32×32 像素的彩色图片, 如图 2.3 所示.

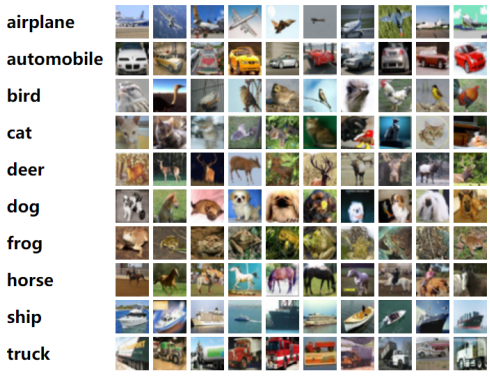


图 2.3　CIFAR-10 数据集.

Fig 2.3　CIFAR-10 dataset.

采用 RGB 颜色通道, 每个图片可以用 $32 \times 32 \times 3$ 的三阶张量表示. 尽管训练

中国知网　https://www.cnki.net

样本足够, 但我们更关注小样本量的问题. 从数据集中随机选择十组图像进行二分类实验, 且在每类图像中无重叠的选取 $m(m \leq 100)$ 个样本. 为了获得更好的数值效果, 对每个图片张量进行归一化预处理, 使每个样本缩放到 [0,1] 范围. 在算法 1 中, 取初始点为 $\mathcal{W}^0 = 0.01 \times \text{tenones}(16, 16, 8)$, $b^0 = 0$, $\mathbf{z}^0 = \mathbf{0}$, $\mathbf{\Lambda}^0 = \mathbf{0}$, 增广拉格朗日罚参数 $\sigma = 10^{-4}$, Tucker 秩 $(r_1, r_2, r_3) = (4, 6, 3)$. 通过四种算法的对比实验, 将 5 次 10 折交叉验证结果的平均值作为最终的数值结果, 记录在表 2.2 与表 2.3 中.

表 2.2 中记录了在均衡数据情形下 (每类样本的个数相同, 均为 $m = 100$) 四种算法的预测精度. 可以看出, 在多数情况下, ADMM-STM 表现最好, 其预测精度高出其他方法 2% – 5%. 值得注意的是, 在 'bird' 和 'deer' 这组二分类问题中, ADMM-STM 的分类精度可以比其他方法高 9%. 同时, 从表 2.2 中也可以看出, 对于不同的分类情况, 分类精度也有一定的差别, 因此对于某些分类较难的问题需要更为灵活的分类函数.

表 2.2　均衡样本量下各方法的分类精度 (%).

Tab 2.2　The classification accuracy (%) for different approaches under balanced sample.

Class pair	样本量	ADMM-STM	LIBSVM	SHTM	K-STTM
'bird','airplane'	100:100	**83.18**	79.08	78.52	73.58
'automobile','airplane'	100:100	**81.82**	79.69	79.96	80.17
'cat','airplane'	100:100	**84.50**	80.18	81.56	78.00
'airplane','frog'	100:100	93.81	**94.89**	94.14	84.64
'truck','horse'	100:100	**83.55**	82.22	80.04	65.54
'dog','ship'	100:100	91.09	89.04	87.88	**91.44**
'automobile','frog'	100:100	**81.05**	79.27	78.28	75.33
'airplane','dog'	100:100	88.52	**89.13**	88.70	83.02
'bird','deer'	100:100	**79.15**	58.46	63.34	69.26
'dog','frog'	100:100	**77.98**	73.41	74.54	73.29

注: 最好的结果由黑体标出.

考虑到现实生活中不均衡数据的情况也十分普遍, 我们测试算法对不平衡数据的有效性, 并将结果列于表 2.3 中. 结果表明, 尽管数据不平衡, 但所提方法仍具有良好的性能, 大多数情况下, 分类精度均高于其他方法. 在 'cat' 和 'airplane' 这组中, 在不同的不平衡比率下, ADMM-STM 的分类精度高于其他方法 1% – 3%.

最后, 以 'dog' 和 'ship' 二分类为例, 采用均衡数据样本 (100 : 100), 测试 ADMM-STM 在不同 Tucker 秩下的分类精度, 并将 10 次 10 折交叉验证的结果记录于表 2.4 中. 从表 2.4 中可以看出, ADMM-STM 在不同的 Tucker 秩下都可以正确

中国知网　https://www.cnki.net

表 2.3　不均衡样本量下各方法的分类精度 (%).

Tab 2.3　The classification accuracy (%) for different approaches under unbalanced sample.

Class pair	样本量	ADMM-STM	LIBSVM	SHTM	K-STTM
'automobile','airplane'	100:50	**82.42**	78.92	77.23	80.73
'bird','airplane'	100:50	**80.62**	76.73	77.57	76.77
'cat','airplane'	100:50	**82.50**	77.82	77.60	80.00
'dog', 'ship'	100:50	**90.32**	88.67	88.59	88.37
'truck','horse'	90:60	86.99	77.21	**87.73**	66.07
'ship', 'truck'	90:60	**88.85**	85.44	85.47	79.74
'cat','airplane'	100:20	**87.75**	84.75	84.37	86.29
'dog','frog'	100:70	**79.92**	79.00	77.98	75.41
'dog','truck'	100:20	93.00	**95.07**	94.83	85.64
'horse','ship'	100:25	**91.15**	90.44	90.32	85.02

预测超过 90% 的样本. 特别地, 当 $(r_1, r_2, r_3) = (3, 3, 3)$ 时, 其准确率已高达 91.62%, 这也体现了所提的 STM 模型中 Tucker 低秩约束的合理性.

表 2.4　不同 Tucker 秩下 ADMM-STM 的分类精度 (%).

Tab 2.4　The classification accuracy (%) for ADMM-STM under different Tucker rank.

Tucker rank	(3 3 3)	(4 4 3)	(5 5 3)	(6 6 3)	(7 7 3)	(8 8 3)	(9 9 3)	(10 10 3)
Accuracy	91.62	91.17	90.99	90.84	91.52	91.07	91.29	91.36

2.4　本章小结

本章针对近似线性可分的二分类张量数据, 采用二分类本原损失函数 0/1 损失, 引入权重参数的 Tucker 低秩约束, 提出了一类新颖的基于 $\ell_{0/1}$ 损失的低秩 STM 模型, 然后设计 ADMM-STM 算法进行有效求解. 在模拟数据和真实数据集上, 通过与三类代表性的分类算法进行数值实验比较, 验证了所提方法在分类精度上的优势.

中国知网　https://www.cnki.net

3 双稀疏秩一支持张量机

对于大规模数据, 具有稀疏损失函数的 SVM 可以对样本进行选择, 挑选出重要的样本减少冗余信息的影响, 提高分类精度. 当样本具有高维特征时, SVM 会面临过拟合和计算复杂度高等问题. 已有的稀疏 SVM[95] 通过 ℓ_1 惩罚同时进行分类和变量选择在一些应用取得较大的成功 [96–98]. 进一步, 为了应对稀疏 SVM 在涉及大样本和高维的大规模学习中的挑战, Zhang 等[99]、Shao 等[100]分别考虑同时对模型进行样本选择和特征选择, 找到了更稀疏的解决方案. 类似思想的其他工作可参考文献 [101,102].

回顾模型 (1-2), Tao[15] 等考虑了经典的秩一 STM,

$$\min_{\mathbf{w}_1,\cdots,\mathbf{w}_N,b} \frac{1}{2}\|\mathbf{w}_1\circ\cdots\circ\mathbf{w}_N\|_F^2 + C\sum_{i=1}^{M}\ell_{hl}(1-y_i f(\mathcal{X}_i)),$$

其中合页损失 $\ell_{hl}(t)$ 定义如 (1-3) 所示, 决策函数 $f(\mathcal{X}) = \mathcal{X}\prod_{n=1}^{N}\times_n\mathbf{w}_n + b$. 已有的 STM 工作侧重于张量权重参数的低秩性上, 而忽略了其稀疏性. 基于此, 结合 0/1 损失, 提出如下双稀疏秩一支持张量机模型,

$$\min_{\mathbf{w}_1,\cdots,\mathbf{w}_N,b} \frac{1}{2}\|\mathbf{w}_1\circ\cdots\circ\mathbf{w}_N\|_F^2 + \frac{1}{2}b^2 + C\sum_{i=1}^{M}\ell_{0/1}(1-y_i f(\mathcal{X}_i)) + \sum_{n=1}^{N}\beta_n\|\mathbf{w}_n\|_1, \tag{3-1}$$

其中, $C>0, \beta_n>0, n\in[N]$. 简单起见, 本文只考虑 $N=3$ 的情况, 并且容易将其推广至 $N(N>3)$阶. 通过定义如下线性算子 $\mathcal{A}:\mathbb{R}^{I_1\times I_2\times I_3}\to\mathbb{R}^M$, 使得

$$\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3) := (\langle\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3, y_1\mathcal{X}_1\rangle,\cdots,\langle\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3, y_M\mathcal{X}_M\rangle)^\top, \tag{3-2}$$

其伴随算子 $\mathcal{A}:\mathbb{R}^M\to\mathbb{R}^{I_1\times\cdots\times I_N}$ 为 $\mathcal{A}^*\mathbf{d} := \sum_{i=1}^{M}\mathbf{y}_i d_i\mathcal{X}_i, \forall\,\mathbf{d}\in\mathbb{R}^M$. 上述模型 (3-1) 可写为

$$\min_{\Xi}\mathcal{F}(\Xi) := \frac{1}{2}\prod_{n=1}^{3}\|\mathbf{w}_n\|^2 + \frac{1}{2}b^2 + C\|(\mathbf{1}-\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)-b\mathbf{y})_+\|_0 + \sum_{n=1}^{3}\beta_n\|\mathbf{w}_n\|_1 \tag{3-3}$$

其中, $\Xi := (\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,b)\in\mathbb{R}^{I_1}\times\mathbb{R}^{I_2}\times\mathbb{R}^{I_3}\times\mathbb{R}$, $\mathbf{y}=(y_1,\ldots,y_M)^\top$ 为标签向量. 下面的引理给出了问题 (3-3) 目标函数的基本性质.

引理 3.1： 函数 $\mathcal{F}:\mathbb{R}^{I_1}\times\mathbb{R}^{I_2}\times\mathbb{R}^{I_3}\times\mathbb{R}\to\mathbb{R}$ 是一个正常、下半连续、半代数函数.

证明 对于任意的点 $\Xi\in\mathbb{R}^{I_1}\times\mathbb{R}^{I_2}\times\mathbb{R}^{I_3}\times\mathbb{R}$, $\mathcal{F}(\Xi)$ 均取得有限值, 结合 $\mathcal{F}(\Xi)$ 的非负性可知 $\mathcal{F}(\Xi)$ 是正常的. 由 $\|\cdot\|^2, \|\cdot\|_1$ 的连续性和 $\|(\cdot)_+\|_0$ 的下半连续性可得 $\mathcal{F}(\Xi)$ 是

中国知网 https://www.cnki.net

下半连续的. 此外, 与文献 [103] 的证明过程类似, 由 $\|\cdot\|^2$ 是多项式函数, $\|\cdot\|_1$ 和 $\|(\cdot)_+\|_0$ 是分片线性函数可得函数 $\mathcal{F}(\Xi)$ 是半代数的. □

3.1 优化模型

对模型 (3-3) 引入辅助变量 $\mathbf{z} := (z_1, \cdots, z_M)^\top \in \mathbb{R}^M$, 模型可等价表示为

$$\begin{aligned} \min_{\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,b,\mathbf{z}} \quad & \tfrac{1}{2}\prod_{n=1}^{3}\|\mathbf{w}_n\|^2 + \tfrac{1}{2}b^2 + C\|\mathbf{z}_+\|_0 + \sum_{n=1}^{3}\beta_n\|\mathbf{w}_n\|_1 \\ \text{s.t.} \quad & \mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2 \circ \mathbf{w}_3) + \mathbf{z} + b\mathbf{y} = \mathbf{1}. \end{aligned} \tag{3-4}$$

由于模型 (3-3) 与 (3-4) 等价, 而 (3-4) 便于求解, 本小节主要研究模型 (3-4) 的最优性条件. 为此, 给出问题 (3-4) 的增广拉格朗日函数

$$\begin{aligned} & L_\sigma(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3, \mathbf{z}, b, \Lambda) \\ = \; & g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) + \sum_{n=1}^{3}\beta_n\|\mathbf{w}_n\|_1 + C\|\mathbf{z}_+\|_0 + \tfrac{1}{2}b^2 \\ & -\langle\Lambda, \mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2 \circ \mathbf{w}_3) + \mathbf{z} + b\mathbf{y} - \mathbf{1}\rangle + \tfrac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2 \circ \mathbf{w}_3) + \mathbf{z} + b\mathbf{y} - \mathbf{1}\|^2, \end{aligned}$$

其中, $g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) = \frac{1}{2}\prod_{n=1}^{3}\|\mathbf{w}_n\|^2$, $\Lambda \in \mathbb{R}^M$ 是拉格朗日乘子, $\sigma > 0$ 是罚参数. 基于上述增广拉格朗日函数和 0/1 次微分的定义, 我们将介绍稳定点来刻画问题 (3-4) 的最优解.

定义 3.1: $(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*)$ 称为问题 (3-4) 的增广拉格朗日函数 L_σ 的稳定点, 如果对于任意的 $\beta_1, \beta_2, \beta_3, C > 0$, 有

$$\begin{cases} \mathbf{0} \in \partial\beta_1\|\mathbf{w}_1^*\|_1 + \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*) - \mathcal{A}^*\Lambda^* \times_2 \mathbf{w}_2^* \times_3 \mathbf{w}_3^*, \\ \mathbf{0} \in \partial\beta_2\|\mathbf{w}_2^*\|_1 + \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*) - \mathcal{A}^*\Lambda^* \times_1 \mathbf{w}_1^* \times_3 \mathbf{w}_3^*, \\ \mathbf{0} \in \partial\beta_3\|\mathbf{w}_3^*\|_1 + \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*) - \mathcal{A}^*\Lambda^* \times_1 \mathbf{w}_1^* \times_2 \mathbf{w}_2^*, \\ \mathbf{0} \in \partial C\|\mathbf{z}_+^*\|_0 - \Lambda^*, \\ 0 = b^* - \mathbf{y}^\top\Lambda^*, \\ \Lambda^* = \Lambda^* - \sigma(\mathcal{A}(\mathbf{w}_1^* \circ \mathbf{w}_2^* \circ \mathbf{w}_3^*) + \mathbf{z}^* + b^*\mathbf{y} - \mathbf{1}). \end{cases} \tag{3-5}$$

函数 L_σ 的所有稳定点的集合定义为 $\mathrm{crit}(L_\sigma)$. 此外, 由文献 [85] 的练习 10.2 可得

$$\mathbf{z} \in \mathrm{Prox}_{\eta C\|(\cdot)_+\|_0}(\mathbf{z} + \eta\Lambda) \Longrightarrow \mathbf{0} \in C\partial\|\mathbf{z}_+\|_0 - \Lambda.$$

为了便于设计算法, 给出邻近算子稳定点 (P(roximal)-稳定点)的定义.

中国知网 https://www.cnki.net

定义 3.2： 给定 $C,\beta_1,\beta_2,\beta_3>0$, $(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*,\mathbf{z}^*,b^*)$ 称为问题 (3-4) 的一个 P-稳定点, 若存在向量 $\Lambda^*\in\mathbb{R}^M$ 和常数 $\eta,\eta_1,\eta_2,\eta_3>0$ 使得

$$\begin{cases}\mathbf{w}_1^*=\mathrm{Prox}_{\beta_1\eta_1\|\cdot\|_1}(\mathbf{w}_1^*+\eta_1(\mathcal{A}^*\Lambda^*\times_2\mathbf{w}_2^*\times_3\mathbf{w}_3^*-\nabla_{\mathbf{w}_1}g(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*))\\ \mathbf{w}_2^*=\mathrm{Prox}_{\beta_2\eta_2\|\cdot\|_1}(\mathbf{w}_2^*+\eta_2(\mathcal{A}^*\Lambda^*\times_1\mathbf{w}_1^*\times_3\mathbf{w}_3^*-\nabla_{\mathbf{w}_2}g(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*))\\ \mathbf{w}_3^*=\mathrm{Prox}_{\beta_3\eta_3\|\cdot\|_1}(\mathbf{w}_3^*+\eta_3(\mathcal{A}^*\Lambda^*\times_1\mathbf{w}_1^*\times_2\mathbf{w}_2^*-\nabla_{\mathbf{w}_3}g(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*))\\ \mathbf{z}^*\in\mathrm{Prox}_{\eta C\|(\cdot)_+\|_0}(\mathbf{z}^*+\eta\Lambda^*)\\ b^*=\langle\Lambda^*,\mathbf{y}\rangle\\ \Lambda^*=\Lambda^*-\sigma(\mathcal{A}(\mathbf{w}_1^*\circ\mathbf{w}_2^*\circ\mathbf{w}_3^*)+\mathbf{z}^*+b^*\mathbf{y}-\mathbf{1}).\end{cases}\tag{3-6}$$

为简单起见, 可将增广拉格朗日函数 L_σ 重新表述为

$$L_\sigma(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,\mathbf{z},b,\Lambda)=h(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,\mathbf{z},b,\Lambda)+C\|\mathbf{z}_+\|_0+\sum_{n=1}^{3}\beta_n\|\mathbf{w}_n\|_1,$$

其中 $h(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,\mathbf{z},b,\Lambda)=\frac{1}{2}\prod_{n=1}^{3}\|\mathbf{w}_n\|^2+\frac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}\|^2+\frac{1}{2}b^2-\langle\Lambda,\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}\rangle$.

性质 3.1.1： 令 $\Theta:=(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,\mathbf{z},b,\Lambda)$, 函数 $h(\Theta)$ 的梯度表示为

$$\nabla h(\Theta)=\begin{bmatrix}\nabla_{\mathbf{w}_1}g(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3)+\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}-\frac{\Lambda}{\sigma})\times_2\mathbf{w}_2\times_3\mathbf{w}_3\\ \nabla_{\mathbf{w}_2}g(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3)+\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}-\frac{\Lambda}{\sigma})\times_1\mathbf{w}_1\times_3\mathbf{w}_3\\ \nabla_{\mathbf{w}_3}g(\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3)+\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}-\frac{\Lambda}{\sigma})\times_1\mathbf{w}_1\times_2\mathbf{w}_2\\ \sigma(\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}-\frac{\Lambda}{\sigma})\\ b+\sigma\mathbf{y}^\top(\mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}-\frac{\Lambda}{\sigma})\\ \mathcal{A}(\mathbf{w}_1\circ\mathbf{w}_2\circ\mathbf{w}_3)+\mathbf{z}+b\mathbf{y}-\mathbf{1}\end{bmatrix}.$$

根据定义 3.2, 下面给出问题 (3-4) 有关 P-稳定点的一阶最优性条件.

定理 3.1： 给定向量 $(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*,\mathbf{z}^*,b^*)\in\mathbb{R}^{I_1}\times\mathbb{R}^{I_2}\times\mathbb{R}^{I_3}\times\mathbb{R}^M\times\mathbb{R}$, 若 $(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*,\mathbf{z}^*,b^*)$ 是问题 (3-4) 的一个局部极小解, 则 $(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*,\mathbf{z}^*,b^*)$ 是该问题的 P-稳定点, 对于 $\Lambda^*\in\mathbb{R}^M$ 以及参数 $\eta_1,\eta_2,\eta_3>0$, $0<\eta<\eta^*$, 其中 $\eta^*=\min\{\eta_\Lambda^*,\eta_\mathbf{z}^*\}$,

$$\eta_\mathbf{z}^*=\begin{cases}+\infty, & \mathbf{z}^*\le 0,\\ \min\limits_{i:z_i^*>0}\frac{z_i^{*2}}{2C}, & \mathbf{z}^*>0,\end{cases}\quad \eta_\Lambda^*=\begin{cases}+\infty, & \Lambda^*\le 0,\\ \min\limits_{i:\lambda_i^*>0}\frac{2C}{\lambda_i^{*2}}, & \Lambda^*>0.\end{cases}$$

中国知网 https://www.cnki.net

证明 为方便起见, 记 $\Theta^* := (\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*)$. 由于 $(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*)$ 是一个局部极小解, 根据文献[85](定理 10.1, 练习 10.10) 可知

$$0 \in \partial L_\sigma(\Theta^*) = \nabla h(\Theta^*) + \partial(C\|\mathbf{z}_+^*\|_0 + \sum_{n=1}^{3} \beta_n \|\mathbf{w}_n^*\|_1).$$

根据文献 [85] 的命题 10.5 及 $\|\cdot\|_1$ 和 $\|(\cdot)_+\|_0$ 的正则性 (引理 2.1)[88] 可知,

$$\partial(C\|\mathbf{z}_+^*\|_0 + \sum_{n=1}^{3} \beta_n \|\mathbf{w}_n^*\|_1) = C\partial\|\mathbf{z}_+^*\|_0 \times \beta_1\partial\|\mathbf{w}_1^*\|_1 \times \beta_2\partial\|\mathbf{w}_2^*\|_1 \times \beta_3\partial\|\mathbf{w}_3^*\|_1 \times \{0\} \times \{\mathbf{0}\}.$$

那么,

$$0 \in \nabla h(\Theta^*) + \begin{pmatrix} \beta_1\partial\|\mathbf{w}_1^*\|_1 \\ \beta_2\partial\|\mathbf{w}_2^*\|_1 \\ \beta_3\partial\|\mathbf{w}_3^*\|_1 \\ C\partial\|\mathbf{z}_+^*\|_0 \\ 0 \\ \mathbf{0} \end{pmatrix} = \begin{pmatrix} \nabla_{\mathbf{w}_1} h(\Theta^*) + \beta_1\partial\|\mathbf{w}_1^*\|_1 \\ \nabla_{\mathbf{w}_2} h(\Theta^*) + \beta_2\partial\|\mathbf{w}_2^*\|_1 \\ \nabla_{\mathbf{w}_3} h(\Theta^*) + \beta_3\partial\|\mathbf{w}_3^*\|_1 \\ \nabla_{\mathbf{z}} h(\Theta^*) + C\partial\|\mathbf{z}_+^*\|_0 \\ \nabla_b h(\Theta^*) \\ \nabla_\Lambda h(\Theta^*) \end{pmatrix}.$$

令 $\Lambda^* = -\nabla_{\mathbf{z}} h(\Theta^*)$, 则有 (3-5) 成立. 为了证明满足 (3-5) 的 Θ^* 对于 $0 < \eta < \eta^*$ 使得 (3-6) 成立, 由文献 [86] 的定理 31.5 可知, $\mathbf{0} \in \partial\beta_n\|\mathbf{w}_n^*\|_1 + \nabla_{\mathbf{w}_n} h(\Theta^*) \Leftrightarrow \mathbf{w}_n^* = \mathrm{Prox}_{\beta_n\eta_n\|\cdot\|_1}(\mathbf{w}_n^* - \eta_n\nabla_{\mathbf{w}_n} h(\Theta^*))$ 对任意的 $\eta_n > 0, n = 1, 2, 3$. 接下来只需证明满足 $\Lambda^* \in C\partial\|\mathbf{z}_+^*\|_0$ 的 Λ^* 和 $\mathbf{z}^*$, 对于任意的 $0 < \eta < \eta^*$ 使得 $\mathbf{z}^* \in \mathrm{Prox}_{\eta C\|(\cdot)_+\|_0}(\mathbf{z}^* + \eta\Lambda^*)$ 成立. 对于向量 $\mathbf{z}^*$, 若存在 $j \in [M], z_j^* > 0$, 从 $0 < \eta < \eta^*$ 可知

$$\eta < \eta^* \le \eta_{\mathbf{z}}^* = \min_{i:z_i^*>0} \frac{z_i^{*2}}{2C} \le \frac{z_j^{*2}}{2C},$$

这意味着 $z_j^* > \sqrt{2\eta C}$. 类似地, 若存在 $j \in [M], \lambda_j > 0$, 从 $0 < \eta < \eta^*$ 可知

$$\eta < \eta^* \le \eta_\Lambda^* = \min_{i:\lambda_i^*>0} \frac{2C}{\lambda_i^2} \le \frac{2C}{\lambda_j^2},$$

可得 $\lambda_j^* < \sqrt{2C/\eta}$. 然后由 $\Lambda^* \in \partial\|\mathbf{z}_+^*\|_0$ 结合性质 1.3.1 可得对任意的 $0 < \eta < \eta^*$,

$$\begin{cases} \lambda_i^* = 0, \quad z_i^* \in (-\infty, 0] \cup (\sqrt{2C\eta}, +\infty), \\ z_i^* = 0, \quad \lambda_i^* \in [0, \sqrt{2C/\eta}). \end{cases}$$

考虑以下情况:

(i): $\lambda_i^* = 0, z_i^* \in (-\infty, 0) \cup (\sqrt{2C\eta}, +\infty)$ 有 $z_i^* + \eta\lambda_i^* \in (-\infty, 0) \cup (\sqrt{2C\eta}, +\infty)$, 因此,

中国知网 https://www.cnki.net

$z_i^* = z_i^* + \eta\lambda_i^* = (\mathrm{Prox}_{C\eta\|(\cdot)_+\|_0}(\mathbf{z}^* + \eta\Lambda^*))_i$.
(ii): $\lambda_i^* = 0, z_i^* = 0$ 有 $z_i^* + \eta\lambda_i^* = 0 \in \{0, \sqrt{2C\eta}\}$. 因此, $z_i^* = 0 \in (\mathrm{Prox}_{C\eta\|(\cdot)_+\|_0}(\mathbf{z}^* + \eta\Lambda^*))_i$.
(iii): $\lambda_i^* \in (0, \sqrt{2C/\eta})$, $z_i^* = 0$ 有 $z_i^* + \eta\lambda_i^* \in (0, \sqrt{2C\eta})$, 因此 $z_i^* = 0 = (\mathrm{Prox}_{C\eta\|(\cdot)_+\|_0}(\mathbf{z}^* + \eta\Lambda^*))_i$.

基于上述分析, 即完成了证明. □

3.2 算法设计

本节提出带有 Bregman 距离的 ADMM 来求解优化问题 (3-4). 给定当前迭代点 $(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)$, 其算法迭代框架如下:

$$\begin{cases} \mathbf{w}_1^{k+1} \in \arg\min\limits_{\mathbf{w}_1} L_\sigma(\mathbf{w}_1, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) + D_{\varphi_1}(\mathbf{w}_1, \mathbf{w}_1^k), \\ \mathbf{w}_2^{k+1} \in \arg\min\limits_{\mathbf{w}_2} L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) + D_{\varphi_2}(\mathbf{w}_2, \mathbf{w}_2^k), \\ \mathbf{w}_3^{k+1} \in \arg\min\limits_{\mathbf{w}_3} L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3, \mathbf{z}^k, b^k, \Lambda^k) + D_{\varphi_3}(\mathbf{w}_3, \mathbf{w}_3^k), \\ \mathbf{z}^{k+1} \in \arg\min\limits_{\mathbf{z}} L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}, b^k, \Lambda^k), \\ b^{k+1} \in \arg\min\limits_{b} L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b, \Lambda^k), \\ \Lambda^{k+1} = \Lambda^k - \sigma(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}), \end{cases} \tag{3-7}$$

其中 Bergman 距离 $D_{\varphi_i}(\mathbf{x}, \mathbf{y}) = \varphi_i(\mathbf{x}) - \varphi_i(\mathbf{y}) - \langle\nabla\varphi_i(\mathbf{y}), \mathbf{x} - \mathbf{y}\rangle, i = 1, 2, 3$. 根据以上迭代框架可得如下的最优性条件,

$$\begin{cases} \mathbf{0} \in \beta_1\partial\|\mathbf{w}_1^{k+1}\|_1 + \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^k, \mathbf{w}_3^k) - \mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k + \nabla\varphi_1(\mathbf{w}_1^{k+1}) \\ \quad - \nabla\varphi_1(\mathbf{w}_1^k) + \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k, \\ \mathbf{0} \in \beta_2\partial\|\mathbf{w}_2^{k+1}\|_1 + \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^k) - \mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k + \nabla\varphi_2(\mathbf{w}_2^{k+1}) \\ \quad - \nabla\varphi_2(\mathbf{w}_2^k) + \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k, \\ \mathbf{0} \in \beta_3\partial\|\mathbf{w}_3^{k+1}\|_1 + \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} + \nabla\varphi_3(\mathbf{w}_3^{k+1}) \\ \quad - \nabla\varphi_3(\mathbf{w}_3^k) + \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1}, \\ \mathbf{0} \in C\partial\|\mathbf{z}_+^{k+1}\|_0 - \Lambda^k + \sigma(\mathbf{z}^{k+1} + \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + b^k\mathbf{y} - \mathbf{1}), \\ 0 = b^{k+1} - \mathbf{y}^\top\Lambda^k + \sigma\mathbf{y}^\top(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}), \\ \Lambda^{k+1} = \Lambda^k - \sigma(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}). \end{cases} \tag{3-8}$$

下面给出 (3-7) 中五个核心子问题的求解公式.

中国知网 https://www.cnki.net

(i) 更新 $\mathbf{w}_1^{k+1}$: 记 $\mathbf{r}^k = b^k\mathbf{y} + \mathbf{z}^k - \mathbf{1} - \frac{\Lambda^k}{\sigma}$, 令

$$\varphi_1(\mathbf{w}_1) = \frac{t_1}{2}\|\mathbf{w}_1\|^2 - g(\mathbf{w}_1, \mathbf{w}_2^k, \mathbf{w}_3^k) - \frac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{r}^k\|^2,$$

其中 $t_1 > \|\mathbf{w}_2^k\|^2\|\mathbf{w}_3^k\|^2(1 + \sigma\|\mathcal{A}^*\mathcal{A}\|) =: \delta_1$, 则有

$$\begin{aligned}
\mathbf{w}_1^{k+1} &= \arg\min_{\mathbf{w}_1} \beta_1\|\mathbf{w}_1\|_1 + g(\mathbf{w}_1, \mathbf{w}_2^k, \mathbf{w}_3^k) + \tfrac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{r}^k\|^2 \\
&\quad + \varphi_1(\mathbf{w}_1) - \varphi_1(\mathbf{w}_1^k) - \langle \nabla\varphi_1(\mathbf{w}_1^k), \mathbf{w}_1 - \mathbf{w}_1^k\rangle \\
&= \arg\min_{\mathbf{w}_1} \beta_1\|\mathbf{w}_1\|_1 + \tfrac{t_1}{2}\|\mathbf{w}_1\|^2 - \langle t_1\mathbf{w}_1^k - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k) - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) \\
&\quad + \mathbf{r}^k) \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k, \mathbf{w}_1 - \mathbf{w}_1^k\rangle \\
&= \arg\min_{\mathbf{w}_1} \beta_1\|\mathbf{w}_1\|_1 + \tfrac{t_1}{2}\|\mathbf{w}_1 - (\mathbf{w}_1^k - \tfrac{1}{t_1}\nabla_{\mathbf{w}_1} g(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k) \\
&\quad - \tfrac{\sigma}{t_1}\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{r}^k) \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k)\|^2,
\end{aligned}$$

即

$$\mathbf{w}_1^{k+1} = \mathrm{Prox}_{\beta_1/t_1\|\cdot\|_1}(\mathbf{w}_1^k - \mathbb{B}_1^k), \tag{3-9}$$

其中 $\mathbb{B}_1^k = \frac{1}{t_1}\nabla_{\mathbf{w}_1} g(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k) + \frac{1}{t_1}\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{r}^k) \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k$. 类似地, 令 $\varphi_2(\mathbf{w}_2) = \frac{t_2}{2}\|\mathbf{w}_2\|^2 - g(\mathbf{w}_1^{k+1}, \mathbf{w}_2, \mathbf{w}_3^k) - \frac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2 \circ \mathbf{w}_3^k) + \mathbf{r}^k\|^2$, 其中 $t_2 >= \|\mathbf{w}_1^{k+1}\|^2\|\mathbf{w}_3^k\|^2(1 + \sigma\|\mathcal{A}^*\mathcal{A}\|) =: \delta_2$, 可得

$$\mathbf{w}_2^{k+1} = \mathrm{Prox}_{\beta_2/t_2\|\cdot\|_1}(\mathbf{w}_2^k - \mathbb{B}_2^k), \tag{3-10}$$

其中

$$\mathbb{B}_2^k = \frac{1}{t_2}\nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^k, \mathbf{w}_3^k) + \frac{1}{t_2}\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{r}^k) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k.$$

令 $\varphi_3(\mathbf{w}_3) = \frac{t_3}{2}\|\mathbf{w}_3\|^2 - g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3) - \frac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3) + \mathbf{r}^k\|^2$, 其中 $t_3 > \|\mathbf{w}_1^{k+1}\|^2\|\mathbf{w}_2^{k+1}\|^2(1 + \sigma\|\mathcal{A}^*\mathcal{A}\|) =: \delta_3$, 即有

$$\mathbf{w}_3^{k+1} = \mathrm{Prox}_{\beta_3/t_3\|\cdot\|_1}(\mathbf{w}_3^k - \mathbb{B}_3^k), \tag{3-11}$$

$$\mathbb{B}_3^k = \frac{1}{t_3}\nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^k) + \frac{1}{t_3}\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k) + \mathbf{r}^k) \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1}.$$

(ii) 更新 $\mathbf{z}$- 子问题. 取 $\eta = 1/\sigma$, $\nabla_{\mathbf{z}} h(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}, b^k, \Lambda^k) = \sigma(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z} + b^k\mathbf{y} - \mathbf{1} - \frac{\Lambda^k}{\sigma}$, 可得

$$\begin{aligned}
\mathbf{z}^{k+1} &\in \mathrm{Prox}_{\eta C\|(\cdot)_+\|_0}(\mathbf{z}^k - \eta\nabla_{\mathbf{z}} h(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^k, b^k, \Lambda^k)) \\
&= \mathrm{Prox}_{\eta C\|(\cdot)_+\|_0}(\tfrac{\Lambda^k}{\sigma} + \mathbf{1} - \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) - b^k\mathbf{y}).
\end{aligned}$$

中国知网 https://www.cnki.net

记 $T_{k+1} := \{i \in [M] : 0 < (\frac{\Lambda^k}{\sigma} + \mathbf{1} - \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) - b^k\mathbf{y})_i < \sqrt{2C\eta}\}$. 由上式和引理 1.3 有

$$\mathbf{z}^{k+1} = \begin{pmatrix} \mathbf{z}_{T_{k+1}}^{k+1} \\ \mathbf{z}_{\bar{T}_{k+1}}^{k+1} \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ (\frac{\Lambda^k}{\sigma} + \mathbf{1} - \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) - b^k\mathbf{y})_{\bar{T}_{k+1}} \end{pmatrix}. \tag{3-12}$$

(iii) 更新 $b-$ 子问题, 从最优性条件 (3-8) 可得,

$$0 = b^{k+1} + \sigma\mathbf{y}^\top(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1} - \frac{\Lambda^k}{\sigma}).$$

由于 $\mathbf{y}$ 为标签向量, 即有

$$b^{k+1} = (1 + \sigma M)^{-1}[\sigma\mathbf{y}^\top(\mathbf{1} + \frac{\Lambda^k}{\sigma} - \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) - \mathbf{z}^{k+1})]. \tag{3-13}$$

将以上对每个子问题的更新总结为算法 2, 称为 0/1-BADMM 算法, 即用带有 Bregman 距离的 ADMM 求解模型 (3-4) 的缩写.

算法 2 (0/1-BADMM) 求解问题 (3-4) 的 ADMM 算法

输入: 训练集 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 参数 $\sigma > 0, \eta = 1/\sigma, \eta_1, \eta_2, \eta_3 > 0$, 精度 $\epsilon > 0$.

输出: 权重参数 $\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3$, 偏置 b.

步 1. 初始化 $(\mathbf{w}_1^0, \mathbf{w}_2^0, \mathbf{w}_3^0, \mathbf{z}^0, b^0, \Lambda^0)$. 令 $k = 0$;

步 2. 根据 (3-9)-(3-13), (3-8) 分别计算 $(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^{k+1})$.

步 3. 若满足给定的终止准则与精度要求 ϵ, 则停止迭代. 否则, 令 $k = k + 1$, 转**步 2**.

3.3 收敛性分析

本节考虑所提算法的收敛性. 理论分析均基于以下两个假设条件.

性质 3.3.1: $g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) = \frac{1}{2}\prod_{n=1}^{3}\|\mathbf{w}_n\|^2$ 的梯度为

$$\nabla g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) = \begin{bmatrix} \nabla_{\mathbf{w}_1} g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) \\ \nabla_{\mathbf{w}_2} g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) \\ \nabla_{\mathbf{w}_3} g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3) \end{bmatrix} = \begin{bmatrix} \|\mathbf{w}_2\|^2\|\mathbf{w}_3\|^2\mathbf{w}_1 \\ \|\mathbf{w}_1\|^2\|\mathbf{w}_3\|^2\mathbf{w}_2 \\ \|\mathbf{w}_1\|^2\|\mathbf{w}_2\|^2\mathbf{w}_3 \end{bmatrix}.$$

假设 3.1: 令 $\mathfrak{H} := (\mathcal{A}, I) : \mathbb{R}^{I_1} \times \mathbb{R}^{I_2} \times \mathbb{R}^{I_3} \times \mathbb{R}^M \to \mathbb{R}^M$, $\mathfrak{H}(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3, \mathbf{z}) = \mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2 \circ \mathbf{w}_3) + \mathbf{z}$. 假设 $\mathbf{1} \cup \mathrm{Im}(\mathfrak{H}) \subset \mathrm{Im}(\mathbf{y})$, 其中 $\mathrm{Im}(\mathfrak{H}) := \{\mathcal{A}(\mathbf{w}_1 \circ \mathbf{w}_2 \circ \mathbf{w}_3) + \mathbf{z} : (\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3, \mathbf{z}) \in \mathbb{R}^{I_1} \times \mathbb{R}^{I_2} \times \mathbb{R}^{I_3} \times \mathbb{R}^M\}$, $\mathrm{Im}(\mathbf{y}) := \{\mathbf{y}b : b \in \mathbb{R}\}$.

中国知网 https://www.cnki.net

假设 3.2： 算法 2 序列 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k)\}$ 是有界的.

根据假设 3.2 和文献 [89] 的定理 5.17, 由上一节中 φ_i 的定义式可知 φ_i 是 δ_i- 强凸的, $i \in [3]$. 由性质 1.3.2 (iii) 可得, Bregman 距离 $D_{\varphi_i}(\mathbf{w}_i, \mathbf{w}_i^k) \geq \frac{\delta_i}{2}\|\mathbf{w}_i - \mathbf{w}_i^k\|^2, i \in [3]$. 下述引理描述了迭代序列如何影响增广拉格朗日函数 L_σ 的函数值.

引理 3.2： (下降性) 若假设 3.1 和 3.2 成立. $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)\}$ 为算法 2 生成的迭代序列. 那么当 $\sigma\mu > 1, \kappa = \min\{\frac{\delta_1}{2}, \frac{\delta_2}{2}, \frac{\delta_3}{2}, \frac{(1+\sigma\mu)\sigma\mu-2}{2\sigma\mu}\}$ 时有

$$L_\sigma(\Theta^{k+1}) - L_\sigma(\Theta^k) \leq -\kappa\|\Xi^{k+1} - \Xi^k\|^2.$$

证明 首先, 由 (3-8) 可知 $\mathbf{y}^\top\Lambda^{k+1} = b^{k+1}$, 进而有 $\mathbf{y}^\top(\Lambda^{k+1} - \Lambda^k) = b^{k+1} - b^k$. 由假设 3.1 可得 $\Lambda^{k+1} - \Lambda^k = -\sigma(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \in \mathrm{Im}(\mathbf{y})$. 故由引理 1.4 可知

$$\|\Lambda^{k+1} - \Lambda^k\| = \|P_{\mathbf{y}}(\Lambda^{k+1} - \Lambda^k)\| \leq \frac{1}{\sqrt{\mu}}|\mathbf{y}^\top(\Lambda^{k+1} - \Lambda^k)|.$$

令 $\mu = \|\mathbf{y}\|^2$, 对上式两边取范数可得

$$\|\Lambda^{k+1} - \Lambda^k\|^2 \leq \frac{1}{\mu}(\mathbf{y}^\top(\Lambda^{k+1} - \Lambda^k))^2 = \frac{1}{\mu}(b^{k+1} - b^k)^2. \tag{3-14}$$

另一方面,

$$\begin{aligned}
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^{k+1}) - L_\sigma(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) \\
= \; & L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^{k+1}) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^k) \\
& + L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^k) - L_\sigma(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k).
\end{aligned}$$

此外, 有

$$\begin{aligned}
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^{k+1}) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^k) \\
= \; & -(\Lambda^{k+1} - \Lambda^k)^\top(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \\
= \; & \tfrac{1}{\sigma}\|\Lambda^{k+1} - \Lambda^k\|^2.
\end{aligned}$$

由 (3-7) 可知

$$\begin{aligned}
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) - L_\sigma(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) \leq -\tfrac{\delta_1}{2}\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\|^2, \\
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) \leq -\tfrac{\delta_2}{2}\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\|^2, \\
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^k, b^k, \Lambda^k) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k) \leq -\tfrac{\delta_3}{2}\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\|^2, \\
& L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^k, \Lambda^k) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^k, b^k, \Lambda^k) \leq 0,
\end{aligned}$$

中国知网 https://www.cnki.net

函数 $L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b, \Lambda^k)$ 关于 b 是 ξ- 强凸的, 其中 $\xi := 1 + \sigma\mu$, 那么

$$L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^{k+1}, \Lambda^k) - L_\sigma(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}, \mathbf{z}^{k+1}, b^k, \Lambda^k) \leq -\frac{\xi}{2}(b^{k+1} - b^k)^2.$$

将以上等式与 (3-14) 相加可得

$$\begin{aligned} L_\sigma(\Theta^{k+1}) - L_\sigma(\Theta^k) \leq \ & -[\tfrac{\delta_1}{2}\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\|^2 + \tfrac{\delta_2}{2}\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\|^2 + \tfrac{\delta_3}{2}\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\|^2 \\ & +(\tfrac{\xi}{2} - \tfrac{1}{\sigma\mu})(b^{k+1} - b^k)^2]. \end{aligned}$$

令 $\kappa := \min\{\frac{\delta_1}{2}, \frac{\delta_2}{2}, \frac{\delta_3}{2}, \frac{\xi\sigma\mu-2}{2\sigma\mu}\}$ 和 $\sigma\mu > 1$, 可得

$$L_\sigma(\Theta^{k+1}) - L_\sigma(\Theta^k) \leq -\kappa\|\Xi^{k+1} - \Xi^k\|^2.$$

证毕. □

命题 3.1： 若 $\Lambda^0 \in \mathrm{Im}(\mathbf{y})$, 且 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, b^k, \mathbf{z}^k)\}$ 有界, 则 $\{\Lambda^k\}$ 有界.

证明 由 $\mathbf{y}^\top\Lambda^{k+1} = b^{k+1}$ 可知 $\|\mathbf{y}^\top\Lambda^{k+1}\|^2 = (b^{k+1})^2$. 由于 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, b^k)\}$ 是有界的, $\{\mathbf{y}^\top\Lambda^{k+1}\}$ 是有界的. 由假设 3.1 和引理 1.4 可知, $\|\Lambda^{k+1}\| \leq \frac{1}{\sqrt{\mu}}|\mathbf{y}^\top\Lambda^{k+1}|$. 因此, $\{\Lambda^k\}$ 是有界的. □

定理 3.2： 若假设 3.1 和 3.2 成立, 且 $\sigma\mu > 1$, 则有以下结论成立:
(i)

$$\lim_{k\to\infty}\|\mathbf{w}_1^k - \mathbf{w}_1^{k+1}\| = 0, \lim_{k\to\infty}\|\mathbf{w}_2^k - \mathbf{w}_2^{k+1}\| = 0, \lim_{k\to\infty}\|\mathbf{w}_3^k - \mathbf{w}_3^{k+1}\| = 0,$$

$$\lim_{k\to\infty}\|\mathbf{z}^k - \mathbf{z}^{k+1}\| = 0, \lim_{k\to\infty}|b^k - b^{k+1}| = 0.$$

(ii) 序列 $\{\Theta^k\}$ 的任意聚点是 P-稳定点.

证明 我们从以下几步证明该定理:
(i) 由函数 L_σ 的定义可知,

$$\begin{aligned} L_\sigma^k \ & := L_\sigma(\Theta^k) \\ & = g(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k) + \beta_1\|\mathbf{w}_1^k\|_1 + \beta_2\|\mathbf{w}_2^k\|_1 + \beta_3\|\mathbf{w}_3^k\|_1 + C\|\mathbf{z}_+^k\|_0 + \tfrac{1}{2}(b^k)^2 \\ & \quad +\tfrac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1} - \tfrac{\Lambda^k}{\sigma}\|^2 - \tfrac{1}{2\sigma}\|\Lambda^k\|^2. \end{aligned}$$

引理 3.2 已证得 $\{L_\sigma^k\}$ 为一个下降序列. 由 $g(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3), \|\cdot\|_1, \|(\cdot)_+\|_0$ 和 $\|\cdot\|^2$ 的下有界性以及 $\{\Lambda^k\}$ 的有界性可知, 函数 L_σ^k 下有界. 由单调有界定理可知, $\{L_\sigma^k\}$ 极限点存在, 不妨记为 L^*, 满足 $\lim_{k\to\infty} L_\sigma^k = L^*$.

中国知网 https://www.cnki.net

对 $L_\sigma^k - L_\sigma^{k+1} \geq \kappa\|\Xi^{k+1} - \Xi^k\|^2$ 两边取极限有

$$\lim_{k\to\infty}\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| = 0, \lim_{k\to\infty}\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| = 0, \lim_{k\to\infty}\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| = 0, \lim_{k\to\infty}|b^{k+1} - b^k| = 0. \tag{3-15}$$

同时, 对 (3-14) 令 $k \to \infty$, 可知 $\lim_{k\to\infty}\|\Lambda^{k+1} - \Lambda^k\| = 0$. 结合 $\Lambda^{k+1} = \Lambda^k - \sigma(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1})$, 则有

$$\begin{aligned}\mathbf{z}^{k+1} - \mathbf{z}^k &= \tfrac{1}{\sigma}(\Lambda^k - \Lambda^{k+1}) - \tfrac{1}{\sigma}(\Lambda^{k-1} - \Lambda^k) + (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + b^{k+1}\mathbf{y} - \mathbf{1}) \\ &\quad -(\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + b^k\mathbf{y} - \mathbf{1}).\end{aligned}$$

进而可得,

$$\begin{aligned}\|\mathbf{z}^{k+1} - \mathbf{z}^k\| &\leq \tfrac{1}{\sigma}\|\Lambda^k - \Lambda^{k+1}\| + \tfrac{1}{\sigma}\|\Lambda^{k-1} - \Lambda^k\| + |b^{k+1} - b^k|\|\mathbf{y}\| \\ &\quad +\|\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) - \mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k)\| \\ &\leq \tfrac{1}{\sigma}\|\Lambda^k - \Lambda^{k+1}\| + \tfrac{1}{\sigma}\|\Lambda^{k-1} - \Lambda^k\| + |b^{k+1} - b^k|\|\mathbf{y}\| \\ &\quad +\|\mathcal{A}\|\|\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1} - \mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k\|_F.\end{aligned} \tag{3-16}$$

此外, 又有

$$\begin{aligned}&\|\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1} - \mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k\|_F \\ =\ &\|(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1} - \mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k) + (\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k - \mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) \\ &+(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k - \mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k)\|_F \\ \leq\ &\|\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1} - \mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k\| + \|\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k - \mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k\|_F \\ &+\|\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k - \mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k\|_F \\ \leq\ &\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + \|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^k\|\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathbf{w}_2^k\|\|\mathbf{w}_3^k\|\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\|.\end{aligned} \tag{3-17}$$

对 (3-16) 两边取极限, 并结合式子 (3-15) 和 (3-17), 可得 $\lim_{k\to\infty}\|\mathbf{z}^{k+1} - \mathbf{z}^k\| = 0$.

(ii) 假设序列 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)\}$ 有界, 那么存在一个聚点 $\{(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*)\}$, 使得收敛子列

$$\lim_{i\to\infty}(\mathbf{w}_1^{k_i}, \mathbf{w}_2^{k_i}, \mathbf{w}_3^{k_i}, \mathbf{z}^{k_i}, b^{k_i}, \Lambda^{k_i}) = (\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*).$$

此外, 有

$$\begin{aligned}&\lim_{i\to\infty}\mathbf{w}_1^{k_i+1} = \lim_{i\to\infty}(\mathbf{w}_1^{k_i+1} - \mathbf{w}_1^{k_i} + \mathbf{w}_1^{k_i}) = \mathbf{w}_1^*, \lim_{i\to\infty}\mathbf{w}_2^{k_i+1} = \lim_{i\to\infty}(\mathbf{w}_2^{k_i+1} - \mathbf{w}_2^{k_i} + \mathbf{w}_2^{k_i}) = \mathbf{w}_2^*, \\ &\lim_{i\to\infty}\mathbf{w}_3^{k_i+1} = \lim_{i\to\infty}(\mathbf{w}_3^{k_i+1} - \mathbf{w}_3^{k_i} + \mathbf{w}_3^{k_i}) = \mathbf{w}_3^*, \lim_{i\to\infty}\mathbf{z}^{k_i+1} = \lim_{i\to\infty}(\mathbf{z}^{k_i+1} - \mathbf{z}^{k_i} + \mathbf{z}^{k_i}) = \mathbf{z}^*.\end{aligned}$$

中国知网 https://www.cnki.net

然后, 考虑 φ_n 的连续性, $n = 1, 2, 3$,

$$\begin{aligned}
&\lim_{i\to\infty}(\mathbf{w}_1^{k_i} + \eta_1(\mathcal{A}^*\Lambda^{k_i} \times_2 \mathbf{w}_2^{k_i} \times_3 \mathbf{w}_3^{k_i} - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k_i}, \mathbf{w}_2^{k_i}, \mathbf{w}_3^{k_i}) - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k_i+1} \circ \mathbf{w}_2^{k_i} \circ \mathbf{w}_3^{k_i}) \\
&\qquad + \mathbf{z}^{k_i} + b^{k_i}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k_i} \times_3 \mathbf{w}_3^{k_i}) + \nabla\varphi_1(\mathbf{w}_1^{k_i}) - \nabla\varphi_1(\mathbf{w}_1^{k_i+1})) \\
&= \mathbf{w}_1^* + \eta_1(\mathcal{A}^*\Lambda^* \times_2 \mathbf{w}_2^* \times_3 \mathbf{w}_3^* - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*)), \\
&\lim_{i\to\infty}(\mathbf{w}_2^{k_i} + \eta_2(\mathcal{A}^*\Lambda^{k_i} \times_1 \mathbf{w}_1^{k_i+1} \times_3 \mathbf{w}_3^{k_i} - \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k_i+1}, \mathbf{w}_2^{k_i}, \mathbf{w}_3^{k_i}) - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k_i+1} \circ \mathbf{w}_2^{k_i+1} \\
&\qquad \circ \mathbf{w}_3^{k_i}) + \mathbf{z}^{k_i} + b^{k_i}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k_i+1} \times_3 \mathbf{w}_3^{k_i}) + \nabla\varphi_2(\mathbf{w}_2^{k_i}) - \nabla\varphi_2(\mathbf{w}_2^{k_i+1})) \\
&= \mathbf{w}_2^* + \eta_2(\mathcal{A}^*\Lambda^* \times_1 \mathbf{w}_1^* \times_3 \mathbf{w}_3^* - \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*)), \\
&\lim_{i\to\infty}(\mathbf{w}_3^{k_i} + \eta_3(\mathcal{A}^*\Lambda^{k_i} \times_1 \mathbf{w}_1^{k_i+1} \times_2 \mathbf{w}_2^{k_i+1} - \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k_i+1}, \mathbf{w}_2^{k_i+1}, \mathbf{w}_3^{k_i}) - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k_i+1} \circ \mathbf{w}_2^{k_i+1} \\
&\qquad \circ \mathbf{w}_3^{k_i+1}) + \mathbf{z}^{k_i} + b^{k_i}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k_i+1} \times_2 \mathbf{w}_2^{k_i+1}) + \nabla\varphi_3(\mathbf{w}_3^{k_i}) - \nabla\varphi_3(\mathbf{w}_3^{k_i+1})) \\
&= \mathbf{w}_3^* + \eta_3(\mathcal{A}^*\Lambda^* \times_1 \mathbf{w}_1^* \times_2 \mathbf{w}_2^* - \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*)), \\
&\lim_{i\to\infty}(\mathbf{z}^{k_i} - \eta\nabla_{\mathbf{z}} h(\mathbf{w}_1^{k_1+1}, \mathbf{w}_2^{k_i+1}, \mathbf{w}_3^{k_i+1}, \mathbf{z}^{k_i}, b^{k_i}, \Lambda^{k_i}) = \mathbf{z}^* + \eta\Lambda^*.
\end{aligned}$$

由 (3-7) 和文献 [85] 的定理 1.25, 可得

$$\begin{cases}
\mathbf{w}_1^* = \mathrm{Prox}_{\beta_1\eta_1\|\cdot\|_1}(\mathbf{w}_1^* + \eta_1(\mathcal{A}^*\Lambda \times_2 \mathbf{w}_2^* \times_3 \mathbf{w}_3^* - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*))), \\
\mathbf{w}_2^* = \mathrm{Prox}_{\beta_2\eta_2\|\cdot\|_1}(\mathbf{w}_2^* + \eta_2(\mathcal{A}^*\Lambda \times_1 \mathbf{w}_1^* \times_3 \mathbf{w}_3^* - \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*))), \\
\mathbf{w}_3^* = \mathrm{Prox}_{\beta_3\eta_3\|\cdot\|_1}(\mathbf{w}_3^* + \eta_3(\mathcal{A}^*\Lambda \times_1 \mathbf{w}_1^* \times_2 \mathbf{w}_2^* - \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*))), \\
\mathbf{z}^* \in \mathrm{Prox}_{C\eta\|(\cdot)_+\|_0}(\mathbf{z}^* + \eta\Lambda^*), \\
b^* = \langle\Lambda^*, \mathbf{y}\rangle, \\
\Lambda^* = \Lambda^* - \sigma(\mathcal{A}(\mathbf{w}_1^* \circ \mathbf{w}_2^* \circ \mathbf{w}_3^*) + \mathbf{z}^* + b^*\mathbf{y} - \mathbf{1}),
\end{cases}$$

即 $\{(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*)\}$ 是一个 P-稳定点. □

引理 3.3： 令$\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)\}$ 为算法 2 生成的迭代序列. 存在 $\varsigma > 0$ 使得

$$\begin{aligned}
\mathrm{dist}(0, \partial L_\sigma(\Theta^{k+1})) \leq\ & \varsigma(\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + |b^{k+1} - b^k| \\
&+ |b^k - b^{k-1}|).
\end{aligned}$$

证明 由增广拉格朗日函数 $L_\sigma(\cdot)$ 的定义可知,

$$\begin{aligned}
\partial_{\mathbf{w}_1} L_\sigma(\Theta^{k+1}) =\ & \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) + \beta_1\partial\|\mathbf{w}_1^{k+1}\|_1 - \mathcal{A}^*\Lambda^{k+1} \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
&+ \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1},
\end{aligned}$$

中国知网 https://www.cnki.net

$$
\begin{aligned}
\partial_{\mathbf{w}_2} L_\sigma(\Theta^{k+1}) = \;& \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) + \beta_2 \partial \|\mathbf{w}_2^{k+1}\|_1 - \mathcal{A}^* \Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
& + \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1}, \\
\partial_{\mathbf{w}_3} L_\sigma(\Theta^{k+1}) = \;& \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) + \beta_3 \partial \|\mathbf{w}_3^{k+1}\|_1 - \mathcal{A}^* \Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} \\
& + \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1}, \\
\partial_{\mathbf{z}} L_\sigma(\Theta^{k+1}) = \;& c\partial \|\mathbf{z}_+^{k+1}\|_0 - \Lambda^{k+1} + \sigma(\mathbf{z}^{k+1} + \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + b^{k+1}\mathbf{y} - \mathbf{1}), \\
\partial_b L_\sigma(\Theta^{k+1}) = \;& b^{k+1} - \mathbf{y}^\top \Lambda^{k+1} + \sigma \mathbf{y}^\top (b^{k+1}\mathbf{y} + \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} - \mathbf{1}), \\
\partial_\Lambda L_\sigma(\Theta^{k+1}) = \;& \mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}.
\end{aligned}
$$

结合 (3-8) 可得

$$
\begin{aligned}
P_1^{k+1} :=\; & \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k}, \mathbf{w}_3^{k}) + \nabla \varphi_1(\mathbf{w}_1^{k}) - \nabla \varphi_1(\mathbf{w}_1^{k+1}) \\
& + \mathcal{A}^* \Lambda^k \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k - \mathcal{A}^* \Lambda^{k+1} \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
& + \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
& - \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k} \circ \mathbf{w}_3^{k}) + \mathbf{z}^{k} + b^{k}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k} \times_3 \mathbf{w}_3^{k} \in \partial_{\mathbf{w}_1} L_\sigma(\Theta^{k+1}), \\
P_2^{k+1} :=\; & \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \nabla_{\mathbf{w}_2} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k}) + \nabla \varphi_2(\mathbf{w}_2^{k}) - \nabla \varphi_2(\mathbf{w}_2^{k+1}) \\
& + \mathcal{A}^* \Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k - \mathcal{A}^* \Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
& + \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
& - \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k}) + \mathbf{z}^{k} + b^{k}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k} \in \partial_{\mathbf{w}_2} L_\sigma(\Theta^{k+1}), \\
P_3^{k+1} :=\; & \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \nabla_{\mathbf{w}_3} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) + \nabla \varphi_3(\mathbf{w}_3^{k}) - \nabla \varphi_3(\mathbf{w}_3^{k+1}) \\
& + \mathcal{A}^* \Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} - \mathcal{A}^* \Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} \\
& + \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} \\
& - \sigma \mathcal{A}^* (\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k} + b^{k}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_2 \mathbf{w}_2^{k+1} \in \partial_{\mathbf{w}_3} L_\sigma(\Theta^{k+1}), \\
P_{\mathbf{z}}^{k+1} :=\; & \Lambda^k - \Lambda^{k+1} + \sigma(b^{k+1} - b^k)\mathbf{y} \in \partial_{\mathbf{z}} L_\sigma(\Theta^{k+1}), \\
P_b^{k+1} :=\; & (\Lambda^k - \Lambda^{k+1})^\top \mathbf{y} \in \partial_b L_\sigma(\Theta^{k+1}), \\
P_\Lambda^{k+1} :=\; & \Lambda^{k+1} - \Lambda^k \in \partial_\Lambda L_\sigma(\Theta^{k+1}).
\end{aligned}
\tag{3-18}
$$

因此, 可得 $P^{k+1} := (P_1^{k+1}, P_2^{k+1}, P_3^{k+1}, P_{\mathbf{z}}^{k+1}, P_b^{k+1}, P_\Lambda^{k+1}) \in \partial L_\sigma(\Theta^{k+1})$.

中国知网 https://www.cnki.net

接下来,

$$\begin{aligned}\|P_1^{k+1}\| \leq\ & \|\nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k}, \mathbf{w}_2^{k}, \mathbf{w}_3^{k})\| + \|\nabla\varphi_1(\mathbf{w}_1^{k}) - \nabla\varphi_1(\mathbf{w}_1^{k+1})\| \\ & + \|\mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^{k+1} \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\ & + \|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\ & - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k} \circ \mathbf{w}_3^{k}) + \mathbf{z}^{k} + b^{k}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k} \times_3 \mathbf{w}_3^{k}\|.\end{aligned}$$

其中,

$$\begin{aligned}& \left\|\nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k+1}, \mathbf{w}_3^{k+1}) - \nabla_{\mathbf{w}_1} g(\mathbf{w}_1^{k+1}, \mathbf{w}_2^{k}, \mathbf{w}_3^{k})\right\| \\ = & \left\|\|\mathbf{w}_2^{k+1}\|^2\|\mathbf{w}_3^{k+1}\|^2\mathbf{w}_1^{k+1} - \|\mathbf{w}_2^{k}\|^2\|\mathbf{w}_3^{k}\|^2\mathbf{w}_1^{k+1}\right\| \\ \leq & \left\|\|\mathbf{w}_2^{k+1}\|^2\|\mathbf{w}_3^{k+1}\|^2\mathbf{w}_1^{k+1} - \|\mathbf{w}_2^{k+1}\|^2\|\mathbf{w}_3^{k}\|^2\mathbf{w}_1^{k+1}\right\| \\ & + \left\|\|\mathbf{w}_2^{k+1}\|^2\|\mathbf{w}_3^{k}\|^2\mathbf{w}_1^{k+1} - \|\mathbf{w}_2^{k}\|^2\|\mathbf{w}_3^{k}\|^2\mathbf{w}_1^{k+1}\right\| \\ \leq & \left\|\|\mathbf{w}_2^{k+1}\|^2(\|\mathbf{w}_3^{k+1}\| + \|\mathbf{w}_3^{k}\|)(\|\mathbf{w}_3^{k+1}\| - \|\mathbf{w}_3^{k}\|)\mathbf{w}_1^{k+1}\right\| \\ & + \left\|\|\mathbf{w}_3^{k}\|^2(\|\mathbf{w}_2^{k+1}\| + \|\mathbf{w}_2^{k}\|)(\|\mathbf{w}_2^{k+1}\| - \|\mathbf{w}_2^{k}\|)\mathbf{w}_1^{k+1}\right\| \\ \leq & \|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|^2(\|\mathbf{w}_3^{k+1}\| + \|\mathbf{w}_3^{k}\|)\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^{k}\| \\ & + \|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^{k}\|^2(\|\mathbf{w}_2^{k+1}\| + \|\mathbf{w}_2^{k}\|)\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^{k}\| \\ =: & q_1\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^{k}\| + q_2\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^{k}\|.\end{aligned}$$

$$\begin{aligned}& \|\mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^{k+1} \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\ \leq & \|\mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^k \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^k\| \\ & + \|\mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\ & + \|\mathcal{A}^*\Lambda^k \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} - \mathcal{A}^*\Lambda^{k+1} \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\ \leq & \|\mathcal{A}^*\Lambda^k\|\|\mathbf{w}_3^k\|\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathcal{A}^*\Lambda^k\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| \\ & + \|\mathcal{A}^*(\Lambda^k - \Lambda^{k+1})\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1}\|.\end{aligned}$$

$$\begin{aligned}& \|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\ & - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k} \circ \mathbf{w}_3^{k}) + \mathbf{z}^{k} + b^{k}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k} \times_3 \mathbf{w}_3^{k}\| \\ \leq & \|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k+1} \\ & - \sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_2 \mathbf{w}_2^{k+1} \times_3 \mathbf{w}_3^{k}\|\end{aligned}$$

中国知网 https://www.cnki.net

$$
\begin{aligned}
&+\|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})+\mathbf{z}^{k+1}+b^{k+1}\mathbf{y}-\mathbf{1})\times_2\mathbf{w}_2^{k+1}\times_3\mathbf{w}_3^{k}\\
&-\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})+\mathbf{z}^{k+1}+b^{k+1}\mathbf{y}-\mathbf{1})\times_2\mathbf{w}_2^{k}\times_3\mathbf{w}_3^{k}\|\\
&+\|\sigma\mathcal{A}^*[\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})-\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k})\\
&+\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k})-\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k}\circ\mathbf{w}_3^{k})\\
&+(\mathbf{z}^{k+1}-\mathbf{z}^{k})+(b^{k+1}-b^{k})\mathbf{y}]\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|\\
\leq\ &\|\sigma\mathcal{A}^*\|\|\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})+\mathbf{z}^{k+1}+b^{k+1}\mathbf{y}-\mathbf{1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|\\
&+\|\sigma\mathcal{A}^*\|\|\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})+\mathbf{z}^{k+1}+b^{k+1}\mathbf{y}-\mathbf{1}\|\|\mathbf{w}_3^{k}\|\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^{k}\|\\
&+\|\sigma\mathcal{A}^*\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|\\
&+\|\sigma\mathcal{A}^*\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|+\|\sigma\mathcal{A}^*\mathbf{y}\|b^{k+1}-b^{k}\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|\\
&+\|\sigma\mathcal{A}^*\|\|\mathbf{z}^{k+1}-\mathbf{z}^{k}\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|.
\end{aligned}
$$

然后, 由 (3-16), (3-17) 和 $\|\Lambda^{k+1}-\Lambda^{k}\|\leq\frac{1}{\sqrt{\mu}}|b^{k+1}-b^{k}|$, 可得

$$
\begin{aligned}
\|\mathbf{z}^{k+1}-\mathbf{z}^{k}\| &\leq \tfrac{1}{\sigma}(\|\Lambda^{k}-\Lambda^{k+1}\|+\|\Lambda^{k-1}-\Lambda^{k}\|)+\|(b^{k+1}-b^{k})\mathbf{y}\|\\
&\quad+\|\mathcal{A}\|\|\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1}-\mathbf{w}_1^{k}\circ\mathbf{w}_2^{k}\circ\mathbf{w}_3^{k}\|\\
&\leq \tfrac{1}{\sigma}(\|\Lambda^{k}-\Lambda^{k+1}\|+\|\Lambda^{k-1}-\Lambda^{k}\|)+\|\mathcal{A}\|(\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|\\
&\quad+\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|+\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^{k}\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|)+|b^{k+1}-b^{k}|\|\mathbf{y}\|\\
&\leq (\tfrac{1}{\sigma\sqrt{\mu}}+\|\mathbf{y}\|)|b^{k+1}-b^{k}|+\tfrac{1}{\sigma\sqrt{\mu}}|b^{k}-b^{k-1}|+\|\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|\\
&\quad+\|\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^{k}\|\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^{k}\|+\|\mathcal{A}\|\|\mathbf{w}_2^{k}\|\|\mathbf{w}_3^{k}\|\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^{k}\|.
\end{aligned}
$$

类似地, 对于 P_2^{k+1}, 有

$$
\begin{aligned}
\|P_2^{k+1}\|\leq\ &\|\nabla_{\mathbf{w}_2}g(\mathbf{w}_1^{k+1},\mathbf{w}_2^{k+1},\mathbf{w}_3^{k+1})-\nabla_{\mathbf{w}_2}g(\mathbf{w}_1^{k+1},\mathbf{w}_2^{k+1},\mathbf{w}_3^{k})\|+\|\nabla\varphi_2(\mathbf{w}_2^{k+1})-\nabla\varphi_2(\mathbf{w}_2^{k})\|\\
&+\|\mathcal{A}^*\Lambda^{k}\times_1\mathbf{w}_1^{k+1}\times_3\mathbf{w}_3^{k}-\mathcal{A}^*\Lambda^{k+1}\times_1\mathbf{w}_1^{k+1}\times_3\mathbf{w}_3^{k+1}\|\\
&+\|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k+1})+\mathbf{z}^{k+1}+b^{k+1}\mathbf{y}-\mathbf{1})\times_1\mathbf{w}_1^{k+1}\times_3\mathbf{w}_3^{k+1}\\
&-\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1}\circ\mathbf{w}_2^{k+1}\circ\mathbf{w}_3^{k})+\mathbf{z}^{k}+b^{k}\mathbf{y}-\mathbf{1})\times_1\mathbf{w}_1^{k+1}\times_3\mathbf{w}_3^{k}\|,
\end{aligned}
$$

其中

$$
\begin{aligned}
&\left\|\nabla_{\mathbf{w}_2}g(\mathbf{w}_1^{k+1},\mathbf{w}_2^{k+1},\mathbf{w}_3^{k+1})-\nabla_{\mathbf{w}_2}g(\mathbf{w}_1^{k+1},\mathbf{w}_2^{k+1},\mathbf{w}_3^{k})\right\|\\
\leq\ &\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_1^{k+1}\|^2(\|\mathbf{w}_3^{k+1}\|+\|\mathbf{w}_3^{k}\|)\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|\\
=:\ &q_3\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^{k}\|,
\end{aligned}
$$

中国知网 https://www.cnki.net

$$
\begin{aligned}
&\|\mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\
\leq\ &\|\mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k - \mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\
&+\|\mathcal{A}^*\Lambda^k \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} - \mathcal{A}^*\Lambda^{k+1} \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1}\| \\
\leq\ &\|\mathcal{A}^*\Lambda^k\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^k - \mathbf{w}_3^{k+1}\| + \|\mathcal{A}^*(\Lambda^k - \Lambda^{k+1})\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^{k+1}\|,
\end{aligned}
$$

$$
\begin{aligned}
&\|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
&\quad -\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k\| \\
\leq\ &\|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^{k+1} \\
&\quad -\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k\| \\
&\quad +\|\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k \\
&\quad -\sigma\mathcal{A}^*(\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^k) + \mathbf{z}^k + b^k\mathbf{y} - \mathbf{1}) \times_1 \mathbf{w}_1^{k+1} \times_3 \mathbf{w}_3^k\| \\
\leq\ &\|\sigma\mathcal{A}^*\|\|\mathcal{A}(\mathbf{w}_1^{k+1} \circ \mathbf{w}_2^{k+1} \circ \mathbf{w}_3^{k+1}) + \mathbf{z}^{k+1} + b^{k+1}\mathbf{y} - \mathbf{1}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| \\
&\quad +\|\sigma\mathcal{A}^*\|\|\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|^2\|\mathbf{w}_2^{k+1}\|\|\mathbf{w}_3^k\|\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + \|\sigma\mathcal{A}^*\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^k\|\|\mathbf{z}^{k+1} - \mathbf{z}^k\| \\
&\quad +\|\sigma\mathcal{A}^*\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_3^k\|\|\mathbf{y}\||b^{k+1} - b^k|.
\end{aligned}
$$

同理可得,

$$
\begin{aligned}
\|P_3^{k+1}\| \leq\ &\|\nabla\varphi_3(\mathbf{w}_3^k) - \nabla\varphi_3(\mathbf{w}_3^{k+1})\| + \|\mathcal{A}^*(\Lambda^k - \Lambda^{k+1})\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\| \\
&+\|\sigma\mathcal{A}^*\|\|\mathcal{A}\|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|\|\mathbf{z}^{k+1} - \mathbf{z}^k\| + \|\sigma\mathcal{A}^*\mathbf{y}\||b^{k+1} - b^k|\|\mathbf{w}_1^{k+1}\|\|\mathbf{w}_2^{k+1}\|, \\
\|P_{\mathbf{z}}^{k+1}\| \leq\ &\|\Lambda^{k+1} - \Lambda^k\| + \sigma|b^{k+1} - b^k|\|\mathbf{y}\|, \\
\|P_b^{k+1}\| \leq\ &\|\Lambda^{k+1} - \Lambda^k\|\|\mathbf{y}\|, \\
\|P_\Lambda^{k+1}\| =\ &\|\Lambda^{k+1} - \Lambda^k\|.
\end{aligned}
$$

由序列 $\{\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, b^k\}$ 的有界性可知 $\{\mathcal{A}(\mathbf{w}_1^k \circ \mathbf{w}_2^k \circ \mathbf{w}_3^k) + b^k\mathbf{y} + \mathbf{z}^k - \mathbf{1}\}$ 有界. 由于算子 $\mathcal{A}$ 如 (3-2) 所定义, 存在常数 $\varrho_1, \varrho_2 > 0$ 使得 $\|\mathcal{A}\| \leq \varrho_1$ 和 $\|\mathcal{A}^*\| \leq \varrho_2$. 结合上述分析可知, 存在 $J_1 > 0$ 使得

$$
\|P_1^{k+1}\| \leq J_1(\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + |b^{k+1} - b^k| + |b^k - b^{k-1}|).
$$

类似地, 对于 $J_2, J_3, J_4, J_5, J_6 > 0$, 有

中国知网 https://www.cnki.net

$$
\begin{aligned}
\|P_2^{k+1}\| \leq\ & J_2(\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^k\|+\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^k\|+\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^k\|+|b^{k+1}-b^k|+|b^k-b^{k-1}|),\\
\|P_3^{k+1}\| \leq\ & J_3(\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^k\|+\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^k\|+\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^k\|+|b^{k+1}-b^k|+|b^k-b^{k-1}|),\\
\|P_{\mathbf{z}}^{k+1}\| \leq\ & J_4(|b^{k+1}-b^k|+|b^k-b^{k-1}|),\\
\|P_b^{k+1}\| \leq\ & J_5|b^{k+1}-b^k|,\\
\|P_\Lambda^{k+1}\| \leq\ & J_6|b^{k+1}-b^k|.
\end{aligned}
$$

因此, 存在 $\varsigma>0$ 有

$$
\begin{aligned}
\operatorname{dist}(0,\partial L_\sigma(\Theta^{k+1})) \leq\ & \varsigma(\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^k\|+\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^k\|+\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^k\|+|b^{k+1}-b^k|\\
&+|b^k-b^{k-1}|),
\end{aligned}
$$

其中 $\varsigma=\max\{J_1,J_2,J_3,J_4,J_5,J_6\}$. 证毕. □

在接下来的内容中, 记 Ω 为序列 $\{\Theta^k\}$ 的所有聚点集合.

引理 3.4: 若假设 3.1 和 3.2 成立. $\{\Theta^k\}$ 为算法 2 生成的迭代序列. 以下结论成立:
(i) 集合 Ω 是非空紧集, 且 $\operatorname{dist}(\Theta^k,\Omega)\to 0, k\to\infty$;
(ii) 假设序列 $\{\Theta^k\}$ 的子序列 $\{\Theta^{k_j}\}$ 当 $j\to\infty$ 收敛到 Θ^*, 则有

$$\lim_{j\to+\infty} L_\sigma(\Theta^{k_j})=L_\sigma(\Theta^*);$$

(iii) $\Omega\subseteq \operatorname{cirt}(L_\sigma)$.

证明 (i) 由极限点的定义可知 $\operatorname{dist}(\Theta^k,\Omega)\to 0, k\to\infty$ 成立, Ω 是非空紧集.
(ii) 令 $\Theta^*:=(\mathbf{w}_1^*,\mathbf{w}_2^*,\mathbf{w}_3^*,\mathbf{z}^*,b^*,\Lambda^*)\in\Omega$, $\{\Theta^{k_j}\}$ 为 $\{\Theta^k\}$ 的子序列, 当 $j\to\infty$ 时收敛到 Θ^*.
因 $\|\cdot\|_1$ 是连续的, 那么 $\lim\limits_{j\to\infty}\|\mathbf{w}_n^{k_j}\|_1=\|\mathbf{w}_n^*\|_1, n=1,2,3$. 由 (3-7) 可知, 对任意的 $j\geq 1$,

$$L_\sigma(\mathbf{w}_1^{k_j+1},\mathbf{w}_2^{k_j+1},\mathbf{w}_3^{k_j+1},\mathbf{z}^{k_j+1},b^{k_j},\Lambda^{k_j})\leq L_\sigma(\mathbf{w}_1^{k_j+1},\mathbf{w}_2^{k_j+1},\mathbf{w}_3^{k_j+1},\mathbf{z}^*,b^{k_j},\Lambda^{k_j}).$$

对上述不等式两边取极限,

$$\limsup_{j\to\infty} C\|\mathbf{z}_+^{k_j+1}\|_0\leq C\|\mathbf{z}_+^*\|_0.$$

结合 L_σ 的下半连续性可得

$$\liminf_{j\to\infty} C\|\mathbf{z}_+^{k_j+1}\|_0\geq C\|\mathbf{z}_+^*\|_0.$$

中国知网 https://www.cnki.net

故有 $\lim\limits_{j\to\infty} C\|\mathbf{z}_+^{k_j+1}\|_0 = C\|\mathbf{z}_+^*\|_0$. 进一步, 结合 $\|\cdot\|^2$ 和 $\|\cdot\|_1$ 的连续性, 可知

$$\begin{aligned}
&\lim_{j\to+\infty} L_\sigma(\mathbf{w}_1^{k_j}, \mathbf{w}_2^{k_j}, \mathbf{w}_3^{k_j}, \mathbf{z}^{k_j}, b^{k_j}, \Lambda^{k_j}) \\
= &\lim_{j\to+\infty} (\beta_1\|\mathbf{w}_1^{k_j}\|_1 + \beta_2\|\mathbf{w}_2^{k_j}\|_1 + \beta_3\|\mathbf{w}_2^{k_j}\|_1 + C\|\mathbf{z}_+^{k_j}\|_0 + \tfrac{1}{2}(b^{k_j})^2 + g(\mathbf{w}_1^{k_j}, \mathbf{w}_2^{k_j}, \mathbf{w}_3^{k_j}) \\
&-\langle\Lambda^{k_j}, \mathcal{A}(\mathbf{w}_1^{k_j}\circ\mathbf{w}_2^{k_j}\circ\mathbf{w}_3^{k_j}) + \mathbf{z}^{k_j} + b^{k_j}\mathbf{y} - \mathbf{1}\rangle \\
&+\tfrac{\sigma}{2}\|\mathcal{A}(\mathbf{w}_1^{k_j}\circ\mathbf{w}_2^{k_j}\circ\mathbf{w}_3^{k_j}) + \mathbf{z}^{k_j} + b^{k_j}\mathbf{y} - \mathbf{1}\|^2) \\
= &\ L_\sigma(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*).
\end{aligned}$$

考虑到 $L_\sigma(\Theta^k)$ 的下降性, 可得

$$\lim_{k\to+\infty} L_\sigma(\Theta^k) = L_\sigma(\Theta^*) = L^*.$$

(iii) 对于 (3-18) 中定义的序列 $\{P_1^k, P_2^k, P_3^k, P_{\mathbf{z}}^k, P_b^k, P_\Lambda^k\}$, 对任意的 $j \geq 1$, 都有 $P^{k_j} \in \partial L_\sigma(\Theta^{k_j})$ 和 $\lim\limits_{j\to+\infty} P^{k_j} = 0$, 而

$$\begin{aligned}
&\lim_{j\to+\infty} (\mathbf{w}_1^{k_j}, \mathbf{w}_2^{k_j}, \mathbf{w}_3^{k_j}, \mathbf{z}^{k_j}, b^{k_j}, \Lambda^{k_j}) = (\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*), \\
&\lim_{j\to+\infty} L_\sigma(\mathbf{w}_1^{k_j}, \mathbf{w}_2^{k_j}, \mathbf{w}_3^{k_j}, \mathbf{z}^{k_j}, b^{k_j}, \Lambda^{k_j}) = L_\sigma(\mathbf{w}_1^*, \mathbf{w}_2^*, \mathbf{w}_3^*, \mathbf{z}^*, b^*, \Lambda^*).
\end{aligned}$$

由 ∂L_σ 的闭性可知 $0 \in \partial L_\sigma(\Theta^*)$, 或者 $\Theta^* \in \mathrm{crit}(L_\sigma)$, 也即 $\Omega \subseteq \mathrm{crit}(L_\sigma(\Theta^k))$. □

在接下来的内容中, 我们将证明在 KL 性质下, 算法 2 生成的迭代序列 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)\}$ 的全局收敛性. 定义对于每个 $k \geq 1$, $\mathcal{E}_k := L_\sigma(\Theta^k) - L_\sigma(\Theta^*) = L_\sigma^k - L^* \geq 0$ 都是单调递减的.

定理 3.3: (全局收敛性) 若假设 3.1 和 3.2 成立, 序列 $\{(\mathbf{w}_1^k, \mathbf{w}_2^k, \mathbf{w}_3^k, \mathbf{z}^k, b^k, \Lambda^k)\}$ 为算法 2 生成的迭代序列, 则有以下结论成立:

(i)

$$\begin{aligned}
&\sum_{k=0}^{+\infty}\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| < +\infty, \sum_{k=0}^{+\infty}\|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| < +\infty, \sum_{k=0}^{+\infty}\|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| < +\infty, \\
&\sum_{k=0}^{+\infty}\|\mathbf{z}^{k+1} - \mathbf{z}^k\| < +\infty, \sum_{k=0}^{+\infty}\|b^{k+1} - b^k\| < +\infty.
\end{aligned}$$

(ii) 序列 $\{\Theta^k\}$ 收敛到函数 $L_\sigma(\cdot)$ 的稳定点.

证明 引理 3.4 已证得 Ω 为一非空紧集. 令 $\Theta^* \in \Omega$, 则有 $L_\sigma(\Theta^*) = L^*$, 且当 $k \to \infty$ 时有 $\{\mathcal{E}_k = L_\sigma^k - L_\sigma^*\} \to 0$. 接下来考虑以下情况:

(a) 假设存在一个整数 $k' \geq 0$ 使得 $L_\sigma^k - L^* = 0$. 考虑到 $\{\mathcal{E}_k\}$ 的单调性, 对所有的 $k \geq k'$ 有 $\mathcal{E}_k = 0$. 结合引理 3.2 可知对所有的 $k > k'$, $\mathbf{w}_1^{k+1} = \mathbf{w}_1^k, \mathbf{w}_2^{k+1} = \mathbf{w}_2^k, \mathbf{w}_3^{k+1} =$

中国知网 https://www.cnki.net

$\mathbf{w}_3^k, b^{k+1} = b^k$. 因此, 由 (3-14) 和 (3-16) 可知, 对所有的 $k > k'$, $\mathbf{z}^{k+1} = \mathbf{z}^k$, 结论成立.

(b) 假设 $L_\sigma^k > L^*$, $\forall k$. 由于 $\lim_{k\to+\infty} \mathrm{dist}(\Theta^k, \Omega) = 0$, 对任意的 $\nu > 0$, 都存在 $k_1 > 0$ 使得对所有的 $k > k_1$, $\mathrm{dist}(\Theta^k, \Omega) < \nu$. 根据 $\lim\limits_{k\to+\infty} L_\sigma^k = L^*$, 对于任意的 $\upsilon > 0$, 存在 $k_2 > 0$ 使得对所有的 $k > k_2$, $L_\sigma^k < L^* + \upsilon$.

因此, 对 $k > k_0 := \max\{k_1, k_2\}$, 有

$$\mathrm{dist}(\Theta^k, \Omega) < \nu, L^* < L_\sigma^k < L^* + \upsilon.$$

由定义 1.18 可知

$$\psi'(L_\sigma^k - L^*) \cdot \mathrm{dist}(0, \partial L_\sigma^k) = \psi'(\mathcal{E}_k) \cdot \mathrm{dist}(0, \partial L_\sigma^k) \geq 1. \tag{3-19}$$

为方便起见, 定义 $\triangle_{p,q} = \psi(L_\sigma^p - L^*) - \psi(L_\sigma^q - L^*) = \psi(\mathcal{E}_p) - \psi(\mathcal{E}_q)$. 对每个 $K \geq k_0 \geq 1$, 都有

$$\sum_{k=k_0}^{K} \triangle_{k,k+1} = \triangle_{k_0,K+1} = \psi(\mathcal{E}_{k_0}) - \psi(\mathcal{E}_{K+1}) \leq \psi(\mathcal{E}_{k_0}),$$

即 $\sum_{k\geq 1} \triangle_{k,k+1} < +\infty$.

结合引理 3.2 已证得的 L_σ^k 的下降性和函数 ψ 的凹性, 可得, 对每个 $k \geq 1$,

$$\triangle_{k,k+1} = \psi(\mathcal{E}_k) - \psi(\mathcal{E}_{k+1}) \geq \psi'(\mathcal{E}_k)(\mathcal{E}_k - \mathcal{E}_{k+1}) = \psi'(\mathcal{E}_k)(L_\sigma^k - L_\sigma^{k+1}) \geq \psi'(\mathcal{E}_k)\kappa\|\Xi^{k+1} - \Xi^k\|^2.$$

由 (3-19) 可知

$$\begin{aligned} \|\Xi^{k+1} - \Xi^k\|^2 &\leq \psi'(\mathcal{E}_k) \cdot \mathrm{dist}(0, \partial L_\sigma^k)\|\Xi^{k+1} - \Xi^k\|^2 \\ &\leq \tfrac{1}{\kappa}\triangle_{k,k+1}\mathrm{dist}(0, \partial L_\sigma^k), \ \forall k \geq k_0. \end{aligned}$$

由于 $\|\Xi^{k+1} - \Xi^k\|^2 = \|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\|^2 + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\|^2 + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\|^2 + |b^{k+1} - b^k|^2$, 可得

$$\begin{aligned} & 3(\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + |b^{k+1} - b^k|) \\ \leq\ & 6(\|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\|^2 + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\|^2 + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\|^2 + |b^{k+1} - b^k|^2)^{1/2} \\ =\ & 6\sqrt{\|\Xi^{k+1} - \Xi^k\|^2} \\ \leq\ & 2\sqrt{\tfrac{9}{\kappa}\triangle_{k,k+1}\mathrm{dist}(0, \partial L_\sigma^k)} \\ \leq\ & \tfrac{9\varsigma}{\kappa}\triangle_{k,k+1} + (\|\mathbf{w}_1^k - \mathbf{w}_1^{k-1}\| + \|\mathbf{w}_2^k - \mathbf{w}_2^{k-1}\| + \|\mathbf{w}_3^k - \mathbf{w}_3^{k-1}\| + |b^k - b^{k-1}| \\ & + |b^{k-1} - b^{k-2}|). \end{aligned}$$

由 $2\sqrt{\alpha\beta} \leq \alpha + \beta(\alpha, \beta > 0)$ 和引理 3.3, 可得最后一个不等式. 为方便, 记 $R_{k+1} = \|\mathbf{w}_1^{k+1} - \mathbf{w}_1^k\| + \|\mathbf{w}_2^{k+1} - \mathbf{w}_2^k\| + \|\mathbf{w}_3^{k+1} - \mathbf{w}_3^k\| + |b^{k+1} - b^k|$. 考虑 $k = k_0 + 1, \ldots, K$, 将上述

中国知网 https://www.cnki.net

公式相加可得

$$\begin{aligned}\sum_{k=k_0+1}^{K} 3R_{k+1} &\leq \sum_{k=k_0+1}^{K}(\tfrac{9\varsigma}{\kappa}\triangle_{k,k+1}+R_k+|b^{k-1}-b^{k-2}|)\\ &\leq \sum_{k=k_0+1}^{K}(\tfrac{9\varsigma}{\kappa}\triangle_{k,k+1}+R_k+\|\mathbf{w}_1^{k-1}-\mathbf{w}_1^{k-2}\|+\|\mathbf{w}_2^{k-1}-\mathbf{w}_2^{k-2}\|+\|\mathbf{w}_3^{k-1}-\mathbf{w}_3^{k-2}\|\\ &\quad+|b^{k-1}-b^{k-2}|)\\ &\leq \sum_{k=k_0+1}^{K}(\tfrac{9\varsigma}{\kappa}\triangle_{k,k+1}+R_k+R_{k-1}).\end{aligned}$$

由 $\psi(L_\sigma^{K+1}-L^*)>0$ 得

$$\begin{aligned}\sum_{k=k_0+1}^{K} R_{k+1} &\leq \sum_{k=k_0+1}^{K}(R_k-R_{k+1}+R_{k-1}-R_{k+1})+\tfrac{9\varsigma}{\kappa}(\psi(L_\sigma^{k_0+1}-L^*)-\psi(L_\sigma^{K+1}-L^*))\\ &\leq \mathcal{B}+\tfrac{9\varsigma}{\kappa}\psi(L_\sigma^{k_0+1}-L^*),\end{aligned}$$

其中 $\mathcal{B}=R_{k_0+1}+R_{k_0}+R_{k_0+1}$. 令 $K\to\infty$, 则有

$$\sum_{k=0}^{\infty} R_{k+1}=\sum_{k=0}^{\infty}(\|\mathbf{w}_1^{k+1}-\mathbf{w}_1^k\|+\|\mathbf{w}_2^{k+1}-\mathbf{w}_2^k\|+\|\mathbf{w}_3^{k+1}-\mathbf{w}_3^k\|+|b^{k+1}-b^k|)<\infty.$$

由式子 (3-14) 可得 $\sum_{k=0}^{\infty}\|\Lambda^{k+1}-\Lambda^k\|<\infty$. 类似地, 有$\sum_{k=0}^{\infty}\|\mathbf{z}^{k+1}-\mathbf{z}^k\|<\infty$, 即

$$\sum_{k=0}^{\infty}\|\Theta^{k+1}-\Theta^k\|<\infty.$$

因此, Θ^k 是一个 Cauchy 数列, 由引理 3.4 可知 Θ^k 收敛到 Θ^* . □

3.4 数值实验

为验证所提模型和方法 0/1-BADMM 的有效性, 本节挑选出代表性算法 LIBSVM, SHTM, 以分类精度为衡量标准, 在模拟数据上进行比较. 数值实验均使用 Matlab 2018b 和 Tensor toolbox, 在 Intel(R) Core(TM) i7-8565U CPU @1.8GHz 电脑上进行计算.

对于算法 2, 采用点距停机准则, 即

$$\max\left\{\frac{\|\mathbf{w}_1^k-\mathbf{w}_1^{k-1}\|}{\|\mathbf{w}_1^{k-1}\|},\frac{\|\mathbf{w}_2^k-\mathbf{w}_2^{k-1}\|}{\|\mathbf{w}_2^{k-1}\|},\frac{\|\mathbf{w}_3^k-\mathbf{w}_3^{k-1}\|}{\|\mathbf{w}_3^{k-1}\|},\frac{|b^k-b^{k-1}|}{|b^{k-1}|}\right\}<\epsilon$$

或迭代次数 $K=\text{itermax}$, 其中, $(\mathbf{w}_1^k,\mathbf{w}_2^k,\mathbf{w}_3^k,b^k)$ 为当前迭代点, 精度参数 $\epsilon=10^{-2}$, 最大迭代次数为 itermax = 5000. 上述四类算法中的模型参数 C 利用网格搜索从集合 $\{2^0,2^1,\cdots,2^8\}$ 中选取. 其中, SHTM 算法的 CP 秩从 $\{1,2,3,4,5\}$ 中网格搜索选取.

随机生成 n 个张量样本 $\mathcal{X}_i\in\mathbb{R}^{I_1\times I_2\times I_3}, i\in[n]$, 随机生成三个服从正态分布的向量 $\hat{\mathbf{w}}_1\in\mathbb{R}^{I_1}$, $\hat{\mathbf{w}}_2\in\mathbb{R}^{I_2}$, $\hat{\mathbf{w}}_2\in\mathbb{R}^{I_3}$, 秩一张量权重参数 $\hat{\mathcal{W}}=\hat{\mathbf{w}}_1\circ\hat{\mathbf{w}}_2\circ\hat{\mathbf{w}}_3$. 取 $\hat{b}=2$. 按照

中国知网 https://www.cnki.net

如下方式对生成的样本进行分类标记

$$y_i = f(\mathcal{X}_i) = \mathrm{sgn}(\langle \hat{\mathcal{W}}, \mathcal{X}_i \rangle + \hat{b}), i \in [n].$$

在数值实验中, 取初始点 $\mathbf{w}_1^0 = \hat{\mathbf{w}}_1 - 0.1 \times \mathrm{rand}(I_1, 1)$, $\mathbf{w}_2^0 = \hat{\mathbf{w}}_2 - 0.1 \times \mathrm{rand}(I_2, 1)$, $\mathbf{w}_3^0 = \hat{\mathbf{w}}_3 - 0.1 \times \mathrm{rand}(I_3, 1)$, $b^0 = 0$, $\mathbf{z}^0 = \mathbf{0}$, $\Lambda^0 = \mathbf{0}$, 增广拉格朗日罚参数 $\sigma = 0.01$. 在数值实验中, 分别在不同的样本数以及不同的维度下进行测试, 所有的数值结果均为 5 次 5 折交叉验证后的均值, 分别记录在表 3.1 和 3.2.

表 3.1 记录了固定张量维度 (I_1, I_2, I_3) 时, 三种算法在不同张量样本 $n = 200$ 下的预测精度. 由表 3.1 可得, 0/1-BADMM 算法分类精度明显高于其他两种算法, 并且随着样本量 n 的增加, 算法数值效果也比较稳定.

表 3.1　固定维度 $(30, 30, 20)$, 不同样本量 n 下的分类精度 (%).

Tab 3.1　The classification accuracy (%) under different sample sizes with $(30, 30, 20)$.

n	0/1-BADMM	LIBSVM	SHTM
100	**94.00**	60.00	65.00
200	**96.46**	62.00	64.50
500	**92.41**	58.60	62.19
1000	**93.90**	52.20	52.01

表 3.2 记录了固定样本量 $n = 200$ 时, 三种算法在不同张量维度 (I_1, I_2, I_3) 下的分类精度. 随着维度 (I_1, I_2, I_3) 的增加, 算法数值效果也比较稳定.

表 3.2　固定样本量 $n = 200$, 不同维度下的分类精度 (%).

Tab 3.2　The classification accuracy (%) under different sample sizes with $n = 200$.

(I_1, I_2, I_3)	0/1-BADMM	LIBSVM	SHTM
$(20, 20, 10)$	**97.52**	58.00	53.00
$(30, 30, 20)$	**96.46**	62.00	64.50
$(40, 40, 30)$	**95.97**	51.50	56.54
$(50, 50, 40)$	**94.50**	56.50	59.46

注: 可用已有的算法求得该二分类问题的最优解作为0/1-BADMM算法的初始点以提高算法的精度

由于生成的模拟数据中真实的张量权重参数为秩一张量, 符合所提模型中的条件, 且 0/1-BADMM 算法选取的初始点在真实值附近, 因此算法可以得到很好的近似解, 这也是表 3.1 和表 3.2 中所提算法优于其他算法的主要原因.

中国知网 https://www.cnki.net

3.5 本章小结

本章首次提出了双稀疏支持张量机模型, 考虑了二分类的本原损失函数 0/1 损失, 并通过 ℓ_1 正则对特征进行选择, 减少冗余信息的影响. 针对这一带有非线性等式约束的非凸非连续优化问题, 给出模型的邻近算子稳定点, 分析其与最优解的关系, 并设计基于Bregman 距离的 ADMM 算法来求解, 在温和条件下借助 KL 性质证明了算法的全局收敛性. 基于模拟数据的数值结果验证了算法的有效性, 未来将继续探索此算法在实际数据集上的性能.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

4 尺度化核技术稀疏支持张量机

前面两章针对近似线性可分的张量数据, 提出了处理二分类问题的支持张量机模型, 模型中的稀疏性多体现在原始问题角度的样本稀疏和特征选择上. 已有的工作缺乏对数据约简方面的考虑, 且实际生活中的数据并不都是线性可分的. 因此, 本章研究从对偶问题的角度出发, 对对偶变量施加稀疏约束来控制支持张量的数量, 并引入张量高斯核函数来进行非线性分类. 为了减轻核函数中恒定核宽度带来的局部风险, 提出两阶段算法对核函数进行尺度化.

4.1 优化模型

由引言可知, 原始的 STM 模型可表述为

$$\min_{\mathcal{W},b} \frac{1}{2}\|\mathcal{W}\|_F^2 + C_0 \sum_{i=1}^{M} \ell(1 - y_i(\langle \mathcal{W}, \mathcal{X}_i\rangle + b)).$$

其中, $\ell(\cdot)$ 为一个损失函数, 用于惩罚训练过程中错误的分类, $C_0 > 0$ 是惩罚参数. 传统的损失函数包括合页损失及其变体、弹球损失及其变体、Sigmoid损失等. 关于损失函数的研究可参考文献 [39,104–106]. 由于以下分段二次光滑损失函数[107]在支持向量机中上具有较好的性能, 本文采用该损失函数来刻画张量样本分类中造成的损失:

$$\ell_{cC}(t) := \begin{cases} Ct^2/2, & t \geq 0, \\ ct^2/2, & t < 0. \end{cases} \tag{4-1}$$

其中, 调节参数 C 和 c 满足 $0 < c < C$. 显然, 当 $c = 0$ 时, $\ell_{cC}(t)$ 退化为平方合页损失 $(\ell_{hl}(t))^2$. 遵循传统 SVM 的核技巧技术, 通过引入非线性特征映射 $\Phi : \mathbb{R}^{I_1\times\cdots\times I_N} \to \mathbb{R}^{H_1\times\cdots\times H_N}$, 此时, STM 的模型可写为

$$\min_{\mathcal{W},b} \frac{1}{2}\|\mathcal{W}\|_F^2 + C_0 \sum_{i=1}^{M} \ell_{cC}(1 - y_i(\langle \mathcal{W}, \Phi(\mathcal{X}_i)\rangle + b)). \tag{4-2}$$

设 $\kappa(\cdot,\cdot)$ 为定义为 (1-11) 的核函数, 然后, 通过在欧几里德空间 $\mathbb{R}^M$ 中求解以下拉格朗日对偶问题, 即可解决高维特征空间中的目标优化问题, 即问题 (4-2):

$$\begin{aligned} \min_{\boldsymbol{\alpha}\in\mathbb{R}^M} \quad & \Upsilon(\boldsymbol{\alpha}) := \tfrac{1}{2}\boldsymbol{\alpha}^\top \mathbb{K}\boldsymbol{\alpha} + \tfrac{1}{2}\langle E(\alpha)\boldsymbol{\alpha}, \boldsymbol{\alpha}\rangle - \langle \mathbf{1}, \boldsymbol{\alpha}\rangle \\ \text{s.t.} \quad & \langle \boldsymbol{\alpha}, \mathbf{y}\rangle = 0, \end{aligned} \tag{4-3}$$

中国知网 https://www.cnki.net

其中, $\mathbf{y} \in \mathbb{R}^M$ 为标签向量, $\mathbf{1} \in \mathbb{R}^M$ 为全 1 向量, $\mathbb{K} := \mathbf{K} \otimes (\mathbf{y}\mathbf{y}^\top)$, 核矩阵

$$\mathbf{K} := \begin{bmatrix} \kappa(\mathcal{X}_1, \mathcal{X}_1), & \cdots & \kappa(\mathcal{X}_1, \mathcal{X}_M) \\ \kappa(\mathcal{X}_2, \mathcal{X}_1), & \cdots & \kappa(\mathcal{X}_2, \mathcal{X}_M) \\ \vdots & & \vdots \\ \kappa(\mathcal{X}_M, \mathcal{X}_1) & \cdots & \kappa(\mathcal{X}_M, \mathcal{X}_M) \end{bmatrix} \in \mathbb{R}^{M \times M},$$

$\otimes$ 为 Hadamard 积, $E(\boldsymbol{\alpha}) \in \mathbb{R}^{M \times M}$ 为对角矩阵, 其对角元素为

$$(E(\boldsymbol{\alpha}))_{ii} = \begin{cases} 1/C, & \text{若 } \alpha_i \geq 0, \\ 1/c, & \text{若 } \alpha_i < 0. \end{cases} \tag{4-4}$$

由原始问题 (4-2) 和对偶问题 (4-3) 的Karush-Kuhn-Tucker(KKT) 最优性条件, 根据文献 [107] 中的定理 2.1, 可得 (4-2) 的最优解 $(\mathcal{W}^*, b^*)$ 与 (4-3) 的最优解 $\boldsymbol{\alpha}^*$ 的关系式:

$$\mathcal{W}^* = \sum_{i \in T^*} \alpha_i^* y_i \Phi(\mathcal{X}_i),$$

$$b^* = \frac{\sum\limits_{i \in T^*} \left[y_i - \sum\limits_{j \in T^*} \alpha_j^* \left(y_j \kappa(\mathcal{X}_i, \mathcal{X}_j) + y_i (E(\boldsymbol{\alpha}^*))_{ij} \right) \right]}{|T^*|},$$

其中, $T^* := \mathrm{supp}(\boldsymbol{\alpha}^*)$ 为 $\boldsymbol{\alpha}^*$ 的支撑集, 收集了 $\boldsymbol{\alpha}^*$ 的非零分量的指标. 此时, 张量数据二分类的决策函数为

$$f(\mathcal{X}) = \sum_{i \in T^*} \alpha_i^* y_i \kappa(\mathcal{X}_i, \mathcal{X}) + b^*. \tag{4-5}$$

其中, $\{\mathcal{X}_i\}_{i \in T^*}$ 称作支持张量. 显然, 来自样本的支持张量在分类中起着至关重要的作用, 其决策规则由 $\mathrm{sgn}(f(\mathcal{X}))$ 决定, 符号函数 $\mathrm{sgn}(\cdot)$ 定义如 (2-8) 所示.

受新兴的稀疏 SVM[107]方案的启发, 考虑在对偶问题 (4-3) 中对 $\boldsymbol{\alpha}$ 施加稀疏性约束, 以控制支持张量的数量, 由此可得稀疏 STM 模型:

$$\begin{aligned} \min_{\boldsymbol{\alpha} \in \mathbb{R}^M} \quad & \Upsilon(\boldsymbol{\alpha}) := \tfrac{1}{2} \boldsymbol{\alpha}^\top \mathbb{K} \boldsymbol{\alpha} + \tfrac{1}{2} \langle E(\boldsymbol{\alpha}) \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle - \langle \mathbf{1}, \boldsymbol{\alpha} \rangle \\ \text{s.t.} \quad & \langle \boldsymbol{\alpha}, \mathbf{y} \rangle = 0, \\ & \|\boldsymbol{\alpha}\|_0 \leq s, \end{aligned} \tag{4-6}$$

其中, $\|\boldsymbol{\alpha}\|_0$ 为 ℓ_0 范数, 表示 $\boldsymbol{\alpha}$ 中的非零元素的个数, $s \in [M]$ 为给定的 STM 中支持张量数量的上界.

中国知网 https://www.cnki.net

4.2 尺度化核函数

基于低秩 CP 分解, 张量核函数可由任意传统的非线性映射 Φ 通过 (1-11) 生成. 为简单起见, 本文采用高斯 RBF 核, 即对于任意相同维度的向量 $\mathbf{x}$ 和 $\mathbf{y}$, 有 $\kappa(\mathbf{x},\mathbf{y}) = \exp\left(\frac{\|\mathbf{x}-\mathbf{y}\|^2}{-2\gamma^2}\right)$, 其中, $\gamma > 0$ 是控制内核宽度的参数. 进而, 张量核函数 (1-11) 可表述为

$$\kappa(\mathcal{X},\mathcal{Y}) = \sum_{p=1}^{R}\sum_{q=1}^{R}\prod_{n=1}^{N}\kappa(\mathbf{x}_p^{(n)},\mathbf{y}_q^{(n)}) = \sum_{p=1}^{R}\sum_{q=1}^{R}\prod_{n=1}^{N}\exp\left(\frac{\|\mathbf{x}_p^{(n)}-\mathbf{y}_q^{(n)}\|^2}{-2\gamma^2}\right).$$

由引言可知在 SVM 情况下, 核函数通过非线性映射在原始输入空间中诱导出黎曼度规; 放大系数由度量矩阵行列式的平方根定义, 表示特征空间中局部区域的放大程度. 已有的工作中考虑通过适当尺度化核函数来改变放大系数来提高分类性能. 因此, 在稀疏 STM 的训练过程中, 我们将改变放大因子的思想推广到 STM , 并自适应缩放张量核函数. 为简单起见, 只讨论秩一张量的情况.

给定张量 $\mathcal{X} = \prod_{n=1}^{N}\circ\mathbf{x}^{(n)} \in \mathbb{R}^{I_1\times\cdots\times I_N}$, $\mathcal{Z} = \Phi(\mathcal{X}) = \prod_{n=1}^{N}\circ\phi\left(\mathbf{x}^{(n)}\right)$, $d\mathcal{Z}$ 表示 $\mathcal{Z}$ 的微分,

$$\begin{aligned} d\mathcal{Z} \;=\;& d\phi(\mathbf{x}^{(1)})\circ\phi(\mathbf{x}^{(2)})\circ\cdots\circ\phi(\mathbf{x}^{(N)}) + \phi(\mathbf{x}^{(1)})\circ d\phi(\mathbf{x}^{(2)})\circ\phi(\mathbf{x}^{(3)})\circ\cdots\circ\phi(\mathbf{x}^{(N)}) \\ &+\cdots+\phi(\mathbf{x}^{(1)})\circ\cdots\circ\phi(\mathbf{x}^{(N-1)})\circ d\phi(\mathbf{x}^{(N)}). \end{aligned} \tag{4-7}$$

引理 4.1： 令 $d\mathcal{Z}$ 如 (4-7) 所定义, 可得 $\|d\mathcal{Z}\|_F^2 = \frac{1}{\gamma^2}\sum_{n=1}^{N}\|d\mathbf{x}^{(n)}\|^2$.

证明 根据张量的高斯 RBF 核函数的定义可知, 对于任意的 $n \in [N]$, 有

$$\begin{cases} \|\phi(\mathbf{x}^{(n)})\|^2 = \kappa\left(\mathbf{x}^{(n)},\mathbf{x}^{(n)}\right) = 1, \\ \|d\left(\phi(\mathbf{x}^{(n)})\right)\|^2 = \frac{1}{\gamma^2}\|d\mathbf{x}^{(n)}\|^2, \\ \left\langle d\left(\phi(\mathbf{x}^{(n)})\right),\phi(\mathbf{x}^{(n)})\right\rangle = \frac{1}{2}d\left(\kappa\left(\mathbf{x}^{(n)},\mathbf{x}^{(n)}\right)\right) = 0. \end{cases} \tag{4-8}$$

由

$$\|\mathbf{x}^{(1)}\circ\cdots\circ\mathbf{x}^{(N)}\|_F^2 = \prod_{n=1}^{N}\|\mathbf{x}^{(n)}\|^2 \tag{4-9}$$

和

$$\begin{aligned} &\|d\mathcal{Z}\|_F^2 \\ =\;& \left\|d\left(\phi(\mathbf{x}^{(1)})\right)\circ\phi(\mathbf{x}^{(2)})\circ\cdots\circ\phi(\mathbf{x}^{(N)})\right\|_F^2 + \left\|\phi(\mathbf{x}^{(1)})\circ d\left(\phi(\mathbf{x}^{(2)})\right)\circ\cdots\circ\phi(\mathbf{x}^{(N)})\right\|_F^2 \\ &+\cdots+\left\|\phi(\mathbf{x}^{(1)})\circ\phi(\mathbf{x}^{(2)})\circ\cdots\circ d\left(\phi(\mathbf{x}^{(N)})\right)\right\|_F^2 \\ &+2\langle d\left(\phi(\mathbf{x}^{(1)})\right)\circ\phi(\mathbf{x}^{(2)})\circ\cdots\circ\phi(\mathbf{x}^{(N)}),\phi(\mathbf{x}^{(1)})\circ d\left(\phi(\mathbf{x}^{(2)})\right)\circ\cdots\circ\phi(\mathbf{x}^{(N)})\rangle+\cdots \\ &+2\langle\phi(\mathbf{x}^{(1)})\circ\cdots\circ d\left(\phi(\mathbf{x}^{(N-1)})\right)\circ\phi(\mathbf{x}^{(N)}),\phi(\mathbf{x}^{(1)})\circ\cdots\circ\phi(\mathbf{x}^{(N-1)})\circ d\left(\phi(\mathbf{x}^{(N)})\right)\rangle, \end{aligned}$$

中国知网 https://www.cnki.net

可得 $\|d\mathcal{Z}\|_F^2 = \frac{1}{\gamma^2}\sum\limits_{n=1}^{N}\|d\mathbf{x}^{(n)}\|^2$. 证毕. □

进一步, 为方便起见, 记

$$\frac{1}{\gamma^2}\|d\mathbf{x}^{(n)}\|^2 = \sum_{i_n,j_n=1}^{I_n}\frac{\delta_{i_nj_n}}{\gamma^2}dx_{i_n}^{(n)}dx_{j_n}^{(n)} = \sum_{i_n,j_n=1}^{I_n}\frac{\partial}{\partial x_{i_n}^{(n)}}\frac{\partial}{\partial y_{j_n}^{(n)}}\kappa\left(\mathbf{x}^{(n)},\mathbf{y}^{(n)}\right)\Big|_{\mathbf{y}^{(n)}=\mathbf{x}^{(n)}}dx_{i_n}^{(n)}dx_{j_n}^{(n)},$$

其中, $\delta_{i_nj_n}$ 表示克罗内克符号, 其定义式为 $\delta_{i_nj_n} = \begin{cases} 1, & i_n = j_n; \\ 0, & i_n \neq j_n. \end{cases}$ 记

$$G(\mathcal{X}) := \frac{1}{\gamma^2}\mathrm{Diag}\left(\mathbb{I}_{I_1\times I_1},\ldots,\mathbb{I}_{I_N\times I_N}\right) \in \mathbb{R}^{\iota\times\iota},$$

其中 $\iota := I_1 + \cdots + I_N$. 根据引理 4.1, 从张量核函数的几何性质可以得到,

$$\|d\mathcal{Z}\|_F^2 = \sum_{i=1}^{\iota}\sum_{j=1}^{\iota}G(\mathcal{X})_{ij}dv_idv_j,$$

其中 v_i 表示 $\left(d\mathbf{x}^{(1)\top},\cdots,d\mathbf{x}^{(N)\top}\right)^\top \in \mathbb{R}^\iota$ 的第 i 个元素. 然后, 张量情况下的放大因子可被定义为

$$\rho(\mathcal{X}) := \sqrt{\det\left(G(\mathcal{X})\right)}.$$

显然, 在高斯 RBF 核函数的情况下, 对任意的秩一张量 $\mathcal{X} \in \mathbb{R}^{I_1\times\cdots\times I_N}$, 有

$$\rho(\mathcal{X}) = \frac{1}{\gamma^\iota}.$$

这个恒定的放大系数不利于适应空间的密度变化, 会造成局部风险. 受 SVM 中使用的尺度化核函数技术的启发, 考虑在训练过程中对核函数 $\kappa(\mathcal{X},\mathcal{Y})$ 进行修改, 使得放大因子 $\rho(\mathcal{X})$ 在 $f(\mathcal{X}) = 0$ 的边界附近相对增大, 以增加两类数据的可分性. 然而, 边界的位置是事先不知道的. 为了解决这个问题，采用了文献 [49] 中提出的两阶段技术. 具体地说, 在第一阶段, 使用 (1-11) 中定义的原始的核函数 $\kappa(\cdot,\cdot)$ 执行稀疏 STM, 通过支持张量获得决策函数 $f(\mathcal{X})$ 的表达式. 在第二阶段, 我们根据第一阶段所获得的支持张量的相关信息对核函数按照以下方式进行尺度化,

$$\tilde{\kappa}(\mathcal{X},\mathcal{Y}) := D(\mathcal{X})\kappa(\mathcal{X},\mathcal{Y})D(\mathcal{Y}) = \langle D(\mathcal{X})\Phi(\mathcal{X}), D(\mathcal{Y})\Phi(\mathcal{Y})\rangle, \tag{4-10}$$

其中 $D(\mathcal{X}) := \exp(-\mu f(\mathcal{X})^2)$, 调节参数 $\mu > 0$. 学习过程中尺度化核函数的可视化过程如图 4.1 所示, 尺度化非线性映射的流程如图 4.2 所示.

中国知网 https://www.cnki.net

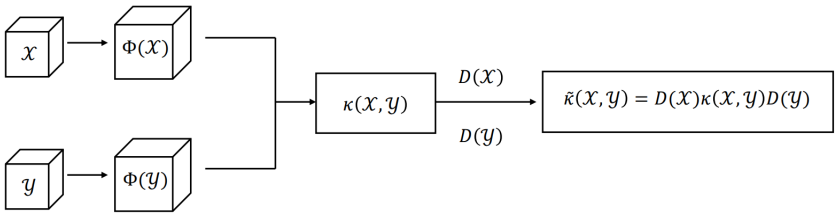


图 4.1 尺度化核函数的流程图.

Fig 4.1 A flowchart of the scaling kernel function.

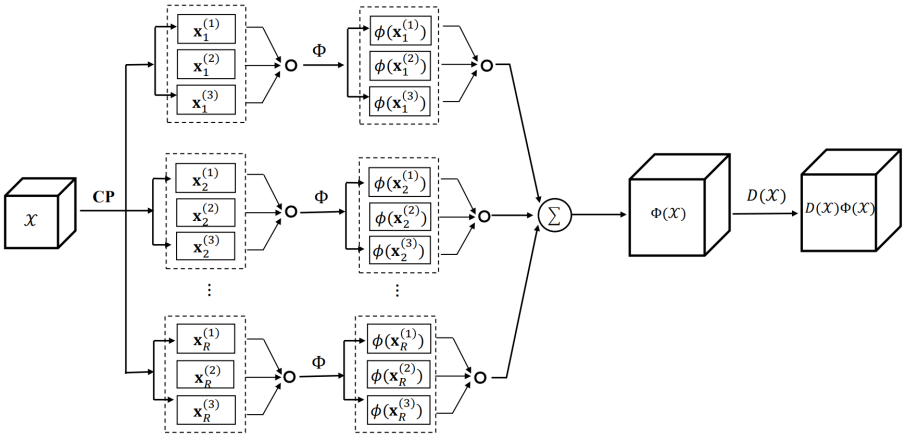


图 4.2 基于 CP 分解的尺度化非线性映射.

Fig 4.2 Scaling nonlinear mapping with CP decomposition.

对任意的秩一张量 $\mathcal{X} = \prod_{n=1}^{N} \circ \mathbf{x}^{(n)}$, 有

$$D(\mathcal{X}) = \exp\left\{-\mu\left[\sum_{i\in T^*}\alpha_i y_i \exp\left\{\frac{\sum_{n=1}^{N}\|\mathbf{x}^{(n)}-\mathbf{x}_i^{(n)}\|^2}{-2\gamma^2}\right\}+b\right]^2\right\} =: \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}).$$

令 $\tilde{\mathcal{Z}} = D(\mathcal{X})\Phi(\mathcal{X}) = \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\Phi(\mathcal{X})$, 可得以下性质.

引理 4.2: $\|d\tilde{\mathcal{Z}}\|_F^2 = D(\mathcal{X})^2\left(\left[d\left(\log \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right)\right]^2 + \|d\mathcal{Z}\|_F^2\right)$.

证明 由$D(\mathcal{X})$ 和 $\tilde{\mathcal{Z}}$ 的定义可得,

$$d\tilde{\mathcal{Z}} = d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}))\Phi(\mathcal{X}) + \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})d(\Phi(\mathcal{X}))$$

和 $d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})) = D(\mathcal{X})d\left(\log \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right)$. 此外, 结合 (4-8) 和 (4-9),

$$\langle\Phi(\mathcal{X}),\Phi(\mathcal{X})\rangle = 1 \text{ 和 } \langle\Phi(\mathcal{X}),d(\Phi(\mathcal{X}))\rangle = 0. \tag{4-11}$$

中国知网 https://www.cnki.net

因此,

$$\begin{aligned}\left\|d\tilde{\mathcal{Z}}\right\|_F^2 &= \left\|d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}))\Phi(\mathcal{X}) + \mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})d(\Phi(\mathcal{X}))\right\|_F^2 \\ &= \left(d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}))\right)^2\langle\Phi(\mathcal{X}),\Phi(\mathcal{X})\rangle + D(\mathcal{X})^2\langle d(\Phi(\mathcal{X})), d(\Phi(\mathcal{X}))\rangle \\ &\quad +2D(\mathcal{X})d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}))\langle\Phi(\mathcal{X}), d(\Phi(\mathcal{X}))\rangle \\ &= (d(\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})))^2 + D(\mathcal{X})^2\|d(\mathcal{Z})\|_F^2 \\ &= D(\mathcal{X})^2\left(\left[d\left(\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right)\right]^2 + \|d\mathcal{Z}\|_F^2\right)\end{aligned}$$

其中第三个等式由 (4-11) 可得. 证毕. □

显然, 在边界 $f(\mathcal{X})=0$ 处, 对任意的 $\mathcal{X}$ 都有 $\|d\tilde{\mathcal{Z}}\|_F^2 = \|d\mathcal{Z}\|_F^2$. 注意到

$$d\left(\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right) = D^{[1]\top}d\mathbf{x}^{(1)} + \cdots + D^{[N]\top}d\mathbf{x}^{(N)},$$

其中 $D^{[n]} = \frac{\partial\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})}{\partial\mathbf{x}^{(n)}}$. 记 $Q_{i,j} = \langle D^{[i]}, D^{[j]}\rangle$, 可得

$$\begin{aligned}&\|d\left(\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right)\|^2 \\ =\ &\left[d\mathbf{x}^{(1)\top},\cdots,d\mathbf{x}^{(N)\top}\right]\begin{bmatrix} Q_{1,1} & \cdots & Q_{1,N} \\ Q_{2,1} & \cdots & Q_{2,N} \\ \vdots & \cdots & \vdots \\ Q_{N-1,1} & \cdots & Q_{N-1,N} \\ Q_{N,1} & \cdots & Q_{N,N}\end{bmatrix}\begin{bmatrix} d\mathbf{x}^{(1)} \\ \vdots \\ d\mathbf{x}^{(N)}\end{bmatrix}.\end{aligned} \tag{4-12}$$

进一步, 考虑支持张量 $\mathcal{X}_i$ 的邻域,

$$\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)}) = \exp\left\{-\mu\left[\alpha_i y_i\exp\left\{\frac{\sum_{n=1}^{N}\|\mathbf{x}^{(n)}-\mathbf{x}_i^{(n)}\|^2}{-2\gamma^2}\right\}+b\right]^2\right\}.$$

为方便起见, 记 $\|d\tilde{\mathcal{Z}}\|_F^2 = \sum_{i=1}^{\iota}\sum_{j=1}^{\iota}\tilde{G}(\mathcal{X})_{ij}dv_i dv_j$, $\tilde{\rho}(\mathcal{X}) = \sqrt{\det(\tilde{G}(\mathcal{X}))}$.

定理 4.1： 放大因子 $\tilde{\rho}(\mathcal{X})$ 与 $\rho(\mathcal{X})$ 的比率为

$$\frac{\tilde{\rho}(\mathcal{X})}{\rho(\mathcal{X})} = D(\mathcal{X})^{\iota}\sqrt{1+\gamma^2\|\nabla\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\|_F^2}. \tag{4-13}$$

证明 由引理 4.2 和式子 (4-12) 可得

$$\begin{aligned}\|d\tilde{\mathcal{Z}}\|_F^2 &= D(\mathcal{X})^2\left(\left[d\left(\log\mathbb{V}(\mathbf{x}^{(1)},\cdots,\mathbf{x}^{(N)})\right)\right]^2 + \|d\mathcal{Z}\|_F^2\right) \\ &= \sum_{i=1}^{\iota}\sum_{j=1}^{\iota}\tilde{G}(\mathcal{X})_{ij}dv_i dv_j,\end{aligned}$$

中国知网 https://www.cnki.net

其中,

$$\tilde{G}(\mathcal{X}) = D(\mathcal{X})^2 \begin{bmatrix} Q_{1,1} & \cdots & Q_{1,N} \\ Q_{2,1} & \cdots & Q_{2,N} \\ \vdots & \cdots & \vdots \\ Q_{N,1} & \cdots & Q_{N,N} \end{bmatrix} + D(\mathcal{X})^2 G(\mathcal{X}).$$

由于 $\tilde{\rho}(\mathcal{X}) = \sqrt{\det(\tilde{G}(\mathcal{X}))}$,

$$\frac{\tilde{\rho}(\mathcal{X})}{\rho(\mathcal{X})} = D(\mathcal{X})^{\iota} \sqrt{1 + \gamma^2 \|\nabla \log \mathbb{V}(\mathbf{x}^{(1)}, \cdots, \mathbf{x}^{(N)})\|_F^2}.$$

证毕. □

为使算法的思想更清晰, 按照文献 [51] 生成的独立同分布的随机样本 $\left\{\mathbf{x}^{(i)} = \left(x_1^{(i)}, x_2^{(i)}\right)^{\top} : i = 1, \ldots, 200\right\}$, 在$[-1, 1] \times [-1, 1]$ 区域内服从均匀分布. 这些数据可以被 $x_2 = \cos(\pi x_1)$ 分隔开, 如图 4.3 所示. 相同的颜色、类型的点表示同一类别的样本.

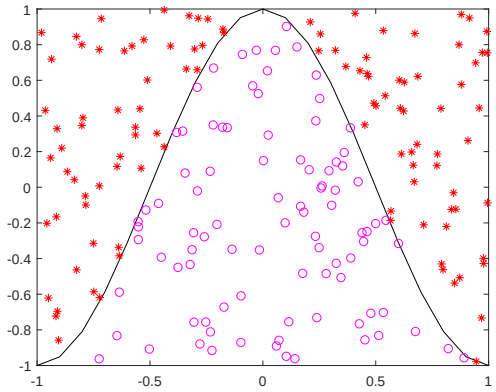


图 4.3 随机生成 200 个二分类的样本点.

Fig 4.3 The binary classification for 200 randomly generated points.

选取 80% 的样本进行训练, 余下的 20% 样本进行测试, 调用程序包LIBSVM, 固定参数 $C = 2^2, \gamma = 0.50$ 和 $\mu = 0.20$, 按照上述两阶段方案测试算法的性能. 第一阶段的分类准确率为 90.00%, 第二阶段的分类准确率为 97.50%. 为了可视化尺度化策略的效果, 绘制了如 (4-13) 所定义的放大因子比率的等高线, 如图 4.4 所示, 其中, " + " 表示支持向量, 分布在边界 $f(x) = 0$ 周围. 从图 4.4 可得, 包含这些支持向量的邻域内的放大系数大于1, 表明这些支持向量的放大系数增大了. 相比之下, 非支持向量点的放大因子在尺度化后变小. 这种放大-缩小的场景将有利于分类边界的检测, 从而使分类精度得到合理的提高.

中国知网 https://www.cnki.net

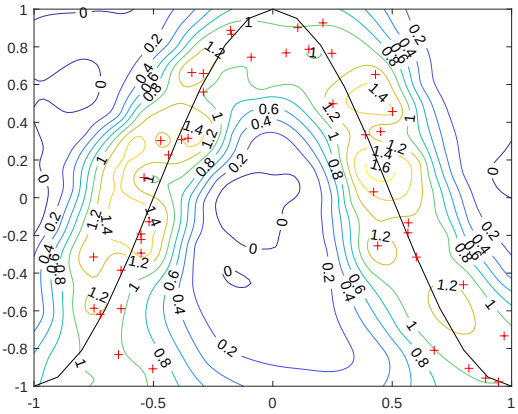


图 4.4　训练数据放大因子比率 (4-13) 的等高线图.

Fig 4.4　The contours of the ratio of magnification factors (4-13) for training data.

4.3　算法设计

为了有效求解该非凸非连续的问题 (4-6), 采用了子空间牛顿法 NSSVM[107]. 问题 (4-6) 中目标函数的梯度和海瑟矩阵分别为

$$\nabla\Upsilon(\boldsymbol{\alpha}) := H(\boldsymbol{\alpha})\boldsymbol{\alpha} - \mathbf{1}, \quad H(\boldsymbol{\alpha}) := \mathbb{K} + E(\boldsymbol{\alpha}).$$

由于 $\mathbb{K}$ 是两个对称的半正定矩阵通过 Hadamard 积作用得到的, 因此也是半正定的. 结合 $E(\boldsymbol{\alpha})$ 是一个正定的对角矩阵, 可以得到, $H(\boldsymbol{\alpha})$ 是正定的. 为方便表示, 记 $\mathbf{z} := (\boldsymbol{\alpha}^\top, b)^\top \in \mathbb{R}^{M+1}$,

$$\begin{aligned} h(\mathbf{z}) &:= \nabla\Upsilon(\boldsymbol{\alpha}) + \mathbf{y}b = H(\boldsymbol{\alpha})\boldsymbol{\alpha} - \mathbf{1} + \mathbf{y}b, \\ h_T(\mathbf{z}) &:= (h(\mathbf{z}))_T, \\ H_T(\boldsymbol{\alpha}) &:= (H(\boldsymbol{\alpha}))_{TT}, \end{aligned}$$

其中 $T := \mathrm{supp}(\boldsymbol{\alpha})$ 为支撑集, $h_T(\mathbf{z})$ 是向量 $h(\mathbf{z})$ 以 T 为索引的子向量, $H_T(\boldsymbol{\alpha})$ 是矩阵 $H(\boldsymbol{\alpha})$ 的行和列以 T 为索引的子矩阵. 给出问题的 (4-6) 的稳定点.

定义 4.1:　(η- 稳定点) 对于任意 $\boldsymbol{\alpha} \in S := \{\boldsymbol{\alpha} \in \mathbb{R}^M : \|\boldsymbol{\alpha}\|_0 \le s\}$, 若存在向量 $b^* \in \mathbb{R}$, $\eta > 0$ 使得

$$\begin{cases} \boldsymbol{\alpha}^* \in \mathbb{P}_s(\boldsymbol{\alpha}^* - \eta h(\mathbf{z}^*)), \\ 0 = \langle \boldsymbol{\alpha}^*, \mathbf{y} \rangle. \end{cases} \tag{4-14}$$

这里, 硬阈值算子 $\mathbb{P}_s$ 的形式如引理 1.2 所示. 记 $\bar{T} := [M]\backslash T$, $|T|$ 是 T 的基数, 它计算集合 T 中的元素个数. 由于 $\mathbb{P}_s$ 不可微, 难以求出使用牛顿法需要的雅可比矩阵.

中国知网　https://www.cnki.net

基于此, 给出该问题的平稳方程,

$$F(\mathbf{z};T):=\begin{bmatrix} h_T(\mathbf{z}) \\ \boldsymbol{\alpha}_{\bar{T}} \\ \langle \boldsymbol{\alpha}_T, \mathbf{y}_T \rangle \end{bmatrix} = \mathbf{0}.$$

对任意固定的指标集 $T \in \mathbb{T}_S(\boldsymbol{\alpha} - \eta h(\mathbf{z}))$, $F(\mathbf{z};T)$ 可微, 其雅可比矩阵为

$$\nabla F(\mathbf{z};T) = \begin{bmatrix} H_T(\boldsymbol{\alpha}) & \mathbf{0} & \mathbf{y}_T \\ \mathbf{0} & \mathbb{I} & \mathbf{0} \\ \mathbf{y}_T^\top & \mathbf{0} & \mathbf{0} \end{bmatrix},$$

由 $H_T(\boldsymbol{\alpha}) \succ 0$ 可得 $\nabla F(\mathbf{z};T)$ 是非奇异的. 选定 $T_k \in \mathbb{T}_s(\boldsymbol{\alpha}^k - \eta h(\mathbf{z}^k))$ 后, 通过求解线性方程 $\nabla F(\mathbf{z}^k;T_k)\mathbf{d}^k = -F(\mathbf{z}^k;T_k)$, 可得牛顿方向 $\mathbf{d}^k \in \mathbb{R}^{M+1}$. 求解稀疏 STM 的算法框架可以总结为算法 3.

算法 3 (NKSTM)　牛顿法求解稀疏核 STM

输入: 训练数据 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 参数 $C > c > 0, \eta, \epsilon, K > 0, s \in [M]$, CP 秩 R.

输出: 最优解 $\mathbf{z}^k$.

步 1: 初始化 $\mathbf{z}^0$, 选取 $T_0 \in \mathbb{T}_s(\boldsymbol{\alpha}^0 - \eta h(\mathbf{z}^0))$, 令 $k := 0$;

步 2: 根据张量核函数利用 NSSVM 计算 $\mathbf{z}^{k+1}$;

步 3: 若满足停机准则和精度要求, 算法停止; 否则, 令 $k = k + 1$, 转 **步 2**.

结合核函数尺度化技术, 得到的基于 NSSVM 两阶段训练过程的框架可以总结为算法 4. 为使算法更清晰, 我们给出如图 4.5 所示的流程图:

算法 4 (re-NKSTM)　两阶段牛顿法求解基于尺度化核函数的稀疏 STM.

输入: 训练数据 $\{\mathcal{X}_i, y_i\}_{i=1}^M$, 参数 $C > c > 0, \eta, \epsilon, K > 0, \mu > 0, s \in [M]$, CP秩 R.

输出: 最优解 $\tilde{\mathbf{z}}^k$.

步 1: 初始化 $\mathbf{z}^0$, 选取 $T_0 \in \mathbb{T}_s(\boldsymbol{\alpha}^0 - \eta h(\mathbf{z}^0))$, 令 $k := 0$;

步 2: 利用原始核 $\kappa(\cdot,\cdot)$ 通过 NSSVM 求解 $\mathbf{z}^{k+1}$;

步 3: 若满足停机准则, 转 **步 4**; 否则, 令 $k = k + 1$, 转 **步 2**;

步 4: 通过 (4-10), 对原始核函数 $\kappa(\cdot,\cdot)$ 尺度化可得修正的核函数 $\tilde{\kappa}(\cdot,\cdot)$;

步 5: 利用修正核 $\tilde{\kappa}(\cdot,\cdot)$ 通过 NSSVM 求解 $\tilde{\mathbf{z}}^{k+1}$;

步 6: 若满足停机准则和精度要求, 算法停止; 否则, 令 $k = k + 1$, 转 **步 5**.

中国知网 https://www.cnki.net

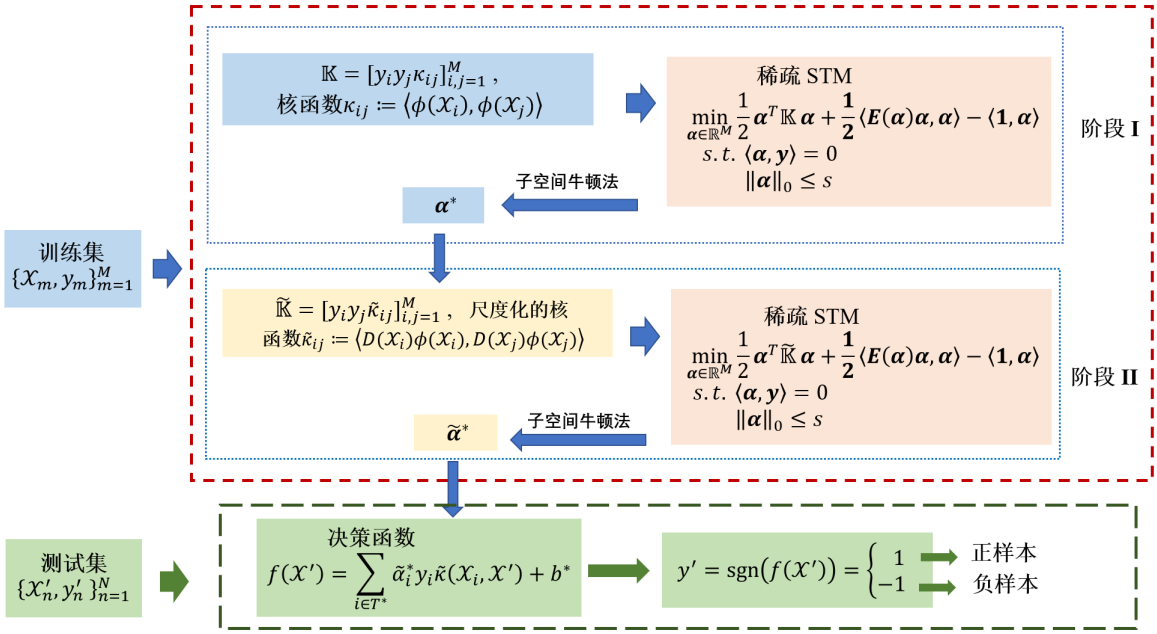


图 4.5　re-NKSTM 求解二分类问题的流程图.

Fig 4.5　A flowchart of the proposed approach re-NKSTM for binary classification.

如下给出算法 3 和 4 的算法收敛性和复杂度分析:

注意到算法 3 是算法 4 的第一阶段. 由文献 [107] 的定理 3.1 可知, 若在稳定点的邻域里选择初始点, 算法 3 具有一步收敛性. 算法 4 每次迭代的计算复杂度分析如下:

- 计算 $H_{T_k}(\boldsymbol{\alpha}^k) = \mathbb{K}_{T_k T_k} + E(\boldsymbol{\alpha})_{T_k T_k}$ 时所涉及的主要一项是 $\mathbb{K}_{T_k T_k}$, 由于 $|T_k| = s$, 其复杂度约为 $O\left(s^2 R^2 \sum_{n=1}^{N} I_n\right)$, 计算 $H_{T_k}(\boldsymbol{\alpha}^k)$ 至多需要 $O\left(s^3\right)$;
- 在选取 $T_{k+1} \in \mathbb{T}_s(\boldsymbol{\alpha}^k - \eta h(\mathbf{z}^k))$ 时, 需要计算 $h(\mathbf{z}^k)$, 其计算复杂度为 $O\left(M^2\right)$, 选择 $|\boldsymbol{\alpha}^k - \eta h(\mathbf{z}^k)|$ 的第 k 个最大元素的复杂度为 $O(M + s\ln s)$.

总的来说, 算法 3 和 4 每次迭代的总计算量为

$$O\left(s^2 \max\left\{R^2 \sum_{n=1}^{N} I_n, s\right\} + M^2\right).$$

算法的存储复杂度为 $O\left(M \sum_{n=1}^{N} I_n + s^2\right)$. 注意到算法 3 和 4 中计算张量 RBF 核的计算都严重依赖于张量样本 $\{\mathcal{X}_i\}_{i=1}^{M}$ 的 CP 分解, 该分解过程采用带有线搜索的 ALS 算法[83] 来执行. 由于这些 CP 分解在两个算法中只执行一次, 因此在这省略了相关的复杂度分析.

4.4　数值实验

本节在真实数据集上进行了数值实验, 以评估所提算法的效率. 数值实验均

中国知网　https://www.cnki.net

在 Intel(R) Core(TM) i7-8565U CPU @1.8GHz RAM 8.0G 电脑上进行, 使用 Matlab R2018b, 并调用 Tensor Toolbox来计算.

为公平起见, 对每个张量样本 $\{\tilde{\mathcal{X}}_j : j \in [M]\}$ 按照以下方式进行了归一化处理,

$$(\mathcal{X}_j)_{i_1 i_2 \cdots i_N} = \frac{(\tilde{\mathcal{X}}_j)_{i_1 i_2 \cdots i_N} - \tilde{\mathcal{X}}_j^{\min}}{\tilde{\mathcal{X}}_j^{\max} - \tilde{\mathcal{X}}_j^{\min}}, \quad \forall i_1, i_2, \ldots, i_N,$$

其中, $\tilde{\mathcal{X}}_j^{\min}$ 和 $\tilde{\mathcal{X}}_j^{\max}$ 分别表示 $\tilde{\mathcal{X}}_j$ 的最小和最大元素.

实验设置. 为了构造张量样本 $\{\mathcal{X}_j : j \in [M]\}$ 的张量核函数, 利用网格搜索法从 $\{1, \cdots, 8\}$ 来确定 CP 秩 R, 并且采用带有线搜索的 ALS 算法[83] 进行低秩 CP 分解近似. 对于 RBF 核函数中的参数 γ 和模型中的超参数 C, 采用网格搜索的方式从 $\{2^{-3}, \cdots, 2^5\}$ 和 $\{2^0, 2^1, \cdots, 2^9\}$ 中选取, 且令 $c = 0.01C$. 第二阶段中的尺度化参数 μ 选为 $\frac{1}{I_1 I_2 \cdots I_N}$ 并且在高维问题中自适应的改变. 稀疏度参数 s 根据训练数据样本量选择.

对于算法 NKSTM, 选择初始点 $\mathbf{z^0} = (\boldsymbol{\alpha}_0^\top, b)^\top$, $\boldsymbol{\alpha}^0 = \mathbf{0}$ 和 $b^0 = \operatorname{sgn}(\langle \mathbf{y}, 1 \rangle)$, 设置平稳性参数 $\eta = \min(\frac{1}{M}, 10^{-4})$. 当达到以下两个条件之一时, 算法停止: (i) 达到最大迭代步数 $K = 1000$; (ii) 满足停机准则:

$$\|F(\mathbf{z}^k; T_k)\| < \epsilon, \quad |\operatorname{acc}(\boldsymbol{\alpha}^k) - \max_{j \in [k-1]} \operatorname{acc}(\boldsymbol{\alpha}^j)| < 10^{-4},$$

其中 $\epsilon = \sqrt{MI_1 \cdots I_N} \times 10^{-6}$, 训练精度 $\operatorname{acc}(\boldsymbol{\alpha})$ 定义为

$$\operatorname{acc}(\boldsymbol{\alpha}) = \left[1 - \frac{1}{M} \left\| \operatorname{sgn}\left(\mathbf{K}(\boldsymbol{\alpha} \odot \mathbf{y}) + b\mathbf{1}\right) - \mathbf{y} \right\|_0 \right] \times 100\%, \tag{4-15}$$

默认情况下, $\operatorname{acc}(\boldsymbol{\alpha}^{-1}) = 0$. 测试精度的定义方式和训练精度 (4-15) 相同, 即用测试样本替换训练样本.

基准分类器. 为了测试算法的性能, 选择了以下几个在前面提到的相关算法进行了比较, 其中包括:

LIBSVM: 利用 Lin 等开发的 LIBSVM[93] 求解合页损失 SVM, 这是基于向量空间的分类器中最流行的分类方法之一.

NSSVM: Zhou[107]提出了基于向量空间的 NSSVM① 方法, 求解的是一个具有稀疏约束的线性核 SVM 问题.

DuSK: He 等[42] 提出了一种基于 CP 分解的对偶结构保持核用于监督张量学习, 提到了分类性能.

TT-MMK: Kour 等[46] 引入了一种张量训练多路多级核 (TT-MMK), 将可用的 TT 分解转化为 CP 分解进行核分类.

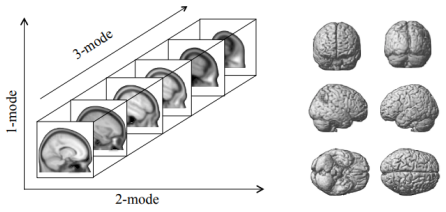
① https://github.com/ShenglongZhou/NSSVM

中国知网 https://www.cnki.net

在本文中,所有方法均采用高斯 RBF 核函数来处理非线性可分问题. 为了公平比较, 不用算法中的相同参数采用相同的设置, 如模型超参数 C, 高斯核核宽度 γ, CP 秩 R, 其他设置保留算法的默认状态. 所有的数值结果均是测试方法在 5 次实验中经过 5 折交叉验证的平均性能. 为了方便起见, 取 'TRACC1' ('TEACC1') 和 'TRACC2' ('TEACC2') 分别表示 NKSTM 和 re-NKSTM 方法的训练 (测试) 精度.

4.4.1 数据集

StarPlus fMRI 数据集 利用神经科学领域的磁共振成像 (fMRI) 图像进行了数值实验. 图像均从 StarPlus 数据集中 ① 选择. 每个样本均可看作一个三阶张量, 如图 4.6 所示[42], 其维度为 $64 \times 64 \times 8$, 包含 25 到 30 个解剖学定义的区域(表示为"感兴趣区域", 或 roi). 关于数据预处理的更多细节可参考文献 [45]. 本文中, 我们从[45] 中选择主题 '04799' 来测试分类性能. 该受试者包含 320 张 fMRI 图像, 其中一半是在向受试者展示图片时收集的, 另一半是在向受试者展示句子时收集的.



(a) (b)

图 4.6 fMRI 图像: (**a**) 三阶张量; (**b**) 可视化.

Fig 4.6 fMRI images: (a) The third-order tensor format; (b) the visualization.

CIFAR-10 数据集 CIFAR-10[94] 数据集如图 2.3 所示, 其每张图片可看作为一个三阶张量, 维度 $32 \times 32 \times 3$. 与第二章类似, 随机选取 9 个类别对来执行二分类. 在没有重叠的情况下, 从每个类的数据集中选择 100 个样本, 每对类别中选取 200 个张量样本.

4.4.2 数值结果

图 4.7 记录了在取定 CP 秩 $R = 2$ 时, 所提算法在不同稀疏度 $s \in \{33, 49, 97, 145, 193, 256\}$ 下的训练和测试分类精度. 由图 4.7 可知, 第二阶段的 re-NKSTM 在测试精度上比 NKSTM 表现得更好, 并且在稀疏度取为 $s = 97$ 的设置

① www.cs.cmu.edu/afs/cs.cmu.edu/project/theo-81/www

中国知网 https://www.cnki.net

下取得最高的测试精度. 因此, 对 $\boldsymbol{\alpha}$ 施加稀疏性约束是有效的, 为了缓解过拟合, 对训练精度做出了一定的牺牲是合理的.

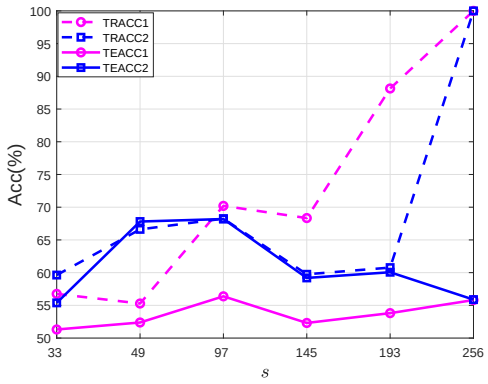


图 4.7 固定 CP 秩 $R = 2$, 不同稀疏度 s 下的分类精度.

Fig 4.7 The classification accuracy of sparsity level s with $R = 2$.

为了测试 CP 秩 R 的影响, 固定稀疏度 $s = 97$, 图 4.8 记录了不同 CP 秩 $R \in \{1, 2, 3, \ldots, 8\}$ 下的训练和测试分类精度. 从图 4.8 可知第二阶段 re-NKSTM 在测试精度上的优越性. 特别地, 当 CP 秩 $R = 4$ 时, 第二阶段的准确率为 76.88%, 比第一阶段的 52.87% 提高了 24%. 此外, 在 CP 秩 $R = 4$ 时, 算法 re-NKSTM 在训练和测试中都表现出最佳的性能, 这在一定程度上表明了将低秩假设应用于张量样本的分类中是合理的.

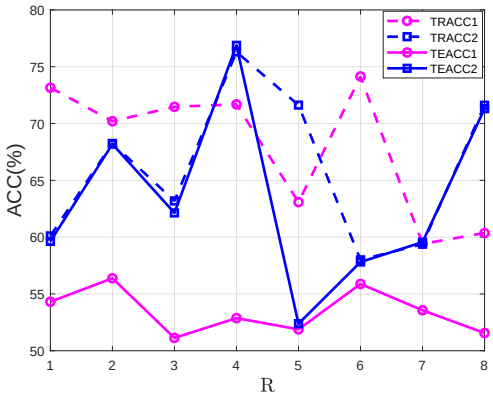


图 4.8 固定 $s = 97$, 不同 CP 秩 R 下的分类精度.

Fig 4.8 The classification accuracy of CP rank R with s = 97.

表 4.1 给出了六种算法的分类精度, 其中, 最好的结果以黑体标出. 这里, 在 NKSTM 和 re-NKSTM 方法中, 选择稀疏度 $s = 97$, 在所有与秩相关的方法 (NKSTM, re-NKSTM, DuSK, TT-MMK) 中, 使用网格搜索来选择相应的张量秩. 从表 4.1 可以看出, re-NKSTM 的测试精度比其他算法高出 20% 左右. 其中,

中国知网 https://www.cnki.net

re-NKSTM 的分类准确率比 NKSTM 的分类准确率提高了 24%.

表 4.1　主题 ‘04799’下不同算法的分类精度 (%).

Tab 4.1　The classification accuracy (%) comparison for subject ‘04799’.

re-NKSTM	NKSTM	LIBSVM	NSSVM	DuSK	TT-MMK
76.88	52.87	50.00	50.00	56.37	57.44

类似地, 为了测试所提出的两阶段方法中稀疏度水平的影响, 选择 ‘automobile’ 和 ‘cat’ 这一类对进行说明. 固定 CP 秩 $R = 1$, 两种方法在不同 $s \in \{28, 56, 84, 112, 140, 160\}$ 值下的训练和测试精度如图 4.9 所示. 从图 4.9 可知, 在不同的稀疏度下, re-NKSTM 的测试精度均高于 NKSTM; 对于稀疏度 $s = 112$, 训练和测试的分类精度都接近 85%.

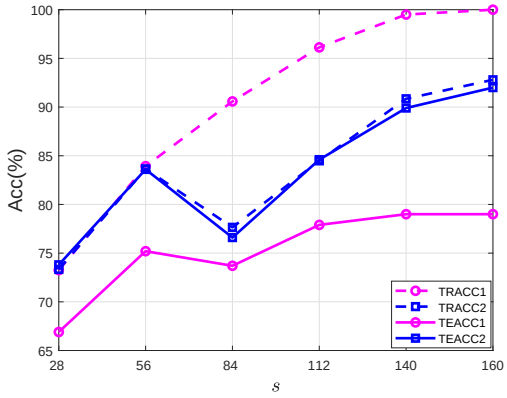


图 4.9　固定$R = 1$, 不同稀疏度 s 的分类精度.

Fig 4.9　The classification accuracy of different sparsity s with R = 1.

固定稀疏度 $s = 112$, 图 4.10 记录了不同 CP 秩 $R \in \{1, 2, 3, \ldots, 8\}$ 下训练和测试分类精度. 从图 4.10 中可得, NKSTM 和 re-NKSTM 方法在秩 $R = 1$ 获得了最好的分类性能, 此时 NKSTM 的测试分类精度约为 78%, re-NKSTM 的测试分类精度约为 85%.

表 4.2 给出了上述六种算法关于九个类对的比较结果. 在上述两种算法中固定稀疏度 $s = 112$, 并对所有算法使用本节开头所描述的实验设置. 从表 4.2 可知, re-NKSTM 在所有情况下的测试分类精度都优于其他五种方法, 并且与 NKSTM 的结果相比, 其优势主要体现在尺度化核函数技术上. 特别地, 在‘bird’ 和 ‘horse’, re-NKSTM 的分类准确率为 90.00%，比 NKSTM 的 69.40% 提高了约 20%.

中国知网　https://www.cnki.net

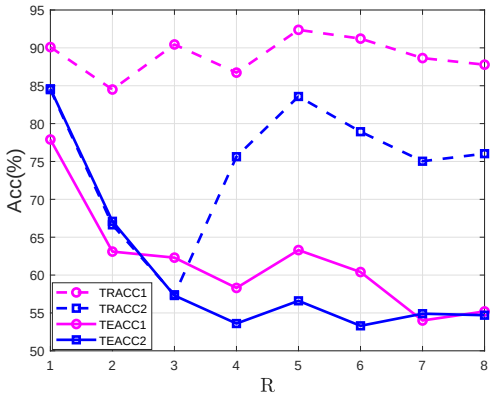


图 4.10 固定 $s = 112$, 不同 CP 秩 R 下的分类精度.

Fig 4.10 The classification accuracy of CP rank R with s = 112

表 4.2 CIFAR-10 数据集在不同算法下的测试精度(%).

Tab 4.2 The classification accuracy (%) comparison for the CIFAR-10 dataset.

Class Pair	re-NKSTM	NKSTM	LIBSVM	NSSVM	DuSK	TT-MMK
'bird, deer'	**75.40**	67.50	62.50	60.70	73.00	73.40
'deer, horse'	**88.30**	66.10	54.70	71.10	70.30	71.20
'bird, horse'	**90.00**	69.40	71.10	72.90	73.20	76.10
'truck, ship'	**82.90**	75.30	76.40	75.80	78.40	78.20
'automobile, ship'	**83.30**	74.40	60.30	77.70	78.30	77.30
'automobile, cat'	**84.60**	77.90	65.80	77.10	79.10	79.50
'automobile, horse'	**79.20**	75.00	72.50	78.60	76.40	75.90
'air, ship'	**73.10**	65.90	65.10	69.80	68.70	71.50
'automobile, truck'	**87.10**	69.00	58.10	71.90	73.10	72.20

4.5 本章小结

本章提出了一种基于对偶结构保持核函数的稀疏 STM 模型, 用于非线性可分数据的二分类问题. 为了消除空间分布不均匀时高斯 RBF 恒定核宽度带来的局部风险, 对核函数进行尺度化, 并在学习过程中设计了一种结合子空间牛顿法的两阶段学习方法. 基于真实数据集的数值实验验证了该方法在分类精度上的优越性.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

5 多模态稀疏支持张量机

前面的工作主要侧重于张量数据的二分类问题. 考虑到张量数据的多分类问题也是实际中的常见问题, 本章提出了一种直接处理多分类问题的支持张量机方法, 并用牛顿型方法求解, 在真实数据集上验证了方法的有效性.

5.1 优化模型

受基于二分类的新型稀疏 SVM[107]的启发, 本章提出了一种基于张量格式的分段二次损失损失函数 $\mathcal{L}_{cC}$ 用来刻画求解多分类问题中造成的损失, 其形式如下:

$$\mathcal{L}_{cC}(\mathcal{T}) := \frac{C\|\mathcal{T}_+\|_F^2}{2} + \frac{c\|\mathcal{T}_-\|_F^2}{2}, \quad \forall\, \mathcal{T} \in \mathbb{R}^{I_1\times\cdots\times I_N}, \tag{5-1}$$

其中, $\mathcal{T}_+ := \max\{\mathcal{T}, \mathcal{O}\}$, $\mathcal{T}_- := \min\{\mathcal{T}, \mathcal{O}\}$, 调节参数 $C > c > 0$. 可以发现, 函数 (5-1) 为函数 (4-1) 基于张量格式的形式. 类似地, 当 $c = 0$, $\mathcal{L}_{cC}$ 即为平方合页损失函数 $(\ell_{(hl)})^2$ 基于张量格式的形式.

定理 5.1： 损失函数 $\mathcal{L}_{cC}$ 的共轭函数如下定义:

$$\mathcal{H}_{cC}(\mathcal{W}) = \frac{\|\mathcal{W}_+\|_F^2}{2C} + \frac{\|\mathcal{W}_-\|_F^2}{2c}, \quad \forall \mathcal{W} \in \mathbb{R}^{I_1\times\cdots\times I_N}.$$

同时, 给定张量 $\mathcal{W}$, 光滑函数 $\mathcal{H}_{cC}$ 的梯度和广义 Hessian 映射分别为

$$\nabla\mathcal{H}_{cC}(\mathcal{W}) = \frac{\mathcal{W}_+}{C} + \frac{\mathcal{W}_-}{c}, \qquad \partial^2\mathcal{H}_{cC}(\mathcal{W})\mathcal{V} = \frac{\mathcal{V}_{\Omega^+_{\mathcal{W}}}}{C} + \frac{\mathcal{V}_{\Omega^-_{\mathcal{W}}}}{c} + \mathbb{V}_0.$$

对任意的 $\mathcal{V} \in \mathbb{R}^{I_1\times\cdots\times I_N}$, 其中 $\varpi^+_{\mathcal{W}} := \{(i_1,\cdots,i_N) : w_{i_1\cdots i_N} > 0\}$, $\varpi^-_{\mathcal{W}} := \{(i_1,\cdots,i_N) : w_{i_1\cdots i_N} < 0\}$, $\varpi^0_{\mathcal{W}} := \{(i_1,\cdots,i_N) : w_{i_1\cdots i_N} = 0\}$, 张量 $\mathcal{V}_{\varpi^+_{\mathcal{W}}}$ 定义为

$$\left(\mathcal{V}_{\varpi^+_{\mathcal{W}}}\right)_{i_1\cdots i_N} = \begin{cases} v_{i_1\cdots i_N}, & \text{若 } (i_1,\ldots,i_N) \in \varpi^+_{\mathcal{W}}; \\ 0, & \text{其他,} \end{cases}$$

张量 $\mathcal{V}_{\varpi^-_{\mathcal{W}}}$ 具有类似的定义方式, 集合 $\mathbb{V}_0$ 定义为

$$\mathbb{V}_0 = \left\{ \mathcal{V}_0 \in \mathbb{R}^{I_1\times\cdots\times I_N} : (\mathcal{V}_0)_{i_1\cdots i_N} \in \begin{cases} \{\frac{v_{i_1\cdots i_N}}{c}, \frac{v_{i_1\cdots i_N}}{C}\}, & \text{若 } (i_1,\ldots,i_N) \in \varpi^0_{\mathcal{W}}; \\ \{0\}, & \text{其他.} \end{cases} \right\}.$$

中国知网 https://www.cnki.net

给定训练集 $\{\mathcal{X}_i, \mathcal{Y}_i\}_{i=1}^M$, 张量样本 $\mathcal{X}_i \in \mathbb{R}^{I_1\times\cdots\times I_s\times\cdots\times I_t\times\cdots\times I_N}$, 标签 $\mathcal{Y}_i \in \mathbb{R}^{I_1\times\cdots\times I_{s-1}\times I_{t+1}\times\cdots\times I_N\times J_1\times\cdots J_{p-1}\times J_{q+1}\times\cdots\times J_M}$, 其元素取自 $\{+1,-1\}$. 基于所提的张量损失函数 $\mathcal{L}_{cC}$, 提出如下多模态支持张量机模型 (MSTM)

$$\min_{\mathcal{W},\mathcal{B}} \frac{1}{2}\|\mathcal{W}\|_F^2 + \sum_{i=1}^M \mathcal{L}_{cC}\left(\mathcal{I} - \mathcal{Y}_i \odot (\mathcal{W} \times_{J_p,\ldots,J_q}^{I_s,\ldots,I_t} \mathcal{X}_i + \mathcal{B})\right), \tag{5-2}$$

其中, 张量权重参数 $\mathcal{W} \in \mathbb{R}^{J_1\times\cdots\times J_p\times\cdots\times J_q\times\cdots\times J_H}$ 与样本 $\mathcal{X}_i$ 在以下维数 $J_p = I_s, \cdots, J_q = I_t$ 相同, 张量偏置 $\mathcal{B}$ 与 $\mathcal{Y}_i$ 具有相同的维数, $\odot$ 表示对应元素相乘. 为简单起见, 令 $H = N-1$, $\mathcal{X}_i$ 与 $\mathcal{W}$ 在除第 k 个模的维数 I_k 不同, 其他维数相同. 引入辅助变量 $\mathcal{Z}_i, i \in [M]$, 上述模型 (5-2) 可转化为

$$\begin{aligned} \min_{\mathcal{W},\mathcal{B},\mathcal{Z}_i} \quad & \tfrac{1}{2}\|\mathcal{W}\|_F^2 + \textstyle\sum_{i=1}^M \ell_{cC}(\mathcal{Z}_i) \\ \text{s.t.} \quad & \mathcal{Z}_i = \mathcal{I} - \mathcal{Y}_i \odot \left(\mathcal{W} \times_{J_1,J_2,\ldots,J_{N-1}}^{I_1,\ldots,I_{k-1},I_{k+1},\ldots,I_N} \mathcal{X}_i + \mathcal{B}\right), \quad i \in [M], \end{aligned} \tag{5-3}$$

其中, $\mathcal{Z}_i, \mathcal{I}, \mathcal{B}, \mathcal{Y}_i \in \mathbb{R}^{I_k}$. 引入拉格朗日乘子 $\boldsymbol{\alpha}_i \in \mathbb{R}^{I_k}$ ($i \in [M]$), 令 $\boldsymbol{\alpha} = [\boldsymbol{\alpha}_1^\top, \boldsymbol{\alpha}_2^\top, \cdots, \boldsymbol{\alpha}_M^\top]^\top \in \mathbb{R}^{MI_k}$, 可得问题 (5-3) 的拉格朗日对偶问题:

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \Gamma(\boldsymbol{\alpha}) = \tfrac{1}{2}\textstyle\sum_{i=1}^M\sum_{j=1}^{I_k}\sum_{p=1}^M\sum_{q=1}^{I_k} \alpha_i^j y_i^j \alpha_p^q y_p^q \langle \mathcal{X}_i^j, \mathcal{X}_p^q\rangle + \sum_{i=1}^M \mathcal{H}_{cC}(\boldsymbol{\alpha}_i) - \sum_{i=1}^M\sum_{j=1}^{I_k} \alpha_i^j \\ \text{s.t.} \quad & \textstyle\sum_{i=1}^M \boldsymbol{\alpha}_i \odot \mathcal{Y}_i = \mathbf{0}, \end{aligned} \tag{5-4}$$

其中, $\mathcal{H}_{cC}(\cdot)$ 具有向量形式, 由定理 5.1 可知其元素为

$$(\mathcal{H}_{cC}(\boldsymbol{u}))_i = \begin{cases} \frac{t_i}{C}, & u_i \geq 0, \\ \frac{t_i}{c}, & u_i < 0. \end{cases}$$

令 $\mathcal{H}_{cC}(\mathbf{u}) = E(\mathbf{u})\mathbf{u}$, 其中正定对角矩阵 $E(\mathbf{u})$ 如 (4-4) 所定义. 令张量

$$\begin{aligned} \mathcal{K}_i &:= [y_i^1\mathcal{X}_i^1 \quad y_i^2\mathcal{X}_i^2 \quad \cdots \quad y_i^{I_k}\mathcal{X}_i^{I_k}] \in \mathbb{R}^{I_1\times\cdots\times I_{k-1}\times I_{k+1}\times\cdots\times I_N\times I_k}, \\ \mathcal{K} &:= [\mathcal{K}_1 \quad \mathcal{K}_2 \quad \cdots \quad \mathcal{K}_M] \in \mathbb{R}^{I_1\times\cdots\times I_{k-1}\times I_{k+1}\times\cdots\times I_N\times MI_k}, \end{aligned}$$

那么问题 (5-4) 的目标函数可等价地写为

$$\Gamma(\boldsymbol{\alpha}) := \frac{1}{2}\|\mathcal{K}\times_N \boldsymbol{\alpha}\|_F^2 + \frac{1}{2}\langle E(\boldsymbol{\alpha})\boldsymbol{\alpha}, \boldsymbol{\alpha}\rangle - \langle \mathbf{1}, \boldsymbol{\alpha}\rangle,$$

其中 $\times_N$ 为张量的 N-模乘积. $\Upsilon(\boldsymbol{\alpha})$ 的梯度和海瑟矩阵分别为

$$\nabla\Gamma(\boldsymbol{\alpha}) = \mathbb{P}\boldsymbol{\alpha} + E(\boldsymbol{\alpha})\boldsymbol{\alpha} - \mathbf{1}, \quad \boldsymbol{H}(\boldsymbol{\alpha}) = \nabla^2\Gamma(\boldsymbol{\alpha}) = \mathbb{P} + \boldsymbol{E}(\boldsymbol{\alpha}),$$

中国知网 https://www.cnki.net

其中矩阵

$$\mathbb{P} := \begin{bmatrix} \langle y_1^1\mathcal{X}_1^1, y_1^1\mathcal{X}_1^1\rangle & \langle y_1^1\mathcal{X}_1^1, y_1^2\mathcal{X}_1^2\rangle & \cdots & \langle y_1^1\mathcal{X}_1^1, y_M^{I_k}\mathcal{X}_M^{I_k}\rangle \\ \langle y_1^2\mathcal{X}_1^2, y_1^1\mathcal{X}_1^1\rangle & \langle y_1^2\mathcal{X}_1^2, y_1^2\mathcal{X}_1^2\rangle & \cdots & \langle y_1^2\mathcal{X}_1^2, y_M^{I_k}\mathcal{X}_M^{I_k}\rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle y_M^{I_k}\mathcal{X}_M^{I_k}, y_1^1\mathcal{X}_1^1\rangle & \langle y_M^{I_k}\mathcal{X}_M^{I_k}, y_1^2\mathcal{X}_1^2\rangle & \cdots & \langle y_M^{I_k}\mathcal{X}_M^{I_k}, y_M^{I_k}\mathcal{X}_M^{I_k}\rangle \end{bmatrix} \in \mathbb{R}^{MI_k\times MI_k}$$

是半正定的, 这是因为对任意的向量 $\boldsymbol{\alpha}\in\mathbb{R}^{MI_k}$, 都有 $\boldsymbol{\alpha}^\top\mathbb{P}\boldsymbol{\alpha} = \|\mathcal{K}\times_N\boldsymbol{\alpha}\|_F^2 \geq 0$. 进一步, 结合对角矩阵 $E(\boldsymbol{\alpha})$ 的正定性, 可得 $\boldsymbol{H}(\boldsymbol{\alpha})$ 的正定性. 因此, 问题 (5-4) 具有唯一解.

与第四章类似, 根据原问题 (5-3) 与对偶问题 (5-4) 的 KKT 条件和文献 [107] 的定理 2.1，可知问题 (5-3)的最优解 $(\mathcal{W}^*, \mathcal{B}^*)$ 和对偶问题 (5-4) 的最优解 $\boldsymbol{\alpha}^*$ 满足如下关系

$$\mathcal{W}^* = \mathcal{K}\times_N\boldsymbol{\alpha}^*, \quad \mathcal{B}^* = \mathcal{Y}_i - \mathcal{Y}_i\odot E(\boldsymbol{\alpha}_i^*)\boldsymbol{\alpha}_i^* - \mathcal{Y}_i\odot(\mathbb{P}\boldsymbol{\alpha}^*)_i\,. \tag{5-5}$$

此外, 借助数据约简的思想, 对对偶变量施加稀疏约束, 构建了多模态稀疏支持张量机模型 (MSSTM):

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \Gamma(\boldsymbol{\alpha}) = \tfrac{1}{2}\|\mathcal{K}\times_N\boldsymbol{\alpha}\|_F^2 + \tfrac{1}{2}\langle E(\boldsymbol{\alpha})\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle - \langle\mathbf{1},\boldsymbol{\alpha}\rangle \\ \text{s.t.} \quad & \textstyle\sum_{i=1}^M \boldsymbol{\alpha}_i\odot\mathcal{Y}_i = \mathbf{0}, \\ & \|\boldsymbol{\alpha}\|_0 \leq s. \end{aligned} \tag{5-6}$$

当求得 $\boldsymbol{\alpha}^*$ 与 $\mathcal{B}^*$后, 根据上述关系式 (5-5) 可对测试样本 $\mathcal{X}$ 按如下决策函数进行分类

$$\operatorname{sgn}(f(\mathcal{X})) = \operatorname{sgn}\left((\mathcal{K}\times_N\boldsymbol{\alpha}^*)\times_{J_1,J_2,\ldots,J_{N-1}}^{I_1,\ldots,I_{k-1},I_{k+1},\ldots,I_N}\mathcal{X} + \mathcal{B}^*\right),$$

其中, 对于 $\mathbf{r}\in\mathbb{R}^M$, 其符号函数 $\operatorname{sgn}(\mathbf{r}) := [\operatorname{sgn}(r_1),\cdots,\operatorname{sgn}(r_M)]^\top$, 每个元素按 (2-8) 定义.

5.2 算法设计

结合前章工作, 考虑到子空间牛顿法求解稀疏优化问题的有效性, 采用牛顿型算法进行求解 (5-4) 和 (5-6).

问题 (5-4) 的拉格朗日函数为

$$L(\boldsymbol{\alpha},\Lambda) = \Gamma(\boldsymbol{\alpha}) + \sum_{j=1}^{I_k}\sum_{i=1}^{M}\Lambda_j\alpha_i^j y_i^j,$$

中国知网 https://www.cnki.net

其中, $\Lambda \in \mathbb{R}^{I_k}$ 为拉格朗日乘子. 记 $\mathbf{z} := [\boldsymbol{\alpha}^\top, \boldsymbol{\Lambda}^\top]^\top$, $\nabla_{\boldsymbol{\alpha}} L(\boldsymbol{\alpha}, \Lambda) = \nabla\Gamma(\boldsymbol{\alpha}) + \mathbb{Y}\Lambda =: g(\mathbf{z})$, 其中, $\mathbb{Y}$ 定义如下

$$\mathbb{Y}^\top = [\mathrm{Diag}(\boldsymbol{\mathcal{Y}}_1), \cdots, \mathrm{Diag}(\boldsymbol{\mathcal{Y}}_M)] \in \mathbb{R}^{I_k \times M I_k}, \tag{5-7}$$

$\boldsymbol{\mathcal{Y}}_i = (y_i^1, \cdots, y_i^{I_k}), y_i^j \in \{+1, -1\}, i \in [M], j \in [I_k]$. 由 KKT 条件可知 $\boldsymbol{\Lambda}^* = \boldsymbol{\mathcal{Y}}_i - \boldsymbol{\mathcal{Y}}_i \odot (\mathbb{P}\boldsymbol{\alpha}^*)_i - \boldsymbol{\mathcal{Y}}_i \odot E(\boldsymbol{\alpha}_i^*)\boldsymbol{\alpha}_i^*$, 结合 (5-5) 可得 $\mathcal{B}^* = \Lambda^*$. 通过求解如下线性方程

$$\begin{bmatrix} \boldsymbol{H}(\boldsymbol{\alpha}^k) & \mathbb{Y} \\ \mathbb{Y}^\top & \mathbf{0} \end{bmatrix} \boldsymbol{d}^k = - \begin{bmatrix} g(\mathbf{z}^k) \\ \sum_{i=1}^M \boldsymbol{\alpha}_i \odot \boldsymbol{\mathcal{Y}}_i \end{bmatrix}, \tag{5-8}$$

可求得牛顿方向 $\mathbf{d}^k \in \mathbb{R}^{(M+1)I_k}$, 且 $\mathbf{z}^{k+1} = \mathbf{z}^k + \mathbf{d}^k$. 下述定理说明了采用牛顿法求解时, 雅可比矩阵的非奇异性.

定理 5.2: 当矩阵 $\boldsymbol{H}$ 为正定矩阵, $\mathbb{Y}^\top$ 如 (5-7) 所示, 矩阵 $\begin{bmatrix} \boldsymbol{H} & \mathbb{Y} \\ \mathbb{Y}^\top & \mathbf{0} \end{bmatrix}$ 是可逆的.

证明 若证明矩阵可逆, 只需证明以下系统有唯一零解:

$$\begin{bmatrix} \boldsymbol{H} & \mathbb{Y} \\ \mathbb{Y}^\top & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{u} \\ \mathbf{t} \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ \mathbf{0} \end{bmatrix}. \tag{5-9}$$

由 $\mathbb{Y}^\top$ 如 (5-7) 所示, 可得 $\mathbb{Y}^\top \mathbf{u} = 0$ 成立, 当且仅当向量 $\mathbf{u} = \mathbf{0}$, 由 (5-9) 的第一个等式也可知 $\mathbf{t} = \mathbf{0}$. 证毕. □

综上所述, 牛顿法求解 (5-4) 的算法可总结为算法 5.

算法 5 牛顿法求解 MSTM.

输入: 训练数据 $\{\mathcal{X}_i, \boldsymbol{\mathcal{Y}}_i\}_{i=1}^M$, 参数: $C > c, \epsilon > 0$, 最大迭代次数 K.
输出: 最优解 $\mathbf{z}^k$.
步 1: 初始化 $\mathbf{z}^0$, 令 $k = 0$;
步 2: 通过 (5-8) 计算 $\boldsymbol{d}^k$;
步 3: 利用 $\mathbf{z}^{k+1} = \mathbf{z}^k + \mathbf{d}^k$ 更新 $\mathbf{z}^k$;
步 4: 若达到停止准则和精度要求, 停止算法; 否则令 $k = k + 1$ 转 **步 2**

由于稀疏约束, 考虑子空间牛顿法求解优化问题 (5-6). 问题 (5-6) 稳定点的定义可由 (4-14) 类似给出. 基于稳定点, 可得问题 (5-6)的平稳方程为

$$F(\mathbf{z}; T) = \begin{bmatrix} g_T(\mathbf{z}) \\ \boldsymbol{\alpha}_{\overline{T}} \\ \sum_{i=1}^M \boldsymbol{\alpha}_i \odot \boldsymbol{\mathcal{Y}}_i \end{bmatrix} = \mathbf{0}.$$

中国知网 https://www.cnki.net

当指标集 $T_k \in \mathbb{T}_s(\boldsymbol{\alpha}^k - \eta g(\mathbf{z}))$ 选定后, 可通过求解如下线性方程

$$\nabla F(\mathbf{z}^k; T_k)\mathbf{d}^k = -F(\mathbf{z}^k; T_k) \tag{5-10}$$

来更新牛顿方向 $\mathbf{d}^k$. 以下定理证明了海瑟矩阵的非奇异性.

定理 5.3: 若 $\boldsymbol{H}$ 正定, $\mathbb{Y}^\top$ 如 (5-7) 所示, 那么矩阵 $\begin{bmatrix} \boldsymbol{H}_{T,T} & \mathbf{0} & \mathbb{Y}_T \\ \mathbf{0} & \mathbb{I} & \mathbf{0} \\ \mathbb{Y}_T^\top & \mathbf{0} & \mathbf{0} \end{bmatrix}$ 是可逆的.

证明 类似于定理 5.2 的证明过程, 只需证明下述系统有唯一零解.

$$\begin{bmatrix} \boldsymbol{H}_{T,T} & \mathbf{0} & \mathbb{Y}_T \\ \mathbf{0} & \mathbb{I} & \mathbf{0} \\ \mathbb{Y}_T^\top & \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{u} \\ \mathbf{v} \\ \mathbf{w} \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ \mathbf{0} \\ \mathbf{0} \end{bmatrix},$$

即可得矩阵的可逆性. □

基于上述分析, 将利用子空间牛顿法求解问题 (5-6) 的算法总结为算法 6.

算法 6 子空间牛顿法求解 MSSTM.

输入: 训练集 $\{\mathcal{X}_i, \mathcal{Y}_i\}_{i=1}^M$, 参数: $C > c > 0, \epsilon, \eta, K > 0, s \in [MI_k]$.

输出: 最优解 $\mathbf{z}^k$.

步 1: 初始化 $\mathbf{z}^0$, $T_0 \in \mathbb{T}_s(\boldsymbol{\alpha}^0 - \eta g(\mathbf{z}^0))$, 令 $k = 0$;

步 2: 由 (5-10)计算 $\mathbf{d}^k$.

步 3: 由 $\mathbf{z}^{k+1} = \mathbf{z}^k + \mathbf{d}^k$ 更新 $\mathbf{t}^k$;

步 4: 更新 $T_{k+1} \in \mathbb{T}_s(\boldsymbol{\alpha}^{k+1} - \eta g(\mathbf{z}^{k+1}))$;

步 5: 若达到停止准则和精度要求, 停止算法; 否则令 $k = k + 1$, 转**步 2**,

算法 6 的收敛性由文献 [107] 可知, 当初始点从稳定点的邻域里选择时, 算法具有一步收敛性. 算法 5 采用的是经典牛顿法, 该算法具有局部二次收敛性.

5.3 数值实验

本节利用三个真实图像数据集来验证所提的两种直接处理多分类问题的算法的有效性. 在 STM 模型的背景下, 除了本文提出的两种方法外, SMTM[61] 是首次提出的一种直接多分类方法, 是一种重要的比较方法. 此外, 选择 ADMM-STM[108] 方法代表 STM 的二分类方法, 以 OAO 方式进行多分类. 所有实验均在 Radeon

中国知网 https://www.cnki.net

Vega Mobile Gfx (8 CPUs) @2.0Ghz RAM 8-GB 电脑上进行, 使用 Matlab R2021a, 并调用 Tensor Toolbox 来计算.

实验设置 本文考虑三分类的问题. 假设总样本量为 $M = 3m$, 其中 m 为每个类别的样本量. 参数 η 取 $\eta = \frac{1}{M}$. 对于调节参数 C, c, 稀疏度 s, 分别从以下集合中$\{2^1, 2^2, 2^3, 2^4, 2^5, 2^6, 2^7, 2^8\}$, $\{2^{-5}, 2^{-4}, 2^{-3}, 2^{-2}, 2^{-1}, 2^0, 2^1\}$, $\{\frac{1m}{3}, \frac{2m}{3}, \frac{3m}{3}, \frac{4m}{3}\}$ 利用网格搜索法选取. 对于所提的两个算法, 选取初始点 $\mathbf{z}^0 = \mathbf{0}$. 当达到以下两个条件之一, 算法停止: 满足 $\|F(\mathbf{z}^k; T_k)\| \leq \epsilon$, 精度参数 $\epsilon = \sqrt{M}10^{-3}$ 或达到最大迭代次数 $K = 500$. 所有的数值实验结果都是测试方法在 5 次实验中经过 10 折交叉验证的平均值. 分类精度由以下方式作为评价指标:

$$\text{Accuracy} = \frac{\text{预测正确样本数}}{\text{样本总数}} \times 100\%.$$

5.3.1 数据集

UC Merced Land Use 数据集 该数据集[①] 是一个研究土地利用图像的遥感数据集, 其中的图像提取自美国地质勘探局国家地图城市地区图像系列. 本数据集中公共领域图像尺寸为 $256 \times 256 \times 3$，包含 21 类场景图像的 2100 幅图像, 如图 5.1 所示. 在本实验中, 从飞机, 森林和港口三大类中选取 30 幅图像进行三分类，并将其大小修改为 $100 \times 100 \times 3$。

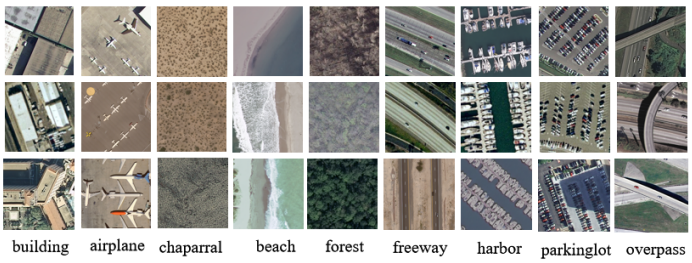


图 5.1 来自 UC Merced Land Use 数据集的图像.

Fig 5.1 The pictures from UC merced land use dataset.

Fashion product images 数据集 该数据集[②] 包含 44000 张高分辨率 2400×1600 的产品, 如图 5.2 所示. 本次实验中, 选择了三类产品, 分别是不同颜色的 T 恤, 裤子和鞋子. 具体来说, 大部分 T 恤是绿色的, 大多数裤子是蓝色的, 大部分的鞋子是红色的, 展现了物品与与颜色很高的相关性. 从每个类别中选择 80 张图像, 并将其大

① http://weegee.vision.ucmerced.edu/datasets/landuse.html

② https://www.kaggle.com/datasets/paramaggarwal/fashion-product-images-dataset

中国知网 https://www.cnki.net

小修改为 $128 \times 128 \times 3$.

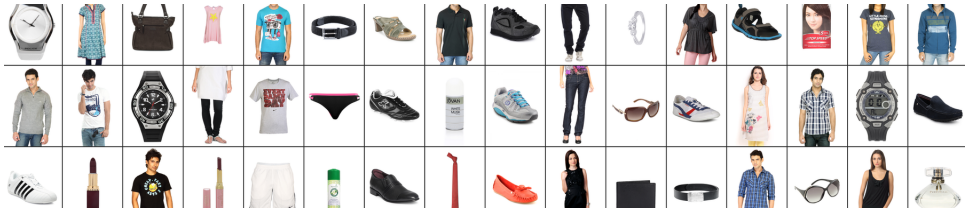


图 5.2 来自 Fashion product images 数据集的图像.

Fig 5.2 The pictures from Fashion product images dataset.

SIRI WHU 数据集 该数据集 ① [109,110]是武汉大学发布的遥感图像数据集, 共包含 12 类 2400 张遥感图像, 像素大小为 $200 \times 200 \times 3$, 如图 5.3所示. 在本实验中, 从农业, 草甸和河流三个类别中选取 60 幅图像进行分类, 并将其大小修改为 $100 \times 100 \times 3$.

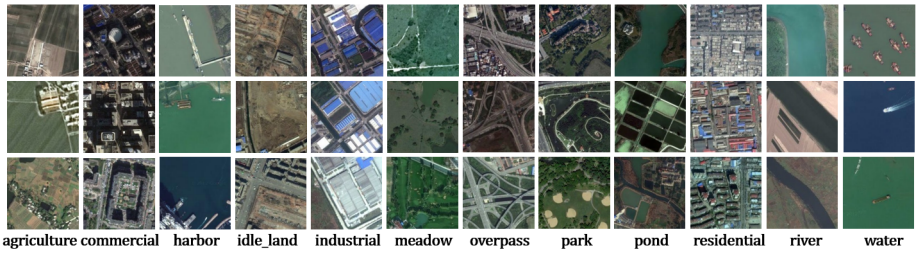


图 5.3 来自 SIRI WHU 数据集的图像.

Fig 5.3 The pictures from SIRI WHU dataset.

5.3.2 数值结果

四种方法关于 UC Merced Land Use 数据集的分类结果如图 5.4 所示. 从图 5.4 可以看出, MSSTM 和 MSTM 在总分类精度上的表现相似, 并且在所有方法中表现最好. 同时, 从每个类别的角度来看, 所提方法的表现也优于其他算法.

四种方法关于 Fashion product images 数据集的分类结果如图 5.5 所示, 从图中可以发现, MSSTM 具有令人满意的分类效果, 相比其他算法, 分类精度至少高了 10%. 同时, 为了测试所提算法的鲁棒性, 我们在数据集中添加了不同程度的高斯噪声, 方差为 $\sigma \in \{0.1, 0.5, 1\}$. 从图 5.5 中可知, 随着 σ 增大, 所有方法的性能开始变差. 然而, 所提出的 MSSTM 仍然比其他方法具有更好的性能.

① http://www.lmars.whu.edu.cn/prof_web/zhongyanfei/e-code.html

中国知网 https://www.cnki.net

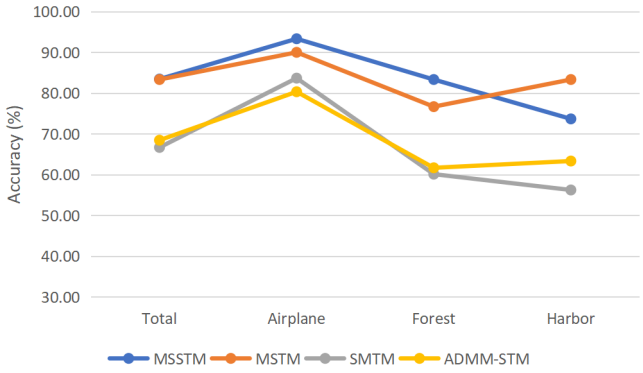


图 5.4　不同算法关于 UC Merced Land Use 数据集的分类精度.

Fig 5.4　The classification accuracy of different methods for UC Merced Land Use dataset.

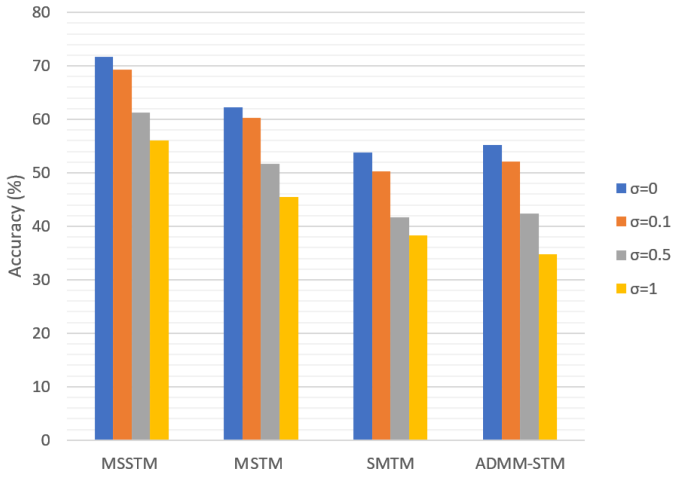


图 5.5　不同高斯噪音下 Fashion product images 数据集的分类精度.

Fig 5.5　The classification accuracy under different noises for Fashion product images dataset.

四种算法关于 SIRI WHU 数据集的分类结果记录于图 5.6. 从图 5.6 可知, MSSTM 和 ADMM-STM 的表现优于其他两种算法. 同样地, 对该数据集加入三种方差较大的噪声, 即 $\sigma \in \{1, 5, 10\}$, 来比较四种算法的鲁棒性, 如图 5.6 所示. 不难发现, MSSTM 在不同噪音下都有很好的表现, 分类精度随噪音影响的变化相对稳定.

如上所述, 所提的两种算法在分类精度上都有令人满意的表现. 为了进一步说明效率, 表 5.1 记录了四种算法的计算时间. 从表 5.1 的第三和第四列中, 我们可以发现由于稀疏性约束, MSSTM 比 MSTM 的时间更少. 与 SMTM 相比, MSSTM 在训练过程中至少要快 7 倍. 如第 3 节所述, MSSTM 和 MSTM 的时间效率有利于二阶牛顿型方法从对偶角度求解问题.

中国知网　https://www.cnki.net

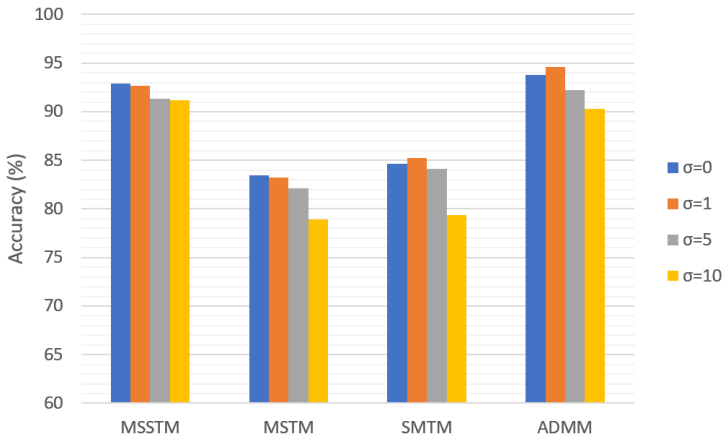


图 5.6 不同噪音下的 SIRI WHU 数据集上的分类精度.

Fig 5.6 The classification accuracy under different noises for SIRI WHU dataset.

表 5.1 不同算法的时间比较 (s)

Tab 5.1 Training time (seconds) comparison for different methods.

Dataset	MSSTM	MSTM	SMTM	ADMM-STM
UC Merced Land Use	55.63	**55.43**	503.25	63.13
Fashion product images	217.87	225.30	5976.60	**184.25**
SIRI WHU	**81.18**	83.69	579.91	85.22

5.4 本章小结

本章针对多分类张量数据, 设计了一种分段二次光滑的张量损失函数, 并利用张量多模态乘积提出了多模态支持张量机模型 (MSTM). 在此基础上, 基于数据约简的思想, 通过对对偶问题的决策变量巧妙地施加稀疏约束, 构造了一个多模态稀疏支持张量机模型 (MSSTM), 以缓解小样本的过拟合现象. 此外, 利用牛顿型算法从对偶角度求解两种模型. 在三个真实图像数据集上的数值实验验证了该方法在分类精度和时间方面的优越性.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

6 总结与展望

随着大数据时代背景下实际问题的数据多样性与结构复杂性, 以张量形式呈现高维数据被广泛应用于医学图像, 机械故障诊断等众多领域. 支持张量机作为一种基于张量空间的机器学习方法, 不但保留了张量数据的空间结构信息, 还避免造成维度灾难. 基于优化理论与算法的支持张量机秉承了优化与机器学习融合的发展理念, 值得深入研究. 本文基于张量优化理论, 充分挖掘张量数据的结构信息, 构建合理的分类模型, 设计高效的求解算法, 在真实数据集上进行了初步实验验证算法的有效性. 本文的主要研究结果从模型和算法两个方面总结如下:

模型方面: (1) 针对近似线性可分的二分类问题,建立了基于 0/1 软间隔损失的低秩 STM 模型; (2) 针对近似线性可分的二分类问题, 基于 0-1 损失, 利用ℓ_1正则化进行特征选择构建了双稀疏秩一支持STM; (3) 针对非线性可分的二分类问题, 基于数据约简的想法, 利用稀疏约束并结合张量核函数构建了稀疏核 STM 模型. 为缓解恒定的高斯核宽度带来的局部风险, 利用两阶段方法对核函数进行尺度化. (4) 针对近似线性可分的多分类问题, 定义了一种张量损失函数, 并结合多模态乘积提出了一种可以直接张量数据多分类的稀疏多模态支持张量机模型.

算法方面: (1) 针对 0/1 损失的低秩 STM 和双稀疏秩一 STM 模型, 由于优化问题具有非凸非连续的特性, 考虑使用 ADMM 算法进行求解. 此外, 在温和条件下, 借助 KL 性质, 证明了基于 Bregman 距离的 ADMM 求解双稀疏秩一 STM 的算法具有全局收敛性. (2) 针对尺度化核技术稀疏 STM 和多模态稀疏 STM, 考虑模型中损失函数的光滑性及硬阈值算子的可微特性, 设计了牛顿类型算法来求解. 在真实数据集上进行了数值实验, 数值结果验证了所提方法的有效性.

关于 STM 问题在以下几个方面有待进一步研究:

(1) 泛化能力分析: 所提模型在分类精度方面的有效性得到了数值验证, 其泛化能力的分析还需要从理论角度进一步研究. 在计算张量核函数过程中张量分解的时间效率有待提高, 特别是对于高维, 高阶张量样本. 此外, 由于 0/1 损失被认为是表征误分类样本数量的理想损失函数, 因此具有这种损失的核化稀疏 STM 将是一个很有前途的模型, 值得在未来的研究中进一步研究.

(2)非线性多分类: 针对多分类问题, 所提方法缺乏对张量样本低秩特性的考虑, 并且不适用于非线性可分数据. 如何利用张量多模态乘积和张量分解, 借助核技巧对非线性可分数据进行多分类, 特别是对于高维高阶张量样本, 值得在未来工作中展开研究.

中国知网 https://www.cnki.net

(3)实际问题应用: 张量数据广泛应用于机器学习, 计算机视觉等众多领域. 如何将 STM 的方法应用于实际生活中的分类问题, 如视频分析, 脑电波图分析等, 提高相应的分类精度, 也是非常有现实意义的研究课题.

中国知网 https://www.cnki.net

参考文献

[1] Boyer R, Lathauwer L D, Karim A M. Higher order tensor-based method for delayed exponential fitting [J]. IEEE Transactions on Signal Processing, 2007, 55(6):2795–2809.

[2] Liu J, Zhu C, Long Z, et al. Tensor regression [J]. Foundations and Trends in Machine Learning, 2021, 14(4):379–565.

[3] Vasilescu M, Terzopoulos D. Multilinear image analysis for facial recognition [C]. Proceedings of 2002 International Conference on Pattern Recognition, volume 2, 2002. 511–514.

[4] Savas B, Eldén L. Handwritten digit classification using higher order singular value decomposition [J]. Pattern Recognition, 2007, 40(3):993–1003.

[5] Cichocki A. Tensor decompositions : New concepts in brain data analysis? [J]. Journal of the Society of Instrument and Control Engineers, 2011, 50:507–516.

[6] Turk M A. Face recognition using eigenfaces [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 1991. 586–591.

[7] Plataniotis K, Venetsanopoulos A. Color Image Processing and Applications [M]. Springer, 2000.

[8] Green R D, Guan L. Quantifying and recognizing human movement patterns from monocular video images-part II: Applications to biometrics [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2004, 14(2):191–198.

[9] Sarkar S, Phillips P J, Liu Z, et al. The humanID gait challenge problem: Data sets, performance, and analysis [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2005, 27(2):162–177.

[10] Chen Z, Wang B, Zhang L M. Dimensionality reduction and classification based on lower rank tensor analysis for hyperspectral imagery [J]. Journal of Infrared and Millimeter Waves, 2013, 32(6):569–575.

[11] Kim M, Jeon J G, Kwak J S, et al. Moving object segmentation in video sequences by user interaction and automatic object tracking [J]. Image and Vision Computing, 2001, 19(5):245–260.

[12] Yan S, Xu D, Yang Q, et al. Multilinear discriminant analysis for face recognition [J]. IEEE Transactions on Image Processing, 2007, 16(1):212–220.

[13] Lu H, Plataniotis K, Venetsanopoulos A. MPCA: Multilinear principal component analysis of tensor objects [J]. IEEE Transactions on Neural Networks, 2008, 19(1):18–39.

[14] Tao D, Li X, Hu W, et al. Supervised tensor learning [C]. Proceedings of the Fifth IEEE International Conference on Data Mining. IEEE, 2005. 450–457.

[15] Tao D, Li X, Wu X, et al. Supervised tensor learning [J]. Knowledge and Information Systems, 2007, 13(1):1–42.

[16] Yan S, Xu D, Yang Q, et al. Multilinear discriminant analysis for face recognition [J]. IEEE Transactions on Image Processing, 2007, 16(1):212–220.

中国知网 https://www.cnki.net

[17] Cortes C, Vapnik V. Support-Vector Networks [J]. Machine Learning, 1995, 20(3):273–297.

[18] Chapelle O, Haffner P, Vapnik V. Support vector machines for histogram-based image classification [J]. IEEE Transactions on Neural Networks, 1999, 10(5):1055–1064.

[19] Zhang W, Yoshida T, Tang X. Text classification based on multi-word with support vector machine [J]. Knowledge-Based Systems, 2008, 21(8):879–886.

[20] Akay M F. Support vector machines combined with feature selection for breast cancer diagnosis [J]. Expert Systems with Applications, 2009, 36(2, Part 2):3240–3247.

[21] Carrizosa E, Martin-Barragan B, Morales D R. Binarized support vector machines [J]. INFORMS Journal on Computing, 2010, 22(1):154–167.

[22] Chen H L, Yang B, Liu J, et al. A support vector machine classifier with rough set-based feature selection for breast cancer diagnosis [J]. Expert Systems with Applications, 2011, 38(7):9014–9022.

[23] Huang L W, Shao Y H, Zhang J, et al. Robust rescaled hinge loss twin support vector machine for imbalanced noisy classification [J]. IEEE Access, 2019, 7:65390–65404.

[24] Montañés D C, Quiroz A J, Dulcerubio M, et al. Efficient nearest neighbors methods for support vector machines in high dimensional feature spaces [J]. Optimization Letters, 2021, 15:391–404.

[25] Kotsia I, Patras I. Support Tucker machines [C]. Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2011. 633–640.

[26] Khemchandani R, Karpatne A, Chandra S. Proximal support tensor machines [J]. International Journal of Machine Learning and Cybernetics, 2013, 4:703–712.

[27] Chen Y, Wang K, Zhong P. One-class support tensor machine [J]. Knowledge-Based Systems, 2016, 96:14–28.

[28] Zhang X, Gao X, Wang Y. Twin support tensor machines for MC detection [J]. Journal of Electronics (China), 2009, 26:318–325.

[29] Shi H, Zhao X, Zhen L, et al. Twin bounded support tensor machine for classification [J]. International Journal of Pattern Recognition and Artificial Intelligence, 2016, 30(1):1650002.1–1650002.20.

[30] Rastogi R, Sharma S. Ternary tree based-structural twin support tensor machine for clustering [J]. Pattern Analysis and Applications, 2021, 24:61–74.

[31] Kiers H A L. Towards a standardized notation and terminology in multiway analysis [J]. Journal of Chemometrics, 2000, 14(3):105–122.

[32] Tucker L R. Some mathematical notes on three-mode factor analysis [J]. Psychometrika, 1966, (31):279–311.

[33] Oseledets I V. Tensor-train decomposition [J]. SIAM Journal on Scientific Computing, 2011, 33(5):2295–2317.

[34] Lian H. Learning rate for convex support tensor machines [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(8):3755–3760.

[35] 舒托, 杨志霞. 基于张量核范数的支持张量机 [J]. 内江师范学院学报, 2017, 32(10):34–39.

[36] Kotsia I, Guo W, Patras I. Higher rank support tensor machines for visual recognition [J]. Pattern Recognition, 2012, 45(12):4192–4203.

中国知网 https://www.cnki.net

[37] 杨兵. 基于张量数据的机器学习方法研究与应用 [D]. 中国农业大学, 2014.

[38] Chen C, Batselier K, Ko C Y, et al. A support tensor train machine [C]. Proceedings of the International Joint Conference on Neural Networks. IEEE, 2019. 1–8.

[39] 王华军, 修乃华. 支持向量机损失函数分析 [J]. 数学进展, 2021, 50(6):801–828.

[40] Wang H, Shao Y, Zhou S, et al. Support vector machine classifier via $\mathcal{L}_{0/1}$ soft-margin loss [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(10):7253–7265.

[41] Rubinov M, Knock S, Stam C, et al. Small-world properties of nonlinear brain activity in schizophrenia [J]. Human Brain Mapping, 2009, 30(2):403–416.

[42] He L, Kong X, Yu P, et al. DuSK: A dual structure-preserving kernel for supervised tensor learning with applications to neuroimages [C]. Proceedings of SIAM International Conference on Data Mining. SIAM, 2014. 127–135.

[43] Hao Z, He L, Chen B, et al. A linear support higher-order tensor machine for classification [J]. IEEE Transactions on Image Processing, 2013, 22(7):2911–2920.

[44] He L, Lu C, Ma G, et al. Kernelized support tensor machines [C]. Proceedings of the 34th International Conference on Machine Learning, volume 70. PMLR, 2017. 1442–1451.

[45] Chen C, Batselier K, Yu W, et al. Kernelized support tensor train machines [J]. Pattern Recognition, 2022, 122:108337.

[46] Kour K, Dolgov S, Stoll M, et al. Efficient structure-preserving support tensor train machine [J]. Journal of Machine Learning Research, 2023, 24(4):1–22.

[47] Deng X, Shi Y, Yao D, et al. A kernelized support tensor-ring machine for high-dimensional data classification [C]. Proceedings of IEEE Conference on Electronics, Information, and Technology for Smart Agriculture. IEEE, 2021. 159–165.

[48] Burges C, Scholkopf B, Smola A. Advances in Kernel Methods: Support Vector Learning [M]. MIT Press, 1999.

[49] Amari S, Wu S. Improving support vector machine classifiers by modifying kernel functions [J]. Neural Networks, 1999, 12:783–789.

[50] Wu S, Amari S. Conformal transformation of kernel functions: A data-dependent way to improve support vector machine classifiers [J]. Neural Processing Letters, 2001, 25:59–67.

[51] Williams P, Li S, Feng J, et al. Scaling the kernel function to improve performance of the support vector machine [C]. Proceedings of Advances in Neural Networks, 2005. 831–836.

[52] Williams P, Wu S, Feng J. Improving the performance of the support vector machine: Two geometrical scaling methods [J]. Studies in Fuzziness and Soft Computing, 2005, 177:205–218.

[53] Chang Q, Chen Q, Wang X. Scaling Gaussian RBF kernel width to improve SVM classification [C]. Proceedings of 2005 International Conference on Neural Networks and Brain, volume 1, 2005. 19–22.

[54] Zhu S, Chen H, Wang M, et al. Plastic solid waste identification system based on near infrared spectroscopy in combination with support vector machine [J]. Advanced Industrial and Engineering Polymer Research, 2019, 2:77–81.

[55] Adedeji O, Wang Z. Intelligent waste classification system using deep learning convolutional neural network [J]. Procedia Manufacturing, 2019, 35:607–612.

中国知网 https://www.cnki.net

[56] Kang C, Huo Y, Xin L, et al. Feature selection and tumor classification for microarray data using relaxed Lasso and generalized multi-class support vector machine [J]. Journal of Theoretical Biology, 2019, 463:77–91.

[57] Sehad M, Ameur S. A multilayer perceptron and multiclass support vector machine based high accuracy technique for daily rainfall estimation from MSG SEVIRI data [J]. Advances in Space Research, 2020, 65(4):1250–1262.

[58] Hsu C W, Lin C J. A comparison of methods for multiclass support vector machines [J]. IEEE Transactions on Neural Networks, 2002, 13(2):415–425.

[59] Lee Y, Lin Y, Wahba G. Multicategory support vector machines [J]. Journal of the American Statistical Association, 2012, 99(465):67–81.

[60] Fu S, Chen P, Ye Z. Simplex-based proximal multicategory support vector machine [J]. IEEE Transactions on Information Theory, 2023, 69(4):2427–2451.

[61] Ma Z, Yang L T, Zhang Q. Support multimode tensor machine for multiple classification on industrial big data [J]. IEEE Transactions on Industrial Informatics, 2021, 17(5):3382–3390.

[62] Xing Y, Wang M, Yang S, et al. Pansharpening with multiscale geometric support tensor machine [J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(5):2503–2517.

[63] Zhang L, Zhang L, Tao D, et al. A multifeature tensor for remote-sensing target recognition [J]. IEEE Geoscience and Remote Sensing Letters, 2011, 8(2):374–378.

[64] Guo X, Huang X, Zhang L, et al. Support tensor machines for classification of hyperspectral remote sensing imagery [J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(6):3248–3264.

[65] Gao T, Gu L, Chen H, et al. Domain adaptation support tensor machine: An extended STM for object recognition using cross-source heterogeneous remote sensing data [J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61:1–21.

[66] Zhou B, Song B, Hassan M, et al. Multilinear rank support tensor machine for crowd density estimation [J]. Engineering Applications of Artificial Intelligence, 2018, 72:382–392.

[67] Zhao Z, Chow T W. Maximum margin multisurface support tensor machines with application to image classification and segmentation [J]. Expert Systems with Applications, 2012, 39(1):849–860.

[68] Chen Z Y, Fan Z P, Sun M. A multi-kernel support tensor machine for classification with multitype multiway data and an application to cross-selling recommendations [J]. European Journal of Operational Research, 2016, 255:110–120.

[69] Calvi G G, Lucic V, Mandic D P. Support tensor machine for financial forecasting [C]. IEEE International Conference on Acoustics, Speech, and Signal Processing, 2019. 8152–8156.

[70] He Z, Shao H, Cheng J, et al. Support tensor machine with dynamic penalty factors and its application to the fault diagnosis of rotating machinery with unbalanced data [J]. Mechanical Systems and Signal Processing, 2020, 141:106441.

[71] Hu C, He S, Wang Y. A classification method to detect faults in a rotating machinery based on kernelled support tensor machine and multilinear principal component analysis [J]. Applied Intelligence, 2021, 51:2609–2621.

中国知网 https://www.cnki.net

[72] Zhao Y, Lu W, Rui Y, et al. Classification of the traffic status subcategory with ETC gantry data: An improved support tensor machine approach [J]. Journal of Advanced Transportation, 2023. 1–21.

[73] Deng X, Jiang P, Peng X, et al. An intelligent outlier detection method with one class support Tucker machine and genetic algorithm toward big sensor data in internet of things [J]. IEEE Transactions on Industrial Electronics, 2019, 66(6):4672–4683.

[74] Liu X, Guo T, He L, et al. A low-rank approximation-based transductive support tensor machine for semisupervised classification [J]. IEEE Transactions on Image Processing, 2015, 24(6):1825–1838.

[75] Xu H, Wang X, Huang J, et al. Semi-supervised multi-sensor information fusion tailored graph embedded low-rank tensor learning machine under extremely low labeled rate [J]. Information Fusion, 2024, 105:102222.

[76] Wang W, Zhang M, Zhang L, et al. Imbalanced data classification for multi-source heterogenous sensor networks [J]. IEEE Access, 2020, 8:27406–27413.

[77] Kolda T, Bader B. Tensor decompositions and applications [J]. SIAM Review, 2009, 51(3):455–500.

[78] Qi L, Luo Z. Tensor Analysis: Spectral Theory and Special Tensors [M]. SIAM Press, 2017.

[79] Yu X, Luo Z, Qi L, et al. SLRTA: A sparse and low-rank tensor-based approach to internet traffic anomaly detection [J]. Neurocomputing, 2021, 434:295–314.

[80] Vannieuwenhoven N, Vandebril R, Meerbergen K. A new truncation strategy for the higher-order singular value decomposition [J]. SIAM Journal on Scientific Computing, 2012, 34(2):A1027–A1052.

[81] Minster R, Saibaba A K, Kilmer M E. Randomized algorithms for low-rank tensor decompositions in the Tucker format [J]. SIAM Journal on Mathematics of Data Science, 2020, 2(1):189–215.

[82] Che M, Wei Y, Yan H. The computation of low multilinear rank approximations of tensors via power scheme and random projection [J]. SIAM Journal on Matrix Analysis and Applications, 2020, 41(2):605–636.

[83] Nion D, Lathauwer L. An enhanced line search scheme for complex-valued tensor decompositions. Application in DS-CDMA [J]. Signal Processing, 2008, 21:749–755.

[84] Cichocki A. Era of big data processing: A new approach via tensor networks and tensor decompositions [C]. Proceedings of International Workshop on Smart Info-Media System in Asia, 2018. 1–30.

[85] Rockafellar R T, Wets R J B. Variational Analysis [M]. Springer Science & Business Media, 2009.

[86] Rockafellar R T. Convex Analysis [M]. Princeton University Press, 1970.

[87] Friedman J, Hastie T, Tibshirani H H. Pathwise coordinate optimization [J]. The Annals of Applied Statistics, 2007, 1(2):302–332.

[88] Zhou S, Pan L, Xiu N, et al. Quadratic convergence of smoothing Newton's method for 0/1 loss optimization [J]. SIAM Journal on Optimization, 2021, 31(4):3184–3211.

[89] Beck A. First-Order Methods in Optimization [M]. SIAM Press, 2017.

中国知网 https://www.cnki.net

[90] Bregman L M. The relaxation method of finding the common point of convex sets and its application to the solution of problems in convex programming [J]. Ussr Computational Mathematics & Mathematical Physics, 1967, 7(3):200–217.

[91] Attouch H, Bolte J, Redont P, et al. Proximal alternating minimization and projection methods for nonconvex problems: An approach based on the Kurdyka ‐ Łojasiewicz inequality [J]. Mathematics of Operations Research, 2010, 35(2):438–457.

[92] Goncalves M L N, Melo J G, Monteiro R D C. Convergence rate bounds for a proximal ADMM with over-relaxation stepsize parameter for solving nonconvex linearly constrained problems [J]. Pacific Journal of Optimization, 2019, 15(3):379–398.

[93] Chang C, Lin C. LIBSVM: A library for support vector machines [J]. ACM Transactions on Intelligent Systems and Technology, 2011, 2(3):1–27.

[94] Krizhevsky A, Hinton G. Learning multiple layers of features from tiny images [T]. University of Toronto, 2009.

[95] Bi J, Bennett K, Embrechts C, et al. Dimensionality reduction via sparse support vector machines [J]. Journal of Machine Learning Research, 2003, 3:1229–1243.

[96] Yoshikawa Y, Iwata T, Sawada H. Latent support measure machines for bag-of-words data classification [C]. Proceedings of Advances in Neural Information Processing Systems, volume 27, 2014.

[97] Mohr J, Obermayer K. A topographic support vector machine: Classification using local label configurations [C]. Proceedings of Advances in Neural Information Processing Systems, volume 17, 2004. 929–936.

[98] Kotsia I, Pitas I. Facial expression recognition in image sequences using geometric deformation features and support vector machines [J]. IEEE Transactions on Image Processing, 2007, 16(1):172–187.

[99] Zhang W, Hong B, Liu W, et al. Scaling up sparse support vector machines by simultaneous feature and sample reduction [C]. Proceedings of the 34th International Conference on Machine Learning, volume 70. PMLR, 2017. 4016–4025.

[100] Shao Y H, Li C N, Huang L W, et al. Joint sample and feature selection via sparse primal and dual LSSVM [J]. Knowledge-Based Systems, 2019, 185:104915.

[101] Pang X, Xu Y, Xiao X. A doubly sparse multiclass support vector machine with simultaneous feature and sample screening [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2021, 51(11):6911–6925.

[102] Wang H, Pan X, Xu Y. Simultaneous safe feature and sample elimination for sparse support vector regression [J]. IEEE Transactions on Signal Processing, 2019, 67(15):4043–4054.

[103] Attouch H, Bolte J, Svaiter B. Convergence of descent methods for semi-algebraic and tame problems: Proximal algorithms, forward-backward splitting, and regularized Gauss-Seidel methods [J]. Mathematical Programming, 2013, (137):91–129.

[104] Christmann A, Steinwart I. Support Vector Machines [M]. Springer, 2008.

[105] Zhao L, Mammadov M, J Y. From convex to nonconvex: A loss function analysis for binary classification [C]. Proceedings of 2010 IEEE International Conference on Data Mining Workshops. IEEE, 2010. 1281–1288.

中国知网 https://www.cnki.net

[106] Wang Q, Ma Y, Zhao K, et al. A comprehensive survey of loss functions in machine learning [J]. Annals of Data Science, 2022, 9:187–212.

[107] Zhou S. Sparse SVM for sufficient data reduction [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(9):5560–5571.

[108] 王双月, 罗自炎. 一类基于 $\mathcal{L}_{0/1}$ 软间隔损失函数的低秩支持张量机 [J]. 运筹学学报, 2021, 25(3):160–172.

[109] Zhu Q, Zhong Y, Zhao B, et al. Bag-of-visual-words scene classifier with local and global features for high spatial resolution remote sensing imagery [J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(6):747–751.

[110] Zhao B, Zhong Y, Xia G S, et al. Dirichlet-derived multiple topic scene classification model for high spatial resolution remote sensing imagery [J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(4):2108–2123.

中国知网 https://www.cnki.net

学位论文数据集

关键词*	密级*	中图分类号	UDC	论文资助
支持张量机; 稀疏低秩; 算法; 尺度化核函数; 分类	公开			国家自然科学基金
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	理学	博士
论文题名*		并列题名		论文语种*
稀疏低秩支持张量机的优化理论与算法研究				中文
作者姓名*	王双月		学号*	19118016
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村3 号	100044
学科专业*		研究方向*	学制*	学位授予年*
系统理论		运筹学中的统计分析	4年	2024
论文提交日期*	2024年7月			
导师姓名*	罗自炎		职称*	教授
评阅人	答辩委员会主席*		答辩委员会成员	
	文再文		韩丛英 张立平 张超 周声龙	
电子版论文提交格式文本（）图像（）视频（）音频（）多媒体（）其他（） 推荐格式：application/msword；application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	85			
共33项，其中带*为必填数据，为21项。				

中国知网 https://www.cnki.net